



Universidad Nacional Autónoma
de México y Universidad
Michoacana de San Nicolás de
Hidalgo



Posgrado Conjunto en Ciencias Matemáticas
UMSNH-UNAM

AQUI VA EL TITULO DE LA TESIS

TESIS

para obtener el grado de

Maestra en Ciencias Matemáticas

presenta

Paula Camila Silva Gomez
`csilva@matmor.unam.mx`

Asesor:

Doctora

Nelly Sélem Mojica
`nselem@matmor.unam.mx`

Morelia, Michoacán, México
Mayo, 2026

PAULA CAMILA SILVA GOMEZ

FIRMA

FECHA

Agradecimientos

Principalmente, agradezco a la Dra. Nelly por su infinita paciencia, dedicación y todo el tiempo y esfuerzo que me brindó a lo largo de este proceso. Su apoyo ha sido invaluable.

Agradezco al universo por enseñarme a mejorar cada día y por recordarme que, aunque el camino no siempre fue fácil y fue más largo de lo esperado, encontré la fortaleza para no rendirme y seguir adelante.

Gracias a las carnitas, los elotes y las nieves, por hacerme enamorar de una cultura que, aunque no soy fan del picante, llevaré siempre en mi corazón con mucho cariño.

Y un agradecimiento inmenso a cada una de las personitas, amigos, compañeros, y mis roomies, que me acompañaron en este camino. Gracias por estar ahí, ya sea desde cerca o a la distancia, con palabras de aliento, compañía y apoyo en esos días difíciles, que, siendo honesta, fueron muchos.

¡Gracias totales!

Índice general

1. Preliminares	1
1.1. Microbioma	3
1.2. Metagenómica	3
1.3. Microbioma de Fresa	5
1.4. Clasificadores	7
1.4.1. Kraken & Braken	7
1.5. Lenguajes	9
1.5.1. BASH	9
1.5.2. R & RStudio	9
1.6. Formatos	11
1.6.1. JSON	11
1.6.2. BIOM	11
1.6.3. FASTA	11
1.6.4. BAM	12
1.7. Índices de Diversidad	12
1.7.1. Diversidad Alfa	13
1.7.2. Diversidad Beta	15
1.8. Prueba de Hipótesis	19
1.8.1. Prueba t para comparar dos medias poblacionales (muestras pequeñas)	21
1.8.2. Prueba F sobre las varianzas de dos poblaciones pe- queñas	22
1.8.3. Prueba de Wilcolxon Mann-Whitney	23
1.9. Normalización y Rarefacción	23
1.9.1. Normalización	23

1.9.2. Rarefacción	23
1.10. Redes Bayesianas	23
2. objetivos	25
2.1. Objetivo general	25
2.2. Objetivos específicos	25
3. Análisis Exploratorio de Datos, metodología	27
3.1. Métodos para caracterización de la diversidad microbiana .	28
3.1.1. Preprocesamiento	28
3.1.2. Filtrado de Calidad	29
3.1.3. Índices de diversidad	31
3.1.4. Exploración a distintos niveles taxonómicos	33
3.2. Prueba de Hipótesis	33
3.2.1. Prueba t de Student sobre el índice de Shannon . . .	34
3.2.2. Prueba F sobre las varianzas	34
3.2.3. Prueba de Wilcoxon-Mann-Whitney	34
3.2.4. Normalización	35
3.2.5. Rarefacción	35
3.3. Rarefacción	36
3.4. Redes	36
3.5. Redes bayesianas	37
3.6. Rs	38
4. Resultados	39
4.1. Caracterización de la composición taxonómica de la micro- biota asociada a plantas de fresa sanas y enfermas	39
4.1.1. Preprocesamiento y Filtrado de Calidad	39
4.2. Evaluar estadísticamente las diferencias entre los microbio- mas de plantas saludables y no saludables	55
4.2.1. Pruebas con muestras pequeñas para comparar dos medias poblacionales	55
4.2.2. Prueba de los rangos con signos de Wilcoxon Mann- Whitney	57
5. Conclusiones	59

<i>ÍNDICE GENERAL</i>	7
6. Perspectivas	61
A. Codigos	65
B. Imagenes	67
Bibliografia	69

Abstract

El microbioma rizosférico es un factor clave en la estabilidad y productividad agrícola, influyendo en la disponibilidad de nutrientes y la interacción de las plantas con su entorno. Su análisis mediante enfoques metagenómicos genera grandes volúmenes de datos, cuya interpretación requiere métodos matemáticos y estadísticos avanzados para identificar patrones de diversidad microbiana.

Este estudio explora las diferencias en la composición del microbioma rizosférico entre plantas saludables y no saludables en cultivos de fresa (*Fragaria ananassa*), aplicando métricas de diversidad alfa y beta, junto con pruebas de hipótesis para evaluar variaciones significativas. Si bien los resultados indican una mayor diversidad microbiana en plantas saludables, las diferencias no fueron concluyentes desde un punto de vista estadístico. No obstante, se identificaron tendencias generales en la estructura microbiana, sugiriendo que otros factores podrían estar modulando la comunidad rizosférica.

Los hallazgos resaltan la importancia de combinar herramientas de modelado estadístico y ciencia de datos en el estudio del microbioma agrícola, proporcionando bases cuantitativas para el diseño de estrategias de manejo del suelo orientadas a mejorar la resiliencia y sostenibilidad de los cultivos.

Palabras clave: Metagenómica, análisis de datos, modelado estadístico, microbioma del suelo, diversidad microbiana, análisis bioinformático, fresa.

Introducción

El análisis metagenómico genera grandes volúmenes de datos cuya interpretación requiere métodos matemáticos y estadísticos avanzados para identificar patrones y variaciones en comunidades microbianas complejas. Dentro de este contexto, el microbioma rizosférico desempeña un papel crucial en la salud y productividad de los cultivos agrícolas, regulando la disponibilidad de nutrientes y la resiliencia del suelo Kumar et al. (2019) Rosenberg (2021). Comprender estas variaciones es fundamental para desarrollar estrategias de manejo agrícola basadas en la manipulación del microbioma del suelo.

En este estudio, se analizan las diferencias en la composición y estructura del microbioma rizosférico entre plantas saludables y no saludables en cultivos de fresa (*Fragaria ananassa*) Yang et al. (2020), utilizando herramientas avanzadas de estadística y modelado matemático Xia et al. (2018) para cuantificar estas variaciones y evaluar su impacto en la agronomía. Teniendo como propósito identificar características diferenciadoras entre los microbiomas de plantas saludables y no saludables, mediante el uso de los datos metagenómicos.

Para describir y modelar los datos metagenómicos, se calcularon índices de diversidad alfa (Chao1, Shannon y Simpson) para estimar la riqueza y equidad de especies en función del estado de la planta, mientras que la diversidad beta se evaluó mediante métricas de distancia (Bray-Curtis, Jaccard y UniFrac) para determinar la variación en la composición microbiana entre grupos.

Para la validación estadística, se aplicaron pruebas de hipótesis como Mann-Whitney Wackerly et al. (2002). Los resultados mostraron que las plantas saludables presentan una mayor diversidad microbiana en comparación con las no saludables. Sin embargo, las pruebas de hipótesis no fueron concluyentes, ya que las diferencias observadas en la diversidad microbiana no alcanzaron un nivel de significancia suficiente para establecer una separación categórica entre los grupos.

A pesar de esto, las métricas de diversidad alfa y beta permitieron identificar tendencias generales en la composición microbiana, sugiriendo que otros factores pueden influir en la estructura de la comunidad rizosférica. A nivel taxonómico, se observó una reducción en la abundancia de ciertos filos microbianos en plantas no saludables, lo que indica una posible relación entre la composición del microbioma y la estabilidad agronómica del cultivo.

En particular, las plantas saludables albergan una microbiota más diversa y equilibrada, mientras que las no saludables presentan un incremento de microorganismos patógenos, reflejando un desequilibrio microbiano que podría comprometer la productividad agrícola.

Este estudio enfatiza la importancia de integrar herramientas matemáticas, estadísticas avanzadas y ciencia de datos en la caracterización del microbioma rizosférico, permitiendo modelar y predecir su influencia en la salud del suelo agrícola. Los hallazgos pueden contribuir a la optimización de prácticas agrícolas basadas en microbiomas, promoviendo la sostenibilidad y eficiencia en la producción de cultivos.

Capítulo 1

Preliminares

La ciencia de datos es el campo que aplica técnicas analíticas avanzadas y principios científicos para extraer información valiosa de los datos. Su objetivo principal es la extracción, el análisis y la comunicación de información útil a partir de los datos. Combina la estadística, la informática y el pensamiento crítico para obtener conocimiento significativo y relevante. Para realizar un análisis de datos, es necesario tener conocimientos en matemáticas, estadística, programación, inteligencia artificial, aprendizaje automático y experiencia en diversas áreas de aplicación. En este caso, es indispensable incursionar en conocimientos de genómica y metagenómica.

En microbiología, un factor importante de estudio son las interacciones entre microorganismos en un ambiente natural, ya que la mayoría de estos estudios se realizan en laboratorios. Los avances tecnológicos han llevado al desarrollo de métodos de secuenciación de ADN. Una de las plataformas más utilizadas y conocidas en el campo de la metagenómica es Illumina. Con este tipo de herramientas, es posible analizar el ADN extraído directamente de una muestra, en lugar de trabajar únicamente con microorganismos cultivados individualmente.

La filogenética es el estudio de la evolución de la vida y las relaciones entre organismos y grupos de organismos. Este análisis se centra en temas como la diversidad, la evolución, la ecología y los genomas, ayudándonos a comprender cómo evolucionan los genes, los genomas y las especies. Una

parte importante de este estudio es la identificación, clasificación y denominación de organismos biológicos, campo conocido como taxonomía.

Carl Linnaeus, considerado el padre de la taxonomía, propuso siete niveles taxonómicos: Reino, Phylum, Clase, Orden, Familia, Género y Especie. Posteriormente, se añadió el Dominio como el octavo grupo taxonómico más amplio, dividido en Arqueas, Bacterias y Eukarya.




Figura 1.1: Representación Jerárquica de los Niveles Taxonómicos para la Clasificación y Análisis de Datos Metagenómicos

Los niveles taxonómicos 1 son categorías jerárquicas utilizadas para clasificar organismos, desde los grupos más generales hasta los más específicos. El Reino es el nivel más amplio y agrupa organismos según características fundamentales, como ser procariotas o eucariotas. Dentro de cada reino, los organismos se subdividen en Filos, que los organizan según estructuras o procesos biológicos compartidos. Estos se clasifican en Clases, que reúnen grupos más específicos de organismos. A su vez, las clases se dividen en Órdenes, que contienen familias relacionadas. Las Familias agrupan Géneros, que son conjuntos de especies estrechamente relacionadas. Finalmente, la Especie es el nivel más específico, que incluye organismos capaces de reproducirse entre sí y producir descendencia viable. Esta jerarquía es esencial

para organizar la biodiversidad y estudiar las relaciones evolutivas entre los organismos.

1.1. Microbioma

El microbioma se define como la comunidad completa de microorganismos (incluyendo bacterias, arqueas, hongos, protozoos y virus) que habitan en un entorno específico, como el cuerpo humano, animales, plantas o ambientes naturales. Este término no solo abarca a los microorganismos vivos, sino también sus genes, metabolitos y las interacciones que tienen entre ellos y con su huésped. La investigación del microbioma utiliza herramientas avanzadas, como la secuenciación de próxima generación y los análisis metagenómicos, para entender su diversidad y funciones en la salud, la enfermedad y los ecosistemas (Marchesi and Ravel, 2015).

1.2. Metagenómica

El microbioma se estudia a través de la metagenómica, que mediante el dato de un archivo de texto llamado metagenoma permite analizar comunidades microbianas en su entorno natural. La metagenómica es el estudio integral del material genético recuperado directamente de muestras ambientales. Este campo se centra en comprender la diversidad microbiana, las estructuras poblacionales, las capacidades funcionales y las interacciones de las comunidades microbianas con su entorno. Se aplica comúnmente en el estudio de ecosistemas como el suelo, el agua, la microbiota humana y otros hábitats microbianos complejos. La metagenómica utiliza tecnologías avanzadas de secuenciación, como la secuenciación de nueva generación, para desentrañar la diversidad genética y funcional de estas comunidades (Zhang, 2021).

La metagenómica permite analizar el genoma colectivo (metagenoma) de todos los microorganismos presentes en un ambiente determinado, sin necesidad de cultivarlos individualmente. El DNA es pasado por un se-

cuenciador, que regresa lecturas que pueden después de un procesamiento bioinformático, ser clasificadas y asignadas a un taxón. En este sentido, los datos metagenómicos pueden representarse como una matriz de conteos, como la siguiente:

$$X = (x_{ij}) \in \mathbb{N}^{n \times p} \quad (1.1)$$

En esta matriz, cada fila puede representar una muestra (por ejemplo, un sitio ambiental), y cada columna corresponde a un taxón (por ejemplo, una especie bacteriana). El elemento x_{ij} indica el número de lecturas asignadas al taxón j en la muestra i . Debido a que las muestras presentan distinta profundidad de secuenciación, se suelen emplear abundancias relativas.

Existen dos enfoques para la secuenciación de DNA ambiental de microorganismos: “Amplicón 16S rRNA” y “Shotgun”. La secuenciación por amplicón 16S fue el primer método de secuenciación metagenómica altamente aceptado. Tiene muchas ventajas: el gen 16S está presente en todas las bacterias y arqueas, contiene las regiones necesarias para un buen análisis de PCR (Polymerase Chain Reaction - Reacción en Cadena de la Polimerasa) altamente conservadas, existen conjuntos de primers altamente estudiados para amplificar la mayoría de los organismos, ya se encuentran disponibles bases de datos públicas y bien seleccionadas que permiten una buena comparación, y la secuenciación por 16S es relativamente barata y simple. Sin embargo, posee algunas desventajas: el gen 16S no está presente en los hongos, por lo que este método no es adecuado cuando se desea trabajar con hongos. Además, existe la posibilidad de que se incremente el error de sesgo si no se elige el conjunto de primers adecuado para el organismo a analizar. La secuenciación shotgun corta al azar todo el ADN presente en la muestra y lee esos fragmentos, sin amplificar previamente ninguna región en particular. El nombre alude a esa fragmentación indiscriminada: en lugar de leer una única región conservada, se obtiene una cobertura dispersa de todo el metagenoma, de modo que cada lectura puede provenir de cualquier parte del genoma de cualquier organismo presente en la muestra. Gracias a ello se detectan a la vez bacterias, hongos y otros eucariotas, que el enfoque por amplicón 16S no alcanza a ver.

En este trabajo utilizaremos metagenomas shotgun de microorganismos relacionados con el cultivo de fresas. Una vez obtenidas las secuencias,

es necesario identificar el grupo taxonómico correspondiente para cada secuencia. Para esto, se realiza un enfoque basado en OTUs (Unidades Taxonómicas Operacionales), que agrupa las secuencias según la similitud entre OTUs. El método de agrupación por OTUs presenta ciertas limitaciones, ya que es relativamente costoso computacionalmente y requiere mucha memoria. Un OTU puede definirse dentro del mismo clúster por un porcentaje de similitud, siendo el 97 % un porcentaje común a nivel de especie. Estos OTUs pueden obtenerse mediante clústering, para lo cual ya existen varios métodos y algoritmos disponibles (Xia et al., 2018). La identificación taxonómica de los OTUs también puede abordarse mediante clasificadores basados en k -meros, que descomponen cada secuencia en sus subcadenas de longitud k y las confrontan contra una base de referencia.

Para el análisis de estos datos, se emplean herramientas bioinformáticas como kraken y braken. A los que posteriori, se pueden realizar análisis estadísticos y de diversidad utilizando herramientas como R y Python. En el entorno de R, herramientas como phyloseq y vegan permiten calcular índices de diversidad (alfa: Shannon, Simpson, Chao1; beta: Bray-Curtis, UniFrac), realizar pruebas estadísticas (Wilcoxon), análisis multivariado (NMDS, PCoA) y análisis funcional (McMurdie Holmes, 2013; Douglas et al., 2020).

1.3. Microbioma de Fresa

La fresa (*Fragaria x ananassa*) es un cultivo de gran relevancia comercial y nutricional a nivel mundial. Sin embargo, su producción se ve afectada por diversos factores, como la susceptibilidad a enfermedades y la influencia de las prácticas agrícolas y del ambiente en la calidad del fruto (Geng et al., 2023). En los últimos años, se ha visto la importancia del estudio del microbioma vegetal, entendido como la comunidad de microorganismos que coexiste con la planta e incluye bacterias, hongos y arqueas, presentes en nichos como el suelo a granel, la rizósfera (zona directamente influenciada por las raíces) y los tejidos internos (Compant et al., 2019; Sieieda et al., 2024). La composición del microbioma de fresa ha sido analizada mediante diferentes métodos, mediante el estudio masivo del ADN microbiano directamente desde las muestras ambientales (Bokulich et al., 2018). Par-

ticularmente, la secuenciación de regiones como ****16S rRNA**** (bacterias) e ****ITS1**** (hongos) ha permitido comenzar a caracterizar comunidades microbianas asociadas a distintos tejidos de la planta (raíces, tallos, hojas) y diferentes estados de salud (Zhang et al., 2023).

La rizósfera constituye un entorno microbiano complejo que alberga una gran variedad de organismos con funciones clave en el desarrollo vegetal, incluyendo la mineralización de nutrientes, producción de hormonas, supresión de patógenos y estimulación de la inmunidad vegetal (Berendsen et al., 2012; Wang et al., 2023). Las comunidades microbianas no solo influyen en el crecimiento y rendimiento de los cultivos, sino que también pueden reflejar su estado de salud, lo cual hace posible identificar biomarcadores microbianos para clasificar plantas sanas y enfermas (Yang et al., 2020; Nam et al., 2023).

Estudios recientes han identificado diferencias taxonómicas significativas entre plantas de fresa sanas y enfermas. Por ejemplo, *Udaeobacter sp.*, *Solibacter sp.* y *Nitrosomonadaceae* son más abundantes en rizósferas no saludables, mientras que *Tepidisphaerales*, *Hydrocarboniphaga* y algunos géneros de *Pseudomonas* están relacionados con condiciones saludables (Nam et al., 2023; Siegieda et al., 2024). Estas diferencias en abundancia sugieren que ciertos microorganismos pueden actuar como indicadores microbianos del estado fisiológico de la planta.

El estudio de Yang et al. (2020), utilizando secuenciación de alto rendimiento, mostró que la infección por oídio inducía cambios significativos en la estructura y diversidad microbiana del suelo rizosférico de la fresa, incluyendo una reducción general de la riqueza microbiana. Esto refuerza la idea de que las alteraciones en el microbioma pueden estar asociadas con la aparición o progresión de enfermedades.

Además, diversas especies de bacterias y hongos han sido identificadas como patógenos relevantes en fresa, como *Colletotrichum sp.*, *Alternaria sp.*, *Botrytis cinerea* y *Dactylonectria sp.*. No obstante, también se han reportado microorganismos benéficos con potencial para ser utilizados como agentes de biocontrol (BCA) o rizobacterias promotoras del crecimiento

(PGPR). Especies como *Bacillus subtilis*, *B. amyloliquefaciens*, *Pseudomonas monteilii*, *Mortierella sp.* y levaduras como *Rhodotorula* o *Trichoderma asperellum* han mostrado eficacia en la mejora de la salud de la planta y en la calidad de la fruta (Geng et al., 2023; Sieieda et al., 2024).

En conjunto, estos hallazgos destacan la importancia del análisis estadístico y bioinformático del microbioma rizosférico, tanto para la comprensión ecológica como para la aplicación biotecnológica en sistemas agrícolas sostenibles. A partir de estos estudios, se pueden desarrollar modelos predictivos y herramientas diagnósticas basadas en perfiles microbianos, útiles para monitorear la salud del cultivo, diseñar estrategias de manejo más eficientes, e incluso seleccionar microorganismos clave como bioinoculantes.

Los datos shotgun que utilizaremos en este estudio, son originales y fueron provistos por Solena, una empresa de biotecnología agrícola (AgTech) enfocada en el análisis y mejora del microbioma del suelo. Su misión es desarrollar soluciones innovadoras basadas en datos moleculares y biotecnología para optimizar la salud del suelo y, como consecuencia, aumentar la productividad agrícola. Aprovechando herramientas avanzadas como inteligencia artificial y genómica, Solena obtiene conocimientos profundos sobre la composición y funcionalidad del microbioma del suelo. Además, en colaboración con organizaciones locales, la empresa implementa centros de diagnóstico molecular agrícola, como el establecido en México, para evaluar la salud de los suelos y fomentar prácticas agrícolas regenerativas.

1.4. Clasificadores

1.4.1. Kraken & Braken

Kraken es una herramienta de clasificación de secuencias de ADN metagenómico mediante alineación exacta de k-mers, asignándoles etiquetas taxonómicas con gran exactitud y velocidad (Wood and Salzberg, 2014). Esta herramienta crea su base de datos de consulta a partir de una biblioteca de datos metagenómicos e información taxonómica de NCBI (National Center for Biotechnology Information).

Kraken deja sin clasificar las secuencias que no tienen k-mers presentes en la base de datos precalculada.

La salida de Kraken consiste en una línea por cada read, que contiene 5 ítems separados por tabulaciones. En primer lugar, se indica si el read fue clasificado o no clasificado (C/U), seguido por el nombre del read (ID de la secuencia, el encabezado del archivo FASTA o FASTQ de entrada), la etiqueta taxonómica asignada por Kraken (0 si la secuencia no queda clasificada), la longitud de la secuencia en pares de bases (bp), y finalmente una lista delimitada por espacios que muestra el mapeo LCA (Lowest Common Ancestor) de cada k-mer de la secuencia (ID taxonómico : número de k-mers).

Para obtener el ID taxonómico completo, Kraken dispone de la herramienta `kraken_translate`, que, después de procesar los resultados con la misma base de datos, genera una lista de los reads junto con el nombre completo del ID taxonómico. Además, tiene una herramienta complementaria (`-mpa`), que presenta la salida ordenada por categoría taxonómica (`root_Super Kingdom`, `d_kingdom`, `p_phylum`, `c_class`, `o_order`, `f_family`, `g_genus`, `s_species`). (Wood and Salzberg, 2014).

BRACKEN (Bayesian Re-estimation of Abundance after Classification with Kraken) calcula la abundancia de especies, géneros u otras categorías taxonómicas a partir de las secuencias de ADN recopiladas en un experimento de metagenómica (Lu et al., 2017).

BRACKEN realiza estimaciones probabilísticas basadas en las salidas de Kraken para completar las asignaciones al nivel taxonómico requerido, con el objetivo de obtener una estimación de abundancia más precisa. Este enfoque permite producir estimaciones fiables de abundancia a nivel de especie y género, incluso cuando una muestra contiene múltiples especies casi idénticas.

1.5. Lenguajes

1.5.1. BASH

Bash (Bourne Again SHell) es un intérprete de comandos y un lenguaje de scripting desarrollado para el sistema operativo Unix y sus derivados, como Linux. Creado en 1989 por Brian Fox, Bash permite automatizar tareas mediante scripts, lo que resulta particularmente útil en entornos de análisis bioinformático, donde se requiere manejar grandes volúmenes de datos. Aunque no está diseñado específicamente para análisis estadísticos o gráficos, Bash es fundamental para la gestión de flujos de trabajo y la integración de herramientas como BLAST, SAMtools y GATK. Se emplea para procesar datos en sistemas de alto rendimiento, administrar flujos de trabajo de análisis masivo y realizar manipulaciones rápidas de datos en formatos de texto o binarios.

1.5.2. R & RStudio

R es un lenguaje de programación y un entorno de software diseñado específicamente para el análisis estadístico y la visualización de datos. Desarrollado inicialmente por Ross Ihaka y Robert Gentleman en 1993, se ha convertido en una herramienta esencial en biología, ecología, genómica y otras disciplinas científicas que requieren análisis cuantitativos. Su principal fortaleza radica en la disponibilidad de bibliotecas especializadas, como ggplot2 para visualización y phyloseq para análisis de microbiomas, además de su comunidad activa, que contribuye con paquetes de código abierto. R se utiliza ampliamente en análisis de datos complejos, modelado estadístico, aprendizaje automático y visualización avanzada, facilitando la reproducibilidad y el manejo de grandes volúmenes de datos.

RStudio es un entorno de desarrollo integrado (IDE) diseñado para trabajar con el lenguaje de programación R. Ofrece una interfaz intuitiva que facilita la escritura, ejecución y depuración de código, así como la visualización de resultados. RStudio permite organizar proyectos, gestionar paquetes y bibliotecas, y crear documentos reproducibles con R Markdown. También es compatible con Shiny para aplicaciones interactivas. Disponible en ver-

siones gratuitas y de pago, RStudio es ideal tanto para principiantes como para expertos en análisis de datos.

Phyloseq

Phyloseq es un software de código abierto diseñado para la manipulación y análisis integral de datos metagenómicos generados mediante tecnologías de secuenciación de alto rendimiento. Esta herramienta, desarrollada en R, ofrece capacidades para importar, almacenar, analizar y visualizar datos metagenómicos de manera eficiente. En el entorno de R, los datos se estructuran en un objeto Phyloseq, que tiene la versatilidad de contener elementos clave, como la tabla de taxonomía, la tabla de conteos, la tabla de muestras o metadatos, y el árbol filogenético. Esta organización multifacética facilita un análisis completo y preciso de la estructura de la comunidad microbiana, brindando una comprensión profunda de los datos metagenómicos. (McMurdie and Holmes, 2013)




Figura 1.2: Estructura del Objeto Phyloseq: Organización Integral de Datos Metagenómicos para Análisis de Diversidad Microbiana, que integra tablas de abundancia, datos taxonómicos, metadatos de las muestras y árboles filogenéticos. Este formato permite un análisis eficiente y completo de las comunidades microbianas.

1.6. Formatos

1.6.1. JSON

JSON (JavaScript Object Notation) es un formato de texto ligero para el intercambio de datos estructurados, representado como pares clave-valor u objetos anidados. En bioinformática, se utiliza comúnmente para almacenar metadatos y resultados jerarquizados debido a su compatibilidad con múltiples lenguajes de programación y su facilidad de lectura. Se emplea frecuentemente para guardar información de taxonomía, anotaciones funcionales o resultados de herramientas como QIIME 2, que lo usa para almacenar objetos complejos, como árboles filogenéticos y tablas de abundancia.

1.6.2. BIOM

El formato BIOM (Biological Observation Matrix) es un estándar binario utilizado en bioinformática para almacenar matrices de datos biológicos, especialmente en estudios de microbiomas. Facilita el almacenamiento eficiente de datos de abundancia y metadatos asociados, y es compatible con herramientas como QIIME y Phyloseq. El formato contiene tablas de abundancia con taxones como filas, muestras como columnas y valores numéricos que representan abundancias relativas o absolutas. Además, permite incluir metadatos sobre muestras y taxones, como información ambiental o taxonómica.

1.6.3. FASTA

FASTA (Fast Alignment Search Tool-All) es un formato de texto plano que almacena secuencias de ADN, ARN o proteínas. Cada entrada contiene un encabezado (precedido por "`>`") seguido de una línea con la secuencia biológica. Es ampliamente utilizado para compartir datos genómicos y transcriptómicos.

FASTQ es un formato que extiende FASTA, añadiendo información sobre la calidad de cada nucleótido o aminoácido. Es fundamental para los

datos generados por plataformas de secuenciación de próxima generación (NGS). Cada entrada en FASTQ tiene cuatro líneas:

1. Un identificador de la secuencia.
2. La secuencia biológica.
3. Un separador "+".
4. Una línea con la puntuación de calidad (en formato ASCII).

1.6.4. BAM

BAM (Binary Alignment/Map) es un formato binario utilizado para almacenar datos de alineamiento de secuencias genómicas. Es una versión comprimida y binaria del formato SAM (Sequence Alignment/Map), que es un formato de texto para almacenar los mismos datos. BAM es ampliamente utilizado en bioinformática, especialmente en análisis de datos de secuenciación de próxima generación (NGS), debido a su eficiencia en el almacenamiento y procesamiento de grandes volúmenes de datos.

Cada archivo BAM contiene información detallada sobre cómo las secuencias de ADN se alinean con una referencia genómica, incluyendo la posición de la secuencia en el genoma, la calidad del alineamiento, las secuencias de los nucleótidos y las puntuaciones de calidad. Dado que el formato BAM es binario, es más compacto y rápido de manejar en comparación con su contraparte en texto, SAM.

1.7. Índices de Diversidad

Un índice de diversidad constituye una medida numérica empleada para cuantificar la variedad y la distribución de especies en una comunidad biológica o un ecosistema. Estos índices son herramientas matemáticas diseñadas para sintetizar y comparar la composición de especies en diversas comunidades.

1.7.1. Diversidad Alfa

La diversidad alfa refleja la riqueza de las muestras, es decir, el número de especies distintas presentes en un determinado entorno, o la abundancia relativa de dichas especies en dicho entorno; es usada principalmente para medir la diversidad local, haciendo referencia a la diversidad dentro de una muestra o comunidad. Para cuantificar esta diversidad, se recurre a diversos índices de medida, cada uno con enfoques particulares.

Chao1, es una métrica que evalúa la riqueza de especies, proporcionando una estimación del número total de especies en una comunidad. Su utilidad se destaca especialmente en situaciones donde la muestra es pequeña o la proporción de especies raras es considerable. Este índice demuestra ser menos sensible a la presencia de especies raras en comparación con otros índices, lo que lo convierte en una herramienta valiosa en estudios centrados en la conservación de especies poco comunes.

La fórmula para calcular el índice Chao1 es la siguiente:

$$S_{Chao1} = S_{Obs} + \frac{F_1 \times (F_1 - 1)}{F_2 \times (F_2 + 1)}$$

Donde:

- S_{Obs} es el número de especies observadas.
- F_1 es el recuento de "singletons" (especies con un solo individuo en todo el inventario).
- F_2 es el recuento de "doubletons" (especies con dos individuos en todo el inventario).

Esta expresión nos proporciona una estimación más completa de la riqueza de especies al considerar las especies raras representadas por singletons y doubletons. En consecuencia, Chao1 emerge como una herramienta valiosa para evaluar y comparar la diversidad de especies en comunidades biológicas, especialmente en situaciones donde la muestra es limitada o las especies raras desempeñan un papel significativo.

El índice de **Shannon**, representado por D_{SH} , es una medida que estima la diversidad de especies, teniendo en cuenta tanto la abundancia como

la uniformidad de las especies en una comunidad. Este índice se enfoca en medir la incertidumbre asociada con la identificación de una especie seleccionada al azar en la comunidad. Cuanto mayor sea el índice de Shannon, mayor será la diversidad de especies en la comunidad.

La fórmula para calcular el índice de Shannon es la siguiente:

$$H = - \sum_{i_1}^S P_i \ln(P_i)$$

Donde:

- S es el número de OTU's (Operational Taxonomic Units).
- P_i es la proporción de la comunidad representada por OTU_i .

Esta expresión matemática nos proporciona una medida cuantitativa de la diversidad de especies, tomando en cuenta la riqueza y la uniformidad de las mismas en la comunidad. Un índice de Shannon más alto indica una mayor diversidad, lo que sugiere una distribución más equitativa de abundancias entre las especies presentes. Es decir, comunidades con índices de Shannon más elevados tienden a tener una mayor variedad de especies y una distribución más equilibrada de individuos entre esas especies.

Simpson, es una medida de la dominancia relativa de una o unas pocas especies en una comunidad. Este índice evalúa la probabilidad de que dos individuos seleccionados al azar pertenezcan a la misma especie. En términos prácticos, un índice de Simpson más bajo indica una mayor diversidad de especies en la comunidad, lo que sugiere una distribución más equitativa de la abundancia entre las especies presentes.

La fórmula para calcular el índice de Simpson es la siguiente:

$$D = \frac{1}{\sum_{i_1}^S P_i^2}$$

Donde:

- S es el número total de especies en la comunidad.
- P_i es la proporción de la comunidad representada por OTU_i .

Esta expresión matemática nos proporciona un indicador cuantitativo de la diversidad de especies, donde un índice de Simpson más bajo refleja una comunidad con una mayor variedad de especies y una distribución más uniforme de individuos entre esas especies.

En el contexto de la diversidad alfa, estos índices nos permiten explorar y comparar la diversidad de especies en cada muestra o subconjunto, como el grupo de muestras sanas y enfermas. Proporcionan una visión detallada de cómo se distribuye la diversidad de especies dentro de cada conjunto, permitiendo evaluaciones comparativas entre diferentes conjuntos o condiciones.

1.7.2. Diversidad Beta

La diversidad beta se encarga de evaluar cuán similares o diferentes son un par de especies, muestras, conjuntos de muestras o poblaciones entre sí. Fue definida por Whittaker como una medida del cambio de diversidad a través de gradientes ambientales, en otras palabras "tasa de cambio en la composición de especies de una comunidad a otra a lo largo de gradientes" (Whittaker, 1960). Para medir esta diversidad, se utilizan métricas como la disimilitud de Bray-Curtis, la distancia Jaccard o la distancia Uni-Frac.

A continuación, se presenta una lista de distancias disponibles que Phyloseq puede utilizar, siendo las siguientes las más comúnmente utilizadas:

La **Disimilitud de Bray-Curtis** es un índice que se fundamenta en la composición y abundancia de especies en diferentes sitios (Bray and Curtis, 1957). Este índice mide la similitud entre dos muestras o poblaciones en términos de las especies que comparten, considerando la ponderación de la abundancia de cada especie en cada población.

La fórmula del índice de disimilitud de Bray-Curtis es:

$$d_{BC} = 1 - \frac{2S}{(S_a + S_b)}$$

donde d_{BC} es el índice de disimilitud de Bray-Curtis, S es el número de especies compartidas entre las poblaciones a y b , y S_a y S_b son los números de especies exclusivas de los sitios a y b , respectivamente.

Este índice proporciona una medida cuantitativa de la diferencia relativa en términos de composición de especies y abundancia entre dos poblaciones o muestras. Cuanto más cercano a 1 sea el valor del índice, mayor será la disimilitud entre las poblaciones.

La **Distancia Jaccard** es un índice de disimilitud que se basa en la presencia o ausencia de especies en diferentes poblaciones. Este índice compara la proporción de especies que son comunes entre dos poblaciones en relación con el total de especies encontradas en ambas poblaciones. Resulta útil para comparar la diversidad de especies entre diferentes poblaciones o evaluar la similitud en la composición de especies entre comunidades diversas.

La fórmula para el índice de disimilitud de Jaccard es la siguiente:

$$d_{JC} = 1 - \frac{S}{(S_a + S_b - S)}$$

donde d_{JC} es el índice de disimilitud de Jaccard, S es el número de especies compartidas entre las poblaciones a y b , y S_a y S_b son los números de especies exclusivas de los sitios a y b , respectivamente.

Este índice ofrece una medida de disimilitud que se centra en la presencia o ausencia de especies, siendo 0 cuando las poblaciones comparten todas las especies y 1 cuando no comparten ninguna. Es especialmente útil para análisis comparativos de la composición de especies entre diferentes comunidades.

La distancia **Euclidean** es comúnmente utilizada en el análisis de datos numéricos y se fundamenta en la diferencia de las abundancias o proporciones de diferentes especies en distintas muestras. Esta distancia mide la separación entre dos muestras como la raíz cuadrada de la suma de las diferencias cuadráticas entre las proporciones de cada especie en ambas muestras.

La fórmula para la distancia Euclidiana entre dos muestras A y B es la

siguiente:

$$d_{euclidean}(A, B) = \sqrt{\sum (A_i - B_i)^2}$$

Donde A_i y B_i son las abundancias o proporciones de la especie i en las muestras A y B , respectivamente.

La distancia Euclidiana es simétrica y cumple con la desigualdad del triángulo, lo que significa que satisface las propiedades de una verdadera distancia. Esta métrica es especialmente adecuada para comparar muestras en términos de diferencias numéricas en las abundancias de las especies.

La distancia **Manhattan** también se emplea en el análisis de datos numéricos y se basa en la diferencia de las abundancias o proporciones de diferentes especies en distintas muestras. En este caso, la distancia de Manhattan entre dos muestras se define como la suma de las diferencias absolutas entre las proporciones de cada especie en ambas muestras.

La fórmula de la distancia de Manhattan entre dos muestras A y B se calcula como:

$$d_{Manhattan}(A, B) = \sum |A_i - B_i|$$

Donde A_i y B_i son las abundancias o proporciones de la especie i en las muestras A y B , respectivamente.

Al igual que la distancia Euclidiana, la distancia de Manhattan es simétrica y satisface la desigualdad del triángulo. Esta métrica es adecuada para comparar muestras en términos de las diferencias absolutas en las abundancias de las especies.

La **Divergencia de Jensen-Shannon (JSD)** se utiliza para comparar la similitud entre dos distribuciones de probabilidad. En el contexto del análisis de datos de diversidad, estas distribuciones de probabilidad pueden representar la proporción de diferentes especies en distintas muestras. La distancia de JSD entre dos distribuciones de probabilidad se calcula como la raíz cuadrada de la divergencia de Kullback-Leibler entre las dos distribuciones, dividida por dos.

La fórmula de la distancia de JSD entre dos distribuciones de probabi-

lidad P y Q es la siguiente:

$$d_{JSD}(P, Q) = \frac{\sqrt{(D_{KL}(P, M) + D_{KL}(Q, M))}}{2}$$

Donde $D_{KL}(P, M)$ y $D_{KL}(Q, M)$ son las divergencias de Kullback-Leibler entre las distribuciones P y Q y la media M de ambas distribuciones, respectivamente.

Al igual que las distancias anteriores, la distancia de JSD es simétrica y satisface la desigualdad del triángulo. Esta métrica es especialmente útil cuando se quiere evaluar la similitud entre las proporciones de especies en diferentes muestras.

La métrica de **UniFrac** es un índice de disimilitud que se basa en la filogenia de las especies presentes en diferentes sitios. Su objetivo es comparar la similitud entre dos sitios en términos de la diversidad filogenética de las especies, teniendo en cuenta la contribución relativa de cada rama en el árbol filogenético. Esta métrica resulta valiosa para evaluar la similitud en la evolución de las especies en diferentes comunidades o para comparar la estructura filogenética de distintas comunidades.

La fórmula del índice de disimilitud de UniFrac es más compleja en comparación con las de Bray-Curtis y Jaccard, ya que se basa en un análisis de la distribución de ramas filogenéticas únicas o compartidas entre los sitios. Este enfoque permite capturar la información sobre las relaciones evolutivas entre las especies, proporcionando una medida más completa de la similitud o disimilitud entre las comunidades estudiadas.

Estas métricas ofrecen diferentes perspectivas sobre la similitud o disimilitud entre muestras, permitiendo seleccionar la más apropiada según el contexto del estudio y los objetivos específicos del análisis de diversidad beta.

1.8. Prueba de Hipótesis

Una hipótesis es una suposición sobre los datos que puede ser verdadera o falsa. Las pruebas de hipótesis son herramientas estadísticas esenciales en diversos campos, ya que permiten contrastar una teoría con la evidencia empírica. A través de un proceso riguroso, estas pruebas ayudan a evaluar la veracidad de una afirmación científica de manera objetiva y fundamentada.

Una prueba de hipótesis es un método estadístico utilizado para tomar decisiones sobre una población a partir de los datos obtenidos de una muestra representativa. Como técnica de inferencia estadística, permite evaluar suposiciones sobre los parámetros de una población basándose en la observación.

El propósito de una prueba estadística es examinar una hipótesis respecto a los valores de uno o más parámetros poblacionales. Para ello, se consideran los siguientes componentes clave:

Hipótesis nula (H_0): Es la idea inicial, la suposición que se pone a prueba. Representa la creencia de que no hay diferencia o efecto significativo. (Pretención que inicialmente se supone cierta)

Hipótesis alternativa (H_1): Es la contrapropuesta, lo que se espera encontrar si la H_0 es falsa. Representa la alternativa que se busca demostrar. (hipótesis contradictoria a la hipótesis nula)

Estadístico de prueba: Es la herramienta matemática (función de las mediciones muestrales) que utilizamos para analizar los datos y determinar si apoyan o no la H_1 . Cada prueba estadística tiene su propio estadístico específico.

Región de rechazo: Es una zona predefinida como territorio prohibido para la H_0 . Si el valor del estadístico de prueba cae en esta región, la H_0 se rechaza por considerarse poco probable. (x es el valor crítico observado, el cual define la región de rechazo) (una hipótesis nula será rechazada si y solo

si el valor estadístico de prueba observado o calculado, queda en la region de rechazo)

P-valor: Es la probabilidad de obtener un valor del estadístico de prueba tan extremo o más extremo que el observado, suponiendo que la H_0 sea verdadera. Un valor de p bajo (menor que el nivel de significancia α el cual se fija previamente) indica que es poco probable que el resultado se deba al azar, lo que lleva al rechazo de la H_0 .

El objetivo principal de una prueba de hipótesis es evaluar si la evidencia muestral es lo suficientemente fuerte como para rechazar H_0 . La hipótesis nula sera rechazada a favor de la hipótesis alternativa solo si la evidencia muestral sugiere que H_0 es falsa. Si la muestra no contradice a H_0 , se continuara creyendo en la veracidad de la hipótesis nula. (rechazar o no rechazar H_0).

En este contexto, el p -valor se considera como una medida de la probabilidad de obtener un resultado específico en un estudio estadístico con los datos observados. Su cálculo depende de la prueba estadística utilizada y de las suposiciones realizadas sobre la distribución de los datos. En general, un valor pequeño del p -valor sugiere que los datos observados son poco probables bajo la hipótesis nula, lo que sugiere que H_0 podría ser falsa.

Existen dos tipos de errores que pueden ocurrir en una prueba de hipótesis:

Error tipo I (α): Ocurre cuando se rechaza H_0 siendo en realidad verdadera.

Error tipo II (β): Se produce cuando no se rechaza H_0 cuando en realidad es falsa.

El balance entre estos errores es fundamental en el diseño de pruebas estadísticas.

Las pruebas de hipótesis pueden aplicarse a diferentes contextos, como la comparación de grupos en estudios médicos o científicos. Por ejemplo, en un análisis sobre la salud de los cultivos, se podrían definir las siguientes hipótesis:

H_0 : No hay diferencias entre muestras de cultivos saludables y no saluda-




Figura 1.3: Se ilustra el concepto esencial de una prueba de hipótesis, mostrando la distribución teórica de la estadística de prueba bajo la hipótesis nula (H_0) y destacando la región de rechazo. La posición del dato observado con respecto a esta región determinará si se rechaza o no H_0 en cada una de las pruebas estadísticas a realizar.

En una prueba de hipótesis, la hipótesis nula (H_0) será rechazada en favor de la hipótesis alternativa (H_1) solo si la evidencia muestral proporciona suficiente soporte para considerar que H_0 es falsa. Si los datos no contradicen significativamente a H_0 , se concluye que no hay suficiente evidencia para rechazarla, y se mantiene su validez.

bles.

H_1 : Existen diferencias significativas entre las muestras de cultivos saludables y no saludables.

1.8.1. Prueba t para comparar dos medias poblacionales (muestras pequeñas)

Suponemos dos poblaciones independientes con distribuciones normales con

$$\sigma_1^2 = \sigma_2^2$$

y queremos probar (tenemos como hipótesis nula):

$$H_0 : \mu_1 = \mu_2$$

respecto a la hipótesis alternativa:

$$H_a : \mu_1 \neq \mu_2$$

tomando como estadístico de prueba:

$$T = \frac{\bar{Y}_1 - \bar{Y}_2}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \quad (1.2)$$

donde:

$$S_p = \sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}}$$

1.8.2. Prueba F sobre las varianzas de dos poblaciones pequeñas

Suponemos dos poblaciones independientes con distribuciones normales y queremos probar:

$$H_0 : \sigma_1^2 = \sigma_2^2$$

respecto a la hipótesis alternativa:

$$H_a : \sigma_1^2 \neq \sigma_2^2$$

tomando como estadístico de prueba:

$$F = \frac{S_1^2}{S_2^2}$$

1.8.3. Prueba de Wilcoxon Mann-Whitney

Las pruebas de Wilcoxon y Mann-Whitney U son pruebas estadísticas no paramétricas, lo que significa que no asumen normalidad en los datos.

Wilcoxon es una prueba no paramétrica para comparar el rango medio de dos muestras relacionadas y determinar si existen diferencias entre ellas. Se usa, ya que los datos no tienen una distribución normal.

La U de Mann-Whitney para comparar las medias de dos grupos independientes. Prueba no paramétrica o libre de distribución, es el análogo no paramétrico a la t de Student para la comparación de dos medias independientes; solo que esta no requiere parámetros y se puede emplear sin ninguna condición de aplicación.

1.9. Normalización y Rarefacción

1.9.1. Normalización

La función `edgeRnorm` escala datos NGS normalizados utilizando la función de normalización provista en `edgeR`. Toma un objeto `phyloseq` y devuelve un objeto `phyloseq` cuya `otu_table` se transforma.

1.9.2. Rarefacción

La rarefacción es una técnica de normalización usada en el preprocesamiento de datos, para equilibrar el tamaño de las muestras en un conjunto de datos. Esta implica un submuestreo aleatorio de secuencias

1.10. Redes Bayesianas

Una red bayesiana es un grafo acíclico dirigido (DAG) $G = (V, E)$ donde cada nodo representa una variable.

Capítulo 2

objetivos

2.1. Objetivo general

Caracterizar y comparar la composición y diversidad del microbioma rizosférico de plantas de fresa saludables y no saludables mediante el análisis estadístico de datos metagenómicos, con el fin de identificar patrones asociados con el estado de salud de las plantas.

2.2. Objetivos específicos

1. Caracterizar la composición taxonómica y la diversidad microbiana de las muestras de rizósfera de plantas saludables y no saludables, mediante métricas de diversidad alfa y beta a diferentes niveles taxonómicos.
2. Evaluar estadísticamente las diferencias entre los microbiomas de plantas saludables y no saludables, utilizando pruebas de hipótesis y métodos de normalización apropiados para los datos metagenómicos.
3. Identificar patrones taxonómicos y de estructura de la comunidad microbiana asociados con el estado de salud de las plantas, explorando taxones diferenciales y las relaciones entre los microorganismos.

Capítulo 3

Análisis Exploratorio de Datos, metodología

El propósito de este análisis es identificar características diferenciadoras entre los microbiomas de plantas sanas y enfermas mediante el uso de datos metagenómicos. Para ello, se obtuvieron datos de microorganismos presentes en cultivos de fresa, proporcionados por la empresa Solena (véase sección ??). Las muestras se dividieron en dos grupos: las etiquetadas como "sanas" y las etiquetadas como "enfermas".

En la primera etapa, se realizó un proceso exhaustivo de preprocesamiento de los datos utilizando lenguajes de programación como BASH y R. Luego, el análisis exploratorio se estructuró en tres partes principales. Primero, se exploraron las diversidades alfa y beta, seguidas de un análisis estadístico respaldado por pruebas de hipótesis. En segundo lugar, se visualizó la correlación entre variables a través de redes.

Este enfoque integral no solo proporciona una comprensión detallada de la composición de los microbiomas en las plantas de fresa, sino que también permite identificar patrones significativos en las diferencias de presencia-ausencia o abundancia de microorganismos, que podrían ser fundamentales para distinguir entre la salud y la enfermedad en estos cultivos (Yang et al., 2020).

3.1. Métodos para caracterización de la diversidad microbiana

3.1.1. Preprocesamiento

Dentro de las etapas principales del análisis, se encuentra la adquisición de datos. En este caso se adquirió un conjunto de datos metagenómicos de cultivos de fresa proporcionados por Solena. Estas secuencias se entregaron en formato FASTA y se encuentran almacenadas en archivos JSON, los cuales contienen los resultados de la clasificación metagenómica realizada mediante el clasificador Kraken. Con el objetivo de identificar características distintivas entre los frutos sanos y enfermos, se ha llevado a cabo un análisis exploratorio detallado de estos datos.




Figura 3.1: Flujo de Trabajo para el Análisis Metagenómico de Microbiomas en Cultivos de Fresa: Desde la Recolección de Datos hasta la Interpretación de Resultados.

Dentro de este preprocesamiento es necesario realizar una limpieza y transformación de los datos para que estos sean adecuados para el análisis. En este caso se realizó un cambio de formato a objeto BIOM, para un mejor manejo de los datos; luego fue necesario renombrar columnas, agregar los metadatos y realizar un filtro de calidad.

Para iniciar el análisis de estos datos, llevamos a cabo una exploración general utilizando índices ecológicos, especialmente centrándonos en las diversidades alfa y beta.

Se Importaron los datos como un objeto Phyloseq, que puede incluir cuatro componentes: la matriz de abundancias, la tabla de taxonomía, los metadatos y el árbol filogenético. Este enfoque nos permite obtener una comprensión más profunda de la estructura de la comunidad microbiana presente en los datos metagenómicos, empleando medidas de diversidad para evaluar la variabilidad intra e inter-muestral. A continuación se listan las muestras utilizadas.

sample_sums(fresa_kraken)

MD2055	MD2056	MD2065	MD2066	MD2075	MD2076	MD2085	MD2086
9782432	12468526	11297600	15580959	12310781	16067839	10524919	9931297
MD2095	MD2096	MD2105	MD2106	MD2115	MD2116	MD2125	MD2126
18009912	14998268	11792397	4053295	13102554	12451637	8355853	14307309
MD2135	MD2136	MP2047	MP2048	MP2049	MP2050	MP2057	MP2058
7280751	6172369	9199079	12146967	13075806	16098757	17141427	20923502
MP2059	MP2060	MP2067	MP2068	MP2069	MP2070	MP2077	MP2078
14129981	13786630	16924218	20873789	15537530	12462356	9617847	7588787
MP2079	MP2080	MP2087	MP2088	MP2089	MP2090	MP2097	MP2098
745830	3125701	20632320	2	16582404	11176782	11714000	16595897
MP2099	MP2100	MP2107	MP2108	MP2109	MP2110	MP2117	MP2118
14844038	13342326	11014462	6728020	1405462	6901265	12624002	14711376
MP2119	MP2120	MP2127	MP2128	MP2129	MP2130	MP2137	MP2138
9835326	10975712	7106567	9974861	8348307	6196725	2169734	8220431
MP2139	MP2140						
6158581	5267510						

3.1.2. Filtrado de Calidad

A través de Solena, obtuvimos una tabla que refleja la calidad de las muestras (fastp.kraken.summary). Esta información es crucial para determinar qué muestras pueden ser eliminadas de nuestro conjunto de datos, ya que no cumplen con ciertos estándares de calidad. La identificación y exclusión de muestras que no cumplen con estos criterios contribuirá a asegurar la integridad y la confiabilidad de nuestro dataset, garantizando que solo las muestras de alta calidad sean consideradas en el análisis subsiguiente. El criterio para eliminar muestras es que, después del filtrado de calidad,

contengan menos de 25 millones de lecturas. Como ejemplo, la muestra MD2055 inicialmente tiene 97 millones de lecturas antes del filtrado, y después del análisis de calidad queda con 79 millones.

Esta tabla proporciona información detallada sobre la calidad de las muestras, destacando diversos parámetros clave:

- **ID de la muestra:** Identificación única de la muestra.
- **Reads_B (Reads_Before):** Número total de lecturas crudas antes del análisis de calidad.
- **Reads_A (Reads_After):** Número total de lecturas después del análisis de calidad.
- **Reads_diff:** Diferencia entre Reads_B y Reads_A.
- **Q30_B:** Porcentaje de lecturas con calidad superior a 30 (escala fred) antes del análisis de calidad.
- **Q30_A:** Porcentaje de lecturas con calidad superior a 30 después del análisis de calidad.
- **LowQua:** Lecturas de baja calidad.
- **N_reads:** Lecturas que contienen 'N' y son descartadas.
- **too_short:** Lecturas que no cumplen con el tamaño mínimo de calidad.
- **Duplication:** Porcentaje de duplicados.
- **LengthR1:** Longitud promedio de las lecturas en la muestra.
- **LengthR2:** Longitud promedio de las lecturas en la muestra.
- **Classified:** Porcentaje de lecturas clasificadas del total después del filtrado.

Este enfoque de eliminación se basa en mantener un umbral mínimo de calidad, contribuyendo así a garantizar la robustez y confiabilidad de las

muestras seleccionadas para análisis subsiguientes. Además, se puede realizar un recuento de lecturas por muestra para evaluar la calidad relativa entre las diferentes muestras. La eliminación de muestras con un conteo bajo es crucial para garantizar la integridad y la confiabilidad de los resultados del análisis. Al eliminar muestras con datos insuficientes, se mejora la calidad general del conjunto de datos y se evitan posibles distorsiones o sesgos que podrían surgir debido a la falta de información significativa. Este enfoque de eliminación selectiva respalda la robustez del análisis de datos metagenómicos, permitiendo una interpretación más precisa y confiable de la diversidad microbiana en las muestras restantes.

3.1.3. Índices de diversidad

Aplicamos índices de diversidad alfa para comprender la estructura de la distribución de la abundancia relativa de las especies en el seno de una población o comunidad biológica. En este contexto, realizamos un análisis de diversidad de nuestras muestras, empleando dos métricas fundamentales: la Diversidad Alfa y la Diversidad Beta (Tuomisto, 2010b). Estas métricas nos permitirán explorar y comprender tanto la variabilidad interna de una sola comunidad como las diferencias entre varias comunidades, respectivamente.

Diversidad Alfa

Para explorar la diversidad alfa de las muestras utilizamos los índices Chao1, Shannon y Simpson, descritos en la Sección 1.7.1, ya que en conjunto capturan tanto la riqueza de especies como su abundancia y dominancia relativa.

Los índices se calcularon con las funciones `estimate_richness` y `plot_richness` del paquete `Phyloseq`, aplicadas sobre el objeto `fresa_kraken` tanto en los datos crudos como en los datos con filtro de calidad, agrupando y coloreando las muestras según el tratamiento (sana o enferma) para poder comparar visualmente ambos grupos.

```
index = estimate_richness(fresa_kraken_fil)
plot_richness(physeq = fresa_kraken_fil,
```

```
measures = c("Observed", "Chao1", "Shannon", "Simpson"),
x = "Treatment", color = "Treatment")
```

Diversidad Beta

La diversidad beta se encarga de evaluar cuán similares o diferentes son un par de especies, muestras, conjuntos de muestras o poblaciones entre sí. Fue definida por Whittaker como una medida del cambio de diversidad a través de gradientes ambientales, en otras palabras "tasa de cambio en la composición de especies de una comunidad a otra a lo largo de gradientes" (Whittaker, 1960). Para medir esta diversidad, se utilizan métricas como la disimilitud de Bray-Curtis, la distancia Jaccard o la distancia Uni-Frac.

Antes de realizar análisis de diversidad beta, es crucial convertir las abundancias absolutas (número de lecturas por OTU) a relativas (porcentajes de lecturas asignadas a un OTU dentro de una muestra). Esta transformación es esencial debido a que los metagenomas tienen tamaños diferentes. Se lleva a cabo el cálculo de las abundancias relativas utilizando la función 'transform_sample' de Phyloseq, tanto para los datos originales como para los datos filtrados.

Este paso es fundamental para garantizar una comparación y evaluación adecuada de la diversidad beta, ya que las abundancias relativas proporcionan una representación más precisa de la estructura de la comunidad, independientemente de las diferencias en el tamaño del metagenoma entre las muestras.

```
transform_sample_counts(fresa_kraken_fil,
function(x) x*100/sum(x) )
```

Usamos "ordinate" para asignar las distancias entre muestras, iniciando y tomando como referencia "Bray-Curtis", ya que es una de las métricas más completas y mayormente utilizadas para medir la diversidad beta.

Para visualizar y presentar los resultados de este análisis, se opta por el uso de NMDS (Non-metric Multidimensional Scaling), una herramienta

de análisis exploratorio de datos que se emplea para visualizar la similitud o disimilitud entre una colección de objetos (por ejemplo, especies, sitios, genes) en un espacio de baja dimensionalidad. Entre otros, se utilizan ampliamente los análisis PCA, PCoA o NMDS.

Tomando los datos con filtro de calidad y utilizando la distancia de Jaccard, la cual es la más comúnmente utilizada en este tipo de estudios, se observa que las muestras, tanto sanas como enfermas, están bastante mezcladas. Ante esta observación, se procede a realizar pruebas con distintas distancias para explorar si alguna otra métrica puede proporcionar una separación más clara o revelar patrones específicos en la composición de especies entre las muestras.

Estas métricas ofrecen diferentes perspectivas sobre la similitud o disimilitud entre muestras, permitiendo seleccionar la más apropiada según el contexto del estudio y los objetivos específicos del análisis de diversidad beta.

Aplicamos la siguiente lista de distancias disponibles en Phyloseq : **Disimilitud de Bray-Curtis, Distancia Jaccard, Euclidean, Manhattan, Divergencia de Jensen-Shannon (JSD)**, y la métrica de **UniFrac**

3.1.4. Exploración a distintos niveles taxonómicos

Podemos visualizar las barras de abundancia absolutas y relativas de nuestros datos representando las muestras en el eje x y las abundancias en el eje y, diferenciando entre muestras sanas y enfermas.

3.2. Prueba de Hipótesis

En este estudio se busca contrastar si existen diferencias de diversidad, medidas a través del índice de Shannon, entre las muestras saludables y no saludables, tanto a nivel general de la comunidad microbiana como a nivel de género dentro de los eucariotas. Las definiciones formales de H_0 , H_1 , el estadístico de prueba, la región de rechazo y el p-valor se presentaron en el

Capítulo 1, Sección 1.8, por lo que aquí no se redefinen y solo se retoman para su aplicación directa sobre los datos.

Todas las pruebas se realizaron con un nivel de significancia $\alpha = 0,05$, utilizando el lenguaje R y las funciones `t.test`, `var.test` y `wilcox.test`. Antes de aplicar la prueba t se verificó el supuesto de homogeneidad de varianzas mediante la prueba F; cuando este supuesto o el de normalidad no se cumplieron, se optó por la alternativa no paramétrica de Wilcoxon-Mann-Whitney.

3.2.1. Prueba t de Student sobre el índice de Shannon

Se contrasta la hipótesis nula

$$H_0 : \mu_{\text{saludable}} = \mu_{\text{no saludable}}$$

frente a la alternativa $H_1 : \mu_{\text{saludable}} \neq \mu_{\text{no saludable}}$, usando el estadístico T definido en la Ecuación 1.2. Esta prueba se aplicó en dos escenarios: (a) sobre el índice de Shannon calculado a nivel general de la comunidad microbiana, y (b) sobre el índice de Shannon calculado a nivel de género dentro de los eucariotas, grupo que incluye a los hongos fitopatógenos de interés como *Fusarium*.

3.2.2. Prueba F sobre las varianzas

Antes de decidir la forma del estadístico T (varianzas iguales o distintas) es necesario verificar el supuesto de homogeneidad de varianzas entre los dos grupos. Para ello se aplicó la prueba F, contrastando $H_0 : \sigma_1^2 = \sigma_2^2$ frente a $H_1 : \sigma_1^2 \neq \sigma_2^2$. El resultado de esta prueba determina si la prueba t del apartado anterior debe calcularse asumiendo varianzas iguales o varianzas diferentes.

3.2.3. Prueba de Wilcoxon-Mann-Whitney

Cuando el supuesto de normalidad de los datos no se cumple, la prueba t deja de ser apropiada y se recurre a su alternativa no paramétrica: la prueba de rangos con signo de Wilcoxon-Mann-Whitney, que compara las distribuciones del índice de Shannon entre los grupos saludable y no saludable sin asumir normalidad.

Los resultados obtenidos al aplicar estas tres pruebas sobre los datos se presentan en el Capítulo 4.

3.2.4. Normalización

Desde un punto de vista matemático, los datos metagenómicos pueden representarse como una matriz de conteos:

$$X = (x_{ij}) \in \mathbb{N}^{n \times p}$$

donde:

- n es el número de muestras,
- p el número de taxones,
- x_{ij} el número de lecturas asignadas al taxón j en la muestra i .

Debido a que las muestras presentan distinta profundidad de secuenciación, se emplean abundancias relativas:

$$a_{ij} = \frac{x_{ij}}{\sum_{k=1}^p x_{ik}}, \quad \sum_{j=1}^p a_{ij} = 1.$$

Estas pertenecen al simplex composicional:

$$S^{p-1} = \left\{ x \in \mathbb{R}_+^p : \sum_{j=1}^p x_j = 1 \right\}.$$

La función `edgeRnorm` escala datos NGS normalizados utilizando la función de normalización provista en `edgeR`. Toma un objeto `phyloseq` y devuelve un objeto `phyloseq` cuya `otu_table` se transforma.

3.2.5. Rarefacción

La rarefacción es una técnica de normalización usada en el preprocesamiento de datos, para equilibrar el tamaño de las muestras en un conjunto de datos. Esta implica un submuestreo aleatorio de secuencias

Rarefy

Se eliminaron 670 OTUs

3.3. Rarefacción

La rarefacción se usa como una medida de saturación de muestras, es decir,

3.4. Redes

Para poder visualizar las redes de nuestros datos, podemos hacer un `data.frame` uniendo toda la información del objeto `phyloseq`.

```
df <- psmelt(fresa_kraken_fil)
```

Hay dos funciones en el paquete `phyloseq` para trazar la red del microbioma usando “`ggplot2`”: `plot_network()` y `plot_net()`. Se crea un grafo basado en “`igraph`”, basado en el método de distancia por defecto, Jaccard y una distancia máxima entre nodos conectados de 0,8. El “`Treatment`” se utiliza para los mapeos de color y forma para visualizar la estructura de las muestras.

Hacemos un grafo a partir de el objeto `phyloseq`

```
ig <- make_network(fresa_kraken_fil, max.dist=0.8)
```

Y luego lo graficamos.

```
plot_network(ig, fresa_kraken_fil, color="Treatment", shape=
```

INSERTAR AQUI IMAGEN DEL GRAFO

En este grafo podemos ver la complejidad de los datos y las conexiones entre nuestras muestras.

En comparación con la función `plot_network()`, la nueva función `plot_net()` no requiere una llamada separada a la función `make_network()`, o un objeto `igraph` separado. Los siguientes códigos crean una red basada en una distancia máxima entre los nodos conectados de 0,5.

```
plot_net(fresa_kraken_fil, maxdist = 0.5, color = "Treatment")
```

INSERTAR AQUI IMAGEN DEL GRAFO

En conclusion para esta observación general de los datos, no es posible ver una separacion entre muestras sanas y enfermas claramente con la diversidad beta,y con los graficos de barras y redes, no es posible identificar datos especiales.

PONER GRAFOS Y DATOS DE REDES HECHAS CON FONTY

Luego de una breve visualizacion de redes simples, tenemos dos opciones para utilizar ls redes de coocurrencia

El analisis de co-ocurrencia utiliza la matriz de interacciones Redes de co-ocurrencia - El total de nodos de la red es el numero de OTU's en una tabla; se quiere ver las relaciones entre nodos. Las aristas representan co-ocurrencia entre de nodos.

MicNet - Microbial Network Esta herramienta nos pide un documento BIOM (la tabla de abundancias) en formato .csv para poder entregar las matriz de correlaciones usando normalizacion de Dirichlet, esta herramienta se divide en tres: UMAP - Cluster - Este algoritmo permite ver los datos en el plano. Sparcc - Matriz de correlación Network - pide los dos anteriores y genera la red completa

Redes en Alnitak Esta herramienta calcula los vecinos de un taxon especifico contra el resto de los taxones, midiendo el taxon de interes con dos metricas diferentes. Aqui pide el documento BIOM cortado por nivel taxonomico del taxon escogido, junto con el TaxID del mismo; entregando una matriz de correlaciones filtrada por el taxon de interes, que solo reporta las correlaciones con el taxon escogido al nivel taxonomico tomado, que pasen los umbrales de correlacion mayor a un 0.7 y disimilitud de bray curis menor a un 0.3. Asi la primera red creada con esta herramienta es tomando Fusarium a nivel de genero, ya que como se vio anteriormente es un genero importante entre los datos de Eucariota. . .

3.5. Redes bayesianas

fundamentos teóricos utilizados para modelar la estructura de dependencia probabilística entre el género fúngico *Fusarium*, el Índice de Shannon (como métrica de diversidad alfa) y los taxones microbianos más abundantes en muestras de fresa. El análisis se basa en Redes Bayesianas (BN), una herramienta de modelado gráfico que permite inferir relaciones direcciona-

les y condicionales. La robustez de los hallazgos se garantiza mediante la aplicación de técnicas avanzadas de validación, incluyendo Bootstrapping y Validación Cruzada K-fold,

3.6. Rs

Se obtuvo un nuevo conjunto de datos complementario, el cual se divide en cinco categorías, respecto al tipo de cultivo de las fresas,

Capítulo 4

Resultados

4.1. Caracterización de la composición taxonómica de la microbiota asociada a plantas de fresa sanas y enfermas

4.1.1. Preprocesamiento y Filtrado de Calidad

Con el objetivo de identificar características distintivas entre los microorganismos presentes en plantas sanas y enfermas, se ha llevado a cabo un análisis exploratorio detallado de estos datos. Eliminamos las muestras con poco número de lecturas o de baja calidad, usando el filtro de menos de 25 millones de lecturas luego del análisis de calidad.

Después de realizar una revisión inicial de los datos, notamos la presencia de muestras con conteos de ceros (número de lecturas por muestras), como en el caso de 'MP2088' que fue eliminada. La muestra MP2088 plantea un desafío evidente al contener solo 2 lecturas. Esta escasez de datos representa un problema significativo durante el análisis, ya que la falta de información sustancial puede afectar la validez y la interpretación de los resultados. Por lo tanto, esta muestra fue eliminada utilizando el filtro de calidad establecido, que se basa en mantener muestras con un número mínimo de lecturas después del análisis. Después de la aplicación de un filtro de calidad, se identificaron cinco muestras que no cumplían con los criterios establecidos, lo que llevó a su eliminación del conjunto de datos. El criterio para eliminar

muestras es que, después del filtrado de calidad, contengan menos de 25 millones de lecturas. Bajo este filtro, se eliminaron las muestras: MP2079, MP2080, MP2088, MP2109, MP2137.

El filtro por control de calidad mejora la comparación por Diversidad Alfa




Figura 4.1: La diversidad alfa en los datos crudos es similar en ambos tratamientos en todos los índices. Al realizar el filtro de calidad se obtienen una mejor visión de esta diversidad. A) Índices de diversidad alfa calculados antes de aplicar el filtro de calidad, las diferencias entre las muestras saludables y enfermas son poco claras debido a la influencia de datos ruidosos. B) Índices de diversidad alfa tras eliminar muestras de baja calidad o datos inconsistentes, mejora la claridad y permite una mejor percepción visual de las diferencias en la diversidad microbiana entre los grupos. (Exploracion.Rmd)

En la imagen, se pueden identificar que los datos con baja calidad afectan la visualización de la diversidad alfa. Eliminar muestras de baja calidad resulta en una mejora significativa en la claridad y la interpretación de la visualización. La diferencia es notable después de descartar las muestras de baja calidad, lo que resalta la importancia de un proceso de filtrado, permitiendo una interpretación más justa. Después de aplicar el filtro de calidad de los datos, la visualización de la

4.1. CARACTERIZACIÓN DE LA COMPOSICIÓN TAXONÓMICA DE LA MICROBIO

diversidad alfa en los conjuntos de muestras de plantas sanas y enfermas sugiere una mayor diversidad en las muestras sanas en comparación con las muestras enfermas. Esta observación es más fuerte con la métrica Chao1, que elimina la influencia de los singletons y doubletons, respaldando la percepción visual de una mayor diversidad en las muestras sanas. A pesar de la diferencia en las diversidades observadas, esta disparidad no es visualmente grande, y sin una prueba estadística no se sabe si existe una diferencia significativa entre las muestras sanas y enfermas. Este problema se abordará en la sección correspondiente a pruebas estadísticas.

Así pues, la aplicación de un filtro de calidad en los datos metagenómicos mejoró la visualización de la diversidad alfa en sus distintos índices. Después del preprocesamiento de datos quedaron para el análisis 35 muestras de microbioma de rizósfera de plantas sanas y 18 muestras correspondientes a rizósfera de plantas enfermas. En general los metagenomas provenientes de plantas saludables contenían más lecturas, lo que puede sesgar su diversidad alfa, sobre todo en los índices números de especies observadas y aquellos que dependen de conteo de singletons. La rarefacción, es decir tomar muestras aleatorias con el mismo número de lecturas en cada metagenoma podría ayudar a mitigar este sesgo.




Figura 4.2: Las muestras saludables (N=35) muestran, en promedio, una mayor cantidad de lecturas en comparación con las no saludables (N=18).

Diversidad Beta

Después de aplicar el filtro de calidad, y observar la diversidad alfa considerando todos los taxones, se procedió a analizar la diversidad beta de las muestras. En la diversidad beta no se observó tampoco una clara separación de los datos por las categorías enfermo y sano para ninguna métrica de distancia. Esto sugiere una gran superposición en la composición microbiana entre las muestras saludables y enfermas, independientemente de la métrica utilizada. Por esta razón se decidió dividir el análisis en conjuntos más pequeños. Este enfoque puede ayudar a identificar patrones más específicos o diferencias significativas en la composición de linajes taxonómicos entre subconjuntos de muestras. Debido a la gran cantidad de linajes, resulta difícil discernir diferencias entre las muestras. Por lo tanto en las siguientes secciones, se crearon subdivisiones para analizar y visualizar los datos en diferentes niveles taxonómicos como reino, phylum y familias.

4.1. CARACTERIZACIÓN DE LA COMPOSICIÓN TAXONÓMICA DE LA MICROBIO




Figura 4.3: La diversidad beta no muestra que diferencias claras entre las muestras sanas y marchitas para ninguna métrica. A) Medida de disimilitud de Bray-Curtis B) Distancia de Jaccard C) Distancia Euclidiana D) Distancia Manhattan E) Medida de divergencia de Jensen-Shannon. (Exploracion.Rmd)

Distribución y diversidad microbiana al separar por reino

En el análisis de diversos grupos taxonómicos, comenzamos examinando gráficos de barras de abundancias como primer paso para seleccionar conjuntos específicos de interés. Al representar las muestras en el eje x y las abundancias en el eje y, obtenemos una visualización clara de las abundancias absolutas y relativas en cada muestra. Este enfoque nos facilita identificar de manera eficiente conjuntos particulares que pueden ser utilizados para un análisis más detallado y específico.

A nivel de phylum, ya podemos apreciar una mayor diversidad en nuestras muestras, siendo la mayoría de los filos pertenecientes a bacterias. Podemos notar algunas diferencias entre los diferentes filos, por ejemplo Actinobacteria y Proteobacteria son en ambas los más abundantes ; sin embargo, la gran cantidad de taxones dificulta distinguir adecuadamente el

color de cada uno, a menos que tengan una abundancia muy significativa. Dado que nuestro objetivo es diferenciar entre muestras sanas y enfermas, agregaremos una distinción adicional utilizando la variable 'Tratamiento': representaremos las muestras sanas en color blanco y las muestras enfermas en color negro.




Figura 4.4: Las barras de abundancia a nivel de FILO muestran a Actinobacteria y Proteobacteria como los más abundantes A) Las barras de abundancia absolutas, representan el conteo total de lecturas asignadas a cada filo en las muestras. B) Las barras de abundancia relativas, representan las proporciones de cada filo dentro de la comunidad microbiana total para cada muestra

4.1. CARACTERIZACIÓN DE LA COMPOSICIÓN TAXONÓMICA DE LA MICROBIOTA




Figura 4.5: A nivel de filo, se observa una menor presencia de ciertos taxones como Oomycota en las plantas enfermas, lo cual es consistente con la hipótesis de que la salud de las plantas está relacionada con una microbiota específica.

De igual manera, la cantidad de taxones continúa dificultando la distinción entre las muestras. Por ello, hemos creado subconjuntos más pequeños para facilitar una observación más clara de nuestros datos. También podríamos restringir sólo a los diez más abundantes por nivel taxonómico. jerárquico, pero decidimos primero explorar los diversos niveles taxonómicos comenzando con los subconjuntos a nivel de reino, en este caso, Bacteriota y Eucariota.

Podemos ver cuantos “Eukaryota” tenemos en “Kingdom”.

```
sum(fresa_kraken_fil@tax_table@.Data[, "Kingdom"]=="Eukaryota")
## [1] 181
```

```
sum(fresa_kraken_fil@tax_table@.Data[, "Kingdom"]=="Bacteria")
## [1] 8822
```

Al verificar lo observado anteriormente con la agrupación de subconjuntos, confirmamos que hay una mayor cantidad de muestras clasificadas como bacterias en comparación con las clasificadas como eucariotas. A par-

tir de estos dos subconjuntos, llevamos a cabo una agrupación adicional por filo, familia, género y especie. La elección de estos niveles taxonómicos se basa en diferentes propósitos: el filo se selecciona como el siguiente nivel después del reino para proporcionar una visualización panorámica de los datos; mientras que la familia, el género y la especie se seleccionan para obtener una visualización más detallada y poder identificar diferencias significativas entre los grupos de datos. Además, con la función **GLOM10%** se realiza una aglomeración al diez por ciento (10%) para tener una mejor visibilidad y podernos enfocar en las muestras con menor (mayor) abundancia.

Distribución y diversidad microbiana en phyla Eucaryota




Figura 4.6: La distribución de la abundancia relativa de microorganismos eucariotas en muestras de plantas saludable y no saludables, desglosada en diferentes niveles taxonómicos. A) Filo: Muestra una disminución significativa de algunos filos en las muestras enfermas, destacando particularmente la baja abundancia de Oomycota, un grupo importante asociado a la salud del suelo y de las plantas. B) Familia: Resalta la disminución específica de familias como Peronosporaceae en las muestras enfermas, lo cual podría indicar una pérdida de componentes microbianos clave para la resistencia a enfermedades. C) Género: Ofrece una visualización más específica que permite identificar biomarcadores positivos, como *Pseudomonas* y *Bacillus*, que se asocian con plantas saludables, así como *Fusarium* y *Phytophthora*, que predominan en condiciones de enfermedad. D) Especie: Se observan diferencias claras que pueden servir para identificar biomarcadores asociados a la salud o enfermedad de las plantas. Como *Pseudomonas* o *Bacillus* en muestras saludables y *Phytophthora* o *Fusarium* en muestras no saludables. (FuncionesGraficas.R)




Figura 4.7: La distribución de la abundancia relativa de bacterias revela que las plantas saludables albergan una microbiota diversa y equilibrada, caracterizada por la dominancia de filos beneficiosos como Actinobacteria y Firmicutes. En contraste, las plantas enfermas presentan una mayor proporción de posibles patógenos, destacando especies como *Ralstonia*. A) Filo, La composición a nivel de filo sugiere diferencias en la dominancia de filos beneficiosos (e.g., Actinobacteria) frente a posibles patógenos o descomponedores en plantas enfermas (e.g., Bacteroidetes). B) Familia, A nivel de familia, se observa cómo las plantas saludables están asociadas con microbiota protectora (e.g., Bacillaceae), mientras que las plantas enfermas presentan familias que incluyen patógenos o microbios oportunistas. C) Género, La identificación de géneros específicos permite asociar *Pseudomonas* y *Bacillus* con la salud de las plantas, mientras que géneros como *Ralstonia* se relacionan con la enfermedad. D) Especie, La diferenciación a nivel de especie permite identificar microorganismos específicos que actúan como indicadores claros de la salud o enfermedad de las plantas. (FuncionesGraficas.R)

En esta representación a nivel de filo, podemos destacar la disminución notable de *Oomycota* en las muestras enfermas en comparación con las

4.1. CARACTERIZACIÓN DE LA COMPOSICIÓN TAXONÓMICA DE LA MICROBIO

muestras sanas. Al profundizar a nivel de familia, observamos una disminución específica de *Peronosporaceae* en las muestras enfermas en comparación con las muestras sanas.

Diversidad alfa para los niveles taxonomicos eucarya




Figura 4.8: Diversidad alfa para eucariotas a nivel de: A) Filo B) Familia C) Género D) Especie




Figura 4.9: Diversidad alfa para bacterias a nivel de: A) Filo B) Familia C) Género D) Especie

4.1. CARACTERIZACIÓN DE LA COMPOSICIÓN TAXONÓMICA DE LA MICROBIO

La diversidad alfa de eucariotas revela que las plantas saludables presentan una microbiota más equilibrada y diversa, mientras que las plantas enfermas están dominadas por eucariotas patógenos, lo que las convierte en indicadores clave para el diagnóstico y manejo de enfermedades en cultivos.

La diversidad alfa de bacterias revela que las plantas saludables albergan una comunidad bacteriana más diversa y equilibrada en todos los niveles taxonómicos, con una prevalencia de microorganismos beneficiosos. Por otro lado, las plantas enfermas muestran un aumento de patógenos específicos, lo que indica un desequilibrio microbiano.

(FuncionesGraficas.R)

En esta imagen, podemos ver que con la diversidad Chao1 a nivel de especie se genera una diferencia considerable de diversidades entre muestras sanas y enfermas, lo cual se detallara mas adelante con una prueba de hipótesis. Tambien ...

En esta imagen, podemos ver que con la diversidad Chao1 a nivel de género se evidencia una diferencia considerable de diversidades entre muestras sanas y enfermas, lo cual se detallara mas adelante con una prueba de hipótesis. Tambien ...

Después de aplicar el filtro de calidad de los datos, la visualización de la diversidad alfa en los conjuntos de muestras de plantas sanas y enfermas revela una mayor diversidad en las muestras sanas en comparación con las muestras enfermas. Esta observación se confirma mediante la métrica Chao1, que elimina la influencia de los singletons y doubletons, respaldando la percepción visual de una mayor diversidad en las muestras sanas. A pesar de la diferencia en las diversidades observadas, cabe destacar que esta disparidad no es significativamente grande, sugiriendo que no hay una diferencia sustancial en la diversidad entre las muestras sanas y enfermas.

Este análisis proporciona una evaluación más completa de la diversidad alfa, indicando que aunque hay variaciones discernibles, estas no son lo suficientemente notables como para afirmar una gran disparidad en la diversidad entre los conjuntos de muestras. Este tipo de conclusiones respaldadas por métricas específicas y visualizaciones contribuyen a una interpretación más precisa de la composición de las comunidades microbianas en plantas sanas y enfermas

Diversidad beta para los niveles taxonomicos

4.1. CARACTERIZACIÓN DE LA COMPOSICIÓN TAXONÓMICA DE LA MICROBIO




Figura 4.10: Diversidad beta para eucariota a nivel de A) Filo, B) Familia, C) Genero, D) Especie




Figura 4.11: Diversidad beta para bacteria a nivel de A) Filo, B) Familia, C) Genero, D) Especie

(FuncionesGraficas.R)

La diversidad beta indica que, aunque hay variación entre los micro-biomas de plantas saludables y enfermas, estas no son lo suficientemente marcadas para dividir los grupos de manera clara. Estos resultados destacan la necesidad de análisis adicionales para identificar biomarcadores específicos o patrones clave en niveles taxonómicos más detallados.

La métrica de Bray-Curtis demuestra que las diferencias en la composición son más evidentes en niveles taxonómicos detallados (género y especie), destacando la importancia de estos análisis para identificar biomarcadores y desarrollar estrategias de manejo agrícola.

4.2. Evaluar estadísticamente las diferencias entre los microbiomas de plantas saludables y no saludables

4.2.1. Pruebas con muestras pequeñas para comparar dos medias poblacionales




Figura 4.12: Prueba t de Student sobre el Índice Shannon no muestra evidencia estadística suficiente para rechazar la hipótesis nula (Varianzas Iguales y Diferentes) A) Los resultados de la prueba t sugieren que, aunque las muestras saludables muestran visualmente una mayor diversidad microbiana, no hay evidencia estadística suficiente para rechazar la hipótesis nula. B) Suponiendo varianzas iguales, no se observa una diferencia significativa en las medias del índice de Shannon entre los grupos saludables y no saludables, ya que el valor p es mayor a 0.05, lo que lleva a no rechazar la hipótesis nula. C) Asumiendo las varianzas diferentes el valor p sigue siendo mayor que 0.05 (0.1501), lo que indica que no hay una diferencia significativa entre las medias del índice de Shannon entre los grupos "saludable" y "no saludable".




Figura 4.13: Prueba t de Student sobre el índice de Shannon calculado a nivel de género en eucariotas (varianzas iguales y diferentes). El índice se obtuvo sobre los 58 géneros de eucariotas identificados en las muestras, entre los que se encuentra *Fusarium*. A) Distribución del índice de Shannon en cada grupo, con la media señalada por la línea punteada. El grupo “Saludable” ($n = 35$, media 3.101) presenta una distribución más amplia y una mayor diversidad promedio que el grupo “No Saludable” ($n = 18$, media 2.988). B) Asumiendo varianzas iguales, el estadístico $t = 3.3081$ con 51 grados de libertad supera el valor crítico de 2.008, con un valor p de 0.0017 y un intervalo de confianza del 95 % de (0.044, 0.181). C) Asumiendo varianzas diferentes, el estadístico $t = 2.7089$ con 21 grados de libertad supera el valor crítico de 2.077, con un valor p de 0.0130 y un intervalo de confianza del 95 % de (0.026, 0.199). En ambos casos el valor p es menor que 0.05 y el intervalo de confianza no contiene al cero, por lo que se rechaza la hipótesis nula: la diversidad de géneros de eucariotas difiere significativamente entre plantas saludables y no saludables.

4.2.2. Prueba de los rangos con signos de Wilcoxon Mann-Whitney




Figura 4.14: La distribución de los rangos en la prueba de Mann-Whitney sobre las distribuciones de los valores de Shannon indica que los valores de los grupos "Saludable" y "No saludable" están mezclados, aunque con algunas diferencias en los extremos. El resultado de la prueba arroja un p-valor de 0.2586, lo que sugiere que no hay suficiente evidencia estadística para afirmar una diferencia significativa en el índice de Shannon entre ambos grupos.

Datos analizados: Se compararon dos grupos: healthy (saludables) y wilted (no saludables).

Estadístico de prueba (W): 376. Este es el valor del estadístico de la prueba de Mann-Whitney.

Valor p (p-value): 0.2586. Dado que este valor es mayor que el umbral típico de significancia (por ejemplo, 0.05), no hay suficiente evidencia estadística para rechazar la hipótesis nula.

Hipótesis alternativa: Se planteaba que había una diferencia en la distribución de los valores entre los grupos (healthy y wilted), es decir, que la ubicación central de los datos no es la misma en ambos grupos.

Intervalo de confianza del 95 %: (-0.01235350, 0.05609928). Esto indica que

la verdadera diferencia en la ubicación de los dos grupos podría estar entre -0.012 y 0.056. Como este intervalo incluye el 0, no hay suficiente evidencia de que haya una diferencia significativa.

Estimación de la diferencia en la ubicación central: 0.01706501. Esto significa que, en promedio, los valores del grupo healthy son aproximadamente 0.017 unidades mayores que los del grupo wilted. Sin embargo, como el intervalo de confianza incluye el 0, esta diferencia no es estadísticamente significativa.

En conclusión, no se encontró una diferencia estadísticamente significativa entre los grupos saludable y no saludable, para las diversidades microbianas con índice Shannon. Es decir, con los datos disponibles, no se puede concluir que haya una diferencia real en la distribución de los valores entre ambos grupos.

Capítulo 5

Conclusiones

Conclusiones analisis de datos

Conclusiones simulador metagenomico

Trabajo a futuro, continuar con un programa de clasificacion de muestras con machine learning, posiblemente un random forest

Capítulo 6

Perspectivas

Conclusiones analisis de datos

Conclusiones simulador metagenomico

Trabajo a futuro, continuar con un programa de clasificacion de muestras con machine learning, posiblemente un random forest

Conclusiones

Apéndice A

Codigos

Cosas.

Apéndice B

Imágenes

Cosas.

Bibliografía

- Anderson, M. J., Crist, T. O., Chase, J. M., Vellend, M., Inouye, B. D., Freestone, A. L., Sanders, N. J., Cornell, H. V., Comita, L. S., Davies, K. F., et al. (2011). Navigating the multiple meanings of β diversity: a roadmap for the practicing ecologist. *Ecology letters*, 14(1):19–28.
- Baselga, A. and Orme, C. D. L. (2012). betapart: an r package for the study of beta diversity. *Methods in ecology and evolution*, 3(5):808–812.
- Beiko, R. G., Hsiao, W., and Parkinson, J. (2018). *Microbiome analysis: methods and protocols*. Springer.
- Berry, D. and Widder, S. (2014). Deciphering microbial interactions and detecting keystone species with co-occurrence networks. *Frontiers in microbiology*, 5:219.
- Bettenfeld, P., i Canals, J. C., Jacquens, L., Fernandez, O., Fontaine, F., van Schaik, E., Courty, P.-E., and Trouvelot, S. (2022). The microbiota of the grapevine holobiont: A key component of plant health. *Journal of Advanced Research*, 40:1–15.
- Bolyen, E., Rideout, J. R., Dillon, M. R., Bokulich, N. A., Abnet, C. C., Al-Ghalith, G. A., Alexander, H., Alm, E. J., Arumugam, M., Asnicar, F., et al. (2019). Reproducible, interactive, scalable and extensible microbiome data science using qiime 2. *Nature biotechnology*, 37(8):852–857.
- Bray, J. R. and Curtis, J. T. (1957). An ordination of the upland forest communities of southern wisconsin. *Ecological monographs*, 27(4):326–349.

- Breitwieser, F. P., Lu, J., and Salzberg, S. L. (2019). A review of methods and databases for metagenomic classification and assembly. *Briefings in bioinformatics*, 20(4):1125–1136.
- Calle, M. L. (2019). Statistical analysis of metagenomics data. *Genomics & informatics*, 17(1).
- Caporaso, J. G., Kuczynski, J., Stombaugh, J., Bittinger, K., Bushman, F. D., Costello, E. K., Fierer, N., Peña, A. G., Goodrich, J. K., Gordon, J. I., et al. (2010). Qiime allows analysis of high-throughput community sequencing data. *Nature methods*, 7(5):335–336.
- Castro, C. J. and Ng, T. F. F. (2017). U50: a new metric for measuring assembly output based on non-overlapping, target-specific contigs. *Journal of Computational Biology*, 24(11):1071–1080.
- Chao, A. (1984). Nonparametric estimation of the number of classes in a population. *Scandinavian Journal of statistics*, pages 265–270.
- Chao, A. (1987). Estimating the population size for capture-recapture data with unequal catchability. *Biometrics*, pages 783–791.
- Danko, D., Bezdan, D., Afshin, E. E., Ahsanuddin, S., Bhattacharya, C., Butler, D. J., Chng, K. R., Donnellan, D., Hecht, J., Jackson, K., et al. (2021). A global metagenomic map of urban microbiomes and antimicrobial resistance. *Cell*, 184(13):3376–3393.
- Datta, S., Guha, S., et al. (2021). *Statistical Analysis of Microbiome Data*. Springer.
- Eduardo Castro Nallar, P. (2020). http://www.castrolab.org/teaching/data_analysis_phyloseq.html.
- Favila, N., Madrigal-Trejo, D., Legorreta, D., Sánchez-Pérez, J., Espinosa-Asuar, L., Eguiarte, L. E., and Souza, V. (2022). Micnet toolbox: Visualizing and unraveling a microbial network. *Plos one*, 17(6):e0259756.
- Fernandez, N. S. M. D. G. G. C. Z. M. J. A. A. R. A. J. E. A. L. F. T. V. A. ((2022, Jan)). <https://doi.org/10.5281/zenodo.4285900>.

- Fritz, A., Hofmann, P., Majda, S., Dahms, E., Dröge, J., Fiedler, J., Lesker, T. R., Belmann, P., DeMaere, M. Z., Darling, A. E., et al. (2019). Camisim: simulating metagenomes and microbial communities. *Microbiome*, 7(1):1–12.
- Gao, M., Xiong, C., Gao, C., Tsui, C. K., Wang, M.-M., Zhou, X., Zhang, A.-M., and Cai, L. (2021). Disease-induced changes in plant microbiome assembly and functional adaptation. *Microbiome*, 9:1–18.
- Gonze, D., Coyte, K. Z., Lahti, L., and Faust, K. (2018). Microbial communities as dynamical systems. *Current opinion in microbiology*, 44:41–49.
- Good, I. J. (1953). The population frequencies of species and the estimation of population parameters. *Biometrika*, 40(3-4):237–264.
- Hall, M. and Beiko, R. G. (2018). 16s rna gene analysis with qiime2. *Microbiome analysis: methods and protocols*, pages 113–129.
- Hurlbert, S. H. (1971). The nonconcept of species diversity: a critique and alternative parameters. *Ecology*, 52(4):577–586.
- Huson, D. H., Richter, D. C., Mitra, S., Auch, A. F., and Schuster, S. C. (2009). Methods for comparative metagenomics. *BMC bioinformatics*, 10:1–10.
- Jauhal, A. A. and Newcomb, R. D. (2021). Assessing genome assembly quality prior to downstream analysis: N50 versus busco. *Molecular Ecology Resources*, 21(5):1416–1421.
- Köberl, M., Dita, M., Martinuz, A., Staver, C., and Berg, G. (2017). Members of gammaproteobacteria as indicator species of healthy banana plants on fusarium wilt-infested fields in central america. *Scientific reports*, 7(1):45318.
- Koleff, P., Gaston, K. J., and Lennon, J. J. (2003). Measuring beta diversity for presence–absence data. *Journal of Animal Ecology*, 72(3):367–382.
- Kumar, V., Prasad, R., Kumar, M., and Choudhary, D. K. (2019). *Microbiome in Plant Health and Disease: Challenges and Opportunities*. Springer.

- Larsen, R. J. and Marx, M. L. (2005). *An introduction to mathematical statistics*. Prentice Hall Hoboken, NJ.
- Lozupone, C. A. and Knight, R. (2008). Species divergence and the measurement of microbial diversity. *FEMS microbiology reviews*, 32(4):557–578.
- Lu, J., Breitwieser, F. P., Thielen, P., and Salzberg, S. L. (2017). Bracken: estimating species abundance in metagenomics data. *PeerJ Computer Science*, 3:e104.
- Lu, J., Rincon, N., Wood, D. E., Breitwieser, F. P., Pockrandt, C., Langmead, B., Salzberg, S. L., and Steinegger, M. (2022). Metagenome analysis using the kraken software suite. *Nature protocols*, 17(12):2815–2839.
- Ma, Z., Li, L., and Gotelli, N. J. (2019). Diversity-disease relationships and shared species analyses for human microbiome-associated diseases. *The ISME Journal*, 13(8):1911–1919.
- Magurran, A. E. (2021). Measuring biological diversity. *Current Biology*, 31(19):R1174–R1177.
- Mäkinen, V., Salmela, L., and Ylinen, J. (2012). Normalized n50 assembly metric using gap-restricted co-linear chaining. *BMC bioinformatics*, 13:1–5.
- Mamet, S. D., Redlick, E., Brabant, M., Lamb, E. G., Helgason, B. L., Stanley, K., and Siciliano, S. D. (2019). Structural equation modeling of a winnowed soil microbiome identifies how invasive plants re-structure microbial networks. *The ISME Journal*, 13(8):1988–1996.
- Marchesi, J. R. and Ravel, J. (2015). The vocabulary of microbiome research: a proposal. *Microbiome*, 3:31.
- Matloff, N. (2019). *Probability and statistics for data science: Math+ R+ data*. CRC Press.
- McMurdie, P. J. and Holmes, S. (2013). phyloseq: an r package for reproducible interactive analysis and graphics of microbiome census data. *PloS one*, 8(4):e61217.

- McMurdie, P. J. and Holmes, S. (2014). Waste not, want not: why rarefying microbiome data is inadmissible. *PLoS computational biology*, 10(4):e1003531.
- Menzel, P., Ng, K. L., and Krogh, A. (2016). Fast and sensitive taxonomic classification for metagenomics with kaiju. *Nature communications*, 7(1):11257.
- Meyer, F., Fritz, A., Deng, Z.-L., Koslicki, D., Lesker, T. R., Gurevich, A., Robertson, G., Alser, M., Antipov, D., Beghini, F., et al. (2022). Critical assessment of metagenome interpretation: the second round of challenges. *Nature methods*, 19(4):429–440.
- Milhaven, M. and Pfeifer, S. P. (2023). Performance evaluation of six popular short-read simulators. *Heredity*, 130(2):55–63.
- Miller, J. R., Koren, S., and Sutton, G. (2010). Assembly algorithms for next-generation sequencing data. *Genomics*, 95(6):315–327.
- Mineeva, O., Rojas-Carulla, M., Ley, R. E., Sch"olkopf, B., and Youngblut, N. D. (2020). Deepmased: evaluating the quality of metagenomic assemblies. *Bioinformatics*, 36(10):3011–3017.
- Morgan, X. C. and Huttenhower, C. (2012). Chapter 12: Human microbiome analysis. *PLoS computational biology*, 8(12):e1002808.
- Nam, J. H., Thibodeau, A., Qian, Y. L., Qian, M. C., and Park, S. H. (2023). Multidisciplinary evaluation of plant growth promoting rhizobacteria on soil microbiome and strawberry quality. *Amb Express*, 13(1):18.
- Nayfach, S., Roux, S., Seshadri, R., Udworthy, D., Varghese, N., Schulz, F., Wu, D., Paez-Espino, D., Chen, I.-M., Huntemann, M., et al. (2021). A genomic catalog of earth’s microbiomes. *Nature biotechnology*, 39(4):499–509.
- Oksanen, J. and Tonteri, T. (1995). Rate of compositional turnover along gradients and total gradient length. *Journal of Vegetation Science*, 6(6):815–824.

- Oulas, A., Pavloudi, C., Polymenakou, P., Pavlopoulos, G. A., Papanikolaou, N., Kotoulas, G., Arvanitidis, C., and Iliopoulos, I. (2015). Metagenomics: tools and insights for analyzing next-generation sequencing data derived from biodiversity studies. *Bioinformatics and biology insights*, 9:BBI-S12462.
- Pan, A. Y. (2021). Statistical analysis of microbiome data: the challenge of sparsity. *Current Opinion in Endocrine and Metabolic Research*, 19:35–40.
- Parks, D. H., Imelfort, M., Skennerton, C. T., Hugenholtz, P., and Tyson, G. W. (2015). Checkm: assessing the quality of microbial genomes recovered from isolates, single cells, and metagenomes. *Genome research*, 25(7):1043–1055.
- Pflughoeft, K. J. and Versalovic, J. (2012). Human microbiome in health and disease. *Annual Review of Pathology: Mechanisms of Disease*, 7:99–122.
- Plaza Onate, F., Batto, J.-M., Juste, C., Fadlallah, J., Fougereux, C., Gouas, D., Pons, N., Kennedy, S., Levenez, F., Dore, J., et al. (2015). Quality control of microbiota metagenomics by k-mer analysis. *BMC genomics*, 16(1):1–10.
- Popescu, S. C., Tomaso-Peterson, M., Wilkerson, T., Bronzato-Badial, A., Wesser, U., and Popescu, G. V. (2022). Metagenomic analyses of the soybean root mycobiome and microbiome reveal signatures of the healthy and diseased plants affected by taproot decline. *Microorganisms*, 10(5):856.
- Rosenberg, E. (2021). *Microbiomes: Current Knowledge and Unanswered Questions*. Springer Nature.
- Sélem-Mojica, N., Aguilar, C., Gutiérrez-García, K., Martínez-Guerrero, C. E., and Barona-Gómez, F. (2019). Evomining reveals the origin and fate of natural product biosynthetic enzymes. *Microbial genomics*, 5(12).
- Seppey, M., Manni, M., and Zdobnov, E. M. (2020). Lemmi: a continuous benchmarking platform for metagenomics classifiers. *Genome research*, 30(8):1208–1216.

- Shannon, C. E. (1948). A mathematical theory of communication. *The Bell system technical journal*, 27(3):379–423.
- Siegieda, D., Panek, J., and Frac, M. (2024). Ecological processes of bacterial microbiome assembly in healthy and dysbiotic strawberry farms. *BMC Plant Biology*, 24(1):692.
- Simpson, E. H. (1949). Measurement of diversity. *nature*, 163(4148):688–688.
- Suhaimi, N. S. M., Goh, S.-Y., Ajam, N., Othman, R. Y., Chan, K.-G., and Thong, K. L. (2017). Diversity of microbiota associated with symptomatic and non-symptomatic bacterial wilt-diseased banana plants determined using 16s rrna metagenome sequencing. *World Journal of Microbiology and Biotechnology*, 33:1–10.
- Tuomisto, H. (2010a). A consistent terminology for quantifying species diversity? yes, it does exist. *Oecologia*, 164(4):853–860.
- Tuomisto, H. (2010b). A diversity of beta diversities: straightening up a concept gone awry. part 1. defining beta diversity as a function of alpha and gamma diversity. *Ecography*, 33(1):2–22.
- Videvall, E. The Molecular Ecologist (29 de Marzo de 2017). www.molecularecologist.com/2017/03/29/whats-n50/.
- Wackerly, D. D., Mendenhall III, W., Scheaffer, R. L., Yescas Milanés, J., et al. (2002). *Estadística matemática con aplicaciones*.
- Wang, H., Wu, C., Zhang, H., Xiao, M., Ge, T., Zhou, Z., Liu, Y., Peng, S., Peng, P., and Chen, J. (2022). Characterization of the belowground microbial community and co-occurrence networks of tobacco plants infected with bacterial wilt disease. *World Journal of Microbiology and Biotechnology*, 38(9):155.
- Wang, Z., Wang, Y., Fuhrman, J. A., Sun, F., and Zhu, S. (2020). Assessment of metagenomic assemblers based on hybrid reads of real and simulated metagenomic sequences. *Briefings in bioinformatics*, 21(3):777–790.

- Washington, H. (1984). Diversity, biotic and similarity indices: a review with special relevance to aquatic ecosystems. *Water research*, 18(6):653–694.
- Whittaker, R. H. (1960). Vegetation of the siskiyou mountains, oregon and california. *Ecological monographs*, 30(3):279–338.
- Whittaker, R. H. (1972). Evolution and measurement of species diversity. *Taxon*, 21(2-3):213–251.
- Wilcox, R. R. (2010). *Fundamentals of Modern Statistical Methods*. Springer New York, NY.
- Wilson, M. V. and Mohler, C. (1983). Measuring compositional change along gradients. *Vegetatio*, 54:129–141.
- Wood, D. E. and Salzberg, S. L. (2014). Kraken: ultrafast metagenomic sequence classification using exact alignments. *Genome biology*, 15(3):1–12.
- Xia, Y. and Sun, J. (2017). Hypothesis testing and statistical analysis of microbiome. *Genes & diseases*, 4(3):138–148.
- Xia, Y., Sun, J., Chen, D.-G., et al. (2018). *Statistical analysis of microbiome data with R*, volume 847. Springer.
- Xiong, W., Song, Y., Yang, K., Gu, Y., Wei, Z., Kowalchuk, G. A., Xu, Y., Jousset, A., Shen, Q., and Geisen, S. (2020). Rhizosphere protists are key determinants of plant health. *Microbiome*, 8:1–9.
- Yang, J., Wei, S., Su, D., Zhang, Z., Chen, S., Luo, Z., Shen, X., Lai, Y., Jamil, A., Tong, J., et al. (2020). Comparison of the rhizosphere soil microbial community structure and diversity between powdery mildew-infected and noninfected strawberry plants in a greenhouse by high-throughput sequencing technology. *Current Microbiology*, 77:1724–1736.
- Yao, Y., Jin, Z., and Lee, J. H. (2018). An improved statistical model for taxonomic assignment of metagenomics. *BMC genetics*, 19(1):1–11.
- Zhou, Q., Su, X., and Ning, K. (2014). Assessment of quality control approaches for metagenomic data analysis. *Scientific reports*, 4(1):6957.