



Universidad Nacional Autónoma
de México y Universidad
Michoacana de San Nicolás de
Hidalgo



Posgrado Conjunto en Ciencias Matemáticas
UMSNH-UNAM

**Análisis estadístico de la diversidad microbiana a
distintos niveles taxonómicos en el microbioma
rizosférico de plantas de fresa saludables y no
saludables**

TESIS

para obtener el grado de

Maestra en Ciencias Matemáticas

presenta

Paula Camila Silva Gomez
`csilva@matmor.unam.mx`

Asesor:

Doctora

Nelly Sélem Mojica
`nselem@matmor.unam.mx`

Morelia, Michoacán, México
Mayo, 2026

PAULA CAMILA SILVA GOMEZ

FIRMA

FECHA

Agradecimientos

Principalmente, agradezco a la Dra. Nelly por su infinita paciencia, dedicación y todo el tiempo y esfuerzo que me brindó a lo largo de este proceso. Su apoyo ha sido invaluable.

Agradezco al universo por enseñarme a mejorar cada día y por recordarme que, aunque el camino no siempre fue fácil y fue más largo de lo esperado, encontré la fortaleza para no rendirme y seguir adelante.

Gracias a las carnitas, los elotes y las nieves, por hacerme enamorar de una cultura que, aunque no soy fan del picante, llevaré siempre en mi corazón con mucho cariño.

Y un agradecimiento inmenso a cada una de las personitas, amigos, compañeros, y mis roomies, que me acompañaron en este camino. Gracias por estar ahí, ya sea desde cerca o a la distancia, con palabras de aliento, compañía y apoyo en esos días difíciles, que, siendo honesta, fueron muchos.

¡Gracias totales!

Índice general

1. Preliminares	1
1.1. Microbioma	3
1.2. Metagenómica	3
1.3. Microbioma de Fresa	5
1.4. Clasificadores	7
1.4.1. Kraken & Braken	7
1.5. Lenguajes	9
1.5.1. BASH	9
1.5.2. R & RStudio	9
1.6. Formatos	11
1.6.1. JSON	11
1.6.2. BIOM	11
1.6.3. FASTA	11
1.6.4. BAM	12
1.7. Índices de Diversidad	12
1.7.1. Diversidad Alfa	13
1.7.2. Diversidad Beta	15
1.8. Prueba de Hipótesis	18
1.8.1. Prueba t para comparar dos medias poblacionales (muestras pequeñas)	21
1.8.2. Prueba F sobre las varianzas de dos poblaciones pe- queñas	22
1.8.3. Prueba de suma de rangos de Wilcoxon (Mann-Whitney)	23
1.9. Normalización y Rarefacción	24
1.9.1. Normalización	24

1.9.2. Rarefacción	24
1.10. Redes Bayesianas	24
2. objetivos	27
2.1. Objetivo general	27
2.2. Objetivos específicos	27
3. Análisis Exploratorio de Datos, metodología	29
3.1. Métodos para caracterización de la diversidad microbiana .	30
3.1.1. Preprocesamiento	30
3.1.2. Filtrado de Calidad	31
3.1.3. Índices de diversidad	33
3.1.4. Exploración a distintos niveles taxonómicos	35
3.2. Prueba de Hipótesis	35
3.2.1. Prueba t de Student sobre el índice de Shannon . . .	36
3.2.2. Prueba F sobre las varianzas	36
3.2.3. Prueba de Wilcoxon-Mann-Whitney	36
3.2.4. Análisis complementarios	37
3.2.5. Normalización	37
3.2.6. Rarefacción	38
3.3. Rarefacción	38
3.4. Redes	38
3.5. Redes bayesianas	40
3.6. Rs	40
4. Resultados	41
4.1. Caracterización de la composición taxonómica y la diversidad microbiana	41
4.1.1. Preprocesamiento y filtro de calidad	41
4.1.2. Diversidad alfa de la comunidad completa	43
4.1.3. Diversidad beta de la comunidad completa	44
4.1.4. Composición taxonómica general	45
4.1.5. Eucariotas por nivel taxonómico	47
4.1.6. Bacterias por nivel taxonómico	50
4.2. Evaluación estadística de las diferencias entre grupos	53
4.2.1. Verificación de supuestos	53

4.2.2.	Prueba t sobre el índice de Shannon de la comunidad completa	54
4.2.3.	Prueba t sobre el índice de Shannon de los géneros de eucariotas	55
4.2.4.	Prueba de Wilcoxon-Mann-Whitney	56
4.2.5.	Tamaño del efecto y potencia estadística	57
4.3.	Patrones asociados con el estado de salud de la planta . . .	58
4.3.1.	Taxones candidatos	58
4.3.2.	Heterogeneidad del grupo no saludable	59
4.3.3.	Dónde está y dónde no está la señal	59
5.	Discusión y conclusiones	61
5.1.	Discusión	61
5.1.1.	La calidad de los datos condiciona la interpretación .	61
5.1.2.	Diversidad alfa: una tendencia consistente pero débil	62
5.1.3.	Diversidad beta: gran superposición entre grupos . .	63
5.1.4.	Composición taxonómica: taxones candidatos, no biomarcadores	63
5.1.5.	Diversidad de eucariotas a nivel de género: una señal que no se confirmó	64
5.1.6.	Tamaño de muestra y potencia estadística	65
5.1.7.	Limitaciones del estudio	65
5.2.	Conclusiones	66
6.	Perspectivas y trabajo a futuro	69
6.1.	Redes bayesianas (en desarrollo)	69
6.2.	Simulador de datos metagenómicos	70
6.3.	Otras líneas	72
A.	Codigos	75
B.	Imagenes	77
	Bibliografía	79

Abstract

El microbioma rizosférico es un factor clave en la estabilidad y productividad agrícola, influyendo en la disponibilidad de nutrientes y la interacción de las plantas con su entorno. Su análisis mediante enfoques metagenómicos genera grandes volúmenes de datos, cuya interpretación requiere métodos matemáticos y estadísticos avanzados para identificar patrones de diversidad microbiana.

Este estudio explora las diferencias en la composición del microbioma rizosférico entre plantas saludables y no saludables en cultivos de fresa (*Fragaria ananassa*), aplicando métricas de diversidad alfa y beta, junto con pruebas de hipótesis para evaluar variaciones significativas. Si bien los resultados indican una mayor diversidad microbiana en plantas saludables, las diferencias no fueron concluyentes desde un punto de vista estadístico. No obstante, se identificaron tendencias generales en la estructura microbiana, sugiriendo que otros factores podrían estar modulando la comunidad rizosférica.

Los hallazgos resaltan la importancia de combinar herramientas de modelado estadístico y ciencia de datos en el estudio del microbioma agrícola, proporcionando bases cuantitativas para el diseño de estrategias de manejo del suelo orientadas a mejorar la resiliencia y sostenibilidad de los cultivos.

Palabras clave: Metagenómica, análisis de datos, modelado estadístico, microbioma del suelo, diversidad microbiana, análisis bioinformático, fresa.

Introducción

El análisis metagenómico genera grandes volúmenes de datos cuya interpretación requiere métodos matemáticos y estadísticos avanzados para identificar patrones y variaciones en comunidades microbianas complejas. Dentro de este contexto, el microbioma rizosférico desempeña un papel crucial en la salud y productividad de los cultivos agrícolas, regulando la disponibilidad de nutrientes y la resiliencia del suelo Kumar et al. (2019) Rosenberg (2021). Comprender estas variaciones es fundamental para desarrollar estrategias de manejo agrícola basadas en la manipulación del microbioma del suelo.

En este estudio, se analizan las diferencias en la composición y estructura del microbioma rizosférico entre plantas saludables y no saludables en cultivos de fresa (*Fragaria ananassa*) Yang et al. (2020), utilizando herramientas avanzadas de estadística y modelado matemático Xia et al. (2018) para cuantificar estas variaciones y evaluar su impacto en la agronomía. Teniendo como propósito identificar características diferenciadoras entre los microbiomas de plantas saludables y no saludables, mediante el uso de los datos metagenómicos.

Para describir y modelar los datos metagenómicos, se calcularon índices de diversidad alfa (Chao1, Shannon y Simpson) para estimar la riqueza y equidad de especies en función del estado de la planta, mientras que la diversidad beta se evaluó mediante medidas de disimilitud (Bray-Curtis, Jaccard, Euclidiana, Manhattan y Jensen-Shannon) para determinar la variación en la composición microbiana entre grupos.

Para la validación estadística, se aplicaron pruebas de hipótesis como Mann-Whitney Wackerly et al. (2002). Los resultados mostraron que las plantas saludables presentan una mayor diversidad microbiana en comparación con las no saludables. Sin embargo, las pruebas de hipótesis no fueron concluyentes, ya que las diferencias observadas en la diversidad microbiana no alcanzaron un nivel de significancia suficiente para establecer una separación categórica entre los grupos.

A pesar de esto, las métricas de diversidad alfa y beta permitieron identificar tendencias generales en la composición microbiana, sugiriendo que otros factores pueden influir en la estructura de la comunidad rizosférica. A nivel taxonómico, se observó una reducción en la abundancia de ciertos filos microbianos en plantas no saludables, lo que indica una posible relación entre la composición del microbioma y la estabilidad agronómica del cultivo.

En particular, las plantas saludables albergan una microbiota más diversa y equilibrada, mientras que las no saludables presentan un incremento de microorganismos patógenos, reflejando un desequilibrio microbiano que podría comprometer la productividad agrícola.

Este estudio enfatiza la importancia de integrar herramientas matemáticas, estadísticas avanzadas y ciencia de datos en la caracterización del microbioma rizosférico, permitiendo modelar y predecir su influencia en la salud del suelo agrícola. Los hallazgos pueden contribuir a la optimización de prácticas agrícolas basadas en microbiomas, promoviendo la sostenibilidad y eficiencia en la producción de cultivos.

Capítulo 1

Preliminares

La ciencia de datos es el campo que aplica técnicas analíticas avanzadas y principios científicos para extraer información valiosa de los datos. Su objetivo principal es la extracción, el análisis y la comunicación de información útil a partir de los datos. Combina la estadística, la informática y el pensamiento crítico para obtener conocimiento significativo y relevante. Para realizar un análisis de datos, es necesario tener conocimientos en matemáticas, estadística, programación, inteligencia artificial, aprendizaje automático y experiencia en diversas áreas de aplicación. En este caso, es indispensable incursionar en conocimientos de genómica y metagenómica.

En microbiología, un factor importante de estudio son las interacciones entre microorganismos en un ambiente natural, ya que la mayoría de estos estudios se realizan en laboratorios. Los avances tecnológicos han llevado al desarrollo de métodos de secuenciación de ADN. Una de las plataformas más utilizadas y conocidas en el campo de la metagenómica es Illumina. Con este tipo de herramientas, es posible analizar el ADN extraído directamente de una muestra, en lugar de trabajar únicamente con microorganismos cultivados individualmente (Oulas et al., 2015).

La filogenética es el estudio de la evolución de la vida y las relaciones entre organismos y grupos de organismos. Este análisis se centra en temas como la diversidad, la evolución, la ecología y los genomas, ayudándonos a comprender cómo evolucionan los genes, los genomas y las especies. Una

parte importante de este estudio es la identificación, clasificación y denominación de organismos biológicos, campo conocido como taxonomía.

Carl Linnaeus, considerado el padre de la taxonomía, propuso siete niveles taxonómicos: Reino, Phylum, Clase, Orden, Familia, Género y Especie. Posteriormente, se añadió el Dominio como el octavo grupo taxonómico más amplio, dividido en Arqueas, Bacterias y Eukarya (Woese et al., 1990).




Figura 1.1: Representación Jerárquica de los Niveles Taxonómicos para la Clasificación y Análisis de Datos Metagenómicos

Los niveles taxonómicos 1 son categorías jerárquicas utilizadas para clasificar organismos, desde los grupos más generales hasta los más específicos. El Reino es el nivel más amplio y agrupa organismos según características fundamentales, como ser procariotas o eucariotas. Dentro de cada reino, los organismos se subdividen en Filos, que los organizan según estructuras o procesos biológicos compartidos. Estos se clasifican en Clases, que reúnen grupos más específicos de organismos. A su vez, las clases se dividen en Órdenes, que contienen familias relacionadas. Las Familias agrupan Géneros, que son conjuntos de especies estrechamente relacionadas. Finalmente, la Especie es el nivel más específico, que incluye organismos capaces de reproducirse entre sí y producir descendencia viable. Esta jerarquía es esencial

para organizar la biodiversidad y estudiar las relaciones evolutivas entre los organismos.

1.1. Microbioma

El microbioma se define como la comunidad completa de microorganismos (incluyendo bacterias, arqueas, hongos, protozoos y virus) que habitan en un entorno específico, como el cuerpo humano, animales, plantas o ambientes naturales. Este término no solo abarca a los microorganismos vivos, sino también sus genes, metabolitos y las interacciones que tienen entre ellos y con su huésped. La investigación del microbioma utiliza herramientas avanzadas, como la secuenciación de próxima generación y los análisis metagenómicos, para entender su diversidad y funciones en la salud, la enfermedad y los ecosistemas (Marchesi and Ravel, 2015).

1.2. Metagenómica

El microbioma se estudia a través de la metagenómica, que mediante el dato de un archivo de texto llamado metagenoma permite analizar comunidades microbianas en su entorno natural. La metagenómica es el estudio integral del material genético recuperado directamente de muestras ambientales. Este campo se centra en comprender la diversidad microbiana, las estructuras poblacionales, las capacidades funcionales y las interacciones de las comunidades microbianas con su entorno. Se aplica comúnmente en el estudio de ecosistemas como el suelo, el agua, la microbiota humana y otros hábitats microbianos complejos. La metagenómica utiliza tecnologías avanzadas de secuenciación, como la secuenciación de nueva generación, para desentrañar la diversidad genética y funcional de estas comunidades (Oulas et al., 2015; Breitwieser et al., 2019).

La metagenómica permite analizar el genoma colectivo (metagenoma) de todos los microorganismos presentes en un ambiente determinado, sin necesidad de cultivarlos individualmente. El DNA es pasado por un se-

cuenciador, que regresa lecturas que pueden después de un procesamiento bioinformático, ser clasificadas y asignadas a un taxón. En este sentido, los datos metagenómicos pueden representarse como una matriz de conteos, como la siguiente:

$$X = (x_{ij}) \in \mathbb{N}^{n \times p} \quad (1.1)$$

En esta matriz, cada fila puede representar una muestra (por ejemplo, un sitio ambiental), y cada columna corresponde a un taxón (por ejemplo, una especie bacteriana). El elemento x_{ij} indica el número de lecturas asignadas al taxón j en la muestra i . Debido a que las muestras presentan distinta profundidad de secuenciación, se suelen emplear abundancias relativas.

Existen dos enfoques para la secuenciación de DNA ambiental de microorganismos: “Amplicón 16S rRNA” y “Shotgun”. La secuenciación por amplicón 16S fue el primer método de secuenciación metagenómica altamente aceptado. Tiene muchas ventajas: el gen 16S está presente en todas las bacterias y arqueas, contiene las regiones necesarias para un buen análisis de PCR (Polymerase Chain Reaction - Reacción en Cadena de la Polimerasa) altamente conservadas, existen conjuntos de primers altamente estudiados para amplificar la mayoría de los organismos, ya se encuentran disponibles bases de datos públicas y bien seleccionadas que permiten una buena comparación, y la secuenciación por 16S es relativamente barata y simple. Sin embargo, posee algunas desventajas: el gen 16S no está presente en los hongos, por lo que este método no es adecuado cuando se desea trabajar con hongos. Además, existe la posibilidad de que se incremente el error de sesgo si no se elige el conjunto de primers adecuado para el organismo a analizar. La secuenciación shotgun corta al azar todo el ADN presente en la muestra y lee esos fragmentos, sin amplificar previamente ninguna región en particular. El nombre alude a esa fragmentación indiscriminada: en lugar de leer una única región conservada, se obtiene una cobertura dispersa de todo el metagenoma, de modo que cada lectura puede provenir de cualquier parte del genoma de cualquier organismo presente en la muestra. Gracias a ello se detectan a la vez bacterias, hongos y otros eucariotas, que el enfoque por amplicón 16S no alcanza a ver (Ranjan et al., 2016; Hall and Beiko, 2018).

En este trabajo utilizaremos metagenomas shotgun de microorganismos relacionados con el cultivo de fresas. Una vez obtenidas las secuencias,

es necesario identificar el grupo taxonómico correspondiente para cada secuencia. Para esto, se realiza un enfoque basado en OTUs (Unidades Taxonómicas Operacionales), que agrupa las secuencias según la similitud entre OTUs. El método de agrupación por OTUs presenta ciertas limitaciones, ya que es relativamente costoso computacionalmente y requiere mucha memoria. Un OTU puede definirse dentro del mismo clúster por un porcentaje de similitud, siendo el 97 % un porcentaje común a nivel de especie. Estos OTUs pueden obtenerse mediante clústering, para lo cual ya existen varios métodos y algoritmos disponibles (Xia et al., 2018). La identificación taxonómica de los OTUs también puede abordarse mediante clasificadores basados en k -meros, que descomponen cada secuencia en sus subcadenas de longitud k y las confrontan contra una base de referencia (Wood and Salzberg, 2014; Menzel et al., 2016; Breitwieser et al., 2019).

Para el análisis de estos datos, se emplean herramientas bioinformáticas como Kraken (Wood and Salzberg, 2014) y Bracken (Lu et al., 2017). A los que posteriori, se pueden realizar análisis estadísticos y de diversidad utilizando herramientas como R y Python. En el entorno de R, herramientas como phyloseq y vegan permiten calcular índices de diversidad (alfa: Shannon, Simpson, Chao1; beta: Bray-Curtis, UniFrac), realizar pruebas estadísticas (Wilcoxon), análisis multivariado (NMDS, PCoA) y análisis funcional (McMurdie and Holmes, 2013; Oksanen et al., 2022; Douglas et al., 2020).

1.3. Microbioma de Fresa

La fresa (*Fragaria x ananassa*) es un cultivo de gran relevancia comercial y nutricional a nivel mundial. Sin embargo, su producción se ve afectada por diversos factores, como la susceptibilidad a enfermedades y la influencia de las prácticas agrícolas y del ambiente en la calidad del fruto (Yang et al., 2020; Nam et al., 2023). En los últimos años, se ha visto la importancia del estudio del microbioma vegetal, entendido como la comunidad de microorganismos que coexiste con la planta e incluye bacterias, hongos y arqueas, presentes en nichos como el suelo a granel, la rizósfera (zona directamente influenciada por las raíces) y los tejidos internos (Compant et al., 2019; Siegiada et al., 2024). La composición del microbioma de fresa ha sido analizada mediante diferentes métodos, mediante el estudio masivo

del ADN microbiano directamente desde las muestras ambientales (Bolyen et al., 2019; Hall and Beiko, 2018). Particularmente, la secuenciación de regiones como 16S rRNA (bacterias) e ITS1 (hongos) ha permitido comenzar a caracterizar comunidades microbianas asociadas a distintos tejidos de la planta (raíces, tallos, hojas) y diferentes estados de salud (Yang et al., 2020; Siegieda et al., 2024).

La rizósfera constituye un entorno microbiano complejo que alberga una gran variedad de organismos con funciones clave en el desarrollo vegetal, incluyendo la mineralización de nutrientes, producción de hormonas, supresión de patógenos y estimulación de la inmunidad vegetal (Berendsen et al., 2012; Wang et al., 2022). Las comunidades microbianas no solo influyen en el crecimiento y rendimiento de los cultivos, sino que también pueden reflejar su estado de salud, lo cual hace posible identificar biomarcadores microbianos para clasificar plantas sanas y enfermas (Yang et al., 2020; Nam et al., 2023).

Estudios recientes han identificado diferencias taxonómicas significativas entre plantas de fresa sanas y enfermas. Por ejemplo, *Udaeobacter sp.*, *Solibacter sp.* y *Nitrosomonadaceae* son más abundantes en rizósferas no saludables, mientras que *Tepidisphaerales*, *Hydrocarboniphaga* y algunos géneros de *Pseudomonas* están relacionados con condiciones saludables (Nam et al., 2023; Siegieda et al., 2024). Estas diferencias en abundancia sugieren que ciertos microorganismos pueden actuar como indicadores microbianos del estado fisiológico de la planta.

El estudio de Yang et al. (2020), utilizando secuenciación de alto rendimiento, mostró que la infección por oídio inducía cambios significativos en la estructura y diversidad microbiana del suelo rizosférico de la fresa, incluyendo una reducción general de la riqueza microbiana. Esto refuerza la idea de que las alteraciones en el microbioma pueden estar asociadas con la aparición o progresión de enfermedades.

Además, diversas especies de bacterias y hongos han sido identificadas como patógenos relevantes en fresa, como *Colletotrichum sp.*, *Alternaria sp.*, *Botrytis cinerea* y *Dactylonectria sp.*. No obstante, también se han re-

portado microorganismos benéficos con potencial para ser utilizados como agentes de biocontrol (BCA) o rizobacterias promotoras del crecimiento (PGPR). Especies como *Bacillus subtilis*, *B. amyloliquefaciens*, *Pseudomonas monteilii*, *Mortierella sp.* y levaduras como *Rhodotorula* o *Trichoderma asperellum* han mostrado eficacia en la mejora de la salud de la planta y en la calidad de la fruta (Nam et al., 2023; Siegieda et al., 2024).

En conjunto, estos hallazgos destacan la importancia del análisis estadístico y bioinformático del microbioma rizosférico, tanto para la comprensión ecológica como para la aplicación biotecnológica en sistemas agrícolas sostenibles. A partir de estos estudios, se pueden desarrollar modelos predictivos y herramientas diagnósticas basadas en perfiles microbianos, útiles para monitorear la salud del cultivo, diseñar estrategias de manejo más eficientes, e incluso seleccionar microorganismos clave como bioinoculantes.

Los datos shotgun que utilizaremos en este estudio, son originales y fueron provistos por Solena, una empresa de biotecnología agrícola (AgTech) enfocada en el análisis y mejora del microbioma del suelo. Su misión es desarrollar soluciones innovadoras basadas en datos moleculares y biotecnología para optimizar la salud del suelo y, como consecuencia, aumentar la productividad agrícola. Aprovechando herramientas avanzadas como inteligencia artificial y genómica, Solena obtiene conocimientos profundos sobre la composición y funcionalidad del microbioma del suelo. Además, en colaboración con organizaciones locales, la empresa implementa centros de diagnóstico molecular agrícola, como el establecido en México, para evaluar la salud de los suelos y fomentar prácticas agrícolas regenerativas.

1.4. Clasificadores

1.4.1. Kraken & Braken

Kraken es una herramienta de clasificación de secuencias de ADN metagenómico mediante alineación exacta de k-mers, asignándoles etiquetas taxonómicas con gran exactitud y velocidad (Wood and Salzberg, 2014). Esta herramienta crea su base de datos de consulta a partir de una biblioteca de datos metagenómicos e información taxonómica de NCBI (National

Center for Biotechnology Information).

Kraken deja sin clasificar las secuencias que no tienen k-mers presentes en la base de datos precalculada.

La salida de Kraken consiste en una línea por cada read, que contiene 5 ítems separados por tabulaciones. En primer lugar, se indica si el read fue clasificado o no clasificado (C/U), seguido por el nombre del read (ID de la secuencia, el encabezado del archivo FASTA o FASTQ de entrada), la etiqueta taxonómica asignada por Kraken (0 si la secuencia no queda clasificada), la longitud de la secuencia en pares de bases (bp), y finalmente una lista delimitada por espacios que muestra el mapeo LCA (Lowest Common Ancestor) de cada k-mer de la secuencia (ID taxonómico : número de k-mers).

Para obtener el ID taxonómico completo, Kraken dispone de la herramienta `kraken_translate`, que, después de procesar los resultados con la misma base de datos, genera una lista de los reads junto con el nombre completo del ID taxonómico. Además, tiene una herramienta complementaria (`-mpa`), que presenta la salida ordenada por categoría taxonómica (`root_Super Kingdom`, `d_kingdom`, `p_phylum`, `c_class`, `o_order`, `f_family`, `g_genus`, `s_species`) (Wood and Salzberg, 2014; Lu et al., 2022).

BRACKEN (Bayesian Re-estimation of Abundance after Classification with **KraKEN**) calcula la abundancia de especies, géneros u otras categorías taxonómicas a partir de las secuencias de ADN recopiladas en un experimento de metagenómica (Lu et al., 2017).

BRACKEN realiza estimaciones probabilísticas basadas en las salidas de Kraken para completar las asignaciones al nivel taxonómico requerido, con el objetivo de obtener una estimación de abundancia más precisa. Este enfoque permite producir estimaciones fiables de abundancia a nivel de especie y género, incluso cuando una muestra contiene múltiples especies casi idénticas.

1.5. Lenguajes

1.5.1. BASH

Bash (Bourne Again SHell) es un intérprete de comandos y un lenguaje de scripting desarrollado para el sistema operativo Unix y sus derivados, como Linux. Creado en 1989 por Brian Fox, Bash permite automatizar tareas mediante scripts, lo que resulta particularmente útil en entornos de análisis bioinformático, donde se requiere manejar grandes volúmenes de datos. Aunque no está diseñado específicamente para análisis estadísticos o gráficos, Bash es fundamental para la gestión de flujos de trabajo y la integración de herramientas como BLAST, SAMtools y GATK. Se emplea para procesar datos en sistemas de alto rendimiento, administrar flujos de trabajo de análisis masivo y realizar manipulaciones rápidas de datos en formatos de texto o binarios.

1.5.2. R & RStudio

R es un lenguaje de programación y un entorno de software diseñado específicamente para el análisis estadístico y la visualización de datos. Desarrollado inicialmente por Ross Ihaka y Robert Gentleman en 1993, se ha convertido en una herramienta esencial en biología, ecología, genómica y otras disciplinas científicas que requieren análisis cuantitativos. Su principal fortaleza radica en la disponibilidad de bibliotecas especializadas, como ggplot2 para visualización y phyloseq para análisis de microbiomas, además de su comunidad activa, que contribuye con paquetes de código abierto. R se utiliza ampliamente en análisis de datos complejos, modelado estadístico, aprendizaje automático y visualización avanzada, facilitando la reproducibilidad y el manejo de grandes volúmenes de datos (R Core Team, 2023; Wickham, 2016).

RStudio es un entorno de desarrollo integrado (IDE) diseñado para trabajar con el lenguaje de programación R. Ofrece una interfaz intuitiva que facilita la escritura, ejecución y depuración de código, así como la visualización de resultados. RStudio permite organizar proyectos, gestionar paquetes y bibliotecas, y crear documentos reproducibles con R Markdown. También

es compatible con Shiny para aplicaciones interactivas. Disponible en versiones gratuitas y de pago, RStudio es ideal tanto para principiantes como para expertos en análisis de datos.

Phyloseq

Phyloseq es un software de código abierto diseñado para la manipulación y análisis integral de datos metagenómicos generados mediante tecnologías de secuenciación de alto rendimiento. Esta herramienta, desarrollada en R, ofrece capacidades para importar, almacenar, analizar y visualizar datos metagenómicos de manera eficiente. En el entorno de R, los datos se estructuran en un objeto Phyloseq, que tiene la versatilidad de contener elementos clave, como la tabla de taxonomía, la tabla de conteos, la tabla de muestras o metadatos, y el árbol filogenético. Esta organización multifacética facilita un análisis completo y preciso de la estructura de la comunidad microbiana, brindando una comprensión profunda de los datos metagenómicos. (McMurdie and Holmes, 2013)




Figura 1.2: Estructura del Objeto Phyloseq: Organización Integral de Datos Metagenómicos para Análisis de Diversidad Microbiana, que integra tablas de abundancia, datos taxonómicos, metadatos de las muestras y árboles filogenéticos. Este formato permite un análisis eficiente y completo de las comunidades microbianas.

1.6. Formatos

1.6.1. JSON

JSON (JavaScript Object Notation) es un formato de texto ligero para el intercambio de datos estructurados, representado como pares clave-valor u objetos anidados. En bioinformática, se utiliza comúnmente para almacenar metadatos y resultados jerarquizados debido a su compatibilidad con múltiples lenguajes de programación y su facilidad de lectura. Se emplea frecuentemente para guardar información de taxonomía, anotaciones funcionales o resultados de herramientas como QIIME 2, que lo usa para almacenar objetos complejos, como árboles filogenéticos y tablas de abundancia.

1.6.2. BIOM

El formato BIOM (Biological Observation Matrix) es un estándar binario utilizado en bioinformática para almacenar matrices de datos biológicos, especialmente en estudios de microbiomas. Facilita el almacenamiento eficiente de datos de abundancia y metadatos asociados, y es compatible con herramientas como QIIME y Phyloseq. El formato contiene tablas de abundancia con taxones como filas, muestras como columnas y valores numéricos que representan abundancias relativas o absolutas. Además, permite incluir metadatos sobre muestras y taxones, como información ambiental o taxonómica (McDonald et al., 2012).

1.6.3. FASTA

FASTA (Fast Alignment Search Tool-All) es un formato de texto plano que almacena secuencias de ADN, ARN o proteínas. Cada entrada contiene un encabezado (precedido por "`>`") seguido de una línea con la secuencia biológica. Es ampliamente utilizado para compartir datos genómicos y transcriptómicos.

FASTQ es un formato que extiende FASTA, añadiendo información sobre la calidad de cada nucleótido o aminoácido. Es fundamental para los

datos generados por plataformas de secuenciación de próxima generación (NGS). Cada entrada en FASTQ tiene cuatro líneas:

1. Un identificador de la secuencia.
2. La secuencia biológica.
3. Un separador "+".
4. Una línea con la puntuación de calidad (en formato ASCII).

El formato FASTQ y sus variantes se describen en Cock et al. (2010).

1.6.4. BAM

BAM (Binary Alignment/Map) es un formato binario utilizado para almacenar datos de alineamiento de secuencias genómicas. Es una versión comprimida y binaria del formato SAM (Sequence Alignment/Map), que es un formato de texto para almacenar los mismos datos. BAM es ampliamente utilizado en bioinformática, especialmente en análisis de datos de secuenciación de próxima generación (NGS), debido a su eficiencia en el almacenamiento y procesamiento de grandes volúmenes de datos.

Cada archivo BAM contiene información detallada sobre cómo las secuencias de ADN se alinean con una referencia genómica, incluyendo la posición de la secuencia en el genoma, la calidad del alineamiento, las secuencias de los nucleótidos y las puntuaciones de calidad. Dado que el formato BAM es binario, es más compacto y rápido de manejar en comparación con su contraparte en texto, SAM (Li et al., 2009).

1.7. Índices de Diversidad

Un índice de diversidad constituye una medida numérica empleada para cuantificar la variedad y la distribución de especies en una comunidad biológica o un ecosistema. Estos índices son herramientas matemáticas diseñadas para sintetizar y comparar la composición de especies en diversas comunidades (Magurran, 2021; Tuomisto, 2010a).

1.7.1. Diversidad Alfa

La diversidad alfa refleja la riqueza de las muestras, es decir, el número de especies distintas presentes en un determinado entorno, o la abundancia relativa de dichas especies en dicho entorno; es usada principalmente para medir la diversidad local, haciendo referencia a la diversidad dentro de una muestra o comunidad (Whittaker, 1960, 1972). Para cuantificar esta diversidad, se recurre a diversos índices de medida, cada uno con enfoques particulares.

En lo que sigue, para una muestra con p taxones se denota por x_i el número de lecturas asignadas al taxón i , por $N = \sum_{i=1}^p x_i$ la profundidad de secuenciación de la muestra y por $p_i = x_i/N$ la abundancia relativa del taxón i , de modo que $\sum_i p_i = 1$.

Chao1 es un estimador no paramétrico de la riqueza de especies, es decir, del número total de especies presentes en la comunidad, incluidas aquellas que no fueron observadas en la muestra (Chao, 1984, 1987). Se basa en la idea de que el número de especies raras observadas, las representadas por uno o dos individuos, contiene información sobre cuántas especies quedaron sin detectar. Por esta razón Chao1 es especialmente sensible a las especies raras y a la profundidad de secuenciación: una muestra con más lecturas tiende a detectar más especies con un solo individuo y, en consecuencia, a producir estimaciones de riqueza mayores.

La forma del estimador corregida por sesgo, que es la que calcula phyloseq, es:

$$S_{Chao1} = S_{obs} + \frac{F_1(F_1 - 1)}{2(F_2 + 1)} \quad (1.2)$$

Donde:

- S_{obs} es el número de especies observadas en la muestra.
- F_1 es el número de *singletons*, especies con exactamente un individuo (una lectura) en la muestra.
- F_2 es el número de *doubletons*, especies con exactamente dos individuos en la muestra.

Cuando $F_2 > 0$, la forma clásica $S_{obs} + F_1^2/(2F_2)$ produce valores muy cercanos; la forma corregida tiene la ventaja de estar definida también cuando no hay *doubletons*. En cualquier caso se cumple $S_{Chao1} \geq S_{obs}$, con

igualdad únicamente cuando no hay *singletons*. Así, Chao1 resulta útil para comparar la riqueza entre comunidades cuando la muestra es limitada o las especies raras tienen un papel importante, siempre que las muestras comparadas tengan profundidades de secuenciación semejantes.

El índice de **Shannon**, denotado por H , es la entropía de la distribución de abundancias relativas de la comunidad (Shannon, 1948). Mide la incertidumbre asociada con la identidad taxonómica de un individuo (una lectura) tomado al azar de la muestra, y por lo tanto tiene en cuenta tanto el número de especies como la uniformidad de sus abundancias. Se define como:

$$H = - \sum_{i=1}^S p_i \ln p_i \quad (1.3)$$

Donde:

- S es el número de taxones observados en la muestra.
- p_i es la abundancia relativa del taxón i , con la convención $0 \ln 0 = 0$ para los taxones ausentes.

El índice toma valores entre 0, cuando toda la comunidad pertenece a una sola especie, y $\ln S$, cuando las S especies son equiprobables. Un valor mayor de H indica mayor diversidad: más especies, una distribución más equitativa de los individuos entre ellas, o ambas cosas. Es menos sensible que Chao1 a las especies raras, porque estas aportan términos $p_i \ln p_i$ cercanos a cero.

Simpson. Sea

$$\lambda = \sum_{i=1}^S p_i^2 \quad (1.4)$$

la probabilidad de que dos individuos tomados al azar, con reemplazo, pertenezcan a la misma especie (Simpson, 1949). La cantidad λ es un índice de *dominancia*: se acerca a 1 cuando una o pocas especies concentran casi toda la abundancia y decrece cuando la abundancia se reparte de manera uniforme. A partir de λ se definen dos índices de diversidad, que crecen cuando la diversidad aumenta:

- El índice de Gini-Simpson, $D = 1 - \lambda$, que es la probabilidad de que dos individuos tomados al azar pertenezcan a especies distintas. Toma valores en $[0, 1 - 1/S]$.
- El inverso de Simpson, $D' = 1/\lambda$, que toma valores en $[1, S]$ y puede interpretarse como el número de especies equiprobables que producirían la misma dominancia.

En esta tesis se utiliza la primera forma, $D = 1 - \lambda$, que es la que calcula la función `estimate_richness` de `phyloseq` bajo el nombre “Simpson”. Por lo tanto, en todas las figuras un valor mayor del índice de Simpson corresponde a una mayor diversidad, del mismo modo que en Shannon y Chao1. Como λ pondera cada especie por el cuadrado de su abundancia relativa, este índice está dominado por las especies más abundantes y es el menos sensible de los tres a las especies raras.

En el contexto de la diversidad alfa, estos índices nos permiten explorar y comparar la diversidad de especies en cada muestra o subconjunto, como el grupo de muestras sanas y enfermas. Proporcionan una visión detallada de cómo se distribuye la diversidad de especies dentro de cada conjunto, permitiendo evaluaciones comparativas entre diferentes conjuntos o condiciones.

1.7.2. Diversidad Beta

La diversidad beta se encarga de evaluar cuán similares o diferentes son un par de especies, muestras, conjuntos de muestras o poblaciones entre sí. Fue definida por Whittaker como una medida del cambio de diversidad a través de gradientes ambientales, en otras palabras "tasa de cambio en la composición de especies de una comunidad a otra a lo largo de gradientes" (Whittaker, 1960). Para medir esta diversidad, se utilizan métricas como la disimilitud de Bray-Curtis, la distancia Jaccard o la distancia Uni-Frac.

A continuación se definen las medidas de disimilitud entre pares de muestras que se utilizan en este trabajo. Para dos muestras a y b se denota

por $x = (x_1, \dots, x_p)$ y $y = (y_1, \dots, y_p)$ sus vectores de abundancia sobre los mismos p taxones, ya sea en conteos o en abundancias relativas. Una función d es una *métrica* si es no negativa, simétrica, vale cero solo entre muestras iguales y cumple la desigualdad del triángulo $d(x, z) \leq d(x, y) + d(y, z)$. Varias de las medidas usadas en ecología no cumplen esta última propiedad, por lo que se las llama *disimilitudes* y no distancias; esto no impide usarlas en métodos de ordenación como NMDS (Kruskal, 1964), que solo requieren el orden de las disimilitudes (Legendre and Legendre, 2012).

La **disimilitud de Bray-Curtis** (Bray and Curtis, 1957) compara la composición de dos muestras ponderando cada taxón por su abundancia:

$$d_{BC}(x, y) = \frac{\sum_{i=1}^p |x_i - y_i|}{\sum_{i=1}^p (x_i + y_i)} \quad (1.5)$$

Toma valores en $[0, 1]$: vale 0 cuando las dos muestras tienen exactamente las mismas abundancias y 1 cuando no comparten ningún taxón. Cuando se calcula sobre abundancias relativas, el denominador es igual a 2 y la disimilitud se reduce a $d_{BC}(p, q) = \frac{1}{2} \sum_i |p_i - q_i|$, es decir, la mitad de la distancia de Manhattan entre los dos vectores de proporciones. Los taxones abundantes dominan el valor de d_{BC} , mientras que los taxones raros apenas contribuyen. Bray-Curtis es simétrica y vale cero solo entre muestras iguales, pero no cumple la desigualdad del triángulo, por lo que es una semimétrica.

La **disimilitud de Jaccard** (Jaccard, 1912) tiene dos versiones. La versión clásica se basa únicamente en la presencia o ausencia de taxones. Si A y B son los conjuntos de taxones presentes en cada muestra,

$$d_J(a, b) = 1 - \frac{|A \cap B|}{|A \cup B|} = 1 - \frac{S_{ab}}{S_a + S_b - S_{ab}} \quad (1.6)$$

donde S_{ab} es el número de taxones compartidos y S_a, S_b son los números totales de taxones presentes en cada muestra. Vale 0 cuando las dos muestras contienen los mismos taxones y 1 cuando no comparten ninguno; esta versión sí es una métrica. La versión cuantitativa, también llamada disimilitud de Ružička, incorpora las abundancias:

$$d_J^q(x, y) = \frac{\sum_{i=1}^p |x_i - y_i|}{\sum_{i=1}^p \max(x_i, y_i)} = \frac{2 d_{BC}(x, y)}{1 + d_{BC}(x, y)} \quad (1.7)$$

Esta es la versión que calculan phyloseq y vegan cuando se aplica el método “jaccard” sobre una tabla de abundancias sin binarizar, y es por lo tanto la que se utilizó en esta tesis. Como es una transformación monótona creciente de Bray-Curtis, ordena los pares de muestras exactamente igual que esta, por lo que las ordenaciones NMDS obtenidas con ambas medidas son muy parecidas.

La **distancia Euclidiana** es la distancia usual de $\mathbb{R}^p$ aplicada a los vectores de abundancia:

$$d_E(x, y) = \sqrt{\sum_{i=1}^p (x_i - y_i)^2} \quad (1.8)$$

Es una métrica (Legendre and Legendre, 2012). Al elevar al cuadrado las diferencias, los taxones muy abundantes dominan por completo su valor, y no está acotada superiormente por 1.

La **distancia de Manhattan** es la suma de las diferencias absolutas:

$$d_M(x, y) = \sum_{i=1}^p |x_i - y_i| \quad (1.9)$$

También es una métrica. Sobre abundancias relativas toma valores en $[0, 2]$ y, como se indicó arriba, coincide con el doble de la disimilitud de Bray-Curtis.

La **divergencia de Jensen-Shannon** compara dos muestras tratando sus abundancias relativas $P = (p_1, \dots, p_p)$ y $Q = (q_1, \dots, q_p)$ como distribuciones de probabilidad. Se construye a partir de la divergencia de Kullback-Leibler (Kullback and Leibler, 1951),

$$D_{KL}(P \parallel Q) = \sum_{i=1}^p p_i \ln \frac{p_i}{q_i}, \quad (1.10)$$

que no es simétrica y es infinita cuando algún taxón está presente en P y ausente en Q . Para evitar estos dos problemas se compara cada distribución

con la mezcla $M = \frac{1}{2}(P + Q)$:

$$JSD(P, Q) = \frac{1}{2}D_{KL}(P \parallel M) + \frac{1}{2}D_{KL}(Q \parallel M) \quad (1.11)$$

La divergencia de Jensen-Shannon (Lin, 1991) es simétrica, siempre finita y toma valores en $[0, \ln 2]$. No cumple la desigualdad del triángulo, pero su raíz cuadrada $\sqrt{JSD}$ sí es una métrica (Endres and Schindelin, 2003). El método “jsd” de phyloseq devuelve la divergencia JSD , sin raíz cuadrada, y esa es la cantidad que se utilizó en las ordenaciones de esta tesis.

La disimilitud **UniFrac** (Lozupone and Knight, 2008) incorpora las relaciones filogenéticas entre los taxones. Requiere un árbol filogenético con longitudes de rama en el que los taxones observados son las hojas. En su versión no ponderada, para cada rama r del árbol con longitud ℓ_r se define $I_r(a) = 1$ si la rama conduce a al menos un taxón presente en la muestra a y $I_r(a) = 0$ en caso contrario, y se calcula

$$d_{UF}(a, b) = \frac{\sum_r \ell_r |I_r(a) - I_r(b)|}{\sum_r \ell_r}, \quad (1.12)$$

es decir, la fracción de la longitud total del árbol que corresponde a ramas exclusivas de una de las dos muestras. La versión ponderada sustituye los indicadores por las abundancias relativas acumuladas bajo cada rama. UniFrac toma valores en $[0, 1]$ y considera más parecidas a dos muestras cuyos taxones, aunque distintos, sean filogenéticamente cercanos. En esta tesis no se utilizó UniFrac, porque la clasificación con Kraken proporciona una jerarquía taxonómica pero no un árbol filogenético con longitudes de rama.

Estas métricas ofrecen diferentes perspectivas sobre la similitud o disimilitud entre muestras, permitiendo seleccionar la más apropiada según el contexto del estudio y los objetivos específicos del análisis de diversidad beta.

1.8. Prueba de Hipótesis

Una hipótesis es una suposición sobre los datos que puede ser verdadera o falsa. Las pruebas de hipótesis son herramientas estadísticas esenciales

en diversos campos, ya que permiten contrastar una teoría con la evidencia empírica. A través de un proceso riguroso, estas pruebas ayudan a evaluar la veracidad de una afirmación científica de manera objetiva y fundamentada (Wackerly et al., 2002; Larsen and Marx, 2005).

Una prueba de hipótesis es un método estadístico utilizado para tomar decisiones sobre una población a partir de los datos obtenidos de una muestra representativa. Como técnica de inferencia estadística, permite evaluar suposiciones sobre los parámetros de una población basándose en la observación.

El propósito de una prueba estadística es examinar una hipótesis respecto a los valores de uno o más parámetros poblacionales. Para ello, se consideran los siguientes componentes clave:

Hipótesis nula (H_0): Es la idea inicial, la suposición que se pone a prueba. Representa la creencia de que no hay diferencia o efecto significativo. (Pretencion que inicialmente sesupone cierta)

Hipótesis alternativa (H_1): Es la contrapropuesta, lo que se espera encontrar si la H_0 es falsa. Representa la alternativa que se busca demostrar. (hipotesis contradictoria a la hipotesis nula)

Estadístico de prueba: Es la herramienta matemática (funcionde las mediciones muestrales) que utilizamos para analizar los datos y determinar si apoyan o no la H_1 . Cada prueba estadística tiene su propio estadístico específico.

Región de rechazo: Es una zona predefinida como territorio prohibido para la H_0 . Si el valor del estadístico de prueba cae en esta región, la H_0 se rechaza por considerarse poco probable. (x es el valor critico observado, el cual define la region de rechazo)(una hipotesis nula sera rechazada si y solo si el valor estadistico de prueba observado o calculado, queda en la region de rechazo)

P-valor: Es la probabilidad de obtener un valor del estadístico de prue-

ba tan extremo o más extremo que el observado, suponiendo que la H_0 sea verdadera. Un valor de p bajo (menor que el nivel de significancia α el cual se fija previamente) indica que es poco probable que el resultado se deba al azar, lo que lleva al rechazo de la H_0 .

El objetivo principal de una prueba de hipótesis es evaluar si la evidencia muestral es lo suficientemente fuerte como para rechazar H_0 . La hipótesis nula será rechazada a favor de la hipótesis alternativa solo si la evidencia muestral sugiere que H_0 es falsa. Si la muestra no contradice a H_0 , se continuará creyendo en la veracidad de la hipótesis nula. (rechazar o no rechazar H_0).

En este contexto, el p -valor se considera como una medida de la probabilidad de obtener un resultado específico en un estudio estadístico con los datos observados. Su cálculo depende de la prueba estadística utilizada y de las suposiciones realizadas sobre la distribución de los datos. En general, un valor pequeño del p -valor sugiere que los datos observados son poco probables bajo la hipótesis nula, lo que sugiere que H_0 podría ser falsa.

Existen dos tipos de errores que pueden ocurrir en una prueba de hipótesis:

Error tipo I (α): Ocurre cuando se rechaza H_0 siendo en realidad verdadera.

Error tipo II (β): Se produce cuando no se rechaza H_0 cuando en realidad es falsa.

El balance entre estos errores es fundamental en el diseño de pruebas estadísticas (Larsen and Marx, 2005). En el contexto de datos de microbioma, Xia and Sun (2017) revisan las pruebas de hipótesis de uso más frecuente.

Las pruebas de hipótesis pueden aplicarse a diferentes contextos, como la comparación de grupos en estudios médicos o científicos. Por ejemplo, en un análisis sobre la salud de los cultivos, se podrían definir las siguientes hipótesis:

H_0 : No hay diferencias entre muestras de cultivos saludables y no saludables.

H_1 : Existen diferencias significativas entre las muestras de cultivos saludables y no saludables.




Figura 1.3: Se ilustra el concepto esencial de una prueba de hipótesis, mostrando la distribución teórica de la estadística de prueba bajo la hipótesis nula (H_0) y destacando la región de rechazo. La posición del dato observado con respecto a esta región determinará si se rechaza o no H_0 en cada una de las pruebas estadísticas a realizar.

En una prueba de hipótesis, la hipótesis nula (H_0) será rechazada en favor de la hipótesis alternativa (H_1) solo si la evidencia muestral proporciona suficiente soporte para considerar que H_0 es falsa. Si los datos no contradicen significativamente a H_0 , se concluye que no hay suficiente evidencia para rechazarla, y se mantiene su validez.

1.8.1. Prueba t para comparar dos medias poblacionales (muestras pequeñas)

Sean $Y_{11}, \dots, Y_{1n_1}$ y $Y_{21}, \dots, Y_{2n_2}$ dos muestras aleatorias independientes de poblaciones normales, $N(\mu_1, \sigma_1^2)$ y $N(\mu_2, \sigma_2^2)$ respectivamente. Se denota por $\bar{Y}_k$ y S_k^2 la media y la varianza muestral de la muestra k . Se desea contrastar

$$H_0 : \mu_1 = \mu_2 \quad \text{frente a} \quad H_1 : \mu_1 \neq \mu_2. \quad (1.13)$$

Caso de varianzas iguales. Si se supone $\sigma_1^2 = \sigma_2^2$, la varianza común se estima con la varianza combinada

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2} \quad (1.14)$$

y el estadístico de prueba es

$$T = \frac{\bar{Y}_1 - \bar{Y}_2}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \quad (1.15)$$

que bajo H_0 sigue una distribución t de Student con $\nu = n_1 + n_2 - 2$ grados de libertad (Wackerly et al., 2002). La región de rechazo al nivel α es $|T| > t_{\alpha/2, \nu}$, donde $t_{\alpha/2, \nu}$ es el cuantil que deja probabilidad $\alpha/2$ en la cola superior, y el p-valor es $2P(t_\nu \geq |t_{obs}|)$.

Caso de varianzas distintas (prueba de Welch). Si no puede suponerse $\sigma_1^2 = \sigma_2^2$, se utiliza el estadístico propuesto por Welch (1947)

$$T' = \frac{\bar{Y}_1 - \bar{Y}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}} \quad (1.16)$$

cuya distribución bajo H_0 se aproxima por una t de Student con grados de libertad dados por la aproximación de Welch-Satterthwaite,

$$\nu' = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}, \quad (1.17)$$

que en general no es un entero y satisface $\min(n_1, n_2) - 1 \leq \nu' \leq n_1 + n_2 - 2$. La región de rechazo y el p-valor se calculan como en el caso anterior, con ν' en lugar de ν . Esta es la versión que la función `t.test` de R aplica por defecto, y es la que se reporta en el Capítulo 4 bajo el nombre “varianzas diferentes”.

1.8.2. Prueba F sobre las varianzas de dos poblaciones pequeñas

Con las mismas hipótesis de normalidad e independencia, se desea contrastar

$$H_0 : \sigma_1^2 = \sigma_2^2 \quad \text{frente a} \quad H_1 : \sigma_1^2 \neq \sigma_2^2 \quad (1.18)$$

mediante el cociente de varianzas muestrales

$$F = \frac{S_1^2}{S_2^2}, \quad (1.19)$$

que bajo H_0 sigue una distribución F de Fisher con $n_1 - 1$ grados de libertad en el numerador y $n_2 - 1$ en el denominador. La región de rechazo al nivel α es $F < F_{1-\alpha/2, n_1-1, n_2-1}$ o $F > F_{\alpha/2, n_1-1, n_2-1}$. El resultado de esta prueba se usa para decidir entre el estadístico (1.15) y el estadístico (1.16). Debe tenerse en cuenta que la prueba F es sensible a desviaciones de la normalidad, por lo que su resultado es menos confiable cuando ese supuesto no se verifica.

1.8.3. Prueba de suma de rangos de Wilcoxon (Mann-Whitney)

Cuando no puede suponerse que los datos provienen de poblaciones normales, se recurre a pruebas no paramétricas basadas en rangos. Conviene distinguir dos pruebas que llevan el nombre de Wilcoxon: la prueba de *rangos con signo*, que compara dos muestras relacionadas o pareadas, y la prueba de *suma de rangos*, equivalente a la prueba U de Mann-Whitney (Wilcoxon, 1945; Mann and Whitney, 1947), que compara dos muestras independientes. En esta tesis los grupos de plantas saludables y no saludables son independientes, por lo que se utiliza la segunda.

Sean $X_1, \dots, X_{n_1}$ y $Y_1, \dots, Y_{n_2}$ dos muestras independientes de poblaciones con funciones de distribución continuas F_X y F_Y . La hipótesis nula es que ambas distribuciones son iguales, $H_0 : F_X = F_Y$, frente a la alternativa de que una de ellas tiende a producir valores mayores que la otra. Se ordenan conjuntamente las $n_1 + n_2$ observaciones y se asigna a cada una su rango; si R_1 es la suma de los rangos de la primera muestra, el estadístico de Mann-Whitney es

$$U = R_1 - \frac{n_1(n_1 + 1)}{2} = \#\{(i, j) : X_i > Y_j\}, \quad (1.20)$$

es decir, el número de pares en los que la observación de la primera muestra supera a la de la segunda (los empates cuentan como medio par). Bajo H_0 , U tiene distribución conocida, con $E(U) = n_1 n_2 / 2$ y $\text{Var}(U) =$

$n_1 n_2 (n_1 + n_2 + 1) / 12$, y para muestras moderadas se aproxima por una distribución normal (Wilcox, 2010). La función `wilcox.test` de R reporta este estadístico con el nombre W .

La prueba solo requiere que las observaciones sean independientes y medidas al menos en escala ordinal, y no supone normalidad. Sin embargo, para interpretar el rechazo de H_0 como una diferencia de medianas, o el intervalo de confianza que acompaña a la prueba como una estimación del desplazamiento entre grupos, se necesita suponer que ambas distribuciones tienen la misma forma y difieren únicamente por una traslación. Sin ese supuesto, un resultado significativo indica solamente que $P(X > Y) \neq 1/2$.

1.9. Normalización y Rarefacción

1.9.1. Normalización

La función `edgeRnorm` escala los conteos con el método TMM (*trimmed mean of M-values*) del paquete `edgeR` (Robinson et al., 2010; Robinson and Oshlack, 2010). Toma un objeto `phyloseq` y devuelve otro cuya tabla de conteos ha sido transformada (McMurdie and Holmes, 2014).

1.9.2. Rarefacción

La rarefacción es una técnica de normalización usada en el preprocesamiento de datos, para equilibrar el tamaño de las muestras en un conjunto de datos. Esta implica un submuestreo aleatorio de secuencias hasta una profundidad común (Hurlbert, 1971); su uso como método de normalización ha sido criticado por descartar datos válidos (McMurdie and Holmes, 2014).

1.10. Redes Bayesianas

Una red bayesiana es un grafo acíclico dirigido (DAG) $G = (V, E)$ en el que cada nodo representa una variable aleatoria y cada arco una dependencia condicional directa (Pearl, 1988; Koller and Friedman, 2009). La distribución conjunta se factoriza como el producto de las distribuciones

condicionales de cada nodo dados sus padres (Ecuación 6.1 del Capítulo 6). En R, el paquete `bnlearn` implementa el aprendizaje de la estructura y de los parámetros (Scutari, 2010).

Capítulo 2

objetivos

2.1. Objetivo general

Caracterizar y comparar la composición y diversidad del microbioma rizosférico de plantas de fresa saludables y no saludables mediante el análisis estadístico de datos metagenómicos, con el fin de identificar patrones asociados con el estado de salud de las plantas.

2.2. Objetivos específicos

1. Caracterizar la composición taxonómica y la diversidad microbiana de las muestras de rizósfera de plantas saludables y no saludables, mediante métricas de diversidad alfa y beta a diferentes niveles taxonómicos.
2. Evaluar estadísticamente las diferencias entre los microbiomas de plantas saludables y no saludables, utilizando pruebas de hipótesis y métodos de normalización apropiados para los datos metagenómicos.
3. Identificar patrones taxonómicos y de estructura de la comunidad microbiana asociados con el estado de salud de las plantas, explorando taxones diferenciales y las relaciones entre los microorganismos.

|

Capítulo 3

Análisis Exploratorio de Datos, metodología

El propósito de este análisis es identificar características diferenciadoras entre los microbiomas de plantas sanas y enfermas mediante el uso de datos metagenómicos. Para ello, se obtuvieron datos de microorganismos presentes en cultivos de fresa, proporcionados por la empresa Solena (véase sección ??). Las muestras se dividieron en dos grupos: las etiquetadas como "sanas" y las etiquetadas como "enfermas".

En la primera etapa, se realizó un proceso exhaustivo de preprocesamiento de los datos utilizando lenguajes de programación como BASH y R. Luego, el análisis exploratorio se estructuró en tres partes principales. Primero, se exploraron las diversidades alfa y beta, seguidas de un análisis estadístico respaldado por pruebas de hipótesis. En segundo lugar, se visualizó la correlación entre variables a través de redes.

Este enfoque integral no solo proporciona una comprensión detallada de la composición de los microbiomas en las plantas de fresa, sino que también permite identificar patrones significativos en las diferencias de presencia-ausencia o abundancia de microorganismos, que podrían ser fundamentales para distinguir entre la salud y la enfermedad en estos cultivos (Yang et al., 2020).

3.1. Métodos para caracterización de la diversidad microbiana

3.1.1. Preprocesamiento

Dentro de las etapas principales del análisis, se encuentra la adquisición de datos. En este caso se adquirió un conjunto de datos metagenómicos de cultivos de fresa proporcionados por Solena. Estas secuencias se entregaron en formato FASTA y se encuentran almacenadas en archivos JSON, los cuales contienen los resultados de la clasificación metagenómica realizada mediante el clasificador Kraken (Wood and Salzberg, 2014). Con el objetivo de identificar características distintivas entre los frutos sanos y enfermos, se ha llevado a cabo un análisis exploratorio detallado de estos datos.




Figura 3.1: Flujo de Trabajo para el Análisis Metagenómico de Microbiomas en Cultivos de Fresa: Desde la Recolección de Datos hasta la Interpretación de Resultados.

Dentro de este preprocesamiento es necesario realizar una limpieza y transformación de los datos para que estos sean adecuados para el análisis. En este caso se realizó un cambio de formato a objeto BIOM (McDonald et al., 2012) con la herramienta kraken-biom (Dabdoub, 2016), para un mejor manejo de los datos; luego fue necesario renombrar columnas, agregar los metadatos y realizar un filtro de calidad.

Para iniciar el análisis de estos datos, llevamos a cabo una exploración general utilizando índices ecológicos, especialmente centrándonos en las diversidades alfa y beta.

Se importaron los datos como un objeto phyloseq (McMurdie and Holmes, 2013), que puede incluir cuatro componentes: la matriz de abundancias, la tabla de taxonomía, los metadatos y el árbol filogenético. Este enfoque nos permite obtener una comprensión más profunda de la estructura de la comunidad microbiana presente en los datos metagenómicos, empleando medidas de diversidad para evaluar la variabilidad intra e inter-muestral. A continuación se listan las muestras utilizadas.

sample_sums(fresa_kraken)

MD2055	MD2056	MD2065	MD2066	MD2075	MD2076	MD2085	MD2086
9782432	12468526	11297600	15580959	12310781	16067839	10524919	9931297
MD2095	MD2096	MD2105	MD2106	MD2115	MD2116	MD2125	MD2126
18009912	14998268	11792397	4053295	13102554	12451637	8355853	14307309
MD2135	MD2136	MP2047	MP2048	MP2049	MP2050	MP2057	MP2058
7280751	6172369	9199079	12146967	13075806	16098757	17141427	20923502
MP2059	MP2060	MP2067	MP2068	MP2069	MP2070	MP2077	MP2078
14129981	13786630	16924218	20873789	15537530	12462356	9617847	7588787
MP2079	MP2080	MP2087	MP2088	MP2089	MP2090	MP2097	MP2098
745830	3125701	20632320	2	16582404	11176782	11714000	16595897
MP2099	MP2100	MP2107	MP2108	MP2109	MP2110	MP2117	MP2118
14844038	13342326	11014462	6728020	1405462	6901265	12624002	14711376
MP2119	MP2120	MP2127	MP2128	MP2129	MP2130	MP2137	MP2138
9835326	10975712	7106567	9974861	8348307	6196725	2169734	8220431
MP2139	MP2140						
6158581	5267510						

3.1.2. Filtrado de Calidad

A través de Solena, obtuvimos una tabla generada con fastp (Chen et al., 2018) que refleja la calidad de las muestras (fastp.kraken.summary). Esta información es crucial para determinar qué muestras pueden ser eliminadas de nuestro conjunto de datos, ya que no cumplen con ciertos estándares de calidad. La identificación y exclusión de muestras que no cumplen con estos criterios contribuirá a asegurar la integridad y la confiabilidad de nuestro dataset, garantizando que solo las muestras de alta calidad sean consideradas en el análisis subsiguiente. El criterio para eliminar muestras es que,

después del filtrado de calidad, contengan menos de 25 millones de lecturas. Como ejemplo, la muestra MD2055 inicialmente tiene 97 millones de lecturas antes del filtrado, y después del análisis de calidad queda con 79 millones.

Esta tabla proporciona información detallada sobre la calidad de las muestras, destacando diversos parámetros clave:

- **ID de la muestra:** Identificación única de la muestra.
- **Reads_B (Reads_Before):** Número total de lecturas crudas antes del análisis de calidad.
- **Reads_A (Reads_After):** Número total de lecturas después del análisis de calidad.
- **Reads_diff:** Diferencia entre Reads_B y Reads_A.
- **Q30_B:** Porcentaje de lecturas con calidad superior a 30 (escala fred) antes del análisis de calidad.
- **Q30_A:** Porcentaje de lecturas con calidad superior a 30 después del análisis de calidad.
- **LowQua:** Lecturas de baja calidad.
- **N_reads:** Lecturas que contienen 'N' y son descartadas.
- **too_short:** Lecturas que no cumplen con el tamaño mínimo de calidad.
- **Duplication:** Porcentaje de duplicados.
- **LengthR1:** Longitud promedio de las lecturas en la muestra.
- **LengthR2:** Longitud promedio de las lecturas en la muestra.
- **Classified:** Porcentaje de lecturas clasificadas del total después del filtrado.

Este enfoque de eliminación se basa en mantener un umbral mínimo de calidad, contribuyendo así a garantizar la robustez y confiabilidad de las muestras seleccionadas para análisis subsiguientes. Además, se puede realizar un recuento de lecturas por muestra para evaluar la calidad relativa entre las diferentes muestras. La eliminación de muestras con un conteo bajo es crucial para garantizar la integridad y la confiabilidad de los resultados del análisis. Al eliminar muestras con datos insuficientes, se mejora la calidad general del conjunto de datos y se evitan posibles distorsiones o sesgos que podrían surgir debido a la falta de información significativa. Este enfoque de eliminación selectiva respalda la robustez del análisis de datos metagenómicos, permitiendo una interpretación más precisa y confiable de la diversidad microbiana en las muestras restantes.

3.1.3. Índices de diversidad

Aplicamos índices de diversidad alfa para comprender la estructura de la distribución de la abundancia relativa de las especies en el seno de una población o comunidad biológica. En este contexto, realizamos un análisis de diversidad de nuestras muestras, empleando dos métricas fundamentales: la Diversidad Alfa y la Diversidad Beta (Tuomisto, 2010b). Estas métricas nos permitirán explorar y comprender tanto la variabilidad interna de una sola comunidad como las diferencias entre varias comunidades, respectivamente.

Diversidad Alfa

Para explorar la diversidad alfa de las muestras utilizamos los índices Chao1, Shannon y Simpson, descritos en la Sección 1.7.1, ya que en conjunto capturan tanto la riqueza de especies como su abundancia y dominancia relativa.

Los índices se calcularon con las funciones `estimate_richness` y `plot_richness` del paquete `Phyloseq`, aplicadas sobre el objeto `fresa_kraken` tanto en los datos crudos como en los datos con filtro de calidad, agrupando y coloreando las muestras según el tratamiento (sana o enferma) para poder comparar visualmente ambos grupos.

```

index = estimate_richness(fresa_kraken_fil)
plot_richness(physeq = fresa_kraken_fil,
              measures = c("Observed", "Chao1", "Shannon", "Simpson"),
              x = "Treatment", color = "Treatment")

```

Diversidad Beta

La diversidad beta se encarga de evaluar cuán similares o diferentes son un par de especies, muestras, conjuntos de muestras o poblaciones entre sí. Fue definida por Whittaker como una medida del cambio de diversidad a través de gradientes ambientales, en otras palabras "tasa de cambio en la composición de especies de una comunidad a otra a lo largo de gradientes" (Whittaker, 1960). Para medir esta diversidad, se utilizan métricas como la disimilitud de Bray-Curtis, la distancia Jaccard o la distancia Uni-Frac.

Antes de realizar análisis de diversidad beta, es crucial convertir las abundancias absolutas (número de lecturas por OTU) a relativas (porcentajes de lecturas asignadas a un OTU dentro de una muestra). Esta transformación es esencial debido a que los metagenomas tienen tamaños diferentes. Se lleva a cabo el cálculo de las abundancias relativas utilizando la función 'transform_sample' de Phyloseq, tanto para los datos originales como para los datos filtrados.

Este paso es fundamental para garantizar una comparación y evaluación adecuada de la diversidad beta, ya que las abundancias relativas proporcionan una representación más precisa de la estructura de la comunidad, independientemente de las diferencias en el tamaño del metagenoma entre las muestras.

```

transform_sample_counts(fresa_kraken_fil,
function(x) x*100/sum(x) )

```

Usamos "ordinate" para asignar las distancias entre muestras, iniciando y tomando como referencia "Bray-Curtis", ya que es una de las métricas más completas y mayormente utilizadas para medir la diversidad beta.

Para visualizar y presentar los resultados de este análisis, se opta por el uso de NMDS (Non-metric Multidimensional Scaling; Kruskal, 1964), una herramienta de análisis exploratorio de datos que se emplea para visualizar la similitud o disimilitud entre una colección de objetos (por ejemplo, especies, sitios, genes) en un espacio de baja dimensionalidad. Entre otros, se utilizan ampliamente los análisis PCA, PCoA (Gower, 1966) o NMDS.

Tomando los datos con filtro de calidad y utilizando la distancia de Jaccard, la cual es la más comúnmente utilizada en este tipo de estudios, se observa que las muestras, tanto sanas como enfermas, están bastante mezcladas. Ante esta observación, se procede a realizar pruebas con distintas distancias para explorar si alguna otra métrica puede proporcionar una separación más clara o revelar patrones específicos en la composición de especies entre las muestras.

Estas métricas ofrecen diferentes perspectivas sobre la similitud o disimilitud entre muestras, permitiendo seleccionar la más apropiada según el contexto del estudio y los objetivos específicos del análisis de diversidad beta.

Aplicamos la siguiente lista de distancias disponibles en Phyloseq : **Disimilitud de Bray-Curtis, Distancia Jaccard, Euclidean, Manhattan, Divergencia de Jensen-Shannon (JSD)**, y la métrica de **UniFrac**

3.1.4. Exploración a distintos niveles taxonómicos

Podemos visualizar las barras de abundancia absolutas y relativas de nuestros datos representando las muestras en el eje x y las abundancias en el eje y, diferenciando entre muestras sanas y enfermas.

3.2. Prueba de Hipótesis

En este estudio se busca contrastar si existen diferencias de diversidad, medidas a través del índice de Shannon, entre las muestras saludables y no saludables, tanto a nivel general de la comunidad microbiana como a nivel

de género dentro de los eucariotas. Las definiciones formales de H_0 , H_1 , el estadístico de prueba, la región de rechazo y el p-valor se presentaron en el Capítulo 1, Sección 1.8, por lo que aquí no se redefinen y solo se retoman para su aplicación directa sobre los datos.

Todas las pruebas se realizaron con un nivel de significancia $\alpha = 0,05$, utilizando el lenguaje R (R Core Team, 2023) y las funciones `t.test`, `var.test` y `wilcox.test`. Antes de aplicar la prueba t se verificó el supuesto de homogeneidad de varianzas mediante la prueba F; cuando este supuesto o el de normalidad no se cumplieron, se optó por la alternativa no paramétrica de Wilcoxon-Mann-Whitney.

3.2.1. Prueba t de Student sobre el índice de Shannon

Se contrasta la hipótesis nula

$$H_0 : \mu_{\text{saludable}} = \mu_{\text{no saludable}} \quad (3.1)$$

frente a la alternativa $H_1 : \mu_{\text{saludable}} \neq \mu_{\text{no saludable}}$, usando el estadístico T definido en la Ecuación 1.15. Esta prueba se aplicó en dos escenarios: (a) sobre el índice de Shannon calculado a nivel general de la comunidad microbiana, y (b) sobre el índice de Shannon calculado a nivel de género dentro de los eucariotas, grupo que incluye a los hongos fitopatógenos de interés como *Fusarium*.

3.2.2. Prueba F sobre las varianzas

Antes de decidir la forma del estadístico T (varianzas iguales o distintas) es necesario verificar el supuesto de homogeneidad de varianzas entre los dos grupos. Para ello se aplicó la prueba F, contrastando $H_0 : \sigma_1^2 = \sigma_2^2$ frente a $H_1 : \sigma_1^2 \neq \sigma_2^2$. El resultado de esta prueba determina si la prueba t del apartado anterior debe calcularse asumiendo varianzas iguales o varianzas diferentes.

3.2.3. Prueba de Wilcoxon-Mann-Whitney

Cuando el supuesto de normalidad de los datos no se cumple, la prueba t deja de ser apropiada y se recurre a su alternativa no paramétrica: la

prueba de suma de rangos de Wilcoxon-Mann-Whitney (Mann and Whitney, 1947), que compara las distribuciones del índice de Shannon entre los grupos saludable y no saludable sin asumir normalidad.

Los resultados obtenidos al aplicar estas tres pruebas sobre los datos se presentan en el Capítulo 4.

3.2.4. Análisis complementarios

La normalidad del índice de Shannon en cada grupo se verificó con la prueba de Shapiro-Wilk (Shapiro and Wilk, 1965). Para contrastar si la composición global de la comunidad difiere entre grupos se aplicó un análisis de varianza multivariado por permutaciones (PERMANOVA; Anderson, 2001; Anderson et al., 2011) sobre la matriz de disimilitud de Bray-Curtis de las abundancias relativas, con 999 permutaciones, mediante la función `adonis2` del paquete `vegan` (Oksanen et al., 2022). Finalmente, se calcularon el tamaño del efecto estandarizado (d de Cohen) y la potencia de la prueba t con la función `power.t.test` (Cohen, 1988; Xia et al., 2018).

3.2.5. Normalización

Desde un punto de vista matemático, los datos metagenómicos pueden representarse como una matriz de conteos:

$$X = (x_{ij}) \in \mathbb{N}^{n \times p} \quad (3.2)$$

donde:

- n es el número de muestras,
- p el número de taxones,
- x_{ij} el número de lecturas asignadas al taxón j en la muestra i .

Debido a que las muestras presentan distinta profundidad de secuenciación, se emplean abundancias relativas:

$$a_{ij} = \frac{x_{ij}}{\sum_{k=1}^p x_{ik}}, \quad \sum_{j=1}^p a_{ij} = 1. \quad (3.3)$$

Estas pertenecen al simplex composicional:

$$S^{p-1} = \left\{ x \in \mathbb{R}_+^p : \sum_{j=1}^p x_j = 1 \right\}. \quad (3.4)$$

La función `edgeRnorm` escala los conteos con el método TMM del paquete `edgeR` (Robinson et al., 2010; Robinson and Oshlack, 2010). Toma un objeto `phyloseq` y devuelve otro cuya tabla de conteos ha sido transformada (McMurdie and Holmes, 2014).

3.2.6. Rarefacción

La rarefacción es una tecnica de normalización usada en el preprocesamiento de datos, para equilibrar el tamaño de las muestras en un conjunto de datos. Esta implica un submuestreo aleatorio de secuencias hasta una profundidad común (Hurlbert, 1971; McMurdie and Holmes, 2014).

Rarefy

Se eliminaron 670 OTUs

3.3. Rarefacción

La rarefacción se usa como una medida de saturacion de muestras, es decir,

3.4. Redes

Para poder visualizar las redes de nuestros datos, podemos hacer un `data.frame` uniendo toda la informacion del objeto `phyloseq`.

```
df <- psmelt(fresa_kraken_fil)
```

Hay dos funciones en el paquete `phyloseq` para trazar la red del microbioma usando “`ggplot2`”: `plot_network()` y `plot_net()`. Se crea un grafo basado en `igraph` (Csardi and Nepusz, 2006), basado en el método de distancia por defecto, Jaccard y una distancia máxima entre nodos conectados de 0,8. El

“Treatment” se utiliza para los mapeos de color y forma para visualizar la estructura de las muestras.

Hacemos un grafo a partir de el objeto phyloseq

```
ig <- make_network(fresa_kraken_fil , max.dist=0.8)
```

Y luego lo graficamos.

```
plot_network(ig , fresa_kraken_fil , color="Treatment" , shape="
```

INSERTAR AQUI IMAGEN DEL GRAFO

En este grafo podemos ver la complejidad de los datos y las conexiones entre nuestras muestras.

En comparacion con la función `plot_network()`, la nueva función `plot_net()` no requiere una llamada separada a la función `make_network()`, o un objeto `igraph` separado. Los siguientes códigos crean una red basada en una distancia máxima entre los nodos conectados de 0,5.

```
plot_net(fresa_kraken_fil , maxdist = 0.5 , color = "Treatment "
```

INSERTAR AQUI IMAGEN DEL GRAFO

En conclusion para esta observación general de los datos, no es posible ver una separacion entre muestras sanas y enfermas claramente con la diversidad beta, y con los graficos de barras y redes, no es posible identificar datos especiales.

PONER GRAFOS Y DATOS DE REDES HECHAS CON FONTY

Luego de una breve visualizacion de redes simples, tenemos dos opciones para utilizar ls redes de coocurrencia

El analisis de co-ocurrencia utiliza la matriz de interacciones (Berry and Widder, 2014). Redes de co-ocurrencia - El total de nodos de la red es el numero de OTU's en una tabla; se quiere ver las relaciones entre nodos. Las aristas representan co-ocurrencia entre de nodos.

MicNet - Microbial Network (Favila et al., 2022) Esta herramienta nos pide un documento BIOM (la tabla de abundancias) en formato .csv para poder entregar las matriz de correlaciones usando normalizacion de Dirichlet, esta herramienta se divide en tres: UMAP (McInnes et al., 2018) - Cluster - Este algoritmo permite ver los datos en el plano. SparCC (Fried-

man and Alm, 2012) - Matriz de correlación Network - pide los dos anteriores y genera la red completa

Redes en Alnitak Esta herramienta calcula los vecinos de un taxon específico contra el resto de los taxones, midiendo el taxon de interes con dos metricas diferentes. Aqui pide el documento BIOM cortado por nivel taxonomico del taxon escojido, junto con el TaxID del mismo; entregando una matriz de correlaciones filtrada por el taxon de interes, que solo reporta las correlaciones con el taxon escojido al nivel taxonomico tomado, que pasen los umbrales de correlacion mayor a un 0.7 y disimilitud de bray curis menor a un 0.3. Asi la primera red creada con esta herramienta es tomando Fusarium a nivel de genero, ya que como se vio anteriormente es un genero importante entre los datos de Eucariota...

3.5. Redes bayesianas

fundamentos teóricos utilizados para modelar la estructura de dependencia probabilística entre el género fúngico *Fusarium*, el Índice de Shannon (como métrica de diversidad alfa) y los taxones microbianos más abundantes en muestras de fresa. El análisis se basa en Redes Bayesianas (BN), una herramienta de modelado gráfico que permite inferir relaciones direccionales y condicionales (Pearl, 1988; Scutari, 2010). La robustez de los hallazgos se garantiza mediante la aplicación de técnicas avanzadas de validación, incluyendo Bootstrapping y Validación Cruzada K-fold,

3.6. Rs

Se obtuvo un nuevo conjunto de datos complementario, el cual se divide en cinco categorias, respecto al tipo de cultivo de las fresas,

Capítulo 4

Resultados

En este capítulo se presentan los resultados del análisis descrito en el Capítulo 3, organizados según los tres objetivos específicos planteados en el Capítulo 2. La Sección 4.1 caracteriza la composición y la diversidad del microbioma rizosférico de plantas de fresa saludables y no saludables, primero sobre la comunidad completa y después por reino y por nivel taxonómico. La Sección 4.2 contrasta estadísticamente las diferencias observadas y evalúa la potencia del diseño. La Sección 4.3 reúne los patrones taxonómicos y de estructura de la comunidad asociados con el estado de salud de la planta. En todo el capítulo se usan los términos *saludable* y *no saludable* para los dos grupos, que en los datos originales aparecen como **healthy** y **wilted** (planta marchita).

4.1. Caracterización de la composición taxonómica y la diversidad microbiana

4.1.1. Preprocesamiento y filtro de calidad

El conjunto de datos original comprendía 58 metagenomas, 40 de plantas saludables y 18 de plantas no saludables. Antes de calcular cualquier medida de diversidad se revisó la tabla de control de calidad de cada muestra, que reporta el número de lecturas antes y después del filtrado con fastp, la proporción de bases con calidad Phred superior a 30 y el porcentaje de lecturas clasificadas por Kraken. Se estableció como criterio de exclusión

un mínimo de 25 millones de lecturas después del filtrado de calidad. Cinco muestras, todas del grupo saludable, no cumplieron el criterio y fueron eliminadas: MP2079, MP2080, MP2088, MP2109 y MP2137. El caso extremo es MP2088, que conservó únicamente dos lecturas tras el filtrado; una muestra así no aporta información sobre la comunidad y, como se muestra a continuación, distorsiona la escala de todos los índices.

Tras el filtro quedaron 53 muestras para el análisis: 35 saludables y 18 no saludables. La Figura 4.1 compara la diversidad alfa antes y después del filtro. En los datos crudos (panel A) las cinco muestras de baja calidad comprimen la escala de los cuatro índices, de modo que ambos grupos parecen indistinguibles. En los datos filtrados (panel B) la escala se ajusta a la variación real entre muestras y se aprecia una ligera tendencia hacia valores mayores en el grupo saludable, más visible en la riqueza observada y en Chao1. El filtro de calidad no cambia los datos de las muestras que se conservan, pero sí determina si las diferencias entre grupos pueden verse.




Figura 4.1: Diversidad alfa (riqueza observada, Chao1, Shannon y Simpson) en muestras saludables y no saludables. A) Antes del filtro de calidad, las muestras con muy pocas lecturas dominan la escala y ocultan las diferencias entre grupos. B) Tras eliminar las cinco muestras con menos de 25 millones de lecturas, se aprecia una tendencia hacia mayor diversidad en las muestras saludables, en particular en la riqueza observada y en Chao1. (Script)

4.1. CARACTERIZACIÓN DE LA COMPOSICIÓN TAXONÓMICA Y LA DIVERSIDAD

Aun después del filtro persiste una diferencia en la profundidad de secuenciación entre grupos. La Figura 4.2 muestra el número de lecturas clasificadas por muestra: los metagenomas de plantas saludables contienen, en promedio, más lecturas que los de plantas no saludables. Esta diferencia debe tenerse presente al interpretar los índices que dependen del esfuerzo de muestreo, como la riqueza observada y Chao1, porque una muestra con más lecturas tiene mayor probabilidad de detectar taxones raros. Las curvas de rarefacción calculadas en el Capítulo 3 indican, sin embargo, que todas las muestras conservadas alcanzan la saturación, es decir, que el número de taxones detectados deja de crecer con la profundidad.




Figura 4.2: Número de lecturas clasificadas por muestra tras el filtro de calidad. Las muestras saludables ($n = 35$) tienen en promedio más lecturas que las no saludables ($n = 18$). (Script)

4.1.2. Diversidad alfa de la comunidad completa

La Tabla 4.1 resume los cuatro índices de diversidad alfa por grupo, calculados sobre las 53 muestras filtradas. En los cuatro índices el promedio del grupo saludable es mayor que el del grupo no saludable, pero las diferencias son pequeñas en relación con la escala de cada índice: 26 taxones observados de más de 8 600, 0.06 unidades de Shannon sobre un valor cercano a

7.5, y una milésima en Simpson. El índice de Simpson está próximo a su máximo en todas las muestras, lo que indica comunidades sin dominancia marcada de ningún taxón. La diferencia más notable entre grupos no está en las medias sino en la dispersión: la desviación estándar del índice de Shannon en el grupo no saludable es casi tres veces la del grupo saludable. Este punto se retoma en la Sección 4.3.

Cuadro 4.1: Promedio de los índices de diversidad alfa por grupo sobre la comunidad completa (53 muestras filtradas). Entre paréntesis, la desviación estándar del índice de Shannon.

Grupo	Riqueza observada	Chao1	Shannon	Simpson
Saludable ($n = 35$)	8639.9	8767.6	7.478 (0.061)	0.998
No saludable ($n = 18$)	8613.7	8751.6	7.417 (0.168)	0.997

4.1.3. Diversidad beta de la comunidad completa

La Figura 4.3 muestra las ordenaciones NMDS (Kruskal, 1964) de las 53 muestras para las cinco medidas de disimilitud calculadas sobre abundancias relativas: Bray-Curtis, Jaccard, Euclidiana, Manhattan y Jensen-Shannon. En ninguna de las cinco se observa una separación entre muestras saludables y no saludables: los dos grupos se superponen en el centro de la ordenación y las pocas muestras alejadas del núcleo pertenecen a ambos grupos. Las ordenaciones de Bray-Curtis, Jaccard y Manhattan son casi idénticas, lo cual es esperable porque, sobre abundancias relativas, Jaccard cuantitativo y Manhattan son transformaciones monótonas de Bray-Curtis (Capítulo 1). La ordenación Euclidiana tiene una escala mucho menor porque, al elevar al cuadrado las diferencias, queda dominada por los dos filos más abundantes. La ordenación de Jensen-Shannon queda determinada por una sola muestra atípica, lo que la hace poco informativa para este conjunto de datos.

4.1. CARACTERIZACIÓN DE LA COMPOSICIÓN TAXONÓMICA Y LA DIVERSIDAD




Figura 4.3: Ordenaciones NMDS de la diversidad beta de la comunidad completa para cinco medidas de disimilitud. A) Bray-Curtis. B) Jaccard. C) Euclidiana. D) Manhattan. E) Jensen-Shannon. Ninguna medida separa las muestras saludables de las no saludables. (Script)

Para cuantificar lo que muestran las ordenaciones se aplicó un análisis PERMANOVA (Anderson, 2001) sobre la matriz de disimilitud de Bray-Curtis, con el estado de la planta como único factor y 999 permutaciones. El estado de la planta explicó el 2.4% de la variación total en la composición ($R^2 = 0,024$, pseudo- $F = 1,26$, $p = 0,202$). Es decir, más del 97% de la variación entre muestras se debe a factores distintos del estado saludable o no saludable, y la fracción atribuible a este no es distinguible de la que se obtendría asignando las etiquetas al azar.

4.1.4. Composición taxonómica general

A nivel de reino, la tabla de clasificación de Kraken contiene 8 822 taxones asignados a Bacteria y 181 a Eukaryota, lo que refleja tanto el predominio bacteriano de los suelos como la menor representación de los eucariotas en la base de datos de referencia. A nivel de filo, la comunidad está dominada por Actinobacteria y Proteobacteria, que juntos suman en promedio más del 90% de las lecturas clasificadas de cada muestra (48.3%

y 43.3%, respectivamente). Les siguen, ya con abundancias relativas menores al 3%, Planctomycetes, Firmicutes, Bacteroidetes y Acidobacteria. La Figura 4.4 muestra las abundancias absolutas y relativas por muestra, y la Figura 4.5 las mismas abundancias relativas con las muestras separadas por grupo. A esta escala los dos grupos son prácticamente indistinguibles: los dos filos dominantes tienen proporciones semejantes en todas las muestras y los filos minoritarios no alcanzan a verse.




Figura 4.4: Abundancia por filo en las 53 muestras filtradas. A) Abundancia absoluta, en número de lecturas asignadas a cada filo. B) Abundancia relativa, en porcentaje por muestra. Actinobacteria y Proteobacteria dominan todas las muestras. (Script)

4.1. CARACTERIZACIÓN DE LA COMPOSICIÓN TAXONÓMICA Y LA DIVERSIDAD




Figura 4.5: Abundancia relativa por filo con las muestras separadas por grupo: saludables (recuadro claro) y no saludables (recuadro oscuro). A nivel de filo y sobre la comunidad completa, la composición de ambos grupos es semejante.

Dado que ni la diversidad ni la composición de la comunidad completa distinguen a los grupos, el análisis se desagregó por reino, Bacteria y Eukaryota, y dentro de cada reino por filo, familia, género y especie. Para las gráficas de barras se aplicó una aglomeración al 10 %, que agrupa bajo la etiqueta “Others” a los taxones cuya abundancia relativa no supera ese umbral en ninguna muestra, de modo que los taxones restantes puedan distinguirse por color.

4.1.5. Eucariotas por nivel taxonómico

La Figura 4.6 muestra la composición de la fracción eucariota en los cuatro niveles taxonómicos. Los eucariotas representan una fracción muy pequeña de las lecturas clasificadas, por lo que sus abundancias relativas dentro del reino están sujetas a mayor variabilidad de muestreo que las bacterianas. A nivel de filo se observa una abundancia relativa ligeramente menor de Oomycota en las muestras no saludables, y a nivel de familia una menor presencia de Peronosporaceae, familia que pertenece a ese filo. A nivel

de género y especie se identifican los hongos fitopatógenos *Fusarium* y el oomiceto *Phytophthora*, ambos documentados como agentes de marchitez y pudrición radicular en fresa (Yang et al., 2020; Siegieda et al., 2024). Sobre la comunidad completa, la abundancia relativa media de *Fusarium* es de 0.144 % en las plantas saludables y de 0.160 % en las no saludables; la de Oomycota es de 0.066 % y 0.061 %, y la de *Phytophthora* de 0.063 % y 0.059 %. Se trata de diferencias pequeñas, que las gráficas de barras por reino amplifican al reescalar la fracción eucariota al 100 %.




Figura 4.6: Abundancia relativa de eucariotas en muestras saludables (recuadro claro) y no saludables (recuadro oscuro), con aglomeración al 10 %. A) Filo: Oomycota muestra una abundancia relativa ligeramente menor en las muestras no saludables. B) Familia: la misma tendencia en Peronosporaceae. C) Género: *Fusarium* y *Phytophthora* entre los géneros distinguibles. D) Especie. (Script)

La Figura 4.7 presenta la diversidad alfa de los eucariotas en cada nivel. En los cuatro niveles, las muestras saludables muestran una tendencia hacia valores mayores de riqueza observada y de Chao1, mientras que Shannon y Simpson son semejantes entre grupos. En el nivel de género, el promedio del

4.1. CARACTERIZACIÓN DE LA COMPOSICIÓN TAXONÓMICA Y LA DIVERSIDAD

índice de Shannon calculado sobre los 58 géneros de eucariotas es de 3.077 en el grupo saludable y de 3.035 en el no saludable; la significancia de esta diferencia se evalúa en la Sección 4.2. La diversidad beta por nivel, en la Figura 4.8, repite lo observado en la comunidad completa: las ordenaciones no separan los grupos en ningún nivel taxonómico.




Figura 4.7: Diversidad alfa de los eucariotas por nivel taxonómico: A) filo, B) familia, C) género, D) especie. Las muestras saludables tienden a mayor riqueza observada y Chao1 en todos los niveles. (Script)




Figura 4.8: Diversidad beta (NMDS, Bray-Curtis) de los eucariotas por nivel taxonómico: A) filo, B) familia, C) género, D) especie. No hay separación entre grupos en ningún nivel.

4.1.6. Bacterias por nivel taxonómico

La Figura 4.9 muestra la composición bacteriana en los cuatro niveles. A nivel de filo, ambos grupos están dominados por Actinobacteria y Proteobacteria, con Firmicutes como tercer filo distinguible; la única diferencia visible es una proporción algo mayor de Firmicutes en algunas muestras no saludables. A nivel de familia y género, la aglomeración al 10 % deja visibles a Streptomycetaceae y su género *Streptomyces*, presentes en proporciones semejantes en ambos grupos, y a Paenibacillaceae con su género *Paenibacillus*, que aparece en unas pocas muestras de ambos grupos. A nivel de especie, *Paenibacillus polymyxa*, una rizobacteria promotora del crecimiento vegetal (Lal and Tabacchioni, 2009), es la única que supera el umbral de aglomeración, y lo hace en muestras aisladas. Por debajo del umbral del 10 %, la exploración de las tablas de abundancia identificó a *Pseudomonas* y *Bacillus* con abundancias relativas algo mayores en las muestras saludables, y a *Ralstonia*, género que incluye a los agentes de la marchitez bacteriana (Suhaimi et al., 2017), con abundancia algo mayor en las no saludables.

4.1. CARACTERIZACIÓN DE LA COMPOSICIÓN TAXONÓMICA Y LA DIVERSIDAD




Figura 4.9: Abundancia relativa de bacterias en muestras saludables (recuadro claro) y no saludables (recuadro oscuro), con aglomeración al 10 %. A) Filo: predominio de Actinobacteria y Proteobacteria. B) Familia: Streptomycetaceae y Paenibacillaceae. C) Género: *Streptomyces* y *Paenibacillus*. D) Especie: *Paenibacillus polymyxa* en muestras aisladas. (Script)

La diversidad alfa de las bacterias por nivel (Figura 4.10) reproduce el patrón de la comunidad completa, lo cual es esperable porque las bacterias constituyen casi la totalidad de las lecturas: tendencia hacia mayor riqueza en el grupo saludable y mayor dispersión en el grupo no saludable, sobre todo en Shannon a nivel de género y especie. La diversidad beta por nivel (Figura 4.11) tampoco separa los grupos. Sí se observa que, con Bray-Curtis, la nube de puntos se vuelve más dispersa a medida que se descende de filo a especie, porque en los niveles finos hay más taxones que pueden diferir entre muestras. Esa mayor dispersión, sin embargo, no se organiza según el estado de la planta.




Figura 4.10: Diversidad alfa de las bacterias por nivel taxonómico: A) filo, B) familia, C) género, D) especie. (Script)




Figura 4.11: Diversidad beta (NMDS, Bray-Curtis) de las bacterias por nivel taxonómico: A) filo, B) familia, C) género, D) especie. La dispersión aumenta en los niveles finos, pero no se organiza según el estado de la planta.

4.2. Evaluación estadística de las diferencias entre grupos

Las tendencias descritas en la sección anterior se contrastaron con las pruebas de hipótesis del Capítulo 3, usando el índice de Shannon como variable de respuesta y un nivel de significancia $\alpha = 0,05$. Todas las pruebas son bilaterales, con hipótesis nula de igualdad entre los grupos saludable y no saludable.

4.2.1. Verificación de supuestos

Antes de aplicar la prueba t se verificaron sus dos supuestos. La prueba de Shapiro-Wilk (Shapiro and Wilk, 1965) no rechaza la normalidad del índice de Shannon en el grupo saludable ($p = 0,130$), pero sí la rechaza en el grupo no saludable ($p < 0,001$), donde una muestra con valor muy bajo

(6.82) se aleja del resto. La prueba F rechaza con claridad la igualdad de varianzas ($F = 0,132$ con 34 y 17 grados de libertad, $p < 0,001$): la varianza del grupo no saludable es unas siete veces mayor que la del saludable. En consecuencia, la versión apropiada de la prueba t es la de Welch, y la prueba de Wilcoxon-Mann-Whitney se aplica como alternativa que no requiere normalidad. Se reportan también los resultados con varianzas iguales para hacer explícito el efecto de ese supuesto.

4.2.2. Prueba t sobre el índice de Shannon de la comunidad completa

La Figura 4.12 resume la prueba t sobre la comunidad completa. Asumiendo varianzas iguales, el estadístico es $t = 1,939$ con 51 grados de libertad y $p = 0,058$; el intervalo de confianza del 95 % para la diferencia de medias, $(-0,002, 0,125)$, incluye al cero por un margen estrecho. Con la prueba de Welch (Welch, 1947), que es la que corresponde dados los supuestos, el estadístico es $t = 1,499$ con 19.3 grados de libertad y $p = 0,150$, con intervalo $(-0,024, 0,147)$. En ninguno de los dos casos se rechaza la hipótesis nula: la diferencia de 0.061 unidades de Shannon a favor del grupo saludable no es distinguible del ruido con el tamaño de muestra disponible. Cabe notar que el supuesto de varianzas iguales, que los datos no cumplen, acerca artificialmente el resultado a la significancia.




Figura 4.12: Prueba t de Student sobre el índice de Shannon de la comunidad completa. A) Distribución del índice en cada grupo, con la media señalada por la línea punteada. B) Asumiendo varianzas iguales: $t = 1,939$, 51 grados de libertad, $p = 0,058$. C) Asumiendo varianzas distintas (Welch): $t = 1,499$, 19.3 grados de libertad, $p = 0,150$. En ambos casos el estadístico queda fuera de la región de rechazo y no se rechaza la hipótesis nula.

4.2.3. Prueba t sobre el índice de Shannon de los géneros de eucariotas

La misma prueba se aplicó al índice de Shannon calculado sobre los 58 géneros de eucariotas, grupo que incluye a *Fusarium* y a *Phytophthora*, con el fin de comprobar si la señal asociada con los fitopatógenos, diluida en la comunidad completa, resultaba detectable al aislar la fracción eucariota. La Figura 4.13 muestra el resultado. Las medias son 3.077 en el grupo saludable y 3.035 en el no saludable. Asumiendo varianzas iguales, $t = 1,139$ con 51 grados de libertad y $p = 0,260$; con la prueba de Welch, $t = 0,902$ con 20.2 grados de libertad y $p = 0,378$. La prueba de Wilcoxon-Mann-Whitney sobre estos mismos valores da $W = 318$ y $p = 0,963$. Los tres intervalos de confianza incluyen al cero. Por lo tanto, la diversidad de géneros de eucariotas tampoco difiere significativamente entre grupos.




Figura 4.13: Prueba t de Student sobre el índice de Shannon calculado a nivel de género en eucariotas (58 géneros, entre ellos *Fusarium*). A) Distribución del índice en cada grupo, con la media señalada por la línea punteada: 3.077 en el grupo saludable y 3.035 en el no saludable. B) Asumiendo varianzas iguales: $t = 1,139$, 51 grados de libertad, $p = 0,260$. C) Asumiendo varianzas distintas (Welch): $t = 0,902$, 20 grados de libertad, $p = 0,378$. En ambos casos el estadístico queda dentro de la región de no rechazo. (Script)

4.2.4. Prueba de Wilcoxon-Mann-Whitney

Dado que el índice de Shannon del grupo no saludable no es normal, se aplicó la prueba de suma de rangos de Wilcoxon-Mann-Whitney sobre la comunidad completa. La Figura 4.14 muestra los 53 valores ordenados por rango: los dos grupos aparecen mezclados a lo largo de todo el recorrido, con las plantas no saludables algo más frecuentes en los rangos bajos y las saludables en los más altos, pero sin una zona en la que un grupo predomine. El estadístico es $W = 376$ con $p = 0,259$. La estimación de la diferencia de ubicación entre grupos es de 0.017 unidades de Shannon a favor del grupo saludable, con intervalo de confianza del 95 % $(-0,012, 0,056)$, que incluye al cero. La prueba no paramétrica coincide, por lo tanto, con la prueba t: no hay evidencia de una diferencia en la distribución del índice de Shannon

entre plantas saludables y no saludables.




Figura 4.14: Valores del índice de Shannon de la comunidad completa ordenados por rango, coloreados por grupo. Los grupos aparecen mezclados en todo el recorrido. Prueba de Wilcoxon-Mann-Whitney: $W = 376$, $p = 0,259$. (Script)

4.2.5. Tamaño del efecto y potencia estadística

La ausencia de significancia debe leerse junto con la potencia del diseño. A partir de las medias y desviaciones estándar de la Tabla 4.1, el tamaño del efecto estandarizado (d de Cohen) para el índice de Shannon de la comunidad completa es $d = 0,56$, un efecto de magnitud moderada según la convención usual (Cohen, 1988). Con 35 y 18 muestras, la potencia de la prueba t para detectar un efecto de ese tamaño al nivel $\alpha = 0,05$ es de 0.48 aproximadamente, calculada con la media armónica de los tamaños de grupo ($n \approx 24$) y la desviación estándar combinada ($s_p = 0,109$). Para alcanzar una potencia de 0.8 se necesitarían alrededor de 51 muestras por grupo, casi el triple de las plantas no saludables disponibles. La Tabla 4.2 resume todas las pruebas de esta sección.

Cuadro 4.2: Resumen de las pruebas de hipótesis sobre el índice de Shannon. Nivel de significancia $\alpha = 0,05$; ninguna prueba rechaza la hipótesis nula de igualdad entre grupos.

Conjunto	Prueba	Estadístico	g.l.
Comunidad completa	t, varianzas iguales	$t = 1,939$	51
Comunidad completa	t de Welch	$t = 1,499$	19.
Comunidad completa	Wilcoxon-Mann-Whitney	$W = 376$	–
Comunidad completa	F de varianzas	$F = 0,132$	34, 1
Géneros de eucariotas	t, varianzas iguales	$t = 1,139$	51
Géneros de eucariotas	t de Welch	$t = 0,902$	20.
Géneros de eucariotas	Wilcoxon-Mann-Whitney	$W = 318$	–
Composición (Bray-Curtis)	PERMANOVA	$F = 1,26, R^2 = 0,024$	1, 5

4.3. Patrones asociados con el estado de salud de la planta

Aunque ninguna prueba sobre los índices agregados alcanzó significancia, el análisis por niveles dejó tres patrones consistentes que se reúnen aquí como respuesta al tercer objetivo. Son observaciones descriptivas, obtenidas por inspección de las abundancias relativas y de la dispersión de los índices, y no resultados de pruebas de abundancia diferencial; su valor es orientar los modelos y los muestreos futuros que se discuten en los Capítulos 5 y 6.

4.3.1. Taxones candidatos

La Tabla 4.3 reúne los taxones cuya abundancia relativa mostró una tendencia consistente en un mismo sentido a lo largo de los niveles taxonómicos explorados. Los taxones asociados con el grupo saludable son géneros bacterianos documentados como promotores del crecimiento vegetal o agentes de biocontrol (Berendsen et al., 2012; Nam et al., 2023); los asociados con el grupo no saludable son géneros que incluyen fitopatógenos de la fresa (Yang et al., 2020). Las diferencias de abundancia relativa entre grupos son pequeñas en todos los casos, y se identificaron sin corrección por comparaciones múltiples, por lo que deben considerarse hipótesis por confirmar.

Cuadro 4.3: Taxones candidatos identificados por inspección de las abundancias relativas por nivel taxonómico. Se indica el grupo en el que la abundancia relativa tiende a ser mayor.

Reino	Nivel	Taxón	Mayor abundancia en
Bacteria	Género	<i>Pseudomonas</i>	Saludable
Bacteria	Género	<i>Bacillus</i>	Saludable
Bacteria	Especie	<i>Paenibacillus polymyxa</i>	Saludable (muestras aisladas)
Bacteria	Género	<i>Ralstonia</i>	No saludable
Eukaryota	Género	<i>Fusarium</i>	No saludable (0.144 % frente a 0.160 %)
Eukaryota	Filo	Oomycota	Saludable (0.066 % frente a 0.061 %)
Eukaryota	Familia	Peronosporaceae	Saludable

4.3.2. Heterogeneidad del grupo no saludable

El patrón estadísticamente más sólido de este trabajo no está en las medias sino en las varianzas. El índice de Shannon de la comunidad completa tiene una desviación estándar de 0.061 en las plantas saludables y de 0.168 en las no saludables, y la prueba F rechaza la igualdad de varianzas con $p < 0,001$. El mismo patrón se repite en la diversidad alfa de bacterias por nivel (Figura 4.10), donde los valores del grupo no saludable se extienden mucho más que los del saludable en Shannon a nivel de género y especie. Es decir, las plantas saludables tienen comunidades parecidas entre sí, mientras que cada planta marchita se aleja de ese perfil a su manera: algunas conservan una diversidad indistinguible de la de las plantas sanas y otras la pierden de forma marcada. Este resultado sugiere que la variable que mejor distingue a los grupos no es el nivel de diversidad sino su estabilidad, y que el diagnóstico del estado de salud a partir del microbioma tendría que apoyarse en la distancia de cada muestra al perfil saludable, más que en un umbral de diversidad.

4.3.3. Dónde está y dónde no está la señal

Los resultados de este capítulo delimitan con claridad dónde no está la señal del estado de salud: no está en la composición global de la comunidad, que el PERMANOVA atribuye en más del 97 % a otros factores; no está en el nivel medio de los índices de diversidad, ni en la comunidad completa ni en la

fracción eucariota; y no está en los filos dominantes, que tienen proporciones semejantes en todas las muestras. Lo que sí se observa es una tendencia débil pero consistente hacia mayor riqueza en las plantas saludables, presente en todos los niveles y reinos, una mayor heterogeneidad de las plantas no saludables, y un conjunto reducido de géneros con abundancias relativas ligeramente distintas entre grupos. Con 53 muestras y una potencia cercana a 0.5 para efectos moderados, estas tendencias no pueden confirmarse ni descartarse con las herramientas de este capítulo; el Capítulo 6 describe cómo el modelado con redes bayesianas y la simulación de metagenomas pueden llevar la pregunta más lejos.

Capítulo 5

Discusión y conclusiones

En este capítulo se interpretan los resultados presentados en el Capítulo 4 a la luz de los objetivos planteados en el Capítulo 2. Primero se discuten los hallazgos sobre la calidad de los datos, la diversidad alfa y beta, la composición taxonómica y las pruebas estadísticas; después se señalan las limitaciones del estudio y se presentan las conclusiones. Las perspectivas y el trabajo a futuro que se derivan de estas conclusiones se presentan en el Capítulo 6.

5.1. Discusión

5.1.1. La calidad de los datos condiciona la interpretación

El primer resultado del análisis fue metodológico: la diversidad alfa calculada sobre los datos crudos no permitía distinguir entre plantas saludables y no saludables, mientras que, tras eliminar las cinco muestras con menos de 25 millones de lecturas (MP2079, MP2080, MP2088, MP2109 y MP2137), las tendencias entre grupos se hicieron visibles. Casos como el de la muestra MP2088, con solo dos lecturas, muestran que una única muestra defectuosa puede dominar la escala de los índices y ocultar la estructura del resto de los datos. El filtrado de calidad no es, por lo tanto, un paso accesorio, sino una condición necesaria para que las comparaciones posteriores tengan sentido.

Sin embargo, aun después del filtrado persistió una diferencia sistemática en la profundidad de secuenciación: las muestras de plantas saludables

tuvieron, en promedio, más lecturas que las de plantas no saludables. Los índices que dependen del número de taxones observados o de los *singletons* y *doubletons*, como Chao1, son sensibles a esta diferencia, porque una muestra con más lecturas tiene mayor probabilidad de detectar taxones raros. Por ello, parte de la mayor diversidad observada en las plantas saludables podría explicarse por el esfuerzo de muestreo y no únicamente por el estado de salud de la planta (McMurdie and Holmes, 2014). Este sesgo refuerza la necesidad de comparar los resultados con datos normalizados o rarificados antes de atribuir las diferencias a la condición biológica.

5.1.2. Diversidad alfa: una tendencia consistente pero débil

En todos los índices de diversidad alfa (Chao1, Shannon y Simpson) las plantas saludables mostraron valores ligeramente mayores que las no saludables, y esta tendencia se repitió al separar los datos por reino y al descender a los niveles de filo, familia, género y especie. Esta dirección coincide con lo reportado en otros estudios sobre la rizósfera de fresa y de otros cultivos, en los que la enfermedad se asocia con una pérdida de diversidad microbiana (Xiong et al., 2020; Gao et al., 2021; Yang et al., 2020).

No obstante, la magnitud de la diferencia fue pequeña. Para el índice de Shannon calculado sobre la comunidad completa, las medias fueron 7.478 en el grupo saludable y 7.417 en el no saludable, una diferencia de apenas 0.061 unidades. Ni la prueba t con varianzas distintas ($p = 0,1501$) ni la prueba de Wilcoxon-Mann-Whitney ($p = 0,2586$) permitieron rechazar la hipótesis nula de igualdad entre grupos. La tendencia visual, por consistente que sea, no alcanzó a separarse del ruido propio de los datos.

Un resultado que merece atención es la diferencia en la dispersión de los grupos. La desviación estándar del índice de Shannon fue de 0.061 en las plantas saludables y de 0.168 en las no saludables, y la prueba F rechazó con claridad la igualdad de varianzas ($F = 0,132$, $p < 0,001$). Es decir, las plantas no saludables no difieren tanto en su diversidad promedio como en su variabilidad: sus comunidades microbianas son más heterogéneas entre sí. Este patrón es consistente con el llamado *principio de Anna Karenina* aplicado a microbiomas, según el cual los microbiomas de hospederos sanos tienden a parecerse entre sí, mientras que cada hospedero enfermo o estre-

sado se desestabiliza a su manera (Zaneveld et al., 2017). Desde el punto de vista estadístico, esta observación sugiere que comparar solo medias puede ser insuficiente y que la dispersión es, en sí misma, una característica diferenciadora entre los grupos.

5.1.3. Diversidad beta: gran superposición entre grupos

Ninguna de las métricas de distancia utilizadas (Bray-Curtis, Jaccard, Euclidiana, Manhattan y Jensen-Shannon) produjo una separación visible entre muestras saludables y no saludables en las ordenaciones. Para cuantificar esta observación se aplicó un análisis PERMANOVA sobre la matriz de disimilitud de Bray-Curtis de las abundancias relativas: el estado de la planta explicó solo el 2.4 % de la variación total en la composición ($R^2 = 0,024$, $F = 1,26$, $p = 0,202$, 999 permutaciones) (Anderson et al., 2011). Es decir, más del 97 % de la variación entre muestras se debe a factores distintos del estado sano o enfermo de la planta.

Esta superposición indica que la composición global del microbioma rizosférico está dominada por otros factores, probablemente el tipo de suelo, el manejo agronómico, el sitio y el momento de muestreo, que no fueron registrados en los metadatos disponibles. Al restringir el análisis a niveles taxonómicos más finos, en particular género y especie, las diferencias en Bray-Curtis resultaron más evidentes, lo que sugiere que la señal asociada a la salud de la planta, si existe, no está en la estructura global de la comunidad sino en un subconjunto reducido de taxones.

5.1.4. Composición taxonómica: taxones candidatos, no biomarcadores

A nivel de filo, Actinobacteria y Proteobacteria fueron los grupos más abundantes en ambos tipos de muestras, lo que concuerda con la composición típica de la rizósfera de fresa (Yang et al., 2020; Xiong et al., 2020). En los eucariotas se observó una menor abundancia de Oomycota y, dentro de este filo, de la familia Peronosporaceae en las plantas no saludables. En las bacterias, las plantas saludables presentaron mayor proporción de géneros comúnmente asociados con la promoción del crecimiento vegetal, como *Bacillus* y *Pseudomonas*, mientras que en las no saludables aparecieron con mayor peso géneros que incluyen fitopatógenos, como *Ralstonia* y

Fusarium.

Estas diferencias deben interpretarse con cautela. Se identificaron a partir de gráficos de abundancia relativa y no mediante una prueba de abundancia diferencial con corrección por comparaciones múltiples. Además, los datos metagenómicos son composicionales: las abundancias relativas suman uno, de modo que el aumento de un taxón obliga a la disminución aparente de otros, aun cuando su abundancia absoluta no haya cambiado (Gloor et al., 2017; Calle, 2019). Por ello, los géneros mencionados deben considerarse *taxones candidatos* a biomarcadores, cuya asociación con el estado de la planta requiere confirmación.

5.1.5. Diversidad de eucariotas a nivel de género: una señal que no se confirmó

Se esperaba que la señal asociada con los fitopatógenos, diluida en la comunidad completa, resultara detectable al aislar la fracción eucariota, y en particular al índice de Shannon calculado sobre los 58 géneros de eucariotas, grupo que incluye a *Fusarium* y a *Phytophthora*. No fue así: las medias fueron 3.077 en las plantas saludables y 3.035 en las no saludables, y ni la prueba t ($p = 0,260$ con varianzas iguales, $p = 0,378$ con Welch) ni la de Wilcoxon-Mann-Whitney ($p = 0,963$) rechazaron la igualdad entre grupos.

Este resultado tiene una historia que conviene dejar registrada. Una versión anterior del análisis reportaba para este mismo contraste una diferencia significativa ($p = 0,0017$), que llegó a presentarse como el hallazgo principal del trabajo. Al recalcularla se encontró que el script construía la tabla de abundancias con funciones que reordenan las muestras por abundancia y luego la unía a los metadatos sin emparejar por nombre de muestra, de modo que cada valor de diversidad quedaba asignado al estado de salud de otra planta. La “diferencia” era un artefacto de ese desemparejamiento. El error es instructivo desde el punto de vista del análisis de datos: una verificación tan simple como comprobar que los identificadores de muestra coinciden antes de unir dos tablas habría evitado un resultado espurio con un valor p muy convincente. Por eso todas las cifras del Capítulo 4 se recalcularon con scripts que verifican explícitamente ese emparejamiento.

Descartada esa señal, la conclusión es coherente con el resto del capítulo:

la comunidad eucariota tampoco distingue a los grupos en su nivel medio de diversidad. Cabe recordar, además, que este contraste fue uno de varios realizados sobre distintos subconjuntos y niveles taxonómicos, de modo que cualquier resultado significativo que aparezca en análisis futuros deberá evaluarse con una corrección por comparaciones múltiples, por ejemplo la de Benjamini-Hochberg (Benjamini and Hochberg, 1995).

5.1.6. Tamaño de muestra y potencia estadística

La ausencia de significancia en la comunidad completa no debe leerse como evidencia de que no exista diferencia entre los grupos. Con las medias y desviaciones estándar observadas del índice de Shannon, el tamaño del efecto estandarizado (d de Cohen) fue de aproximadamente 0.56, un efecto de magnitud moderada. Con los 35 y 18 metagenomas disponibles, la potencia de una prueba t para detectar un efecto de ese tamaño con $\alpha = 0,05$ es de apenas 0.48 aproximadamente: aun si la diferencia fuera real, el diseño la detectaría menos de la mitad de las veces. Para alcanzar una potencia de 0.8 se necesitarían alrededor de 51 muestras por grupo, casi el triple del número actual de plantas no saludables (Xia et al., 2018).

Este cálculo reencuadra los resultados del Capítulo 4: la falta de significancia es compatible con un efecto real que el diseño no tiene potencia suficiente para detectar. El desbalance entre grupos, con casi el doble de muestras saludables que no saludables, y la mayor varianza precisamente en el grupo más pequeño agravan el problema. Esta limitación motiva directamente el trabajo a futuro descrito en el Capítulo 6.

5.1.7. Limitaciones del estudio

Además del tamaño de muestra, el estudio presenta las siguientes limitaciones:

- **Diseño observacional y metadatos limitados.** Solo se contó con la etiqueta saludable o no saludable de cada planta. No se dispuso de variables como tipo de suelo, sitio, fecha de muestreo, variedad o manejo agronómico, que podrían explicar buena parte de la variación observada en la diversidad beta.

- **Etiquetado binario de la enfermedad.** La categoría “no saludable” agrupa plantas marchitas sin identificar el agente causal ni la severidad de la enfermedad, lo que puede contribuir a la alta variabilidad observada en ese grupo.
- **Clasificación taxonómica.** La asignación con Kraken depende de la base de datos de referencia; los eucariotas, en particular los hongos, están menos representados que las bacterias, lo que puede sesgar su detección y abundancia.
- **Profundidad de secuenciación desigual.** Las muestras saludables tuvieron más lecturas, lo que puede inflar los índices de riqueza en ese grupo.
- **Asociación y no causalidad.** Las diferencias observadas son asociaciones; con el diseño actual no es posible determinar si los cambios en el microbioma son causa o consecuencia de la enfermedad.

5.2. Conclusiones

En relación con los objetivos planteados, se concluye lo siguiente:

1. **Caracterización de la composición y la diversidad.** Se caracterizó el microbioma rizosférico de 53 plantas de fresa, 35 saludables y 18 no saludables, a los niveles de reino, filo, familia, género y especie. La comunidad está dominada por bacterias, principalmente Actinobacteria y Proteobacteria, en ambos grupos. Las plantas saludables mostraron de forma consistente una diversidad alfa ligeramente mayor en todos los índices y niveles taxonómicos. Además, el filtrado de calidad resultó indispensable para obtener comparaciones interpretables.
2. **Evaluación estadística de las diferencias.** Ni en la comunidad completa ni en la fracción eucariota las diferencias en diversidad alfa fueron estadísticamente significativas, y el estado de la planta explicó una fracción muy pequeña de la variación en la composición. La única prueba que rechazó su hipótesis nula fue la de igualdad de varianzas:

las plantas no saludables son significativamente más heterogéneas entre sí. El análisis de potencia muestra que el tamaño de muestra actual es insuficiente para detectar efectos moderados, por lo que los resultados no significativos deben interpretarse como no concluyentes y no como ausencia de efecto.

3. **Patrones asociados con el estado de salud.** Las plantas no saludables presentaron comunidades más heterogéneas entre sí, con una varianza de la diversidad significativamente mayor. Asimismo, se identificaron taxones candidatos asociados con cada condición, como *Bacillus* y *Pseudomonas* en plantas saludables y *Fusarium* y *Ralstonia* en plantas no saludables, cuya relevancia debe confirmarse con pruebas de abundancia diferencial y modelos que capturen las relaciones entre microorganismos.

En conjunto, este trabajo muestra que el análisis de datos metagenómicos requiere algo más que la aplicación directa de índices ecológicos: exige controlar la calidad y la profundidad de los datos, tener en cuenta su naturaleza composicional, evaluar la potencia estadística del diseño y considerar la dispersión, y no solo las medias, como una característica informativa. Las tendencias observadas son consistentes con la hipótesis de que la salud de la planta de fresa se asocia con un microbioma rizosférico más diverso y estable, pero confirmarla requiere más datos y modelos capaces de capturar la estructura de dependencia entre los microorganismos.

Capítulo 6

Perspectivas y trabajo a futuro

Las limitaciones identificadas en el Capítulo 5, en particular la baja potencia estadística y la dificultad de separar los grupos con métricas globales, orientan el trabajo a futuro en dos líneas complementarias: una que se encuentra actualmente en desarrollo, la modelación con redes bayesianas, y otra de más largo plazo, la puesta en funcionamiento de un simulador de datos metagenómicos.

6.1. Redes bayesianas (en desarrollo)

Los índices de diversidad resumen toda la comunidad en un solo número y las pruebas de hipótesis comparan esos resúmenes entre grupos; ninguno de los dos enfoques describe cómo se relacionan los microorganismos entre sí ni cómo esas relaciones se vinculan con el estado de la planta. Para abordar esta pregunta se está desarrollando un modelo de redes bayesianas, un modelo gráfico probabilístico (Pearl, 1988; Koller and Friedman, 2009) en el que un grafo acíclico dirigido $G = (V, E)$ codifica las dependencias condicionales entre variables, de modo que la distribución conjunta se factoriza como

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Pa}(X_i)), \quad (6.1)$$

donde $\text{Pa}(X_i)$ denota el conjunto de padres del nodo X_i en el grafo.

En este trabajo, los nodos de la red son la abundancia del género fúngico *Fusarium*, el índice de Shannon como medida de diversidad alfa, la abundancia de los taxones más abundantes y el estado de salud de la planta. La estructura se aprende a partir de los datos, por ejemplo con el paquete **bnlearn** de R (Scutari, 2010), y su robustez se evalúa mediante *bootstrapping*, conservando solo los arcos que aparecen en una proporción alta de las redes remuestreadas, y validación cruzada de k particiones para medir la capacidad predictiva del modelo.

Este enfoque complementa los resultados de esta tesis en tres aspectos:

- Permite pasar de preguntar *si* los grupos difieren a preguntar *qué* variables están relacionadas con el estado de la planta y a través de qué otras variables.
- Permite examinar el papel de *Fusarium*, cuya abundancia relativa es algo mayor en las plantas no saludables pero cuya señal no se detectó con los índices agregados, a través de su relación con la diversidad y con los taxones dominantes.
- Extiende el análisis de redes de coocurrencia exploratorio, basado en correlaciones y herramientas como MicNet (Favila et al., 2022), hacia un modelo probabilístico con el que se puede hacer inferencia y predicción.

Cabe advertir que, con 53 muestras, el aprendizaje de la estructura de una red bayesiana es inestable cuando el número de nodos es grande; de ahí la importancia del *bootstrapping* y de limitar la red a un número reducido de taxones. Esta restricción conecta directamente con la segunda línea de trabajo.

6.2. Simulador de datos metagenómicos

A más largo plazo, se propone contar con un simulador de datos metagenómicos plenamente funcional, que permita generar conjuntos de datos adicionales para fortalecer el análisis y llegar a resultados más significativos. Como parte de este proyecto se desarrolló una primera versión de PyMetaSeem, un simulador escrito en Python que genera lecturas a partir

de genomas de referencia en formato FASTA. PyMetaSeem recibe un perfil taxonómico con la cantidad de lecturas por genoma, corta lecturas aleatorias de longitud determinada, calcula su reverso complementario y produce archivos FASTQ con la calidad asociada. Se concibió como una alternativa más sencilla de instalar y usar que simuladores como CAMISIM (Fritz et al., 2019). El desempeño de este y otros simuladores de lecturas cortas ha sido evaluado de manera sistemática (Milhaven and Pfeifer, 2023), y los retos CAMI han mostrado el valor de los metagenomas simulados para comparar clasificadores y ensambladores (Meyer et al., 2022).

El flujo de trabajo propuesto consiste en:

1. Estimar, a partir de los datos reales, los perfiles taxonómicos característicos de las plantas saludables y no saludables: las abundancias medias de cada taxón, su variabilidad y las relaciones entre taxones, incluidas las aprendidas por la red bayesiana.
2. Generar nuevos perfiles taxonómicos muestreando de esos modelos y convertirlos, con PyMetaSeem, en metagenomas sintéticos, es decir, archivos de lecturas FASTQ.
3. Procesar los metagenomas sintéticos con el mismo flujo del Capítulo 3: clasificación con Kraken, filtrado, índices de diversidad y pruebas de hipótesis.

Este esquema cumple varios propósitos. En primer lugar, permite realizar análisis de potencia por simulación: generar conjuntos de datos con distintos tamaños de muestra y tamaños de efecto conocidos, y estimar cuántas muestras reales serían necesarias para detectar con confianza las diferencias observadas, lo que puede orientar el diseño de futuros muestreos. En segundo lugar, como en los datos simulados la composición verdadera es conocida, permite evaluar la exactitud del propio flujo de análisis: qué tanto sesgan la clasificación taxonómica, la profundidad de secuenciación desigual y la rarefacción los índices de diversidad. En tercer lugar, permite validar las redes bayesianas: si se simulan datos a partir de una red con estructura conocida, es posible medir qué tan bien los algoritmos de aprendizaje recuperan esa estructura con el tamaño de muestra disponible.

Es importante precisar el alcance de esta línea de trabajo. Los datos simulados heredan los supuestos del modelo con el que se generan, por lo

que no sustituyen a nuevas muestras biológicas como evidencia de una diferencia real entre plantas sanas y enfermas. Su valor está en cuantificar la incertidumbre, validar los métodos y diseñar mejores experimentos. La combinación de un simulador funcional, un modelo de redes bayesianas y nuevos muestreos dirigidos permitiría, en conjunto, llegar a conclusiones estadísticamente más sólidas sobre la relación entre el microbioma rizosférico y la salud de la fresa.

6.3. Otras líneas

Por último, se identifican otras extensiones naturales de este trabajo:

- Aplicar pruebas de abundancia diferencial que consideren la naturaleza composicional de los datos, con corrección por comparaciones múltiples, para confirmar los taxones candidatos.
- Construir un clasificador de muestras saludables y no saludables con aprendizaje automático, por ejemplo un bosque aleatorio (*random forest*; Breiman, 2001), que además permita ordenar los taxones por su importancia para la clasificación.
- Integrar los conjuntos de datos adicionales obtenidos, con cinco categorías según el tipo de cultivo y el estado de la planta, para evaluar si los patrones observados se mantienen en otros contextos agronómicos.

Conclusiones

Apéndice A

Codigos

Cosas.

Apéndice B

Imágenes

Cosas.

Bibliografía

- Anderson, M. J. (2001). A new method for non-parametric multivariate analysis of variance. *Austral Ecology*, 26(1):32–46.
- Anderson, M. J., Crist, T. O., Chase, J. M., Vellend, M., Inouye, B. D., Freestone, A. L., Sanders, N. J., Cornell, H. V., Comita, L. S., Davies, K. F., et al. (2011). Navigating the multiple meanings of β diversity: a roadmap for the practicing ecologist. *Ecology letters*, 14(1):19–28.
- Benjamini, Y. and Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological)*, 57(1):289–300.
- Berendsen, R. L., Pieterse, C. M. J., and Bakker, P. A. H. M. (2012). The rhizosphere microbiome and plant health. *Trends in Plant Science*, 17(8):478–486.
- Berry, D. and Widder, S. (2014). Deciphering microbial interactions and detecting keystone species with co-occurrence networks. *Frontiers in microbiology*, 5:219.
- Bolyen, E., Rideout, J. R., Dillon, M. R., Bokulich, N. A., Abnet, C. C., Al-Ghalith, G. A., Alexander, H., Alm, E. J., Arumugam, M., Asnicar, F., et al. (2019). Reproducible, interactive, scalable and extensible microbiome data science using qiime 2. *Nature biotechnology*, 37(8):852–857.
- Bray, J. R. and Curtis, J. T. (1957). An ordination of the upland forest communities of southern wisconsin. *Ecological monographs*, 27(4):326–349.

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Breitwieser, F. P., Lu, J., and Salzberg, S. L. (2019). A review of methods and databases for metagenomic classification and assembly. *Briefings in bioinformatics*, 20(4):1125–1136.
- Calle, M. L. (2019). Statistical analysis of metagenomics data. *Genomics & informatics*, 17(1).
- Chao, A. (1984). Nonparametric estimation of the number of classes in a population. *Scandinavian Journal of statistics*, pages 265–270.
- Chao, A. (1987). Estimating the population size for capture-recapture data with unequal catchability. *Biometrics*, pages 783–791.
- Chen, S., Zhou, Y., Chen, Y., and Gu, J. (2018). fastp: an ultra-fast all-in-one FASTQ preprocessor. *Bioinformatics*, 34(17):i884–i890.
- Cock, P. J. A., Fields, C. J., Goto, N., Heuer, M. L., and Rice, P. M. (2010). The Sanger FASTQ file format for sequences with quality scores, and the Solexa/Illumina FASTQ variants. *Nucleic Acids Research*, 38(6):1767–1771.
- Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, Hillsdale, NJ, 2 edition.
- Compant, S., Samad, A., Faist, H., and Sessitsch, A. (2019). A review on the plant microbiome: Ecology, functions, and emerging trends in microbial application. *Journal of Advanced Research*, 19:29–37.
- Csardi, G. and Nepusz, T. (2006). The igraph software package for complex network research. *InterJournal, Complex Systems*, 1695.
- Dabdoub, S. M. (2016). kraken-biom: Enabling interoperative format conversion for Kraken results. <https://github.com/smdabdoub/kraken-biom>.
- Douglas, G. M., Maffei, V. J., Zaneveld, J. R., Yurgel, S. N., Brown, J. R., Taylor, C. M., Huttenhower, C., and Langille, M. G. I. (2020). PICRUSt2 for prediction of metagenome functions. *Nature Biotechnology*, 38(6):685–688.

- Endres, D. M. and Schindelin, J. E. (2003). A new metric for probability distributions. *IEEE Transactions on Information Theory*, 49(7):1858–1860.
- Favila, N., Madrigal-Trejo, D., Legorreta, D., Sánchez-Pérez, J., Espinosa-Asuar, L., Eguiarte, L. E., and Souza, V. (2022). Micnet toolbox: Visualizing and unraveling a microbial network. *Plos one*, 17(6):e0259756.
- Friedman, J. and Alm, E. J. (2012). Inferring correlation networks from genomic survey data. *PLoS Computational Biology*, 8(9):e1002687.
- Fritz, A., Hofmann, P., Majda, S., Dahms, E., Dröge, J., Fiedler, J., Lesker, T. R., Belmann, P., DeMaere, M. Z., Darling, A. E., et al. (2019). Camisim: simulating metagenomes and microbial communities. *Microbiome*, 7(1):1–12.
- Gao, M., Xiong, C., Gao, C., Tsui, C. K., Wang, M.-M., Zhou, X., Zhang, A.-M., and Cai, L. (2021). Disease-induced changes in plant microbiome assembly and functional adaptation. *Microbiome*, 9:1–18.
- Gloor, G. B., Macklaim, J. M., Pawlowsky-Glahn, V., and Egozcue, J. J. (2017). Microbiome datasets are compositional: and this is not optional. *Frontiers in Microbiology*, 8:2224.
- Gower, J. C. (1966). Some distance properties of latent root and vector methods used in multivariate analysis. *Biometrika*, 53(3-4):325–338.
- Hall, M. and Beiko, R. G. (2018). 16s rrna gene analysis with qiime2. *Microbiome analysis: methods and protocols*, pages 113–129.
- Hurlbert, S. H. (1971). The nonconcept of species diversity: a critique and alternative parameters. *Ecology*, 52(4):577–586.
- Jaccard, P. (1912). The distribution of the flora in the alpine zone. *New Phytologist*, 11(2):37–50.
- Koller, D. and Friedman, N. (2009). *Probabilistic Graphical Models: Principles and Techniques*. MIT Press, Cambridge, MA.
- Kruskal, J. B. (1964). Multidimensional scaling by optimizing goodness of fit to a nonmetric hypothesis. *Psychometrika*, 29(1):1–27.

- Kullback, S. and Leibler, R. A. (1951). On information and sufficiency. *The Annals of Mathematical Statistics*, 22(1):79–86.
- Kumar, V., Prasad, R., Kumar, M., and Choudhary, D. K. (2019). *Microbiome in Plant Health and Disease: Challenges and Opportunities*. Springer.
- Lal, S. and Tabacchioni, S. (2009). Ecology and biotechnological potential of *Paenibacillus polymyxa*: a minireview. *Indian Journal of Microbiology*, 49(1):2–10.
- Larsen, R. J. and Marx, M. L. (2005). *An introduction to mathematical statistics*. Prentice Hall Hoboken, NJ.
- Legendre, P. and Legendre, L. (2012). *Numerical Ecology*. Elsevier, Amsterdam, 3 edition.
- Li, H., Handsaker, B., Wysoker, A., Fennell, T., Ruan, J., Homer, N., Marth, G., Abecasis, G., Durbin, R., and 1000 Genome Project Data Processing Subgroup (2009). The Sequence Alignment/Map format and SAMtools. *Bioinformatics*, 25(16):2078–2079.
- Lin, J. (1991). Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, 37(1):145–151.
- Lozupone, C. A. and Knight, R. (2008). Species divergence and the measurement of microbial diversity. *FEMS microbiology reviews*, 32(4):557–578.
- Lu, J., Breitwieser, F. P., Thielen, P., and Salzberg, S. L. (2017). Bracken: estimating species abundance in metagenomics data. *PeerJ Computer Science*, 3:e104.
- Lu, J., Rincon, N., Wood, D. E., Breitwieser, F. P., Pockrandt, C., Langmead, B., Salzberg, S. L., and Steinegger, M. (2022). Metagenome analysis using the kraken software suite. *Nature protocols*, 17(12):2815–2839.
- Magurran, A. E. (2021). Measuring biological diversity. *Current Biology*, 31(19):R1174–R1177.
- Mann, H. B. and Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1):50–60.

- Marchesi, J. R. and Ravel, J. (2015). The vocabulary of microbiome research: a proposal. *Microbiome*, 3:31.
- McDonald, D., Clemente, J. C., Kuczynski, J., Rideout, J. R., Stombaugh, J., Wendel, D., Wilke, A., Huse, S., Hufnagle, J., Meyer, F., Knight, R., and Caporaso, J. G. (2012). The Biological Observation Matrix (BIOM) format or: how I learned to stop worrying and love the ome-ome. *GigaScience*, 1:7.
- McInnes, L., Healy, J., and Melville, J. (2018). UMAP: Uniform manifold approximation and projection for dimension reduction. arXiv:1802.03426.
- McMurdie, P. J. and Holmes, S. (2013). phyloseq: an r package for reproducible interactive analysis and graphics of microbiome census data. *PloS one*, 8(4):e61217.
- McMurdie, P. J. and Holmes, S. (2014). Waste not, want not: why rarefying microbiome data is inadmissible. *PLoS computational biology*, 10(4):e1003531.
- Menzel, P., Ng, K. L., and Krogh, A. (2016). Fast and sensitive taxonomic classification for metagenomics with kaiju. *Nature communications*, 7(1):11257.
- Meyer, F., Fritz, A., Deng, Z.-L., Koslicki, D., Lesker, T. R., Gurevich, A., Robertson, G., Alser, M., Antipov, D., Beghini, F., et al. (2022). Critical assessment of metagenome interpretation: the second round of challenges. *Nature methods*, 19(4):429–440.
- Milhaven, M. and Pfeifer, S. P. (2023). Performance evaluation of six popular short-read simulators. *Heredity*, 130(2):55–63.
- Nam, J. H., Thibodeau, A., Qian, Y. L., Qian, M. C., and Park, S. H. (2023). Multidisciplinary evaluation of plant growth promoting rhizobacteria on soil microbiome and strawberry quality. *Amb Express*, 13(1):18.
- Oksanen, J., Simpson, G. L., Blanchet, F. G., Kindt, R., Legendre, P., Minchin, P. R., O'Hara, R. B., Solymos, P., Stevens, M. H. H., Szoecs, E., Wagner, H., et al. (2022). vegan: Community ecology package. R package version 2.6-4. <https://CRAN.R-project.org/package=vegan>.

- Oulas, A., Pavloudi, C., Polymenakou, P., Pavlopoulos, G. A., Papanikolaou, N., Kotoulas, G., Arvanitidis, C., and Iliopoulos, I. (2015). Metagenomics: tools and insights for analyzing next-generation sequencing data derived from biodiversity studies. *Bioinformatics and biology insights*, 9:BBI-S12462.
- Pearl, J. (1988). *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*. Morgan Kaufmann, San Mateo, CA.
- R Core Team (2023). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. <https://www.R-project.org/>.
- Ranjan, R., Rani, A., Metwally, A., McGee, H. S., and Perkins, D. L. (2016). Analysis of the microbiome: Advantages of whole genome shotgun versus 16S amplicon sequencing. *Biochemical and Biophysical Research Communications*, 469(4):967–977.
- Robinson, M. D., McCarthy, D. J., and Smyth, G. K. (2010). edgeR: a Bioconductor package for differential expression analysis of digital gene expression data. *Bioinformatics*, 26(1):139–140.
- Robinson, M. D. and Oshlack, A. (2010). A scaling normalization method for differential expression analysis of RNA-seq data. *Genome Biology*, 11(3):R25.
- Rosenberg, E. (2021). *Microbiomes: Current Knowledge and Unanswered Questions*. Springer Nature.
- Scutari, M. (2010). Learning Bayesian networks with the bnlearn R package. *Journal of Statistical Software*, 35(3):1–22.
- Shannon, C. E. (1948). A mathematical theory of communication. *The Bell system technical journal*, 27(3):379–423.
- Shapiro, S. S. and Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, 52(3-4):591–611.
- Siegieda, D., Panek, J., and Frąc, M. (2024). Ecological processes of bacterial microbiome assembly in healthy and dysbiotic strawberry farms. *BMC Plant Biology*, 24(1):692.

- Simpson, E. H. (1949). Measurement of diversity. *nature*, 163(4148):688–688.
- Suhaimi, N. S. M., Goh, S.-Y., Ajam, N., Othman, R. Y., Chan, K.-G., and Thong, K. L. (2017). Diversity of microbiota associated with symptomatic and non-symptomatic bacterial wilt-diseased banana plants determined using 16s rRNA metagenome sequencing. *World Journal of Microbiology and Biotechnology*, 33:1–10.
- Tuomisto, H. (2010a). A consistent terminology for quantifying species diversity? yes, it does exist. *Oecologia*, 164(4):853–860.
- Tuomisto, H. (2010b). A diversity of beta diversities: straightening up a concept gone awry. part 1. defining beta diversity as a function of alpha and gamma diversity. *Ecography*, 33(1):2–22.
- Wackerly, D. D., Mendenhall III, W., Scheaffer, R. L., Yescas Milanés, J., et al. (2002). *Estadística matemática con aplicaciones*.
- Wang, H., Wu, C., Zhang, H., Xiao, M., Ge, T., Zhou, Z., Liu, Y., Peng, S., Peng, P., and Chen, J. (2022). Characterization of the belowground microbial community and co-occurrence networks of tobacco plants infected with bacterial wilt disease. *World Journal of Microbiology and Biotechnology*, 38(9):155.
- Welch, B. L. (1947). The generalization of “Student’s” problem when several different population variances are involved. *Biometrika*, 34(1-2):28–35.
- Whittaker, R. H. (1960). Vegetation of the siskiyou mountains, oregon and california. *Ecological monographs*, 30(3):279–338.
- Whittaker, R. H. (1972). Evolution and measurement of species diversity. *Taxon*, 21(2-3):213–251.
- Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag, New York.
- Wilcox, R. R. (2010). *Fundamentals of Modern Statistical Methods*. Springer New York, NY.

- Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83.
- Woese, C. R., Kandler, O., and Wheelis, M. L. (1990). Towards a natural system of organisms: proposal for the domains Archaea, Bacteria, and Eucarya. *Proceedings of the National Academy of Sciences*, 87(12):4576–4579.
- Wood, D. E. and Salzberg, S. L. (2014). Kraken: ultrafast metagenomic sequence classification using exact alignments. *Genome biology*, 15(3):1–12.
- Xia, Y. and Sun, J. (2017). Hypothesis testing and statistical analysis of microbiome. *Genes & diseases*, 4(3):138–148.
- Xia, Y., Sun, J., Chen, D.-G., et al. (2018). *Statistical analysis of microbiome data with R*, volume 847. Springer.
- Xiong, W., Song, Y., Yang, K., Gu, Y., Wei, Z., Kowalchuk, G. A., Xu, Y., Jousset, A., Shen, Q., and Geisen, S. (2020). Rhizosphere protists are key determinants of plant health. *Microbiome*, 8:1–9.
- Yang, J., Wei, S., Su, D., Zhang, Z., Chen, S., Luo, Z., Shen, X., Lai, Y., Jamil, A., Tong, J., et al. (2020). Comparison of the rhizosphere soil microbial community structure and diversity between powdery mildew-infected and noninfected strawberry plants in a greenhouse by high-throughput sequencing technology. *Current Microbiology*, 77:1724–1736.
- Zaneveld, J. R., McMinds, R., and Vega Thurber, R. (2017). Stress and stability: applying the Anna Karenina principle to animal microbiomes. *Nature Microbiology*, 2(9):17121.