

Universidad Nacional Autónoma de México y Universidad Michoacana de San Nicolás de Hidalgo



Posgrado Conjunto en Ciencias Matemáticas
UMSNH-UNAM

Análisis estadístico de la diversidad microbiana a distintos niveles taxonómicos en el microbioma rizosférico de plantas de fresa saludables y no saludables

---

TESIS

para obtener el grado de

Maestra en Ciencias Matemáticas

presenta

Paula Camila Silva Gomez
csilva@matmor.unam.mx

Asesora:
Doctora Nelly Sélem Mojica
nselem@matmor.unam.mx

Coasesor:
Doctor José Alexander Fuentes Montoya
jamontoya.d@universidadean.edu.co

Morelia, Michoacán, México
Octubre, 2026

Paula Camila Silva Gomez

Firma

Fecha

Agradecimientos

Principalmente, agradezco a la Dra. Nelly por su infinita paciencia, dedicación y todo el tiempo y esfuerzo que me brindó a lo largo de este proceso. Su apoyo ha sido invaluable.

Agradezco al Dr. José Alexander Fuentes Montoya, de la Universidad EAN, coasesor de este trabajo y coautor del artículo derivado de él, por su acompañamiento en la metodología, su supervisión y la revisión cuidadosa de los resultados.

Agradezco a la empresa Solena Ag, y en particular al Dr. Obed Ramírez Sánchez, por facilitar los datos metagenómicos de los cultivos de fresa que hicieron posible este trabajo y por su apoyo en la interpretación de los resultados.

Agradezco al universo por enseñarme a mejorar cada día y por recordarme que, aunque el camino no siempre fue fácil y fue más largo de lo esperado, encontré la fortaleza para no rendirme y seguir adelante.

Gracias a las carnitas, los elotes y las nieves, por hacerme enamorar de una cultura que, aunque no soy fan del picante, llevaré siempre en mi corazón con mucho cariño.

Y un agradecimiento inmenso a cada una de las personitas, amigos, compañeros, y mis roomies, que me acompañaron en este camino. Gracias por estar ahí, ya sea desde cerca o a la distancia, con palabras de aliento, compañía y apoyo en esos días difíciles, que, siendo honesta, fueron muchos.

Por último, hago constar que en la edición del texto de este trabajo me apoyé en herramientas de inteligencia artificial, como Claude y ChatGPT, para revisar la redacción, la ortografía y la consistencia del documento. Las ideas, el análisis, los resultados y las conclusiones son míos.

¡Gracias totales!

Índice general

1. Preliminares **1**
1.1. Microbioma 3
1.2. Metagenómica 3
1.3. Microbioma de Fresa 5
1.4. Clasificadores 8
1.4.1. Kraken y Bracken 8
1.5. Lenguajes utilizados 9
1.5.1. Bash 10
1.5.2. R y RStudio 10
1.5.3. Python y Google Colab 11
1.6. Formatos utilizados 12
1.6.1. FASTA y FASTQ 12
1.6.2. JSON 12
1.6.3. Reportes de Kraken 13
1.6.4. BIOM 13
1.6.5. SAM y BAM 13
1.7. Índices de diversidad 14
1.7.1. Diversidad alfa 14
1.7.2. Diversidad beta 15
1.8. Pruebas de hipótesis 18
1.8.1. Prueba t para dos medias 20
1.8.2. Prueba F para dos varianzas 21
1.8.3. Prueba de Wilcoxon-Mann-Whitney 22
1.9. PERMANOVA y PERMDISP 23
1.10. Normalización y rarefacción 24

1.11. Redes de muestras y de coocurrencia 26

2. Objetivos **29**
2.1. Objetivo general 29
2.2. Objetivos específicos 29

3. Análisis exploratorio y metodología **31**
3.1. Métodos para caracterizar la diversidad 32
3.1.1. Conjunto de datos principal 32
3.1.2. Preprocesamiento 33
3.1.3. Filtrado de calidad 36
3.1.4. Índices de diversidad 38
3.1.5. Exploración a distintos niveles taxonómicos 40
3.2. Prueba de Hipótesis 41
3.2.1. Prueba t de Student sobre el índice de Shannon . . . 41
3.2.2. Prueba F sobre las varianzas 42
3.2.3. Prueba de Wilcoxon-Mann-Whitney 42
3.2.4. Análisis complementarios 42
3.2.5. Normalización y rarefacción 43
3.3. Redes de muestras y de coocurrencia 44
3.3.1. Redes de muestras 45
3.3.2. Redes de coocurrencia 45
3.4. Conjuntos de datos complementarios 50
3.4.1. Conjuntos de datos 50
3.4.2. Diversidad alfa 51
3.4.3. Composición y diversidad beta 51
3.4.4. Cultivo frente a suelo nativo 54
3.4.5. Lo que aportan los conjuntos complementarios . . . 55

4. Resultados **57**
4.1. Composición taxonómica y diversidad 57
4.1.1. Preprocesamiento y filtro de calidad 57
4.1.2. Diversidad alfa de la comunidad completa 58
4.1.3. Diversidad beta de la comunidad completa 60
4.1.4. Composición taxonómica general 62
4.1.5. Eucariotas por nivel taxonómico 66

4.1.6. Bacterias por nivel taxonómico 68
4.2. Evaluación estadística entre grupos 72
4.2.1. Verificación de supuestos 74
4.2.2. Prueba t sobre el índice de Shannon de la comunidad completa 74
4.2.3. Prueba t sobre el índice de Shannon de los géneros de eucariotas 75
4.2.4. Prueba de Wilcoxon-Mann-Whitney 76
4.2.5. Tamaño del efecto y potencia estadística 77
4.2.6. Sensibilidad a la normalización y la rarefacción . . . 78
4.3. Patrones asociados con el estado de salud 81
4.3.1. Taxones candidatos 81
4.3.2. Heterogeneidad del grupo no saludable 83
4.3.3. Dónde está y dónde no está la señal 85
4.4. Material didáctico: taller práctico 86

5. Discusión y conclusiones 89
5.1. Discusión 89
5.1.1. La calidad de los datos condiciona la interpretación . 89
5.1.2. Diversidad alfa: una tendencia consistente pero débil 90
5.1.3. Diversidad beta: gran superposición entre grupos . . 91
5.1.4. Composición taxonómica: taxones candidatos, no biomarcadores 92
5.1.5. Diversidad de eucariotas a nivel de género: una señal que no se confirmó 93
5.1.6. Tamaño de muestra y potencia estadística 94
5.1.7. Limitaciones del estudio 94
5.2. Conclusiones 95

6. Perspectivas y trabajo a futuro 99
6.1. Redes bayesianas (en desarrollo) 99
6.2. Simulador de datos metagenómicos 101
6.3. Otras líneas 102

A. Procedencia de figuras y tablas 105

B. Datos, entorno y reproducción **109**

Bibliografía **113**

Abstract

El microbioma rizosférico es un factor clave en la estabilidad y productividad agrícola, influyendo en la disponibilidad de nutrientes y la interacción de las plantas con su entorno. Su análisis mediante enfoques metagenómicos genera grandes volúmenes de datos, cuya interpretación requiere métodos matemáticos y estadísticos avanzados para identificar patrones de diversidad microbiana.

Este estudio explora las diferencias en la composición del microbioma rizosférico entre plantas saludables y no saludables en cultivos de fresa (Fragaria ananassa), aplicando métricas de diversidad alfa y beta, junto con pruebas de hipótesis para evaluar variaciones significativas. Las plantas saludables mostraron una diversidad microbiana ligeramente mayor, pero la diferencia no fue estadísticamente significativa y el estado de la planta explicó una fracción muy pequeña de la variación en la composición. El hallazgo más consistente fue otro: las plantas no saludables son significativamente más heterogéneas entre sí, tanto en diversidad como en composición, mientras que las saludables se parecen unas a otras; la proporción de *Fusarium* y de otros géneros candidatos no difirió entre grupos. Un análisis de potencia muestra que el tamaño de muestra disponible es insuficiente para detectar efectos moderados, por lo que los resultados no significativos deben leerse como no concluyentes.

Los hallazgos resaltan la importancia de combinar herramientas de modelado estadístico y ciencia de datos en el estudio del microbioma agrícola, proporcionando bases cuantitativas para el diseño de estrategias de manejo del suelo orientadas a mejorar la resiliencia y sostenibilidad de los cultivos.

Palabras clave: Metagenómica, análisis de datos, modelado estadístico, microbioma del suelo, diversidad microbiana, análisis bioinformático, fresa.

Introducción

El análisis metagenómico genera grandes volúmenes de datos cuya interpretación requiere métodos matemáticos y estadísticos avanzados para identificar patrones y variaciones en comunidades microbianas complejas. Dentro de este contexto, el microbioma rizosférico desempeña un papel crucial en la salud y productividad de los cultivos agrícolas, regulando la disponibilidad de nutrientes y la resiliencia del suelo Kumar et al. (2019) Rosenberg (2021). Comprender estas variaciones es fundamental para desarrollar estrategias de manejo agrícola basadas en la manipulación del microbioma del suelo.

En este estudio, se analizan las diferencias en la composición y estructura del microbioma rizosférico entre plantas saludables y no saludables en cultivos de fresa (Fragaria ananassa) Yang et al. (2020), utilizando herramientas avanzadas de estadística y modelado matemático Xia et al. (2018) para cuantificar estas variaciones y evaluar su impacto en la agronomía. Teniendo como propósito identificar características diferenciadoras entre los microbiomas de plantas saludables y no saludables, mediante el uso de los datos metagenómicos.

Para describir y modelar los datos metagenómicos, se calcularon índices de diversidad alfa (Chao1, Shannon y Simpson) para estimar la riqueza y equidad de especies en función del estado de la planta, mientras que la diversidad beta se evaluó mediante medidas de disimilitud (Bray-Curtis, Jaccard, Euclidiana, Manhattan y Jensen-Shannon) para determinar la variación en la composición microbiana entre grupos.

Para la validación estadística, se aplicaron pruebas de hipótesis como Mann-Whitney Wackerly et al. (2002). Los resultados mostraron que las plantas saludables presentan una diversidad microbiana ligeramente mayor que las no saludables sobre la comunidad completa, pero las pruebas de hipótesis no fueron concluyentes: las diferencias observadas no alcanzaron un nivel de significancia suficiente para establecer una separación entre los grupos, y parte de la diferencia en riqueza se explica por la mayor profundidad de secuenciación de las plantas saludables.

A pesar de esto, el análisis permitió identificar un patrón consistente: las plantas no saludables son significativamente más heterogéneas entre sí, tanto en su diversidad como en su composición, mientras que las saludables se parecen unas a otras. En cambio, la proporción de *Fusarium* y de otros géneros candidatos, patógenos y benéficos, resultó prácticamente igual en ambos grupos, de modo que el estado de salud no se refleja en la abundancia de taxones particulares sino en la estabilidad del conjunto.

Estos resultados indican que, con el tamaño de muestra disponible, la señal del estado de salud es débil y se concentra en la variabilidad de la comunidad; la tesis cuantifica esa limitación mediante un análisis de potencia y propone, como trabajo futuro, modelos de redes bayesianas y la simulación de metagenomas para fortalecer el análisis.

Este estudio enfatiza la importancia de integrar herramientas matemáticas, estadísticas avanzadas y ciencia de datos en la caracterización del microbioma rizosférico, permitiendo modelar y predecir su influencia en la salud del suelo agrícola. Los hallazgos pueden contribuir a la optimización de prácticas agrícolas basadas en microbiomas, promoviendo la sostenibilidad y eficiencia en la producción de cultivos.

Capítulo 1

Preliminares

La ciencia de datos es el campo que aplica técnicas analíticas avanzadas y principios científicos para extraer información valiosa de los datos. Su objetivo principal es la extracción, el análisis y la comunicación de información útil a partir de los datos. Esta disciplina integra la estadística, la informática y el pensamiento crítico con el fin de generar conocimiento significativo y pertinente. Analizar datos exige dominar las matemáticas, la estadística, la programación, la inteligencia artificial y el aprendizaje automático, además de contar con experiencia en los distintos campos donde se aplica. En este caso, es indispensable incursionar en conocimientos de genómica y metagenómica.

En microbiología, un factor importante de estudio son las interacciones entre microorganismos en un ambiente natural, ya que la mayoría de estos estudios se realizan en laboratorios. Los avances tecnológicos han llevado al desarrollo de métodos de secuenciación de ADN. Una de las plataformas más utilizadas y conocidas en el campo de la metagenómica es Illumina. Con este tipo de herramientas, es posible analizar el ADN extraído directamente de una muestra, en lugar de trabajar únicamente con microorganismos cultivados individualmente (Oulas et al., 2015).

La filogenética es el estudio de la evolución de la vida y las relaciones entre organismos y grupos de organismos. Este análisis se centra en temas como la diversidad, la evolución, la ecología y los genomas, ayudándonos

a comprender cómo evolucionan los genes, los genomas y las especies. Una parte importante de este estudio es la identificación, clasificación y denominación de organismos biológicos, campo conocido como taxonomía.

Carl Linnaeus, considerado el padre de la taxonomía, propuso siete niveles taxonómicos: Reino, Phylum, Clase, Orden, Familia, Género y Especie. Posteriormente, se añadió el Dominio como el octavo grupo taxonómico más amplio, dividido en Arqueas, Bacterias y Eukarya (Woese et al., 1990).

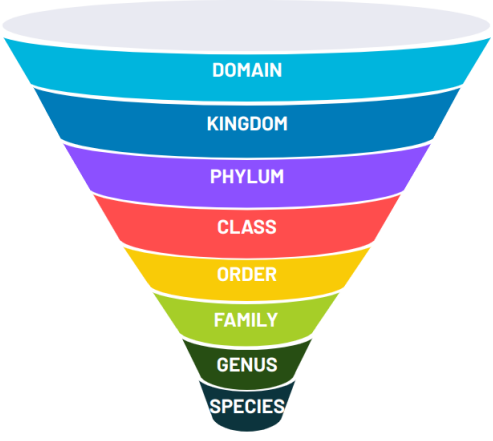


Figura 1.1: Representación jerárquica de los niveles taxonómicos usados para la clasificación y el análisis de datos metagenómicos. Diagrama de elaboración propia.

Los niveles taxonómicos (Figura 1.1) son categorías jerárquicas utilizadas para clasificar organismos, desde los grupos más generales hasta los más específicos. El Reino es el nivel más amplio y agrupa organismos según características fundamentales, como ser procariotas o eucariotas. Dentro de cada reino, los organismos se subdividen en Filos, que los organizan según estructuras o procesos biológicos compartidos. Estos se clasifican en Clases, que reúnen grupos más específicos de organismos. A su vez, las clases se dividen en Órdenes, que contienen familias relacionadas. Las Familias agrupan Géneros, que son conjuntos de especies estrechamente relacionadas. Final-

mente, la Especie es el nivel más específico, que incluye organismos capaces de reproducirse entre sí y producir descendencia viable. Esta jerarquía es esencial para organizar la biodiversidad y estudiar las relaciones evolutivas entre los organismos.

1.1. Microbioma

El microbioma se define como la comunidad completa de microorganismos (incluyendo bacterias, arqueas, hongos, protozoos y virus) que habitan en un entorno específico, como el cuerpo humano, animales, plantas o ambientes naturales. Este término no solo abarca a los microorganismos vivos, sino también sus genes, metabolitos y las interacciones que tienen entre ellos y con su huésped. La investigación del microbioma utiliza herramientas avanzadas, como la secuenciación de próxima generación y los análisis metagenómicos, para entender su diversidad y funciones en la salud, la enfermedad y los ecosistemas (Marchesi and Ravel, 2015).

1.2. Metagenómica

El microbioma se estudia a través de la metagenómica, que mediante el dato de un archivo de texto llamado metagenoma permite analizar comunidades microbianas en su entorno natural. La metagenómica es el estudio integral del material genético recuperado directamente de muestras ambientales. Este campo se centra en comprender la diversidad microbiana, las estructuras poblacionales, las capacidades funcionales y las interacciones de las comunidades microbianas con su entorno. Se aplica comúnmente en el estudio de ecosistemas como el suelo, el agua, la microbiota humana y otros hábitats microbianos complejos. La metagenómica utiliza tecnologías avanzadas de secuenciación, como la secuenciación de nueva generación, para desentrañar la diversidad genética y funcional de estas comunidades (Zhang et al., 2021; Oulas et al., 2015; Breitwieser et al., 2019).

La metagenómica permite analizar el genoma colectivo (metagenoma)

de todos los microorganismos presentes en un ambiente determinado, sin necesidad de cultivarlos individualmente. El DNA es pasado por un secuenciador, que regresa lecturas que pueden después de un procesamiento bioinformático, ser clasificadas y asignadas a un taxón. En este sentido, los datos metagenómicos pueden representarse como una matriz de conteos, como la siguiente:

$$X = (x_{ij}) \in \mathbb{N}^{n \times p}. \tag{1.1}$$

En esta matriz, cada fila puede representar una muestra (por ejemplo, un sitio ambiental), y cada columna corresponde a un taxón (por ejemplo, una especie bacteriana). El elemento x_{ij} indica el número de lecturas asignadas al taxón j en la muestra i. Debido a que las muestras presentan distinta profundidad de secuenciación, se suelen emplear abundancias relativas.

Existen dos enfoques para la secuenciación de DNA ambiental de microorganismos: "Amplicón 16S rRNA" y "Shotgun".

La secuenciación por amplicón 16S fue el primer método de secuenciación metagenómica ampliamente aceptado, y tiene varias ventajas: el gen 16S está presente en todas las bacterias y arqueas; contiene regiones altamente conservadas, necesarias para un buen análisis de PCR (*Polymerase Chain Reaction*, reacción en cadena de la polimerasa); existen conjuntos de *primers* bien estudiados para amplificar la mayoría de los organismos y bases de datos públicas bien curadas con las que comparar; y es relativamente barata y simple. Tiene, sin embargo, dos desventajas importantes: el gen 16S no está presente en los hongos, por lo que el método no sirve cuando se quiere trabajar con los mismos, y la elección de los *primers* puede introducir sesgo si no es la adecuada para los organismos de interés.

La secuenciación *shotgun* corta al azar todo el ADN presente en la muestra y lee esos fragmentos, sin amplificar previamente ninguna región en particular. El nombre alude a esa fragmentación indiscriminada: en lugar de leer una única región conservada, se obtiene una cobertura dispersa de todo el metagenoma, de modo que cada lectura puede provenir de cualquier parte del genoma de cualquier organismo presente en la muestra. Gracias a ello se detectan a la vez bacterias, hongos y otros eucariotas, que el enfoque por amplicón 16S no alcanza a ver (Ranjan et al., 2016; Hall and Beiko, 2018). En este trabajo se utilizan metagenomas *shotgun* de microorganismos asociados al cultivo de fresa.

Una vez obtenidas las secuencias, es necesario identificar el grupo taxonómico al que corresponde cada una. Un primer enfoque se basa en OTUs (unidades taxonómicas operacionales): las secuencias se agrupan por similitud, de modo que un OTU reúne a las que se parecen más de cierto porcentaje, siendo el 97 % un umbral habitual a nivel de especie. Los OTUs se obtienen mediante clústering, para lo cual existen varios métodos y algoritmos (Xia et al., 2018), aunque el procedimiento es relativamente costoso en cómputo y en memoria.

Un segundo enfoque son los clasificadores basados en *k-mers*. Un k-mer es una subcadena de longitud fija k de una secuencia de ADN; por ejemplo, la secuencia ACGTAC contiene los 3-mers ACG, CGT, GTA y TAC, y en general una lectura de longitud L contiene $L - k + 1$ k-mers consecutivos. Estos clasificadores descomponen cada secuencia en sus k-mers y los confrontan contra una base de referencia en la que cada k-mer está asociado a un taxón, lo que resulta mucho más rápido que alinear la lectura completa (Wood and Salzberg, 2014; Menzel et al., 2016; Breitwieser et al., 2019).

Para el análisis de estos datos, se emplean herramientas bioinformáticas como Kraken (Wood and Salzberg, 2014) y Bracken (Lu et al., 2017). A los que posteriori, se pueden realizar análisis estadísticos y de diversidad utilizando herramientas como R y Python. En el entorno de R, herramientas como phyloseq y vegan permiten calcular índices de diversidad (alfa: Shannon, Simpson, Chao1; beta: Bray-Curtis, UniFrac), realizar pruebas estadísticas (Wilcoxon), análisis multivariado (NMDS, PCoA) y análisis funcional (McMurdie and Holmes, 2013; Oksanen et al., 2022; Douglas et al., 2020).

1.3. Microbioma de Fresa

La fresa *(Fragaria x ananassa)* es un cultivo de gran relevancia comercial y nutricional a nivel mundial. Sin embargo, su producción se ve afectada por diversos factores, como la susceptibilidad a enfermedades y la influencia de las prácticas agrícolas y del ambiente en la calidad del fruto (Yang et al., 2020; Nam et al., 2023; Yang et al., 2023). En los últimos años, se he visto la importancia del estudio del microbioma vegetal, entendido como la comunidad de microorganismos que coexiste con la planta e incluye bacterias,

hongos y arqueas, presentes en nichos como el suelo a granel, la rizósfera (zona directamente influenciada por las raíces) y los tejidos internos (Compant et al., 2019; Siegieda et al., 2024). La composición del microbioma de fresa ha sido analizada mediante diferentes métodos, mediante el estudio masivo del ADN microbiano directamente desde las muestras ambientales (Bolyen et al., 2019; Bokulich et al., 2018; Hall and Beiko, 2018). Particularmente, la secuenciación de regiones como 16S rRNA (bacterias) e ITS1 (hongos) ha permitido comenzar a caracterizar comunidades microbianas asociadas a distintos tejidos de la planta (raíces, tallos, hojas) y diferentes estados de salud (Yang et al., 2020; Zhang et al., 2023; Siegieda et al., 2024).

La rizósfera constituye un entorno microbiano complejo que alberga una gran variedad de organismos con funciones clave en el desarrollo vegetal, incluyendo la mineralización de nutrientes, producción de hormonas, supresión de patógenos y estimulación de la inmunidad vegetal (Berendsen et al., 2012; Trivedi et al., 2020). Las comunidades microbianas no solo influyen en el crecimiento y rendimiento de los cultivos, sino que también pueden reflejar su estado de salud, lo cual hace posible identificar biomarcadores microbianos para clasificar plantas sanas y enfermas (Yang et al., 2020; Nam et al., 2023).

Estudios recientes han identificado diferencias taxonómicas significativas entre plantas de fresa sanas y enfermas. Por ejemplo, *Udaeobacter sp.*, *Solibacter sp.* y *Nitrosomonadaceae* son más abundantes en rizósferas no saludables, mientras que *Tepidisphaerales*, *Hydrocarboniphaga* y algunos géneros de *Pseudomonas* están relacionados con condiciones saludables (Nam et al., 2023; Siegieda et al., 2024). Estas diferencias en abundancia sugieren que ciertos microorganismos pueden actuar como indicadores microbianos del estado fisiológico de la planta.

El estudio de Yang et al. (2020), utilizando secuenciación de alto rendimiento, mostró que la infección por oídio inducía cambios significativos en la estructura y diversidad microbiana del suelo rizosférico de la fresa, incluyendo una reducción general de la riqueza microbiana. Esto refuerza la idea de que las alteraciones en el microbioma pueden estar asociadas con la aparición o progresión de enfermedades.

Trabajos más recientes han precisado este cuadro. En fresa, la invasión por *Fusarium* reduce la diversidad bacteriana y fúngica de los tejidos y la rizósfera, y disminuye la abundancia relativa de géneros benéficos como *Bacillus*, *Streptomyces* y *Trichoderma* (Yang et al., 2023); la pudrición radicular produce cambios semejantes en la rizósfera (Zhang et al., 2023). Un metaanálisis de rizósferas con marchitez por *Fusarium* en distintos cultivos encontró que la infección modifica de forma reproducible la composición bacteriana (Su et al., 2025). A escala continental, se ha mostrado que las plantas enfermas no solo cambian de composición sino que se vuelven más heterogéneas entre sí, en concordancia con el principio de Anna Karenina (Li et al., 2026). Estos resultados se enmarcan en la idea de que la planta recluta activamente microbiomas supresores de enfermedad, en los que *Pseudomonas*, *Bacillus* y *Streptomyces* tienen un papel central (Spooren et al., 2024), y de que la pérdida de ese equilibrio, o disbiosis, favorece a los patógenos (Du et al., 2024).

Además, diversas especies de bacterias y hongos han sido identificadas como patógenos relevantes en fresa, como *Colletotrichum sp.*, *Alternaria sp.*, *Botrytis cinerea* y *Dactylonectria sp.*. No obstante, también se han reportado microorganismos benéficos con potencial para ser utilizados como agentes de biocontrol (BCA) o rizobacterias promotoras del crecimiento (PGPR). Especies como *Bacillus subtilis*, *B. amyloliquefaciens*, *Pseudomonas monteilii*, *Mortierella sp.* y levaduras como *Rhodotorula* o *Trichoderma asperellum* han mostrado eficacia en la mejora de la salud de la planta y en la calidad de la fruta (Nam et al., 2023; Siegieda et al., 2024; Drobek et al., 2021).

En conjunto, estos hallazgos destacan la importancia del análisis estadístico y bioinformático del microbioma rizosférico, tanto para la comprensión ecológica como para la aplicación biotecnológica en sistemas agrícolas sostenibles. A partir de estos estudios, se pueden desarrollar modelos predictivos y herramientas diagnósticas basadas en perfiles microbianos, útiles para monitorear la salud del cultivo, diseñar estrategias de manejo más eficientes, e incluso seleccionar microorganismos clave como bioinoculantes.

Los datos shotgun que utilizaremos en este estudio , son originales y fueron provistos por Solena, una empresa de biotecnología agrícola (AgTech) enfocada en el análisis y mejora del microbioma del suelo. Su misión es desarrollar soluciones innovadoras basadas en datos moleculares y biotecnología para optimizar la salud del suelo y, como consecuencia, aumentar la productividad agrícola. Aprovechando herramientas avanzadas como inteligencia artificial y genómica, Solena obtiene conocimientos profundos sobre la composición y funcionalidad del microbioma del suelo. Además, en colaboración con organizaciones locales, la empresa implementa centros de diagnóstico molecular agrícola, como el establecido en México, para evaluar la salud de los suelos y fomentar prácticas agrícolas regenerativas. De esa colaboración nace la pregunta que guía este trabajo: con datos metagenómicos de la rizósfera, ¿puede distinguirse el microbioma de una planta de fresa saludable del de una planta marchita, y qué lo distingue? Las herramientas de las secciones siguientes son las que se necesitan para responderla.

1.4. Clasificadores

1.4.1. Kraken y Bracken

Kraken es una herramienta de clasificación de secuencias de ADN metagenómico mediante coincidencia exacta de k-mers, es decir, de las subcadenas de longitud fija k en que se descompone cada lectura (véase la Sección 1.2), asignándoles etiquetas taxonómicas con gran exactitud y velocidad (Wood and Salzberg, 2014). Kraken usa por defecto $k = 31$: busca cada k-mer de la lectura en una base de datos que lo asocia con el ancestro común más bajo de todos los genomas de referencia en los que aparece, y combina esas coincidencias para asignar la lectura a un taxón. Esta herramienta crea su base de datos de consulta a partir de una biblioteca de genomas de referencia e información taxonómica de NCBI (National Center for Biotechnology Information).

Kraken deja sin clasificar las secuencias que no tienen k-mers presentes en la base de datos precalculada.

La salida de Kraken consiste en una línea por cada read, que contiene

5 ítems separados por tabulaciones. En primer lugar, se indica si el read fue clasificado o no clasificado (C/U), seguido por el nombre del read (ID de la secuencia, el encabezado del archivo FASTA o FASTQ de entrada), la etiqueta taxonómica asignada por Kraken (0 si la secuencia no queda clasificada), la longitud de la secuencia en pares de bases (bp), y finalmente una lista delimitada por espacios que muestra el mapeo LCA (Lowest Common Ancestor) de cada k-mer de la secuencia (ID taxonómico : número de k-mers).

Para obtener el ID taxonómico completo, Kraken dispone de la herramienta kraken_translate, que, después de procesar los resultados con la misma base de datos, genera una lista de los reads junto con el nombre completo del ID taxonómico. Además, tiene una herramienta complementaria (-mpa), que presenta la salida ordenada por categoría taxonómica (root_Super Kingdom, d_kingdom, p_phylum, c_class, o_order, f_family, g_genus, s_species) (Wood and Salzberg, 2014; Lu et al., 2022).

Bracken, sigla de *Bayesian Reestimation of Abundance with KrakEN* (reestimación bayesiana de la abundancia con Kraken), calcula la abundancia de especies, géneros u otras categorías taxonómicas a partir de las secuencias de ADN recopiladas en un experimento de metagenómica (Lu et al., 2017).

Bracken realiza estimaciones probabilísticas basadas en las salidas de Kraken para completar las asignaciones al nivel taxonómico requerido, con el objetivo de obtener una estimación de abundancia más precisa. Este enfoque permite producir estimaciones fiables de abundancia a nivel de especie y género, incluso cuando una muestra contiene múltiples especies casi idénticas.

1.5. Lenguajes utilizados

En este trabajo se usaron tres lenguajes, cada uno en una etapa distinta: Bash para preparar los datos en el servidor, R para todo el análisis estadístico y las figuras, y Python para el simulador y el taller práctico.

1.5.1. Bash

Bash (*Bourne Again SHell*) es el intérprete de comandos de los sistemas Unix y Linux. Permite encadenar programas y automatizar tareas mediante scripts, por lo que es la herramienta habitual para manejar archivos de secuenciación de gran tamaño en servidores de cómputo. Aquí se usó para descargar y organizar los reportes de Kraken de cada muestra y para construir, con la herramienta kraken-biom (Dabdoub, 2016), la tabla de abundancias en formato BIOM que leen los demás programas.

1.5.2. R y RStudio

R es un lenguaje y entorno de software para el análisis estadístico y la visualización de datos (R Core Team, 2023), desarrollado por Ross Ihaka y Robert Gentleman en 1993. Su fortaleza es el conjunto de paquetes de código abierto especializados: en este trabajo se usaron phyloseq para manejar los datos metagenómicos (McMurdie and Holmes, 2013), vegan para las medidas de diversidad, las ordenaciones y el PERMANOVA (Oksanen et al., 2022), edgeR para la normalización TMM (Robinson et al., 2010), igraph para las redes (Csardi and Nepusz, 2006) y ggplot2 para las figuras (Wickham, 2016). Todos los resultados de los Capítulos 3 y 4 se obtuvieron con scripts de R, que se ejecutaron en RStudio, un entorno de desarrollo que facilita escribir y depurar código, organizar proyectos y redactar reportes reproducibles con R Markdown.

Phyloseq

Phyloseq (McMurdie and Holmes, 2013) es el paquete de R que organiza los datos metagenómicos en un solo objeto con cuatro componentes: la tabla de conteos, la tabla de taxonomía, los metadatos de las muestras y, si existe, el árbol filogenético (Figura 1.2). Mantener los cuatro componentes unidos garantiza que, al filtrar muestras o aglomerar taxones a un nivel taxonómico, todas las tablas se actualicen de manera consistente, y permite calcular índices de diversidad, distancias y ordenaciones directamente sobre el objeto.

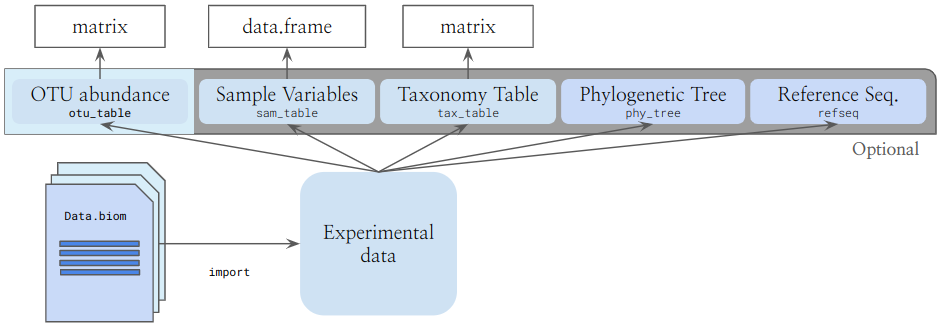


Figura 1.2: Estructura del objeto phyloseq, que integra la tabla de abundancias, la tabla de taxonomía, los metadatos de las muestras y el árbol filogenético. Diagrama de elaboración propia a partir de McMurdie and Holmes (2013).

1.5.3. Python y Google Colab

Python es un lenguaje de propósito general muy usado en ciencia de datos gracias a sus bibliotecas de código abierto: NumPy para el cálculo con arreglos (Harris et al., 2020), pandas para tablas (McKinney, 2010), SciPy para estadística (Virtanen et al., 2020) y Matplotlib para gráficas (Hunter, 2007). Frente a R, cuyo ecosistema para microbiomas está más desarrollado, Python tiene una sintaxis más legible y facilita escribir desde cero los algoritmos que se quieren enseñar. En este trabajo se usó para el simulador de lecturas PyMetaSeem (Capítulo 6) y para el taller práctico que acompaña a este trabajo, donde las pruebas de hipótesis, la prueba de Mann-Whitney y el PERMANOVA se implementan paso a paso con estas bibliotecas.

Google Colab es un servicio gratuito que ejecuta cuadernos de Jupyter en la nube con Python y sus bibliotecas científicas preinstalados (Bisong, 2019). Un cuaderno combina texto, código y resultados en un mismo documento, lo que lo hace adecuado para la enseñanza. El taller práctico, disponible en el repositorio del proyecto, está diseñado para abrirse directamente en Colab: los datos se descargan desde GitHub y los estudiantes pueden ejecutar y modificar cada paso del análisis sin instalar nada. Que el análisis pueda enseñarse y reproducirse es, de hecho, uno de los obje-

tivos del trabajo, y no solo un subproducto: las herramientas que aquí se combinan, de la ecología microbiana a la inferencia estadística, rara vez se presentan juntas.

1.6. Formatos utilizados

Los datos de este trabajo pasaron por varios formatos antes de convertirse en una tabla sobre la que se pudieran calcular índices y pruebas. Seguir ese recorrido ayuda a entender qué contiene cada archivo del repositorio y por qué se transformó en el siguiente: las lecturas del secuenciador llegan en FASTQ, el control de calidad produce reportes en JSON, Kraken escribe un reporte de texto por muestra, y de todos esos reportes se construye una única matriz en formato BIOM, que es la que se carga en R.

1.6.1. FASTA y FASTQ

FASTA es el formato de texto más simple para guardar secuencias de ADN, ARN o proteínas: cada entrada tiene un encabezado precedido por "$>$" y, debajo, la secuencia. FASTQ lo extiende para las lecturas de secuenciación masiva añadiendo, por cada nucleótido, una puntuación de calidad codificada en caracteres ASCII; cada lectura ocupa cuatro líneas: el identificador, la secuencia, un separador "+" y la línea de calidades (Cock et al., 2010). Las muestras de rizósfera de fresa se secuenciaron en formato FASTQ y fueron procesadas por Solena con fastp, que elimina adaptadores y bases de mala calidad. En este trabajo no se manipularon directamente los FASTQ, que ocupan varios gigabytes por muestra, sino los productos derivados de ellos.

1.6.2. JSON

JSON (*JavaScript Object Notation*) es un formato de texto para datos estructurados en pares clave-valor, legible tanto por personas como por cualquier lenguaje de programación. Aquí aparece en los reportes que fastp genera para cada muestra (`MD2055.fastp.json`, etc.), que registran cuántas lecturas había antes y después del filtrado y sus estadísticas de calidad. De esos reportes se extrajo la tabla `fastp_kraken_summary.csv`, con la que

se aplicó el filtro de calidad de la Sección 3: las muestras con menos de 25 millones de lecturas tras fastp se eliminaron del análisis.

1.6.3. Reportes de Kraken

Kraken escribe por cada muestra un reporte de texto delimitado por tabulaciones en el que cada fila es un taxón y las columnas indican el porcentaje y el número de lecturas asignadas a él y a sus descendientes, el nivel taxonómico y el identificador del NCBI. Estos 58 reportes, uno por muestra, son el punto de partida del trabajo estadístico, pero por separado no sirven para comparar muestras: hace falta juntarlos en una sola matriz.

1.6.4. BIOM

El formato BIOM (*Biological Observation Matrix*) es el estándar para almacenar esa matriz (McDonald et al., 2012): taxones en las filas, muestras en las columnas, número de lecturas en cada celda, y además metadatos de las filas (el linaje taxonómico completo de cada taxón) y de las columnas. Con la herramienta kraken-biom (Dabdoub, 2016), ejecutada desde Bash, los 58 reportes de Kraken se combinaron en el archivo `fresa_kraken.biom`. Ese archivo es el que lee la función `import_biom` de phyloseq para crear el objeto con el que se calcularon todos los índices, distancias y pruebas de los capítulos siguientes. Los metadatos de las muestras (identificador y estado de la planta) se guardaron aparte en un archivo CSV y se añadieron al objeto phyloseq en R.

1.6.5. SAM y BAM

En los flujos de trabajo que alinean las lecturas contra genomas de referencia, el resultado se guarda en SAM (*Sequence Alignment/Map*), un formato de texto con la posición y la calidad de cada alineamiento, o en su versión binaria comprimida BAM (Li et al., 2009). Kraken no alinea: clasifica por coincidencia de k-mers, de modo que en este trabajo no se generaron archivos SAM ni BAM. Se mencionan porque son el formato habitual en estudios metagenómicos basados en alineamiento, y porque herramientas como SAMtools los requieren.

1.7. Índices de diversidad

Después del preprocesamiento, cada muestra de rizósfera queda reducida a un vector de conteos: cuántas lecturas se asignaron a cada uno de los p taxones. La pregunta de este trabajo, si las plantas saludables y las no saludables tienen microbiomas distintos, exige comparar esos vectores, pero comparar directamente miles de coordenadas no es práctico ni interpretable. Los índices de diversidad resuelven el problema en dos pasos (Magurran, 2021; Tuomisto, 2010a): la *diversidad alfa* resume cada muestra en un solo número, que después puede compararse entre grupos con una prueba de hipótesis; la *diversidad beta* mide cuánto difieren dos muestras entre sí y produce una matriz de disimilitudes sobre la que se construyen las ordenaciones y el PERMANOVA. En lo que sigue, para una muestra se denota por x_i el número de lecturas del taxón i, por $N = \sum_i x_i$ su profundidad de secuenciación y por $p_i = x_i/N$ la abundancia relativa del taxón i.

1.7.1. Diversidad alfa

La diversidad alfa es la diversidad *dentro* de una muestra (Whittaker, 1960, 1972). Tiene dos caras: la riqueza, cuántos taxones hay, y la equitatividad, qué tan repartidas están las lecturas entre ellos. Los tres índices usados en este trabajo, que son los que calcula la función `estimate_richness` de phyloseq, miran esas dos caras con distinta sensibilidad a los taxones raros.

Chao1 estima la riqueza total, incluidos los taxones que la muestra no alcanzó a detectar (Chao, 1984, 1987). La idea es que los taxones vistos una sola vez (*singletons*, F_1) y dos veces (*doubletons*, F_2) delatan cuántos quedaron sin ver:

$$S_{Chao1} = S_{obs} + \frac{F_1(F_1 - 1)}{2(F_2 + 1)}, \tag{1.2}$$

donde S_{obs} es el número de taxones observados. Siempre $S_{Chao1} \geq S_{obs}$, con igualdad cuando no hay *singletons*. Es el índice más sensible a los taxones raros y, por ello, a la profundidad de secuenciación: una muestra con más lecturas detecta más *singletons* y recibe una estimación mayor, lo que obliga a comparar muestras de profundidad semejante o rarificadas (Sección 1.10).

El índice de **Shannon** es la entropía de las abundancias relativas (Shannon, 1948): la incertidumbre sobre a qué taxón pertenece una lectura to-

mada al azar,

$$H = -\sum_{i=1}^{S} h(p_i), \qquad h(p) = \begin{cases} p \ln p & \text{si } p > 0, \\ 0 & \text{si } p = 0, \end{cases} \tag{1.3}$$

de modo que los taxones ausentes de la muestra no aportan nada a la suma. Vale 0 si toda la muestra es un solo taxón y $\ln S$ si los S taxones son equiprobables, así que combina riqueza y equitatividad. Los taxones raros aportan términos cercanos a cero, por lo que es mucho menos sensible que Chao1 a la profundidad. Es el índice sobre el que se hacen las pruebas de hipótesis de este trabajo.

El índice de **Simpson** parte de la dominancia

$$\lambda = \sum_{i=1}^{S} p_i^2, \tag{1.4}$$

la probabilidad de que dos lecturas tomadas al azar pertenezcan al mismo taxón (Simpson, 1949). Como pondera cada taxón por el cuadrado de su abundancia, está dominado por los taxones más abundantes y es el menos sensible de los tres a los raros. Para que un valor mayor signifique mayor diversidad, como en Chao1 y Shannon, se usa el índice de Gini-Simpson $D = 1 - \lambda$, que es el que phyloseq reporta bajo el nombre "Simpson" y el que aparece en todas las figuras.

1.7.2. Diversidad beta

La diversidad beta es la diversidad *entre* muestras: Whittaker la definió como la tasa de cambio en la composición de una comunidad a otra (Whittaker, 1960). En la práctica se calcula una disimilitud $d(x, y)$ para cada par de muestras, con x e y sus vectores de abundancia sobre los mismos p taxones. Una disimilitud es una *métrica* si además de ser no negativa, simétrica y nula solo entre muestras iguales, cumple la desigualdad triangular $d(x, z) \leq d(x, y) + d(y, z)$. Varias de las medidas ecológicas no la cumplen; esto no impide usarlas en ordenaciones como NMDS (Kruskal, 1964), que solo necesitan el orden de las disimilitudes (Legendre and Legendre, 2012). En este trabajo se compararon cinco medidas, para comprobar que la conclusión no depende de la elegida.

La **disimilitud de Bray-Curtis** (Bray and Curtis, 1957) es la más usada en ecología microbiana:

$$d_{BC}(x, y) = \frac{\sum_{i=1}^{p} |x_i - y_i|}{\sum_{i=1}^{p} (x_i + y_i)}. \tag{1.5}$$

Vale 0 entre muestras idénticas y 1 entre muestras sin taxones en común; los taxones abundantes dominan su valor. Sobre abundancias relativas se reduce a $\frac{1}{2}\sum_i |p_i - q_i|$, la mitad de la distancia de Manhattan. No cumple la desigualdad triangular.

La **disimilitud de Jaccard** (Jaccard, 1912) nació para presencia y ausencia. Si A y B son los conjuntos de taxones presentes en cada muestra,

$$d_J(a, b) = 1 - \frac{|A \cap B|}{|A \cup B|}, \tag{1.6}$$

que vale 0 cuando ambas contienen los mismos taxones y 1 cuando no comparten ninguno. La versión cuantitativa, que es la que calculan phyloseq y vegan sobre una tabla de abundancias y la que se usó aquí, es

$$d_J^q(x, y) = \frac{\sum_{i=1}^{p} |x_i - y_i|}{\sum_{i=1}^{p} \max(x_i, y_i)} = \frac{2\, d_{BC}(x, y)}{1 + d_{BC}(x, y)}, \tag{1.7}$$

una transformación monótona de Bray-Curtis, lo que explica por qué ambas producen ordenaciones casi idénticas en el Capítulo 4.

La **distancia euclidiana** y la **distancia de Manhattan** son las distancias usuales de $\mathbb{R}^p$ aplicadas a los vectores de abundancia (Legendre and Legendre, 2012):

$$d_E(x, y) = \sqrt{\sum_{i=1}^{p} (x_i - y_i)^2}, \qquad d_M(x, y) = \sum_{i=1}^{p} |x_i - y_i|. \tag{1.8}$$

Ambas son métricas, pero la euclidiana, al elevar al cuadrado, queda dominada por completo por los dos o tres taxones más abundantes; la de Manhattan sobre abundancias relativas es el doble de Bray-Curtis.

La **divergencia de Jensen-Shannon** trata las abundancias relativas $P = (p_1, \ldots, p_p)$ y $Q = (q_1, \ldots, q_p)$ de dos muestras como distribuciones de

probabilidad y mide cuánto se parecen. Parte de la divergencia de Kullback-Leibler (Kullback and Leibler, 1951),

$$D_{KL}(P \,\|\, Q) = \sum_{i=1}^{p} p_i \ln \frac{p_i}{q_i}, \tag{1.9}$$

donde la doble barra es solo notación: se lee "divergencia de P respecto de Q" e indica cuál distribución se evalúa y cuál sirve de referencia. Taxón por taxón, $\ln(p_i/q_i)$ es positivo si el taxón es más abundante en P que en Q, negativo si lo es menos y cero si tiene la misma proporción; cada término se pondera por p_i y la suma es cero solo cuando $P = Q$. Por ejemplo, con $P = (0{,}5, 0{,}3, 0{,}2)$ y $Q = (0{,}3, 0{,}3, 0{,}4)$ se obtiene $D_{KL}(P \,\|\, Q) = 0{,}117$, pero $D_{KL}(Q \,\|\, P) = 0{,}124$: el orden importa, no es simétrica. Además, si un taxón de P falta en Q, el cociente $p_i/0$ la hace infinita, algo frecuente en tablas de abundancias. Jensen-Shannon resuelve ambos problemas comparando cada muestra con el promedio de las dos, $M = \frac{1}{2}(P + Q)$, que contiene todo taxón presente en cualquiera de ellas:

$$JSD(P, Q) = \frac{1}{2} D_{KL}(P \,\|\, M) + \frac{1}{2} D_{KL}(Q \,\|\, M). \tag{1.10}$$

En el ejemplo, $JSD(P, Q) = 0{,}030$. Es simétrica, finita y acotada por $\ln 2$ (Lin, 1991); su raíz cuadrada es una métrica (Endres and Schindelin, 2003). Phyloseq devuelve JSD sin raíz, que es lo que se usó.

Por último, **UniFrac** (Lozupone and Knight, 2008) mide la fracción de longitud de un árbol filogenético que es exclusiva de una de las dos muestras, de modo que dos muestras con taxones distintos pero emparentados resultan parecidas. No se usó en este trabajo porque Kraken entrega una jerarquía taxonómica, no un árbol con longitudes de rama.

Con los índices alfa y las disimilitudes beta queda cubierta la primera tarea del trabajo: *describir* la composición y la diversidad de las comunidades de cada grupo, y hacerlo a varios niveles taxonómicos, porque una diferencia invisible a nivel de filo puede aparecer a nivel de género. Pero describir no basta: una diferencia en los índices puede ser real o puede ser azar, y decidirlo exige las herramientas de la sección siguiente.

1.8. Pruebas de hipótesis

Con un índice de diversidad por muestra, la pregunta de este trabajo se vuelve concreta. En las 35 plantas saludables el índice de Shannon promedia 7.48; en las 18 no saludables, 7.42. La diferencia existe en los datos, pero ¿qué significa? Si se tomaran otras 53 plantas del mismo campo, las medias cambiarían un poco, y es perfectamente posible que dos grupos de plantas *idénticas* en su microbioma arrojaran, solo por el azar del muestreo, una diferencia de ese tamaño o mayor. Una prueba de hipótesis es el procedimiento que permite distinguir entre una diferencia que el azar explica con facilidad y una que no (Wackerly et al., 2002; Larsen and Marx, 2005).

La lógica es la de un juicio. Se parte de una presunción, la **hipótesis nula** H_0, que afirma que no hay efecto: aquí, que la diversidad media es la misma en ambos grupos. Frente a ella está la **hipótesis alternativa** H_1, que sí hay diferencia. La carga de la prueba recae sobre H_1: no se abandona H_0 a menos que los datos la contradigan con fuerza. Para medir esa fuerza se calcula un **estadístico de prueba**, una función de los datos, como la diferencia de medias dividida por su error estándar, cuya distribución se conoce *si H_0 es cierta*. Esa distribución teórica dice qué valores del estadístico son habituales bajo H_0 y cuáles serían sorprendentes. Los sorprendentes forman la **región de rechazo** (Figura 1.3): si el estadístico observado cae en ella, se concluye que los datos son demasiado improbables bajo H_0 y se la rechaza en favor de H_1.

El **valor** p resume ese veredicto en un número: es la probabilidad, suponiendo que H_0 es cierta, de obtener un estadístico al menos tan extremo como el observado. Un valor p de 0.058, como el que aparecerá en el Capítulo 4, se lee así: si los dos grupos de plantas tuvieran de verdad la misma diversidad, una diferencia como la observada o mayor ocurriría en cerca de 6 de cada 100 repeticiones del muestreo. Para convertir esa probabilidad en una decisión se fija de antemano un umbral, el **nivel de significancia** α, que en este trabajo es 0.05: se rechaza H_0 si $p < \alpha$. El umbral es una convención y no una frontera natural; un valor p de 0.058 y uno de 0.045 cuentan casi la misma historia, y por eso los resultados se reportan siempre con el valor p completo y el tamaño de la diferencia, no solo con el veredicto.

Toda decisión de este tipo puede equivocarse de dos maneras. Rechazar una H_0 verdadera, ver una diferencia donde no la hay, es el **error de**

tipo I, y su probabilidad es exactamente α: el umbral se fija precisamente para controlarlo. No rechazar una H_0 falsa, no ver una diferencia que sí existe, es el **error de tipo II**, con probabilidad β. A diferencia de α, β no se elige: depende de cuán grande sea la diferencia real y, sobre todo, de cuántas muestras haya. Su complemento, $1-\beta$, es la **potencia** de la prueba, la probabilidad de detectar una diferencia cuando existe. Esta asimetría tiene una consecuencia que conviene fijar desde ahora: no rechazar H_0 no demuestra que H_0 sea cierta. Puede ser que la diferencia exista y que con 35 y 18 muestras la prueba simplemente no tenga potencia para verla. Esa es, en buena medida, la situación de este trabajo, y por eso el Capítulo 4 acompaña las pruebas con un cálculo de potencia.

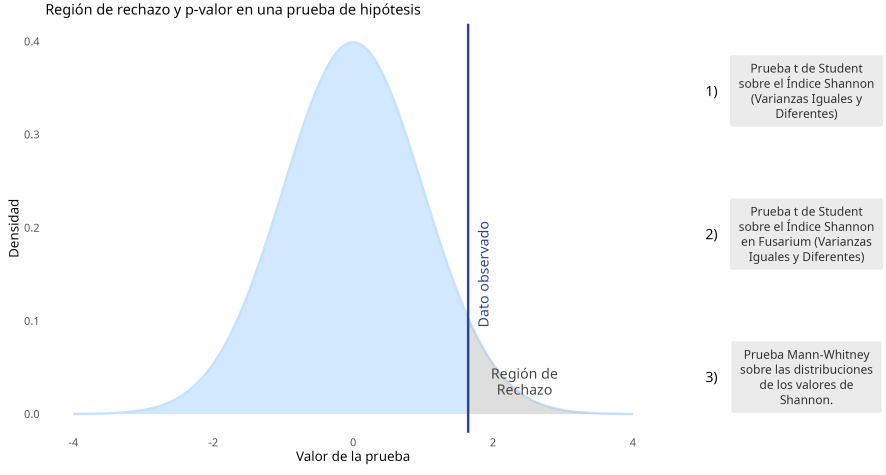


Figura 1.3: Esquema de una prueba de hipótesis: distribución del estadístico bajo H_0, región de rechazo (gris) y valor observado. H_0 se rechaza solo si el estadístico cae en la región de rechazo. A la derecha, las tres pruebas que se aplican en este trabajo. (Script: `20260919_RegenerarPruebatExplicacion13.R`)

Queda por elegir el estadístico, y la elección depende de lo que pueda suponerse de los datos. Si el índice de Shannon se distribuye de forma aproximadamente normal en cada grupo, la prueba t de Student es la más potente; pero tiene dos versiones según las varianzas de los grupos sean

iguales o no, y para decidir entre ellas se usa la prueba F. Si la normalidad no puede suponerse, como ocurre en el grupo no saludable, donde una sola planta con diversidad muy baja deforma la distribución, se recurre a la prueba de Mann-Whitney, que trabaja con los rangos de las observaciones y no necesita ninguna distribución. Las tres se describen a continuación y las tres se aplican en el Capítulo 4, porque cuando coinciden la conclusión es más sólida y cuando no coinciden la discrepancia misma es informativa.

1.8.1. Prueba t para dos medias

La situación es la siguiente: dos muestras independientes, $Y_{11}, \ldots, Y_{1n_1}$ y $Y_{21}, \ldots, Y_{2n_2}$, extraídas de poblaciones normales $N(\mu_1, \sigma_1^2)$ y $N(\mu_2, \sigma_2^2)$, con medias y varianzas muestrales $\bar{Y}_k$ y S_k^2. Se contrasta

$$H_0 : \mu_1 = \mu_2 \qquad \text{frente a} \qquad H_1 : \mu_1 \neq \mu_2. \tag{1.11}$$

La evidencia natural es la diferencia de medias $\bar{Y}_1 - \bar{Y}_2$, pero una misma diferencia puede ser enorme o insignificante según cuánto varíen los datos; por eso el estadístico la divide por una estimación de su error estándar. Si las varianzas pueden suponerse iguales, se estiman juntas con la varianza combinada

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2} \tag{1.12}$$

y el estadístico es

$$T = \frac{\bar{Y}_1 - \bar{Y}_2}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}, \tag{1.13}$$

que bajo H_0 sigue una distribución t de Student con $\nu = n_1 + n_2 - 2$ grados de libertad (Wackerly et al., 2002). Se rechaza H_0 si $|T| > t_{\alpha/2,\,\nu}$, el cuantil que deja probabilidad $\alpha/2$ en cada cola, y el valor p es $2\,P(t_\nu \geq |t_{obs}|)$.

Suponer varianzas iguales es cómodo, pero no es gratis: si un grupo es mucho más variable que el otro, la varianza combinada subestima el error y la prueba rechaza con más facilidad de la debida. Welch (1947) propuso mantener cada varianza por separado,

$$T' = \frac{\bar{Y}_1 - \bar{Y}_2}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}, \tag{1.14}$$

y aproximar su distribución por una t con los grados de libertad de Welch-Satterthwaite

$$\nu' = \frac{\left(\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}\right)^2}{\frac{(S_1^2/n_1)^2}{n_1-1} + \frac{(S_2^2/n_2)^2}{n_2-1}}, \tag{1.15}$$

que en general no es entero y es menor que ν: la prueba paga la incertidumbre adicional con menos grados de libertad y, por tanto, con un umbral de rechazo más exigente. Es la versión que `t.test` de R aplica por defecto. En este trabajo la versión con varianzas iguales fue la primera que se aplicó, en la fase exploratoria y antes de verificar los supuestos; una vez comprobado que las varianzas difieren, la prueba de Welch pasó a ser la prueba principal. Se reportan las dos, precisamente para mostrar cómo el supuesto de varianzas iguales acerca el resultado a la significancia cuando los datos no lo cumplen.

1.8.2. Prueba F para dos varianzas

Para saber cuál versión de la prueba t corresponde hay que preguntar primero si las varianzas difieren, y eso es en sí mismo una prueba de hipótesis:

$$H_0 : \sigma_1^2 = \sigma_2^2 \qquad \text{frente a} \qquad H_1 : \sigma_1^2 \neq \sigma_2^2. \tag{1.16}$$

El estadístico es el cociente

$$F = \frac{S_1^2}{S_2^2}, \tag{1.17}$$

que bajo H_0 y normalidad sigue una distribución F de Fisher con $n_1 - 1$ y $n_2 - 1$ grados de libertad; si las varianzas son iguales el cociente ronda 1, y se rechaza H_0 cuando cae fuera del intervalo $[F_{1-\alpha/2,\, n_1-1,\, n_2-1},\ F_{\alpha/2,\, n_1-1,\, n_2-1}]$. En este trabajo la prueba F hace más que elegir entre dos versiones de la t: una diferencia de varianzas entre grupos es por sí misma un hallazgo, porque dice que las plantas de un grupo se parecen entre sí y las del otro no. Hay que tener presente, eso sí, que la prueba F es sensible a desviaciones de la normalidad, de modo que su resultado debe leerse junto con una prueba de normalidad como la de Shapiro-Wilk.

1.8.3. Prueba de Wilcoxon-Mann-Whitney

Las dos pruebas anteriores descansan en que el índice de Shannon siga una distribución normal en cada grupo, y en estos datos ese supuesto falla justo donde más importa: en el grupo no saludable, una planta con diversidad muy baja deforma la distribución y la prueba de Shapiro-Wilk la rechaza (Capítulo 4). Con 18 observaciones, un solo valor extremo basta para mover la media y la varianza y, con ellas, el resultado de la prueba t. Para situaciones así existe una alternativa que no supone ninguna distribución: dejar de mirar los valores y mirar solo su orden. Si se juntan las observaciones de los dos grupos y se ordenan de menor a mayor, bajo H_0 las de un grupo deberían quedar repartidas al azar entre las del otro; si uno tiende a ocupar las posiciones altas, hay evidencia de diferencia. Es la prueba de suma de rangos de Wilcoxon, equivalente a la prueba U de Mann-Whitney (Wilcoxon, 1945; Mann and Whitney, 1947), y por esa robustez es la prueba de uso más extendido para comparar índices de diversidad entre dos grupos en estudios de microbioma (Aldirawi and Morales, 2023). No debe confundirse con la prueba de *rangos con signo* de Wilcoxon, que es para muestras pareadas; aquí los grupos son independientes.

Sean $X_1, \ldots, X_{n_1}$ y $Y_1, \ldots, Y_{n_2}$ independientes con distribuciones continuas F_X y F_Y. Se contrasta

$$H_0 : F_X = F_Y \qquad \text{frente a} \qquad H_1 : F_X \neq F_Y. \tag{1.18}$$

Se asigna a cada observación su rango en la muestra conjunta, se suman los rangos de la primera muestra, R_1, y se calcula

$$U = R_1 - \frac{n_1(n_1+1)}{2} = \#\{(i,j) : X_i > Y_j\}, \tag{1.19}$$

donde $\#A$ denota el número de elementos del conjunto A; U es, por tanto, el número de pares, uno de cada grupo, en los que la primera observación supera a la segunda. Si los grupos no difieren, U ronda la mitad de los $n_1 n_2$ pares; bajo H_0 su media es $n_1 n_2/2$, su varianza $n_1 n_2(n_1 + n_2 + 1)/12$ y para muestras moderadas se aproxima por una normal (Wilcox, 2010). La función `wilcox.test` de R lo reporta como W. El precio de no suponer nada es una conclusión más modesta: un rechazo solo indica que una observación de un grupo tiende a superar a una del otro, $P(X > Y) \neq 1/2$; leerlo como

diferencia de medianas exige que ambas distribuciones tengan la misma forma.

Estas tres pruebas son el núcleo de la segunda tarea del trabajo: *contrastar* formalmente las diferencias entre grupos que la descripción sugiera. Comparan, sin embargo, un solo número por muestra; para contrastar la composición completa hace falta extenderlas.

1.9. Análisis multivariado por permutaciones: PERMANOVA y PERMDISP

Las pruebas anteriores comparan un número por muestra. Para preguntar si la *composición completa* difiere entre grupos hay que trabajar sobre la matriz de disimilitudes de la Sección 1.7.2, y para eso está el análisis de varianza multivariado por permutaciones, PERMANOVA (Anderson, 2001), el método más usado con este fin en estudios de microbioma (Kleine Bardenhorst et al., 2021; Aldirawi and Morales, 2023). La idea es la del análisis de varianza clásico, pero sin coordenadas: si N muestras se reparten en a grupos de tamaños n_g y d_{ij} es la disimilitud entre las muestras i y j, la variación total y la variación dentro de los grupos se obtienen directamente de las disimilitudes,

$$SS_T = \frac{1}{N}\sum_{i<j} d_{ij}^2, \qquad SS_W = \sum_{g=1}^{a} \frac{1}{n_g} \sum_{\substack{i<j \\ i,j\in g}} d_{ij}^2, \tag{1.20}$$

y la variación entre grupos es $SS_A = SS_T - SS_W$. Con la distancia euclidiana estas sumas coinciden con las del ANOVA; con cualquier otra disimilitud la partición sigue valiendo en el espacio que d define. El estadístico

$$F = \frac{SS_A/(a-1)}{SS_W/(N-a)} \tag{1.21}$$

se llama pseudo-F porque no sigue la distribución de Fisher, y $R^2 = SS_A/SS_T$ es la fracción de la variación que explica el factor, el tamaño del efecto que debe reportarse con el valor p. Como no hay distribución teórica, el valor p se obtiene por permutaciones: bajo H_0 las etiquetas de

grupo son intercambiables, así que se barajan B veces, se recalcula F en cada una y

$$p = \frac{1 + \#\{b : F^{(b)} \geq F_{obs}\}}{1 + B}, \tag{1.22}$$

donde $\#\{b : F^{(b)} \geq F_{obs}\}$ es el número de permutaciones cuyo estadístico iguala o supera al observado (el símbolo # cuenta los elementos de un conjunto, como en la Ecuación 1.19) y el 1 cuenta la configuración observada. Con $B = 999$ la resolución es de una milésima.

El PERMANOVA tiene una limitación que importa en este trabajo: supone que los grupos tienen la misma dispersión y, si no es así, puede rechazar H_0 aunque los centroides coincidan, sobre todo con grupos desiguales (Anderson, 2001; Kleine Bardenhorst et al., 2021). Por eso se acompaña siempre de **PERMDISP** (Anderson, 2006), que proyecta las muestras en coordenadas principales, mide la distancia de cada una al centroide de su grupo y contrasta por permutaciones si esas distancias medias difieren. Un PERMDISP significativo con PERMANOVA no significativo dice que los grupos no se distinguen por dónde están sino por cuánto se dispersan. En microbiomas ese patrón, una mayor dispersión en el grupo enfermo, se conoce como principio de Anna Karenina: los hospederos sanos se parecen entre sí y cada enfermo se desvía a su manera (Zaneveld et al., 2017; Li et al., 2026). En R, vegan (Oksanen et al., 2022) implementa ambas pruebas en `adonis2` y `betadisper`.

1.10. Normalización y rarefacción

Hay un detalle que amenaza todo lo anterior, y para verlo conviene presentar ya los datos con los que se trabaja. El conjunto principal son 58 metagenomas *shotgun* de rizósfera de fresa proporcionados por Solena, una muestra por planta, de las cuales 40 corresponden a plantas saludables y 18 a plantas marchitas; cinco se descartan por tener muy pocas lecturas, lo que deja 53 muestras, 35 saludables y 18 no saludables (Sección 3.1.1). Cada muestra llega como un reporte de Kraken con el número de lecturas asignadas a cada uno de 9 003 taxones. Y aquí está el detalle: esas 53 muestras no tienen la misma profundidad. El número de lecturas clasificadas va de 4 a 21 millones (Capítulo 4), y esa diferencia no es biológica sino de

esfuerzo de muestreo. Una muestra con más lecturas detecta más taxones raros, así que su riqueza y su Chao1 son mayores por construcción, y una disimilitud calculada sobre conteos crudos confunde composición con tamaño. Normalizar es hacer comparables las muestras eliminando ese efecto (McMurdie and Holmes, 2014; Weiss et al., 2017); en este trabajo se usaron tres estrategias, cada una para lo que sirve.

Abundancias relativas. Dividir cada fila de la matriz de conteos (Ecuación 1.1) por su total, $a_{ij} = x_{ij}/N_i$, convierte cada muestra en un vector de proporciones. Es lo que se hizo para las disimilitudes y las ordenaciones. Shannon y Simpson dependen solo de las proporciones, así que son invariantes a este escalado y a cualquier otro; la riqueza observada y Chao1, en cambio, dependen de los conteos enteros de *singletons* y no se corrigen. Las proporciones son además datos composicionales: viven en el simplex, y el aumento de un taxón hace bajar aparentemente a los demás (Gloor et al., 2017).

Rarefacción. Para hacer comparable la riqueza hay que igualar el esfuerzo: la rarefacción submuestrea al azar, sin reemplazo, m lecturas de cada muestra, con m la profundidad de la muestra más pequeña (Hurlbert, 1971). Antes de usarla como normalización sirve como diagnóstico. Para una muestra con conteos $x_1, \ldots, x_p$ y total N, el número esperado de taxones en un submuestreo de tamaño m es

$$E[S_m] = \sum_{j=1}^{p} \left[1 - \frac{\binom{N - x_j}{m}}{\binom{N}{m}} \right], \tag{1.23}$$

donde el cociente es la probabilidad hipergeométrica de no ver el taxón j. La *curva de rarefacción* grafica $E[S_m]$ contra m: si se aplana antes de N, el muestreo está saturado y secuenciar más apenas descubriría taxones nuevos. Como normalización, rarificar descarta lecturas de las muestras profundas y añade azar, por lo que se fija una semilla. McMurdie and Holmes (2014) la criticaron por el desperdicio de datos, sobre todo para abundancia diferencial; Weiss et al. (2017) mostraron que para diversidad alfa y ordenaciones sigue siendo razonable cuando las profundidades difieren mucho entre grupos, como aquí. En R, `rarefy_even_depth` de phyloseq submuestrea y `rarecurve` de vegan calcula las curvas.

TMM. Un tercer camino, heredado del análisis de expresión génica, estima para cada muestra un factor de escala que corrige la profundidad

y también la composición. El método TMM (*trimmed mean of M-values*; Robinson and Oshlack, 2010), del paquete edgeR (Robinson et al., 2010), compara cada muestra con una de referencia mediante los logaritmos de los cocientes de proporciones taxón por taxón, recorta los más extremos para que unos pocos taxones no dominen, y toma la media ponderada de los restantes como factor. La idea es que la mayoría de los taxones no cambia entre muestras, de modo que el desplazamiento típico refleja un sesgo composicional. Como es un escalado por muestra, no altera Shannon ni Simpson; su efecto está en las comparaciones entre muestras, y por eso en este trabajo se usa solo como análisis de sensibilidad del PERMANOVA. Que una diferencia entre grupos sobreviva a las distintas formas de normalizar los datos es parte de lo que se exige antes de darla por establecida; por eso la normalización forma parte del mismo objetivo que las pruebas de hipótesis.

1.11. Redes: relaciones entre muestras y entre taxones

Los índices resumen cada muestra en un número y las disimilitudes comparan muestras de dos en dos, pero ninguna de las dos representaciones muestra cómo se relacionan los elementos de una comunidad entre sí. Para eso sirven las redes. Una *red* o *grafo* $G = (V, E)$ es un conjunto de nodos V unidos por aristas E; aquí las aristas no tienen dirección y pueden llevar un peso. En ecología microbiana se usan dos tipos (Berry and Widder, 2014). En una *red de muestras* los nodos son muestras y dos se unen si su disimilitud está por debajo de un umbral; sirve para ver si las muestras de un grupo forman una comunidad separada. En una *red de coocurrencia* los nodos son taxones y dos se unen si sus abundancias varían de forma coordinada a lo largo de las muestras, es decir, si su correlación supera un umbral en valor absoluto; sirve para preguntar qué taxones acompañan a un taxón de interés.

Unas pocas cantidades describen la forma de una red: el *grado* de un nodo es su número de vecinos; la *densidad*, la fracción de pares de nodos unidos; el *componente gigante*, el mayor conjunto de nodos conectados entre sí por algún camino; el *coeficiente de agrupamiento*, la frecuencia con que dos vecinos de un nodo son también vecinos entre sí; la *modularidad* (New-

man, 2003), cuánto se divide la red en módulos con muchas aristas internas y pocas hacia afuera, que el algoritmo de Louvain (Blondel et al., 2008) maximiza; y la *asortatividad* por una etiqueta, como el estado de la planta, que vale cerca de 1 si las aristas unen nodos del mismo grupo y cerca de 0 si la etiqueta no importa. El trazado de una red por fuerzas (Fruchterman and Reingold, 1991) parte de posiciones aleatorias, por lo que se fija una semilla.

Las redes de coocurrencia tienen una trampa propia de la metagenómica: como las abundancias son relativas, el aumento de un taxón hace bajar la proporción de los demás y una correlación ordinaria produce asociaciones negativas espurias. SparCC (Friedman and Alm, 2012) evita el problema al estimar las correlaciones sobre logaritmos de cocientes entre taxones, que no dependen del total; es el método de MicNet (Favila et al., 2022) y el que se usa en este trabajo, con igraph (Csardi and Nepusz, 2006) para construir las redes y calcular sus métricas. Estas redes describen asociación, no causa: una arista dice que dos taxones varían juntos, no que uno influya en el otro. Dar ese paso es lo que propone el Capítulo 6 con redes bayesianas. Unas y otras responden a la tercera tarea del trabajo: una vez descritas y contrastadas las comunidades, *buscar los patrones* de taxones y de relaciones entre taxones que acompañan al estado de la planta, con *Fusarium* como punto de partida. Describir, contrastar, buscar patrones y enseñar el análisis son, en ese orden, los objetivos que formula el capítulo siguiente.

Capítulo 2

Objetivos

2.1. Objetivo general

Caracterizar y comparar la composición y diversidad del microbioma rizosférico de plantas de fresa saludables y no saludables mediante el análisis estadístico de datos metagenómicos, con el fin de identificar patrones asociados con el estado de salud de las plantas.

2.2. Objetivos específicos

1. Caracterizar la composición taxonómica y la diversidad microbiana de las muestras de rizósfera de plantas saludables y no saludables, mediante métricas de diversidad alfa y beta a diferentes niveles taxonómicos.

2. Evaluar estadísticamente las diferencias entre los microbiomas de plantas saludables y no saludables, utilizando pruebas de hipótesis y métodos de normalización apropiados para los datos metagenómicos.

3. Identificar patrones taxonómicos y de estructura de la comunidad microbiana asociados con el estado de salud de las plantas, explorando taxones diferenciales y las relaciones entre los microorganismos.

4. Diseñar una clase práctica y didáctica, en forma de cuaderno ejecutable de acceso abierto, que conduzca al entendimiento del análisis

estadístico realizado en este trabajo: la formulación de pruebas de hipótesis, las pruebas t, de Welch, de Mann-Whitney y de Wilcoxon, el PERMANOVA y la comparación de proporciones de *Fusarium* entre plantas saludables y no saludables, aplicados sobre los mismos datos del estudio.

Capítulo 3

Análisis Exploratorio de Datos, metodología

El propósito de este análisis es identificar características que diferencien al microbioma rizosférico de las plantas de fresa saludables del de las no saludables, a partir de datos metagenómicos. Es la pregunta con la que cerró el Capítulo 1 y que el Capítulo 2 desdobló en cuatro objetivos: caracterizar la composición y la diversidad de las comunidades, contrastar estadísticamente las diferencias entre grupos, identificar patrones taxonómicos y de estructura asociados con el estado de la planta, y convertir el análisis en una clase práctica. Este capítulo describe cómo se abordaron los tres primeros; el cuarto se presenta con los resultados (Yang et al., 2020).

El trabajo se organizó en etapas que el capítulo recorre en orden. En la primera se obtuvo el conjunto de datos principal, 58 metagenomas de rizósfera de fresa proporcionados por la empresa Solena, y se sometió a un preprocesamiento exhaustivo en Bash y R que terminó con un filtro de calidad. Sobre los datos ya preparados, el análisis exploratorio se estructuró en tres partes: primero se exploraron las diversidades alfa y beta a distintos niveles taxonómicos, seguidas de un análisis estadístico respaldado por pruebas de hipótesis, por análisis multivariado por permutaciones y por una evaluación de la sensibilidad a la normalización; en segundo lugar se examinaron las relaciones entre muestras y entre taxones mediante redes; y, en tercer lugar, se incorporaron dos conjuntos de datos complementarios que sitúan la comparación entre plantas saludables y marchitas frente a la

variación entre tipos de suelo. Este enfoque busca no solo una descripción detallada de la composición de los microbiomas, sino también patrones en la presencia, la abundancia y la estructura de la comunidad que ayuden a distinguir la salud de la enfermedad en el cultivo. Los resultados de cada etapa se presentan en el Capítulo 4.

3.1. Métodos para caracterización de la diversidad microbiana

3.1.1. Conjunto de datos principal

El conjunto principal consta de 58 metagenomas *shotgun* de rizósfera de fresa (*Fragaria* × *ananassa*) proporcionados por Solena Ag, una empresa de biotecnología agrícola dedicada al análisis del microbioma del suelo, con Obed Ramírez Sánchez como contacto. Cada muestra proviene de la rizósfera de una planta distinta y lleva una sola etiqueta: 40 plantas estaban saludables y 18 presentaban marchitez. Esa etiqueta, saludable o no saludable, es la única variable explicativa del estudio, y la pregunta que atraviesa todo el trabajo es si el microbioma permite distinguirla.

Los identificadores de muestra llevan la etiqueta incorporada: las 40 plantas saludables se nombran `MP` seguido de un número (`MP2047`, ..., `MP2140`) y las 18 marchitas `MD` (`MD2055`, ..., `MD2136`). Los metadatos entregados contienen únicamente ese identificador y la etiqueta; no se dispone de información sobre lotes, fechas de muestreo, localización de las plantas ni prácticas de manejo, de modo que esas fuentes de variación no pueden controlarse en el análisis y toda diferencia o ausencia de diferencia entre grupos debe leerse con esa limitación en mente.

Los datos son metagenomas *shotgun*: se secuenció el ADN total extraído de la rizósfera, sin amplificar un gen marcador como el 16S o el ITS, lo que permite ver a la vez bacterias, hongos y otros eucariotas. La secuenciación fue de extremos pareados, con lecturas de entre 111 y 127 pares de bases tras el recorte de calidad. Solena realizó por su cuenta las dos primeras etapas del procesamiento y entregó sus productos. La primera es el control de calidad con fastp (Chen et al., 2018), que elimina adaptadores, bases ambiguas y lecturas cortas o de baja calidad; en las muestras que superan el filtro, el 97 % de las bases conserva una calidad Phred superior a 30 y

la duplicación es de apenas el 3 %. Cada muestra pasó de una mediana de 118 millones de lecturas crudas a 98 millones tras fastp. La segunda es la clasificación taxonómica con Kraken 2 (Wood and Salzberg, 2014), que asigna cada lectura al taxón más específico compatible con sus k-mers dentro de la jerarquía del NCBI. Solo entre el 25 % y el 35 % de las lecturas de cada muestra encuentra coincidencia en la base de referencia, una proporción normal en suelos, donde buena parte de los microorganismos no tiene genoma secuenciado; el resto queda sin clasificar y no interviene en el análisis. Quedan así entre 4 y 21 millones de lecturas clasificadas por muestra (Figura 4.2).

Lo que recibió este trabajo fueron, por tanto, tres cosas por muestra: el reporte de calidad de fastp, el reporte de Kraken con el número de lecturas asignadas a cada taxón de la jerarquía, y la etiqueta de la planta. No se trabajó con las lecturas crudas, sino con su clasificación. Reunidos los 58 reportes, la tabla de abundancias contiene 9 003 taxones, 8 822 de Bacteria y 181 de Eukaryota; esa desproporción refleja tanto el predominio bacteriano de los suelos como la menor representación de hongos y oomicetos en la base de referencia, y es la razón por la que la fracción eucariota, que incluye a *Fusarium*, se analiza por separado en varios puntos del trabajo.

Dos rasgos de este conjunto condicionan todo lo que sigue. El primero es el desbalance: hay más del doble de plantas saludables que marchitas, lo que reduce la potencia de cualquier comparación y obliga a usar pruebas que no supongan varianzas iguales. El segundo es que la profundidad varía cinco veces entre la muestra más pequeña y la más grande, con cinco muestras muy por debajo del resto; de ahí el filtro de calidad de la Sección 3.1.3, que reduce el conjunto a 53 muestras, 35 saludables y 18 no saludables, y la atención a la normalización de la Sección 3.2.5. Los archivos del conjunto están documentados en el Apéndice B.

3.1.2. Preprocesamiento

Los reportes de Kraken descritos en la sección anterior no se pueden analizar tal como llegan: son 58 archivos de texto independientes, uno por muestra, y la etiqueta de cada planta está en otro archivo. Antes de calcular cualquier índice hubo que reunirlos en una sola estructura de datos consistente. Ese proceso de preparación se describe aquí como un flujo ETL,

siglas en inglés de *Extract, Transform, Load* (extraer, transformar, cargar), el esquema habitual en ingeniería de datos para llevar información desde sus fuentes originales hasta el formato en que se analiza: primero se extraen los datos de donde están, después se transforman para limpiarlos, unificarlos y darles estructura, y por último se cargan en el sistema donde se van a usar. La Figura 3.1 resume las tres etapas tal como se aplicaron en este trabajo; el código está en los scripts que indica su leyenda.

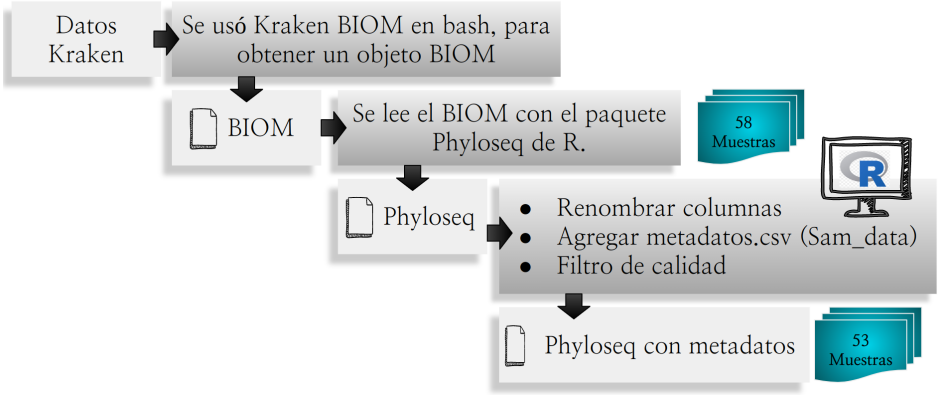


Figura 3.1: Flujo de trabajo del preprocesamiento, de los reportes de Kraken al objeto phyloseq con metadatos y filtro de calidad: extracción de los reportes, transformación a una tabla BIOM y carga en R. Diagrama de elaboración propia; el código correspondiente está en 01_Exploracion.Rmd y 20230130_PreprocesamientoDatos.R.

Extracción. Solena entregó los resultados en una carpeta compartida con tres archivos comprimidos: los reportes de Kraken, los de Bracken y los de fastp, además del archivo de metadatos. Se descargaron, se copiaron al servidor de cómputo del Centro de Ciencias Matemáticas y se descomprimieron desde Bash. En ese punto los datos ya estaban en el entorno de trabajo, pero seguían siendo 58 reportes separados, con nombres de archivo largos (`MD2055.kraken2.report`) y cada uno con su propia lista de taxones.

Transformación. Esta es la etapa que más trabajo exige, porque es donde los datos cambian de forma. Con la herramienta kraken-biom (Dabdoub, 2016), ejecutada desde Bash en un entorno de conda, los 58 reportes

se combinaron en una única matriz en formato BIOM (McDonald et al., 2012): una fila por taxón, una columna por muestra y, en cada celda, el número de lecturas asignadas. El BIOM guarda además, para cada taxón, su linaje completo desde el reino hasta la especie. Una vez en R, la tabla necesitó cuatro ajustes para quedar lista. Primero, las columnas de la tabla de taxonomía, que kraken-biom numera genéricamente, se renombraron con los niveles taxonómicos (`Kingdom`, `Phylum`, ..., `Species`). Segundo, se eliminó el prefijo de tres caracteres que Kraken antepone a cada nombre (`k__`, `p__`, etc.), para que los taxones aparezcan por su nombre en figuras y tablas. Tercero, los nombres de muestra se acortaron a su identificador de seis caracteres (`MD2055`, `MP2047`), que es el que usan los metadatos. Cuarto, se leyó el archivo de metadatos, se verificó que cada identificador de muestra tuviera una etiqueta y se unieron ambas tablas por ese identificador, de modo que a cada columna de conteos le correspondiera su estado, saludable o no saludable. Esta verificación es importante: un emparejamiento por posición en lugar de por nombre fue, de hecho, el origen de un error que se detectó y corrigió más adelante en el trabajo (Capítulo 4).

Carga. El destino de los datos es un objeto phyloseq (McMurdie and Holmes, 2013), la estructura de R descrita en la Sección 1.5 que mantiene unidas la tabla de conteos, la tabla de taxonomía y los metadatos de las muestras. La función `import_biom` lee el archivo BIOM y construye las dos primeras; los metadatos se añaden como tercer componente. A partir de ese objeto se calcularon todos los índices, distancias, pruebas y figuras de los capítulos siguientes, y de él se derivan los subconjuntos por reino y por nivel taxonómico. El objeto contiene las 58 muestras originales; la Tabla 3.1 lista cuántas lecturas clasificadas tiene cada una, obtenidas con `sample_sums`, y anticipa el último paso del preprocesamiento, el filtro de calidad, que se describe en la sección siguiente.

```
sample_sums(fresa_kraken)
```

Tabla 3.1: Lecturas clasificadas por Kraken en cada una de las 58 muestras originales, obtenidas con `sample_sums`. En negrita, las cinco muestras eliminadas por el filtro de calidad (menos de 25 millones de lecturas tras fastp). (Script: `01_Exploracion.Rmd`)

MD2055	MD2056	MD2065	MD2066	MD2075	MD2076	MD2085	MD2086
9 782 432	12 468 526	11 297 600	15 580 959	12 310 781	16 067 839	10 524 919	9 931 297
MD2095	MD2096	MD2105	MD2106	MD2115	MD2116	MD2125	MD2126
18 009 912	14 998 268	11 792 397	4 053 295	13 102 554	12 451 637	8 355 853	14 307 309
MD2135	MD2136	MP2047	MP2048	MP2049	MP2050	MP2057	MP2058
7 280 751	6 172 369	9 199 079	12 146 967	13 075 806	16 098 757	17 141 427	20 923 502
MP2059	MP2060	MP2067	MP2068	MP2069	MP2070	MP2077	MP2078
14 129 981	13 786 630	16 924 218	20 873 789	15 537 530	12 462 356	9 617 847	7 588 787
MP2079	**MP2080**	MP2087	**MP2088**	MP2089	MP2090	MP2097	MP2098
745 830	**3 125 701**	20 632 320	**2**	16 582 404	11 176 782	11 714 000	16 595 897
MP2099	MP2100	MP2107	MP2108	**MP2109**	MP2110	MP2117	MP2118
14 844 038	13 342 326	11 014 462	6 728 020	**1 405 462**	6 901 265	12 624 002	14 711 376
MP2119	MP2120	MP2127	MP2128	MP2129	MP2130	**MP2137**	MP2138
9 835 326	10 975 712	7 106 567	9 974 861	8 348 307	6 196 725	**2 169 734**	8 220 431
MP2139	MP2140						
6 158 581	5 267 510						

3.1.3. Filtrado de calidad

A través de Solena, obtuvimos una tabla generada con fastp (Chen et al., 2018) que refleja la calidad de las muestras (fastp.kraken.summary). Esta información es crucial para determinar qué muestras pueden ser eliminadas de nuestro conjunto de datos, ya que no cumplen con ciertos estándares de calidad. La identificación y exclusión de muestras que no cumplen con estos criterios contribuirá a asegurar la integridad y la confiabilidad de nuestro dataset, garantizando que solo las muestras de alta calidad sean consideradas en el análisis subsiguiente. El criterio para eliminar muestras es que, después del filtrado de calidad, contengan menos de 25 millones de lecturas. Como ejemplo, la muestra MD2055 inicialmente tiene 97 millones de lecturas antes del filtrado, y después del análisis de calidad queda con 79 millones.
Esta tabla proporciona información detallada sobre la calidad de las muestras, destacando diversos parámetros clave:

- **ID de la muestra:** Identificación única de la muestra.

- **Reads_B (Reads_Before):** Número total de lecturas crudas antes del análisis de calidad.
- **Reads_A (Reads_After):** Número total de lecturas después del análisis de calidad.
- **Reads_diff:** Diferencia entre Reads_B y Reads_A.
- **Q30_B:** Porcentaje de lecturas con calidad superior a 30 (escala fred) antes del análisis de calidad.
- **Q30_A:** Porcentaje de lecturas con calidad superior a 30 después del análisis de calidad.
- **LowQua:** Lecturas de baja calidad.
- **N_reads:** Lecturas que contienen 'N' y son descartadas.
- **too_short:** Lecturas que no cumplen con el tamaño mínimo de calidad.
- **Duplication:** Porcentaje de duplicados.
- **LengthR1:** Longitud promedio de las lecturas en la muestra.
- **LengthR2:** Longitud promedio de las lecturas en la muestra.
- **Classified:** Porcentaje de lecturas clasificadas del total después del filtrado.

Este enfoque de eliminación se basa en mantener un umbral mínimo de calidad. Las columnas de la tabla provienen del reporte de fastp (Chen et al., 2018), que es la herramienta habitual para el control de calidad de lecturas cortas, y el número de lecturas que sobreviven a ese filtro es el indicador más directo de cuánta información aporta cada muestra. Eliminar las muestras con muy pocas lecturas no es un detalle cosmético: la riqueza observada y Chao1 crecen con la profundidad de secuenciación, de modo que una muestra con un conteo muy bajo aparece como artificialmente pobre y distorsiona cualquier comparación entre grupos (Sección 1.10; McMurdie and Holmes, 2014; Weiss et al., 2017). En este conjunto el caso extremo es la muestra MP2088, que conservó únicamente dos lecturas

(Tabla 3.1). El efecto del filtro se aprecia en la Figura 4.1: antes de aplicarlo, las muestras de baja profundidad dominan la escala de los índices y ocultan las diferencias entre grupos; después, la comparación es legible. Fijar un umbral de profundidad y documentar qué muestras se excluyen es práctica recomendada en el análisis de datos de microbioma (Xia et al., 2018; Kleine Bardenhorst et al., 2021). El umbral de 25 millones de lecturas tras fastp deja fuera a cinco muestras, con entre 0 y 24 millones de lecturas, y conserva 53, la menor de ellas con 39 millones; la muestra excluida más cercana al umbral, MP2080, está en cualquier caso lejos de la mediana del conjunto, que es de 98 millones.

3.1.4. Índices de diversidad

Aplicamos índices de diversidad alfa para comprender la estructura de la distribución de la abundancia relativa de las especies en el seno de una población o comunidad biológica. En este contexto, realizamos un análisis de diversidad de nuestras muestras, empleando dos métricas fundamentales: la Diversidad Alfa y la Diversidad Beta (Tuomisto, 2010b). Estas métricas nos permitirán explorar y comprender tanto la variabilidad interna de una sola comunidad como las diferencias entre varias comunidades, respectivamente.

Diversidad Alfa

Para explorar la diversidad alfa de las muestras utilizamos los índices Chao1, Shannon y Simpson, descritos en la Sección 1.7.1, ya que en conjunto capturan tanto la riqueza de especies como su abundancia y dominancia relativa.

Los índices se calcularon con las funciones `estimate_richness` y `plot_richness` de Phyloseq, aplicadas sobre el objeto `fresa_kraken` tanto en los datos crudos como en los datos con filtro de calidad, agrupando y coloreando las muestras según el tratamiento (sana o enferma) para poder comparar visualmente ambos grupos.

```
index = estimate_richness(fresa_kraken_fil)
plot_richness(physeq = fresa_kraken_fil,
```

```
measures = c("Observed","Chao1","Shannon","
    ↪ Simpson"),
x = "Treatment", color = "Treatment")
```

Diversidad Beta

La diversidad beta se encarga de evaluar cuán similares o diferentes son un par de especies, muestras, conjuntos de muestras o poblaciones entre sí. Fue definida por Whittaker como una medida del cambio de diversidad a traves de gradientes ambientales, en otras palabras "tasa de cambio en la composisión de especies de una comunidad a otra a los largo de gradientes"(Whittaker, 1960). Para medir esta diversidad, se utilizan métricas como la disimilitud de Bray-Curtis, la distancia Jaccard o la distancia UniFrac.

Antes de realizar análisis de diversidad beta, es crucial convertir las abundancias absolutas (número de lecturas por OTU) a relativas (porcentajes de lecturas asignadas a un OTU dentro de una muestra). Esta transformación es esencial debido a que los metagenomas tienen tamaños diferentes. Se lleva a cabo el cálculo de las abundancias relativas utilizando la función 'transform_sample' de Phyloseq, tanto para los datos originales como para los datos filtrados.

Este paso es fundamental para garantizar una comparación y evaluación adecuada de la diversidad beta, ya que las abundancias relativas proporcionan una representación más precisa de la estructura de la comunidad, independientemente de las diferencias en el tamaño del metagenoma entre las muestras.

```
transform_sample_counts(fresa_kraken_fil,
function(x) x*100/sum(x) )
```

Usamos “ordinate” para asignar las distancias entre muestras, iniciando y tomando como referencia “Bray-Curtis”, ya que es una de las metricas mas completas y mayormente utilizadas para medir la diversidad beta.

Para visualizar y presentar los resultados de este análisis, se opta por el uso de NMDS (Non-metric Multidimensional Scaling; Kruskal, 1964), una herramienta de análisis exploratorio de datos que se emplea para visualizar la similitud o disimilitud entre una colección de objetos (por ejemplo, especies, sitios, genes) en un espacio de baja dimensionalidad. Entre otros, se utilizan ampliamente los análisis PCA, PCoA (Gower, 1966) o NMDS.

Tomando los datos con filtro de calidad y utilizando la disimilitud de Jaccard cuantitativa (Ecuación 1.7), que junto con Bray-Curtis es una de las medidas de uso más extendido para comparar la composición de comunidades microbianas entre muestras (Legendre and Legendre, 2012; Kleine Bardenhorst et al., 2021), se observa que las muestras, tanto sanas como enfermas, están bastante mezcladas. Ante esta observación, se procede a realizar pruebas con distintas distancias para explorar si alguna otra métrica puede proporcionar una separación más clara o revelar patrones específicos en la composición de especies entre las muestras.

Estas métricas ofrecen diferentes perspectivas sobre la similitud o disimilitud entre muestras, permitiendo seleccionar la más apropiada según el contexto del estudio y los objetivos específicos del análisis de diversidad beta.

Aplicamos la siguiente lista de distancias disponibles en Phyloseq : **Disimilitud de Bray-Curtis**, **Distancia Jaccard**, **Euclideana**, **Manhattan**, **Divergencia de Jensen-Shannon (JSD)**, y la metrica de **UniFrac**

3.1.5. Exploración a distintos niveles taxonómicos

Podemos visualizar las barras de abundancia absolutas y relativas de nuestros datos representando las muestras en el eje x y las abundancias en el eje y, diferenciando entre muestras sanas y enfermas.

3.2. Prueba de Hipótesis

En este estudio se busca contrastar si existen diferencias de diversidad, medidas a través del índice de Shannon, entre las muestras saludables y no saludables, tanto a nivel general de la comunidad microbiana como a nivel de género dentro de los eucariotas. Las definiciones formales de H_0, H_1, el estadístico de prueba, la región de rechazo y el p-valor se presentaron en el Capítulo 1, Sección 1.8, por lo que aquí no se redefinen y solo se retoman para su aplicación directa sobre los datos.

Todas las pruebas se realizaron con un nivel de significancia $\alpha = 0{,}05$, utilizando el lenguaje R (R Core Team, 2023) y las funciones `t.test`, `var.test` y `wilcox.test`. El orden de aplicación fue el del propio trabajo: en la fase exploratoria se aplicó primero la prueba t clásica; después se verificaron sus supuestos, la normalidad con Shapiro-Wilk y la homogeneidad de varianzas con la prueba F, y como no se cumplieron se adoptaron la prueba de Welch y la alternativa no paramétrica de Wilcoxon-Mann-Whitney como pruebas principales, conservando el resultado exploratorio como referencia.

3.2.1. Prueba t de Student sobre el índice de Shannon

Se contrasta la hipótesis nula

$$H_0 : \mu_{\text{saludable}} = \mu_{\text{no saludable}} \tag{3.1}$$

frente a la alternativa $H_1 : \mu_{\text{saludable}} \neq \mu_{\text{no saludable}}$, usando el estadístico T definido en la Ecuación 1.13. Esta prueba se aplicó en dos escenarios: (a) sobre el índice de Shannon calculado a nivel general de la comunidad microbiana, y (b) sobre el índice de Shannon calculado a nivel de género dentro de los eucariotas, grupo que incluye a los hongos fitopatógenos de interés como *Fusarium*. En la fase exploratoria se aplicó primero la versión clásica de la prueba, con varianzas iguales; después de verificar los supuestos con las pruebas de Shapiro-Wilk y F (Sección 3.2.4) se adoptó la prueba de Welch (Ecuación 1.14) como prueba principal, y el resultado exploratorio se conservó como referencia para mostrar el efecto del supuesto.

3.2.2. Prueba F sobre las varianzas

Antes de decidir la forma del estadístico T (varianzas iguales o distintas) es necesario verificar el supuesto de homogeneidad de varianzas entre los dos grupos. Para ello se aplicó la prueba F, contrastando $H_0 : \sigma_1^2 = \sigma_2^2$ frente a $H_1 : \sigma_1^2 \neq \sigma_2^2$. El resultado de esta prueba determina si la prueba t del apartado anterior debe calcularse asumiendo varianzas iguales o varianzas diferentes.

3.2.3. Prueba de Wilcoxon-Mann-Whitney

Cuando el supuesto de normalidad de los datos no se cumple, la prueba t deja de ser apropiada y se recurre a su alternativa no paramétrica: la prueba de suma de rangos de Wilcoxon-Mann-Whitney (Mann and Whitney, 1947), que compara las distribuciones del índice de Shannon entre los grupos saludable y no saludable sin asumir normalidad.

Los resultados obtenidos al aplicar estas tres pruebas sobre los datos se presentan en el Capítulo 4.

3.2.4. Análisis complementarios

La normalidad del índice de Shannon en cada grupo se verificó con la prueba de Shapiro-Wilk (Shapiro and Wilk, 1965). Para contrastar si la composición global de la comunidad difiere entre grupos se aplicó un análisis de varianza multivariado por permutaciones (PERMANOVA; Anderson, 2001; Anderson et al., 2011), descrito en la Sección 1.9, sobre las matrices de disimilitud de Bray-Curtis y de Jaccard cuantitativo de las abundancias relativas, con 999 permutaciones, mediante la función `adonis2` del paquete vegan (Oksanen et al., 2022). Como el PERMANOVA es sensible a diferencias de dispersión entre grupos desbalanceados, se acompañó de la prueba de homogeneidad de dispersiones PERMDISP (Anderson, 2006), con la función `betadisper` y 999 permutaciones. El script correspondiente es `20260930_RegenerarPermanovaPermdisp44.R`, en la carpeta de análisis del repositorio. Todos los procedimientos con componente aleatoria de este trabajo, las ordenaciones NMDS y las pruebas por permutaciones, se ejecutaron con la semilla `set.seed(2026)`, de modo que las figuras y los valores p reportados son reproducibles exactamente con los scripts del repositorio.

Finalmente, se calcularon el tamaño del efecto estandarizado (d de Cohen) y la potencia de la prueba t con la función `power.t.test` (Cohen, 1988; Xia et al., 2018).

3.2.5. Normalización y rarefacción

Desde un punto de vista matemático, los datos metagenómicos pueden representarse como una matriz de conteos:

$$X = (x_{ij}) \in \mathbb{N}^{n \times p}, \tag{3.2}$$

donde n es el número de muestras, p el número de taxones y x_{ij} el número de lecturas asignadas al taxón j en la muestra i. Como las muestras tienen distinta profundidad de secuenciación, se emplearon tres estrategias de normalización, descritas en la Sección 1.10, cada una con un propósito distinto.

Abundancias relativas. Para la diversidad beta, las ordenaciones NMDS y el PERMANOVA se transformaron los conteos a abundancias relativas por muestra,

$$a_{ij} = \frac{x_{ij}}{\sum_{k=1}^{p} x_{ik}}, \quad \sum_{j=1}^{p} a_{ij} = 1, \tag{3.3}$$

que pertenecen al simplex composicional

$$S^{p-1} = \left\{ x \in \mathbb{R}_{+}^{p} : \sum_{j=1}^{p} x_j = 1 \right\}. \tag{3.4}$$

Esta transformación se hizo con la función `transform_sample_counts` de phyloseq. Los índices de Shannon y Simpson son invariantes ante ella, por lo que la diversidad alfa de las Secciones 4.1 y 4.2 se calculó directamente sobre los conteos filtrados.

Rarefacción. Se usó con dos fines. Primero, como diagnóstico de saturación: se calcularon las curvas de rarefacción de las 53 muestras filtradas con la función `rarecurve` de vegan, en pasos de 200 000 lecturas, y se evaluó qué fracción de la riqueza observada de cada muestra se alcanza ya a la profundidad de la muestra más pequeña. Segundo, como normalización:

con `rarefy_even_depth` de phyloseq se submuestrearon sin reemplazo todas las muestras a la profundidad mínima del conjunto filtrado, 4 053 295 lecturas (muestra MD2106), con la semilla 2026. Sobre los datos rarificados se recalcularon los cuatro índices de diversidad alfa y se repitieron la prueba F, la prueba de Welch y la de Mann-Whitney, con el fin de comprobar si la tendencia observada en los datos originales depende de la diferencia de profundidad entre grupos.

Normalización TMM. Se calcularon los factores de escala TMM con la función `calcNormFactors` del paquete edgeR (Robinson et al., 2010) y se obtuvieron los conteos normalizados dividiendo cada muestra por su tamaño de biblioteca efectivo. Como TMM no altera los índices de diversidad alfa, su efecto se evaluó donde sí puede influir: se repitió el PERMANOVA sobre la disimilitud de Bray-Curtis con tres versiones de la tabla, abundancias relativas, conteos normalizados por TMM y conteos rarificados, como análisis de sensibilidad de la conclusión sobre la composición. El script correspondiente es `20261001_RegenerarRarefaccionNormalizacion416.R`; los resultados se presentan en la Sección 4.2.6.

3.3. Análisis de redes: similitud entre muestras y coocurrencia de taxones

Los índices de diversidad resumen cada muestra en un número y las ordenaciones muestran las muestras como puntos; ninguna de las dos representaciones dice cómo se relacionan los elementos entre sí. Con las definiciones de la Sección 1.11, en este trabajo se exploraron dos tipos de redes: las *redes de muestras*, en las que los nodos son las 53 muestras y dos muestras se unen si su composición es parecida, y las *redes de coocurrencia*, en las que los nodos son taxones y dos taxones se unen si sus abundancias varían de forma coordinada a lo largo de las muestras (Berry and Widder, 2014). Las primeras sirven para preguntar si las muestras saludables y no saludables forman comunidades separadas; las segundas, para preguntar qué taxones acompañan a un taxón de interés, en este caso *Fusarium*. Ambas se construyeron sobre los datos filtrados de la Sección 3.1.3 y los scripts que las regeneran son `20261002_RegenerarRedesMuestras32.R` y `20261002_RegenerarRedesCoocurrencia33.R`.

3.3.1. Redes de muestras

Con la función `make_network` de phyloseq (McMurdie and Holmes, 2013) se construyó un grafo en el que cada nodo es una muestra y existe una arista entre dos muestras cuando su disimilitud de Jaccard cuantitativa (Ecuación 1.7), calculada sobre abundancias relativas, no supera un umbral $d_{\text{máx}}$. El grafo se dibujó con `plot_network` y `plot_net`, usando el trazado de Fruchterman-Reingold de igraph (Csardi and Nepusz, 2006), con la semilla 2026, y coloreando los nodos por tratamiento. Los umbrales de la exploración original, 0.8 y 0.5, resultaron inútiles con estos datos: la disimilitud de Jaccard entre las 53 muestras va de 0.08 a 0.47, de modo que ambos umbrales producen el grafo completo de 1 378 aristas. Por eso los umbrales se fijaron a partir de la distribución de las distancias: $d_{\text{máx}} = 0{,}16$ conserva el 25 % de los pares más parecidos y $d_{\text{máx}} = 0{,}13$ el 10 %. Para cuantificar si las muestras del mismo grupo tienden a conectarse entre sí se calculó la fracción de aristas que unen muestras del mismo tratamiento y se comparó con la fracción esperada si las etiquetas se repartieran al azar, mediante una prueba de permutación con 999 barajadas.

La Figura 3.2 muestra el resultado. En ambos umbrales las muestras saludables y no saludables aparecen entremezcladas en un solo componente, sin subgrupos por tratamiento. La fracción de aristas que unen muestras del mismo grupo fue de 55.6 % con el umbral de 0.16 y de 52.2 % con el de 0.13, frente a un 54.3 % esperado por azar; la prueba de permutación no detecta asortatividad por grupo ($p = 0{,}34$ y $p = 0{,}60$). Es decir, una muestra saludable no tiene más probabilidad de parecerse a otra saludable que a una no saludable, lo que coincide con el PERMANOVA del Capítulo 4. Sí se observa un detalle que anticipa el patrón de heterogeneidad: la disimilitud media entre pares de muestras saludables es de 0.199, mientras que entre pares de muestras no saludables es de 0.255, y entre grupos de 0.227. Las plantas saludables se parecen más entre sí que las no saludables, que es lo que la prueba PERMDISP confirma formalmente.

3.3.2. Redes de coocurrencia

Para construir redes entre taxones no basta con calcular correlaciones ordinarias entre abundancias relativas: como las proporciones de cada muestra suman uno, dos taxones no relacionados muestran correlaciones negati-

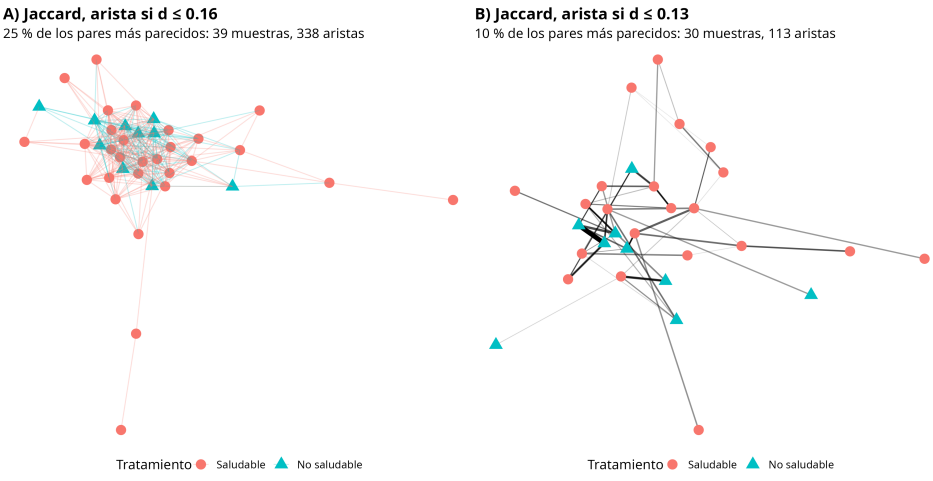


Figura 3.2: Redes de muestras construidas con la disimilitud de Jaccard cuantitativa. Cada nodo es una muestra, coloreada por tratamiento, y cada arista une dos muestras cuya disimilitud no supera el umbral. A) Umbral $d \leq 0{,}16$, que conserva el 25 % de los pares más parecidos: 39 muestras conectadas y 338 aristas. B) Umbral $d \leq 0{,}13$, el 10 % de los pares: 30 muestras y 113 aristas; el grosor de la arista indica la distancia. En ninguna de las dos los colores se separan. (Script: `20261002_RegenerarRedesMuestras32.R`)

vas espurias, y las correlaciones positivas pueden deberse a cambios en un tercer taxón (Gloor et al., 2017). SparCC (Friedman and Alm, 2012) estima la correlación entre taxones a partir de las razones logarítmicas entre pares, lo que elimina el efecto de la suma constante, bajo el supuesto de que la mayoría de los pares no están correlacionados. Se usó la herramienta MicNet (Favila et al., 2022), que recibe la tabla de abundancias aglomerada a nivel de género, 1 795 géneros, y realiza tres pasos: una reducción de dimensión con UMAP (McInnes et al., 2018) seguida de agrupamiento con HDBSCAN, que asignó los géneros a 32 grupos y dejó 501 sin asignar; el cálculo de la matriz de correlaciones SparCC entre los 1 795 géneros; y la construcción de la red. Las matrices de salida de MicNet, obtenidas en marzo de 2023, se conservan en el repositorio y son la entrada de la figura que sigue. La red reportada por MicNet con su umbral por defecto tenía 845 248 aristas y una densidad de 0.53, es decir, era casi completa; para obtener una red legible se fijó aquí el umbral $|r| \geq 0{,}8$, que conserva 7 757 aristas entre 650 géneros, y se analizó su componente gigante con igraph.

Como análisis complementario centrado en *Fusarium*, se usó la herramienta Alnitak (Laboratorio de la Dra. Nelly Sélem Mojica, 2023), desarrollada en el laboratorio de la Dra. Nelly Sélem Mojica, que calcula los vecinos de un taxón de interés contra el resto de la tabla completa, no aglomerada, y conserva únicamente los pares con correlación de Spearman mayor o igual a 0.7 y disimilitud de Bray-Curtis menor o igual a 0.3, con valores p ajustados por permutación.

La Figura 3.3 resume los tres resultados. La red de géneros (panel A) tiene una estructura modular clara: con $|r| \geq 0{,}8$ el componente gigante reúne 482 géneros con un coeficiente de agrupamiento de 0.69 y una modularidad de 0.55, y sus módulos coinciden en buena medida con los filos, con Actinobacteria, Proteobacteria y Planctomycetes formando bloques casi separados. Al bajar el umbral la red se vuelve rápidamente densa: con $|r| \geq 0{,}5$ hay 94 455 aristas entre 1 357 géneros y la modularidad cae a 0.34. La Tabla 3.2 resume estas métricas. Que los módulos sigan a la taxonomía indica que la coocurrencia entre géneros cercanos está dominada por su detección conjunta, es decir, por lecturas que Kraken reparte entre géneros del mismo linaje, más que por interacciones ecológicas.

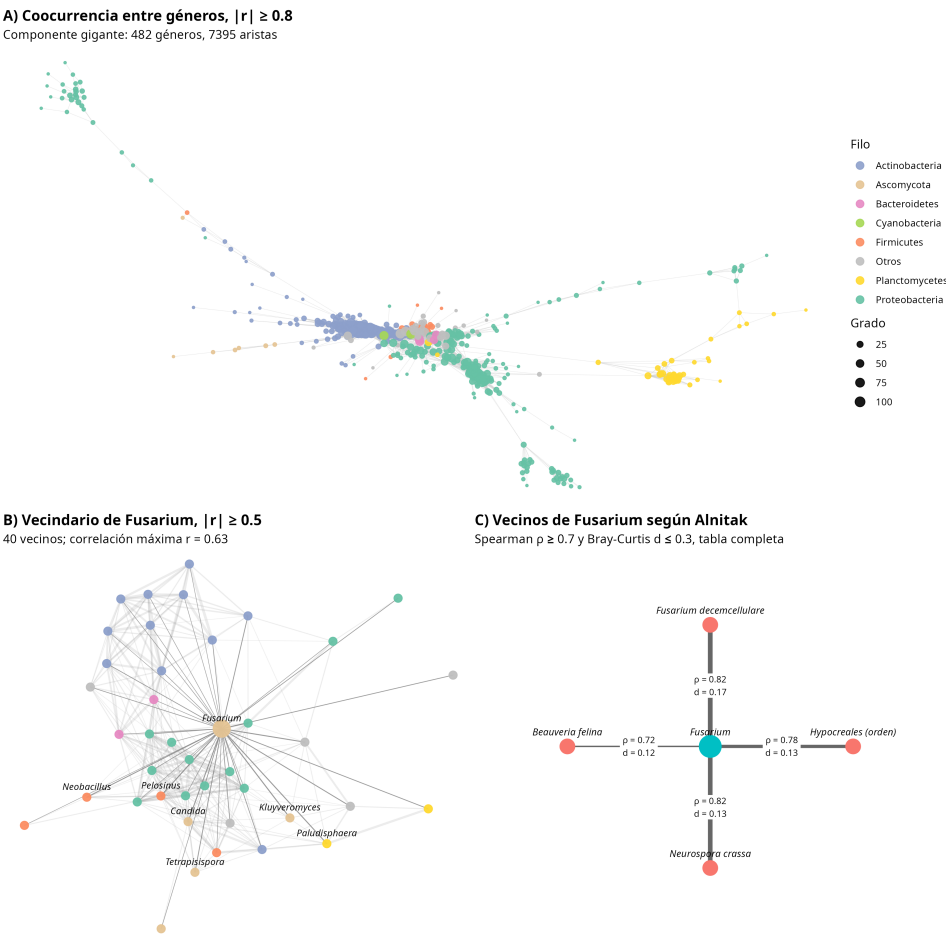


Figura 3.3: Redes de coocurrencia entre taxones. A) Componente gigante de la red de géneros con correlación SparCC $|r| \geq 0{,}8$: 482 géneros y 7 395 aristas; el color indica el filo y el tamaño el número de vecinos. Los grupos de Actinobacteria, Proteobacteria y Planctomycetes forman módulos casi separados. *Fusarium* no tiene vecinos a este umbral. B) Vecindario de *Fusarium* con $|r| \geq 0{,}5$: sus 40 géneros más correlacionados, con los seis mayores etiquetados; la correlación máxima es 0.63. C) Vecinos de *Fusarium* según Alnitak sobre la tabla completa, con la correlación de Spearman ρ y la disimilitud de Bray-Curtis d de cada par. (Script: `20261002_RegenerarRedesCoocurrencia33.R`)

Tabla 3.2: Métricas de la red de coocurrencia SparCC entre géneros según el umbral de correlación. "Neg." es el número de aristas con correlación negativa, "Gigante" el tamaño del componente gigante, "Agrup." el coeficiente de agrupamiento y la modularidad se calcula con el método de Louvain; el grado de *Fusarium* es su número de vecinos. (Script: `20261002_RegenerarRedesCoocurrencia33.R`)

$\|r\| \geq$	Géneros	Aristas	Neg.	Densidad	Gigante	Agrup.	Modularidad	Grado *Fus.*
0.5	1357	94455	17370	0.103	1352	0.58	0.34	40
0.6	1131	44734	3623	0.070	1119	0.59	0.41	5
0.7	906	19911	270	0.049	863	0.64	0.52	0
0.8	650	7757	0	0.037	482	0.69	0.55	0

Fusarium resulta ser un género poco conectado. Con $|r| \geq 0{,}7$ no tiene ningún vecino y su correlación más alta con otro género es 0.63 (panel B), con un conjunto heterogéneo de géneros sin un patrón ecológico reconocible: bacterias de Firmicutes como *Pelosinus* y *Neobacillus*, levaduras como *Kluyveromyces*, *Candida* y *Tetrapisispora*, y Planctomycetes como *Paludisphaera*. Alnitak, que trabaja sobre la tabla completa, señala como vecinos de *Fusarium* (panel C) a cuatro taxones que son todos hongos del mismo linaje: el orden Hypocreales al que pertenece, la especie *Fusarium decemcellulare*, y los hongos *Beauveria felina* y *Neurospora crassa*, con correlaciones de Spearman entre 0.72 y 0.82. Esto confirma la lectura anterior: la coocurrencia más fuerte de *Fusarium* es con taxones filogenéticamente cercanos, lo que refleja cómo el clasificador reparte las lecturas de hongos Sordariomycetes, y no una asociación con bacterias benéficas o patógenas.

En conjunto, las redes exploratorias no revelan una separación entre muestras saludables y no saludables ni un conjunto de taxones asociados con *Fusarium* que apunte a una interacción ecológica, pero sí dejan dos ideas que orientan el trabajo posterior. La primera es que las muestras no saludables son más dispersas entre sí, lo que las pruebas del Capítulo 4 confirman. La segunda es que las correlaciones entre taxones están fuertemente estructuradas por la taxonomía, de modo que un modelo que busque dependencias entre *Fusarium*, la diversidad y el estado de la planta, como las redes bayesianas del Capítulo 6, debe trabajar con un número reducido de variables elegidas por su sentido biológico y no con la red completa.

3.4. Conjuntos de datos complementarios: cultivo, suelos circundantes y suelo nativo

Además del conjunto principal de 58 metagenomas de rizósfera de fresa, Solena Ag proporcionó dos conjuntos complementarios que permiten situar la comparación entre plantas saludables y no saludables en un contexto más amplio: ¿cuánto difieren entre sí las dos clases de plantas de cultivo, comparado con cuánto difieren ambas de los suelos que las rodean? Esta sección describe esos conjuntos, el análisis que se les aplicó y lo que mostraron. Las figuras las regeneran los scripts `20261002_RegenerarComplementarios34.R`, `35.R` y `36.R`, que comparten el cargador `_cargar_complementarios.R`.

3.4.1. Conjuntos de datos

El segundo conjunto contiene 27 metagenomas de suelo tomados en tres tipos de sitio: cerca del cultivo de fresa (10 muestras), suelo no cultivado (10) y bosque degradado (7). Al unirlo con el conjunto principal se obtiene una tabla de 85 muestras y 9 027 taxones con cinco categorías: cultivo saludable, cultivo marchito, cerca del cultivo, suelo no cultivado y bosque degradado. Se aplicó el mismo filtro de calidad de la Sección 3.1.3, que elimina las cinco muestras ya conocidas del conjunto principal; ninguna de las 27 muestras nuevas quedó por debajo de los 25 millones de lecturas, de modo que el análisis se hizo con 80 muestras. Los nombres de muestra de los dos conjuntos tienen formatos distintos, por lo que la unión con los metadatos se hizo por identificador y se verificó explícitamente. El tercer conjunto es más pequeño: 8 metagenomas, cuatro de suelo de cultivo y cuatro de suelo nativo no intervenido, tomados en los mismos cuatro sitios.

Las muestras de suelo tienen una profundidad de secuenciación mayor que las del cultivo: entre 18 y 21 millones de lecturas clasificadas en promedio, frente a 11 y 12 millones en las plantas saludables y marchitas (Figura 3.4, panel A). Por ello, como en el resto de la tesis, las comparaciones de composición se hicieron sobre abundancias relativas y las de diversidad con los índices de Shannon y Simpson, que no dependen de la profundidad.

3.4.2. Diversidad alfa

Para las cinco categorías se calcularon los cuatro índices de diversidad alfa y se contrastaron con la prueba de Kruskal-Wallis, la generalización no paramétrica de Mann-Whitney a más de dos grupos, seguida de comparaciones por pares con Mann-Whitney y corrección de Benjamini-Hochberg. La Figura 3.4, panel B, muestra el resultado. La riqueza observada, Chao1 y Simpson no difieren entre categorías ($p = 0{,}46$, 0,42 y 0,13). Shannon sí alcanza significancia global ($p = 0{,}037$): las dos clases de cultivo tienen las medias más altas, 7.478 y 7.417, y los tres suelos no cultivados valores algo menores, de 7.405 a 7.439. Sin embargo, ninguna de las diez comparaciones por pares sobrevive a la corrección (el menor valor p ajustado es 0.11), de modo que la diferencia global es pequeña y no puede atribuirse a un par de categorías en particular. La diversidad alfa, en suma, es notablemente homogénea entre el cultivo y los suelos de su entorno.

3.4.3. Composición y diversidad beta

La composición por filo (Figura 3.5, panel A) es parecida en las cinco categorías, con Actinobacteria y Proteobacteria sumando más del 90 % de las lecturas en todas las muestras, pero con un cambio de proporción: en los suelos cercanos al cultivo y no cultivados Actinobacteria sube a cerca del 55 % y Proteobacteria baja al 39 %, mientras que en el cultivo y en el bosque degradado ambos filos están más equilibrados, en torno al 47 % y 44 %. La ordenación NMDS sobre la disimilitud de Bray-Curtis (panel B, estrés 0.12) muestra lo que las barras sugieren: las muestras de cultivo, saludables y marchitas por igual, ocupan una misma región del plano, los suelos cercanos al cultivo y no cultivados ocupan otra, superpuesta entre sí, y el bosque degradado queda disperso entre ambas.

El PERMANOVA con la categoría como factor (Sección 1.9) confirma la lectura visual y la pone en escala: el tipo de sitio explica el 33 % de la variación en composición (pseudo-$F = 9{,}25$, $R^2 = 0{,}330$, $p = 0{,}001$, 999 permutaciones), frente al 2.4 % que explicaba el estado de salud dentro del cultivo. Los PERMANOVA por pares, con corrección de Benjamini-Hochberg (Tabla 3.3), precisan de dónde viene esa variación: todas las comparaciones entre una categoría de cultivo y una de suelo son significativas, con R^2 entre 0.22 y 0.33; la comparación entre suelo cercano al cultivo y suelo no

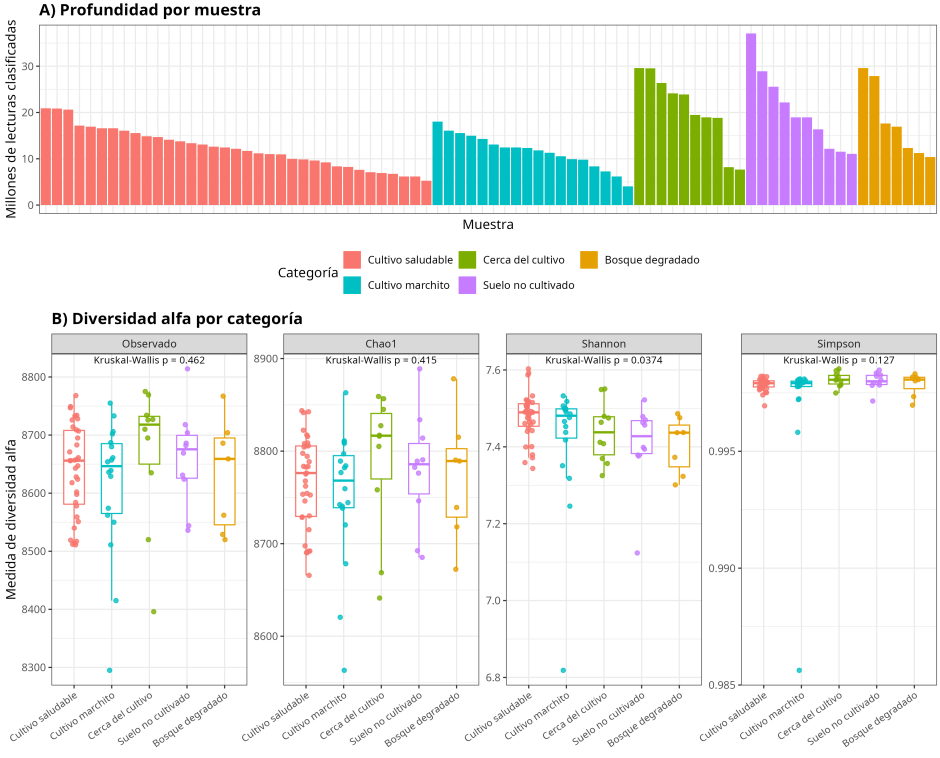


Figura 3.4: Conjunto complementario de cinco categorías, 80 muestras. A) Lecturas clasificadas por muestra, agrupadas por categoría: los suelos no cultivados tienen mayor profundidad que las muestras de cultivo. B) Diversidad alfa por categoría, con el valor p de la prueba de Kruskal-Wallis en cada índice. Solo Shannon difiere globalmente, sin diferencias por pares tras la corrección por comparaciones múltiples. (Script: `20261002_RegenerarComplementarios34.R`)

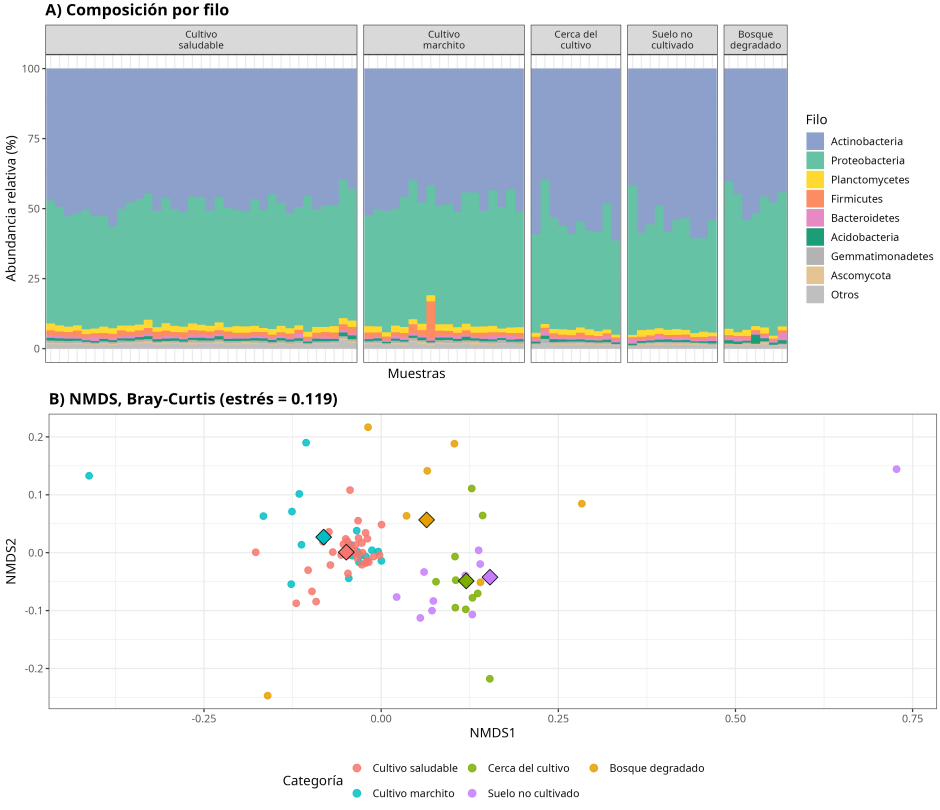


Figura 3.5: Composición y diversidad beta del conjunto de cinco categorías. A) Abundancia relativa de los ocho filos más abundantes por muestra, agrupadas por categoría. B) Ordenación NMDS de la disimilitud de Bray-Curtis entre las 80 muestras, con el centroide de cada categoría (rombos). Las dos clases de cultivo se superponen entre sí y se separan de los suelos no cultivados. (Script: `20261002_RegenerarComplementarios35.R`)

cultivado no lo es ($R^2 = 0{,}06$, $p = 0{,}26$); y la comparación entre cultivo saludable y cultivo marchito es exactamente la del Capítulo 4 ($R^2 = 0{,}024$, $p = 0{,}17$). El PERMDISP también fue significativo ($F = 3{,}33$, $p = 0{,}027$), lo que indica que las categorías difieren además en su dispersión interna, por lo que parte del resultado del PERMANOVA puede deberse a diferencias de heterogeneidad y no solo de centroide.

Tabla 3.3: PERMANOVA por pares entre las cinco categorías sobre la disimilitud de Bray-Curtis, con 999 permutaciones y valores p ajustados por Benjamini-Hochberg. (Script: `20261002_RegenerarComplementarios35.R`)

Categoría 1	Categoría 2	R^2	p	p ajustado
Cultivo saludable	Cultivo marchito	0.024	0.167	0.186
Cultivo saludable	Cerca del cultivo	0.326	0.001	0.002
Cultivo saludable	Suelo no cultivado	0.302	0.001	0.002
Cultivo saludable	Bosque degradado	0.245	0.001	0.002
Cultivo marchito	Cerca del cultivo	0.303	0.001	0.002
Cultivo marchito	Suelo no cultivado	0.271	0.001	0.002
Cultivo marchito	Bosque degradado	0.222	0.001	0.002
Cerca del cultivo	Suelo no cultivado	0.060	0.257	0.257
Cerca del cultivo	Bosque degradado	0.237	0.003	0.004
Suelo no cultivado	Bosque degradado	0.180	0.008	0.010

3.4.4. Cultivo frente a suelo nativo

El tercer conjunto, con cuatro muestras de cultivo y cuatro de suelo nativo, repite el contraste a pequeña escala (Figura 3.6). Con cuatro muestras por grupo, el valor p más pequeño que puede dar la prueba exacta de Mann-Whitney es 0.029, que es precisamente el que se obtiene para Shannon y Simpson: las cuatro muestras de cultivo tienen mayor diversidad que las cuatro nativas, con medias de Shannon de 7.57 frente a 7.28. La riqueza observada y Chao1 no difieren. El PERMANOVA sobre Bray-Curtis da $R^2 = 0{,}38$ y $p = 0{,}032$, en línea con el conjunto de cinco categorías. Con un tamaño de muestra tan reducido estos resultados solo tienen valor confirmatorio de la tendencia general; por eso la ordenación se hizo con PCoA, que es determinista, en lugar de NMDS, que con ocho puntos produce un estrés cercano a cero y no es interpretable.

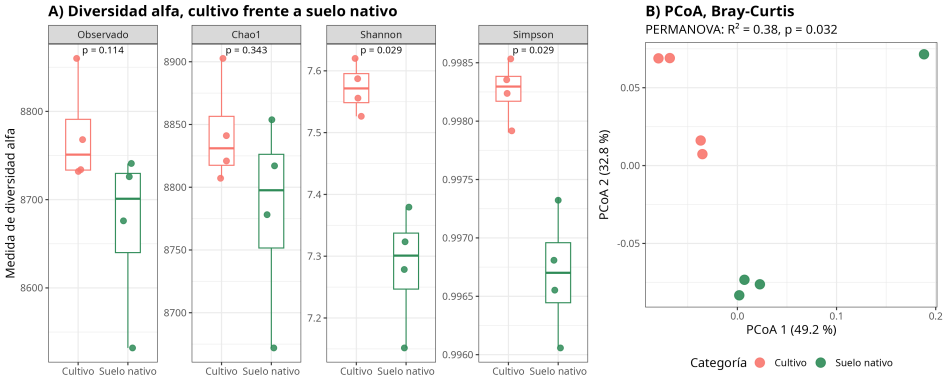


Figura 3.6: Tercer conjunto complementario: cuatro muestras de suelo de cultivo y cuatro de suelo nativo. A) Diversidad alfa, con el valor p de la prueba exacta de Mann-Whitney en cada índice. B) Ordenación PCoA de la disimilitud de Bray-Curtis, con el resultado del PERMANOVA. (Script: `20261002_RegenerarComplementarios36.R`)

3.4.5. Lo que aportan los conjuntos complementarios

Los conjuntos complementarios sirven como control de escala para el resultado central de la tesis. El método es capaz de detectar diferencias de composición cuando existen: entre el cultivo y los suelos de su entorno el PERMANOVA explica un tercio de la variación con valores p de 0.001, y lo hace con los mismos datos, el mismo clasificador y las mismas disimilitudes con que no detecta diferencia entre plantas saludables y marchitas. La ausencia de señal del estado de salud no es, por lo tanto, un problema de sensibilidad del análisis, sino una propiedad de los datos: el cultivo de fresa, saludable o marchito, tiene un microbioma rizosférico propio y distinto del suelo circundante, y dentro de ese microbioma la marchitez no se refleja en la composición promedio. Esto refuerza la conclusión del Capítulo 5 de que la señal, si existe, está en la heterogeneidad y en las dependencias entre taxones, y no en la abundancia de taxones aislados.

Capítulo 4

Resultados

En este capítulo se presentan los resultados del análisis descrito en el Capítulo 3, organizados según los cuatro objetivos específicos planteados en el Capítulo 2. La Sección 4.1 caracteriza la composición y la diversidad del microbioma rizosférico de plantas de fresa saludables y no saludables, primero sobre la comunidad completa y después por reino y por nivel taxonómico. La Sección 4.2 contrasta estadísticamente las diferencias observadas y evalúa la potencia del diseño. La Sección 4.3 reúne los patrones taxonómicos y de estructura de la comunidad asociados con el estado de salud de la planta, y la Sección 4.4 describe el material didáctico construido a partir del análisis. En todo el capítulo se usan los términos *saludable* y *no saludable* para los dos grupos, que en los datos originales aparecen como `healthy` y `wilted` (planta marchita).

4.1. Caracterización de la composición taxonómica y la diversidad microbiana

4.1.1. Preprocesamiento y filtro de calidad

El conjunto de datos original comprendía 58 metagenomas, 40 de plantas saludables y 18 de plantas no saludables. Antes de calcular cualquier medida de diversidad se revisó la tabla de control de calidad de cada muestra, que reporta el número de lecturas antes y después del filtrado con fastp, la proporción de bases con calidad Phred superior a 30 y el porcentaje de

lecturas clasificadas por Kraken. Se estableció como criterio de exclusión un mínimo de 25 millones de lecturas después del filtrado de calidad. Cinco muestras, todas del grupo saludable, no cumplieron el criterio y fueron eliminadas: MP2079, MP2080, MP2088, MP2109 y MP2137. El caso extremo es MP2088, que conservó únicamente dos lecturas tras el filtrado; una muestra así no aporta información sobre la comunidad y, como se muestra a continuación, distorsiona la escala de todos los índices.

Tras el filtro quedaron 53 muestras para el análisis: 35 saludables y 18 no saludables. La Figura 4.1 compara la diversidad alfa antes y después del filtro. En los datos crudos (panel A) las cinco muestras de baja calidad comprimen la escala de los cuatro índices, de modo que ambos grupos parecen indistinguibles. En los datos filtrados (panel B) la escala se ajusta a la variación real entre muestras y se aprecia una ligera tendencia hacia valores mayores en el grupo saludable, más visible en la riqueza observada y en Chao1. El filtro de calidad no cambia los datos de las muestras que se conservan, pero sí determina si las diferencias entre grupos pueden verse.

Aun después del filtro persiste una diferencia en la profundidad de secuenciación entre grupos. La Figura 4.2 muestra el número de lecturas clasificadas por muestra: los metagenomas de plantas saludables contienen, en promedio, más lecturas que los de plantas no saludables. Esta diferencia debe tenerse presente al interpretar los índices que dependen del esfuerzo de muestreo, como la riqueza observada y Chao1, porque una muestra con más lecturas tiene mayor probabilidad de detectar taxones raros. En la Sección 4.2.6 se evalúa, con curvas de rarefacción y con los datos rarificados a profundidad común, cuánto de la tendencia observada se debe a esta diferencia.

4.1.2. Diversidad alfa de la comunidad completa

La Tabla 4.1 resume los cuatro índices de diversidad alfa por grupo, calculados sobre las 53 muestras filtradas. En los cuatro índices el promedio del grupo saludable es mayor que el del grupo no saludable, pero las diferencias son pequeñas en relación con la escala de cada índice: 26 taxones observados de más de 8 600, 0.06 unidades de Shannon sobre un valor cercano a 7.5, y una milésima en Simpson. El índice de Simpson está próximo a su máximo en todas las muestras, lo que indica comunidades sin dominancia

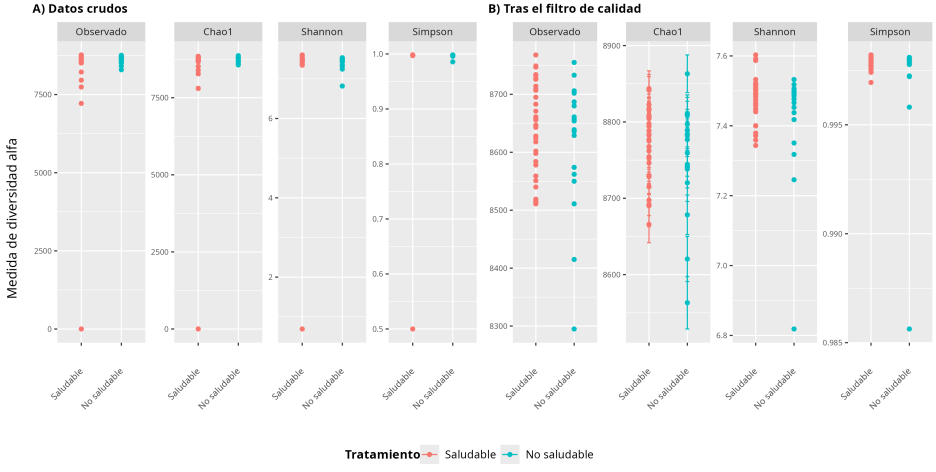


Figura 4.1: Diversidad alfa (riqueza observada, Chao1, Shannon y Simpson) en muestras saludables y no saludables. A) Antes del filtro de calidad, las muestras con muy pocas lecturas dominan la escala y ocultan las diferencias entre grupos. B) Tras eliminar las cinco muestras con menos de 25 millones de lecturas, se aprecia una tendencia hacia mayor diversidad en las muestras saludables, en particular en la riqueza observada y en Chao1. (Script: `20260924_RegenerarAlphaCrudosFiltrados41.R`)

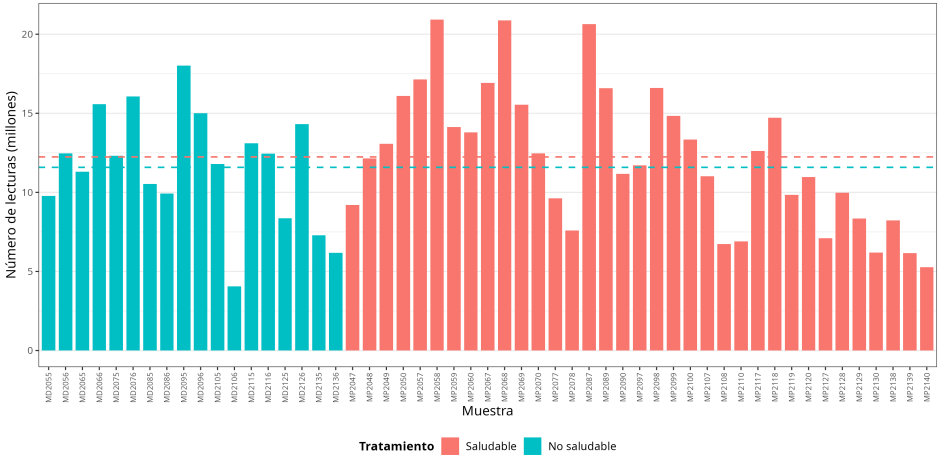


Figura 4.2: Número de lecturas clasificadas por muestra tras el filtro de calidad. Las muestras saludables ($n = 35$) tienen en promedio más lecturas que las no saludables ($n = 18$). (Script: `20260924_RegenerarBarrasLecturas42.R`)

marcada de ningún taxón. La diferencia más notable entre grupos no está en las medias sino en la dispersión: la desviación estándar del índice de Shannon en el grupo no saludable es casi tres veces la del grupo saludable. Este punto se retoma en la Sección 4.3.

Tabla 4.1: Promedio de los índices de diversidad alfa por grupo sobre la comunidad completa (53 muestras filtradas). Entre paréntesis, la desviación estándar del índice de Shannon. (Script: `20260924_RegenerarAlphaCrudosFiltrados41.R`)

Grupo	Riqueza obs.	Chao1	Shannon	Simpson
Saludable ($n = 35$)	8639.9	8767.6	7.478 (0.061)	0.998
No saludable ($n = 18$)	8613.7	8751.6	7.417 (0.168)	0.997

4.1.3. Diversidad beta de la comunidad completa

La Figura 4.3 muestra las ordenaciones NMDS (Kruskal, 1964) de las 53 muestras para las cinco medidas de disimilitud calculadas sobre abun-

dancias relativas: Bray-Curtis, Jaccard, Euclidiana, Manhattan y Jensen-Shannon. En ninguna de las cinco se observa una separación entre muestras saludables y no saludables: los dos grupos se superponen en el centro de la ordenación y las pocas muestras alejadas del núcleo pertenecen a ambos grupos. Las ordenaciones de Bray-Curtis, Jaccard y Manhattan son casi idénticas, lo cual es esperable porque, sobre abundancias relativas, Jaccard cuantitativo y Manhattan son transformaciones monótonas de Bray-Curtis (Capítulo 1). La ordenación Euclidiana tiene una escala mucho menor porque, al elevar al cuadrado las diferencias, queda dominada por los dos filos más abundantes. La ordenación de Jensen-Shannon queda determinada por una sola muestra atípica, lo que la hace poco informativa para este conjunto de datos.

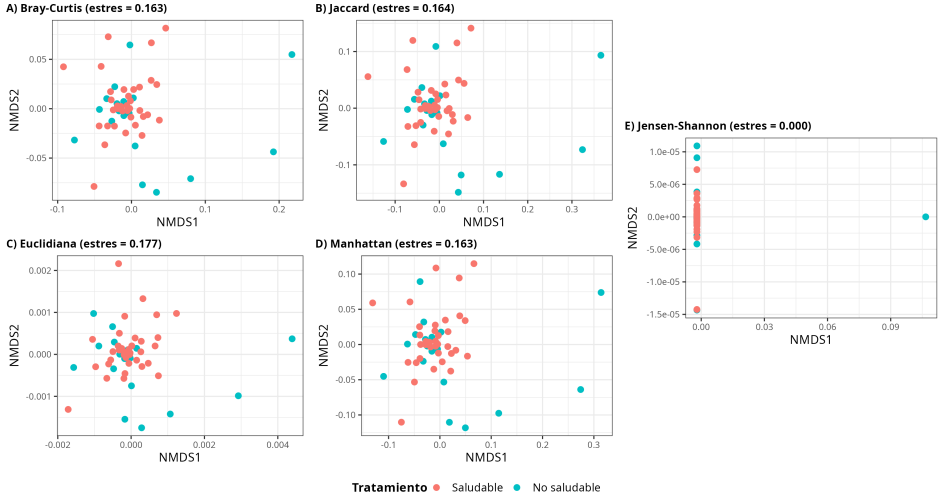


Figura 4.3: Ordenaciones NMDS de la diversidad beta de la comunidad completa para cinco medidas de disimilitud. A) Bray-Curtis. B) Jaccard. C) Euclidiana. D) Manhattan. E) Jensen-Shannon. Ninguna medida separa las muestras saludables de las no saludables. (Script: `20260924_RegenerarBetaDiversity43.R`)

Para cuantificar lo que muestran las ordenaciones se aplicó un análisis PERMANOVA (Anderson, 2001) sobre la matriz de disimilitud de Bray-Curtis, con el estado de la planta como único factor y 999 permutaciones. El

estado de la planta explicó el 2.4 % de la variación total en la composición ($R^2 = 0{,}024$, pseudo-$F = 1{,}26$, $p = 0{,}167$). Con la disimilitud de Jaccard cuantitativa el resultado es prácticamente idéntico ($R^2 = 0{,}024$, pseudo-$F = 1{,}24$, $p = 0{,}170$). Es decir, más del 97 % de la variación entre muestras se debe a factores distintos del estado saludable o no saludable, y la fracción atribuible a este no es distinguible de la que se obtendría asignando las etiquetas al azar. El panel A de la Figura 4.4 muestra las muestras en el espacio de coordenadas principales con el centroide de cada grupo: los dos centroides están casi superpuestos.

Como el PERMANOVA puede reaccionar a diferencias de dispersión y los grupos son desbalanceados, se aplicó la prueba PERMDISP sobre la misma matriz de Bray-Curtis. La distancia media de cada muestra al centroide de su grupo fue de 0.077 en las plantas saludables y de 0.100 en las no saludables, y la prueba rechazó la igualdad de dispersiones ($F = 5{,}10$ con 1 y 51 grados de libertad, $p = 0{,}023$; panel B de la Figura 4.4). Los grupos no difieren, por lo tanto, en su composición promedio, pero sí en cuánto varía la composición dentro de cada uno: las plantas no saludables son más heterogéneas entre sí. Este resultado se retoma en la Sección 4.3.

4.1.4. Composición taxonómica general

A nivel de reino, la tabla de clasificación de Kraken contiene 8 822 taxones asignados a Bacteria y 181 a Eukaryota, lo que refleja tanto el predominio bacteriano de los suelos como la menor representación de los eucariotas en la base de datos de referencia. A nivel de filo, la comunidad está dominada por Actinobacteria y Proteobacteria, que juntos suman en promedio más del 90 % de las lecturas clasificadas de cada muestra (48.3 % y 43.3 %, respectivamente). Les siguen, ya con abundancias relativas menores al 3 %, Planctomycetes, Firmicutes, Bacteroidetes y Acidobacteria. La Figura 4.5 muestra las abundancias absolutas y relativas por muestra, con las muestras separadas por grupo, y la Figura 4.6 resume la composición media de cada grupo y muestra en escala logarítmica los filos minoritarios, que en las barras apiladas no alcanzan a verse. A esta escala los dos grupos son prácticamente indistinguibles: los dos filos dominantes tienen proporciones semejantes en todas las muestras y ninguno de los diez filos principales difiere entre grupos una vez ajustados los valores p por compa-

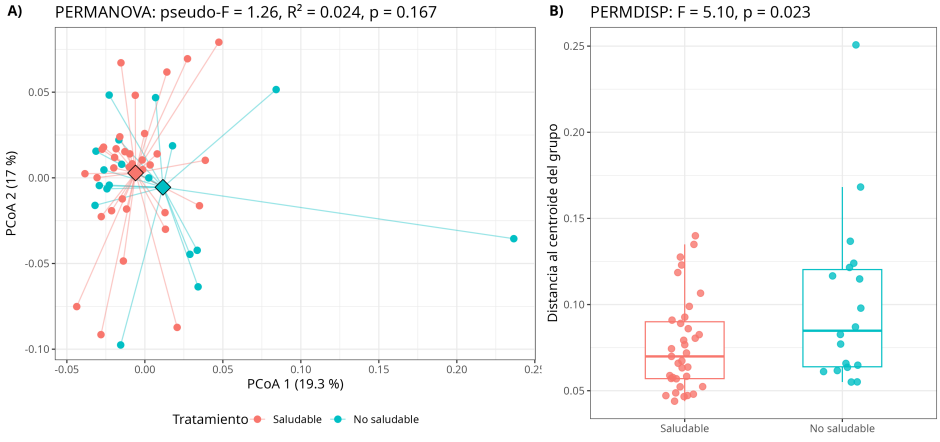


Figura 4.4: PERMANOVA y PERMDISP sobre la disimilitud de Bray-Curtis de la comunidad completa. A) Muestras en los dos primeros ejes de coordenadas principales, con el centroide de cada grupo (rombos) y un segmento de cada muestra a su centroide. Los centroides casi coinciden (pseudo-$F = 1{,}26$, $R^2 = 0{,}024$, $p = 0{,}167$). B) Distancia de cada muestra al centroide de su grupo. Las plantas no saludables están más dispersas ($F = 5{,}10$, $p = 0{,}023$). (Script: `20260930_RegenerarPermanovaPermdisp44.R`)

raciones múltiples.

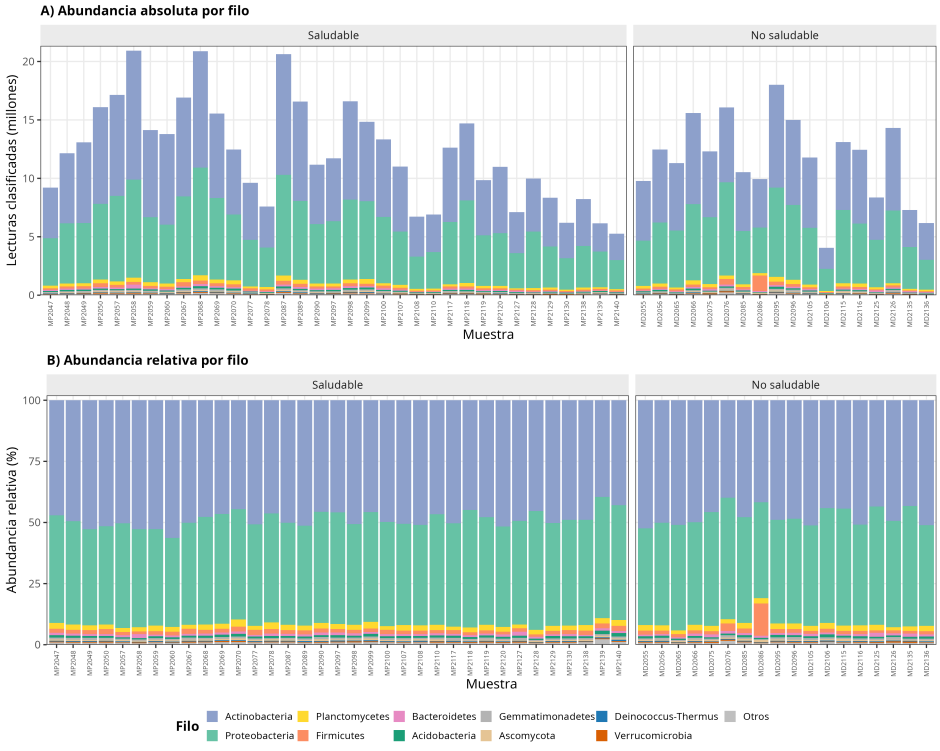


Figura 4.5: Abundancia por filo en las 53 muestras filtradas, separadas por grupo. A) Abundancia absoluta, en millones de lecturas asignadas a cada filo. B) Abundancia relativa, en porcentaje por muestra. Se muestran los diez filos de mayor abundancia media y el resto se agrupa en "Otros"; cada filo conserva el mismo color en todas las figuras de la tesis. Actinobacteria y Proteobacteria dominan todas las muestras. (Script: `20260919_RegenerarBarrasFilo45.R`)

Dado que ni la diversidad ni la composición de la comunidad completa distinguen a los grupos, el análisis se desagregó por reino, Bacteria y Eukaryota, y dentro de cada reino por filo, familia, género y especie. El propósito de esta desagregación, que corresponde al primer objetivo específico, es comprobar si una diferencia entre grupos que no se aprecia sobre

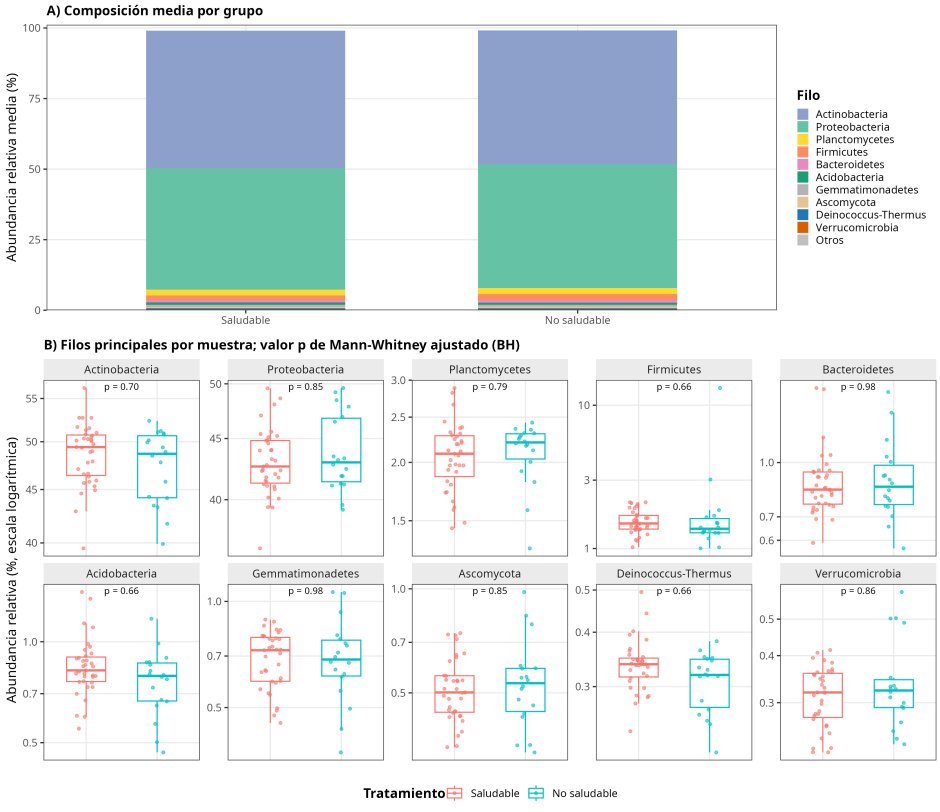


Figura 4.6: Composición por filo en cada grupo. A) Abundancia relativa media de los diez filos principales en las muestras saludables y no saludables. B) Los mismos filos, muestra por muestra y en escala logarítmica, con el valor p de Mann-Whitney ajustado por Benjamini-Hochberg. Ningún filo difiere entre grupos tras el ajuste. (Script: `20260906_RegenerarBarrasFiloBN46.R`)

la comunidad completa aparece al mirar un reino o un nivel taxonómico en particular: una señal concentrada en unos pocos taxones, por ejemplo en los hongos patógenos, puede quedar diluida entre los miles de taxones bacterianos que dominan los índices globales. Para cada reino se presentan, en ese orden, la composición, la diversidad alfa y la diversidad beta en los cuatro niveles. Para las gráficas de barras se aplicó una aglomeración al 10 %, que agrupa bajo la etiqueta "Otros" a los taxones cuya abundancia relativa no supera ese umbral en ninguna muestra, de modo que los taxones restantes puedan distinguirse por color.

4.1.5. Eucariotas por nivel taxonómico

La Figura 4.7 muestra la composición de la fracción eucariota en los cuatro niveles taxonómicos. Los eucariotas representan una fracción muy pequeña de las lecturas clasificadas, por lo que sus abundancias relativas dentro del reino están sujetas a mayor variabilidad de muestreo que las bacterianas. A nivel de filo se observa una abundancia relativa ligeramente menor de Oomycota en las muestras no saludables, y a nivel de familia una menor presencia de Peronosporaceae, familia que pertenece a ese filo. A nivel de género y especie se identifican los hongos fitopatógenos *Fusarium* y el oomiceto *Phytophthora*, ambos documentados como agentes de marchitez y pudrición radicular en fresa (Yang et al., 2020; Siegieda et al., 2024). Sobre la comunidad completa, la abundancia relativa media de *Fusarium* es de 0.136 % en las plantas saludables y de 0.151 % en las no saludables; la de Oomycota es de 0.066 % y 0.061 %, y la de *Phytophthora* de 0.060 % y 0.055 %. Se trata de diferencias pequeñas, que las gráficas de barras por reino amplifican al reescalar la fracción eucariota al 100 %. La Sección 4.3 las contrasta formalmente entre grupos.

La Figura 4.8 presenta la diversidad alfa de los eucariotas en cada nivel. La riqueza observada y Chao1 no distinguen a los grupos: tras aglomerar los conteos, todas las muestras contienen los mismos 4 filos, 35 familias y 58 géneros de eucariotas, y 144 o 145 de las 145 especies, de modo que ambos índices son prácticamente constantes y Chao1 coincide con la riqueza observada por ausencia de *singletons*. La información está en Shannon y Simpson, cuyas medianas son semejantes entre grupos en los cuatro niveles; lo que difiere es la dispersión, mayor en el grupo no saludable, que en todos



Figura 4.7: Abundancia relativa de eucariotas por nivel taxonómico, con las muestras separadas por grupo y aglomeración al 10 %. A) Filo: Oomycota muestra una abundancia relativa ligeramente menor en las muestras no saludables. B) Familia: la misma tendencia en Peronosporaceae. C) Género: *Fusarium* y *Phytophthora* entre los géneros distinguibles. D) Especie. (Script: `20260924_RegenerarBarrasEukarya47.R`)

los niveles incluye una o dos muestras con valores muy bajos. En el nivel de género, el promedio del índice de Shannon calculado sobre los 58 géneros de eucariotas es de 3.077 en el grupo saludable y de 3.035 en el no saludable; la significancia de esta diferencia se evalúa en la Sección 4.2. La diversidad beta por nivel, en la Figura 4.9, repite lo observado en la comunidad completa: las ordenaciones no separan los grupos en ningún nivel taxonómico.

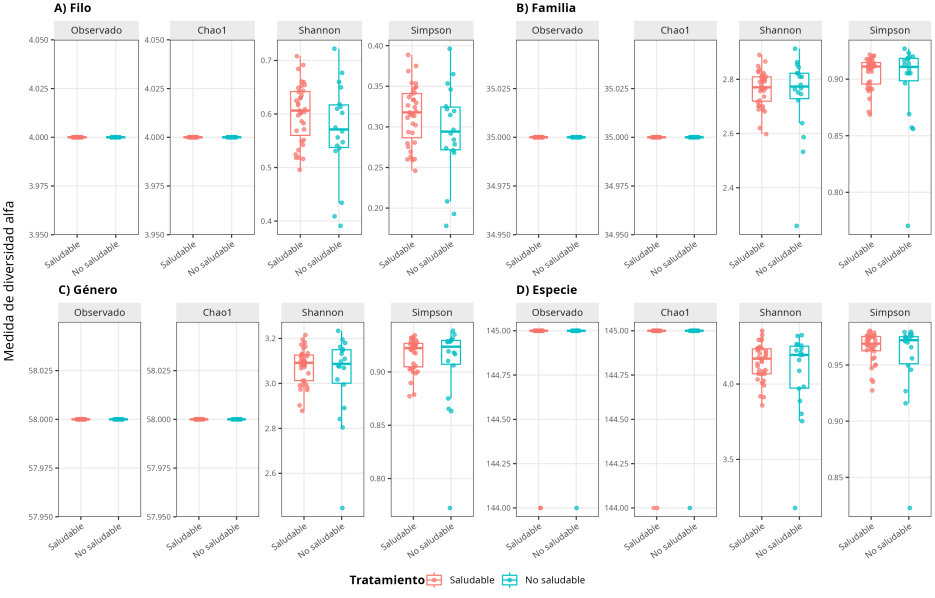


Figura 4.8: Diversidad alfa de los eucariotas por nivel taxonómico: A) filo, B) familia, C) género, D) especie. La riqueza observada y Chao1 son constantes en ambos grupos, porque todas las muestras contienen los mismos taxones a cada nivel; Shannon y Simpson tienen medianas semejantes y mayor dispersión en el grupo no saludable. (Script: `20260919_RegenerarAlphaEukarya48.R`)

4.1.6. Bacterias por nivel taxonómico

La Figura 4.10 muestra la composición bacteriana en los cuatro niveles. A nivel de filo, ambos grupos están dominados por Actinobacteria y Pro-

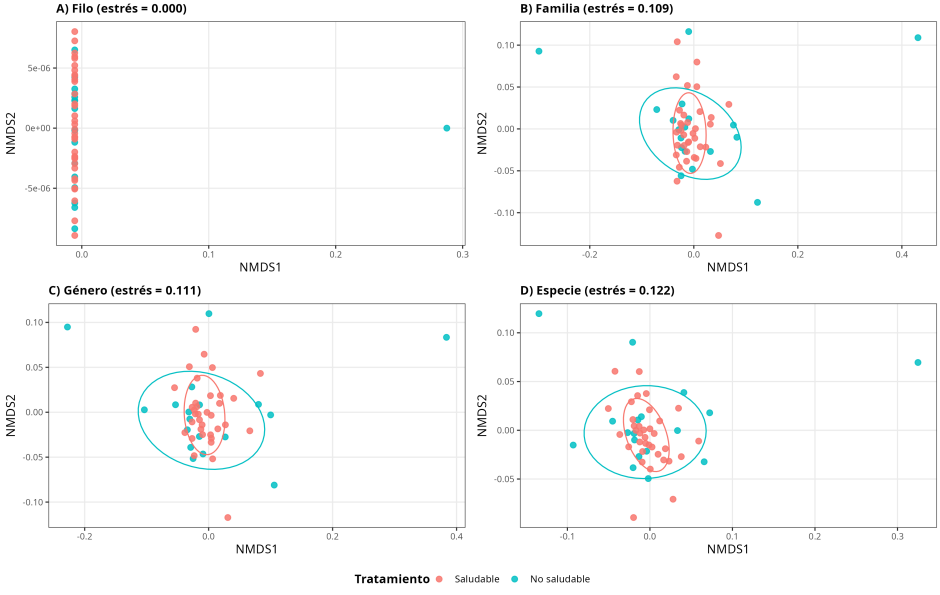


Figura 4.9: Diversidad beta (NMDS, Bray-Curtis) de los eucariotas por nivel taxonómico: A) filo, B) familia, C) género, D) especie. Las elipses cubren el 68 % de cada grupo. A nivel de filo solo hay cuatro taxones, por lo que la ordenación es degenerada (estrés cero) y se omite la elipse. No hay separación entre grupos en ningún nivel. (Script: `20260919_RegenerarBetaEukarya49.R`)

teobacteria, con Firmicutes como tercer filo distinguible; la única diferencia visible es una proporción algo mayor de Firmicutes en algunas muestras no saludables. A nivel de familia y género, la aglomeración al 10 % deja visibles a Streptomycetaceae y su género *Streptomyces*, presentes en proporciones semejantes en ambos grupos, y a Paenibacillaceae con su género *Paenibacillus*, que aparece en unas pocas muestras de ambos grupos. A nivel de especie, *Paenibacillus polymyxa*, una rizobacteria promotora del crecimiento vegetal (Lal and Tabacchioni, 2009), es la única que supera el umbral de aglomeración, y lo hace en muestras aisladas. Por debajo del umbral del 10 %, la inspección de las gráficas de barras de los reportes exploratorios sugería una presencia algo mayor de *Pseudomonas* y *Bacillus* en las muestras saludables, y de *Ralstonia*, género que incluye a los agentes de la marchitez bacteriana (Suhaimi et al., 2017), en las no saludables. La comparación cuantitativa de esas proporciones, en la Sección 4.3, muestra que esas impresiones visuales no se sostienen.

La diversidad alfa de las bacterias por nivel (Figura 4.11) reproduce el patrón de la comunidad completa, lo cual es esperable porque las bacterias constituyen casi la totalidad de las lecturas. A nivel de filo y familia la riqueza es constante (39 filos y 448 familias en todas las muestras) y solo a nivel de especie reaparece la ligera tendencia hacia mayor riqueza en el grupo saludable, con una media de 7 471 especies frente a 7 450; en Shannon y Simpson las medianas son semejantes y la dispersión es mayor en el grupo no saludable, sobre todo a nivel de género y especie. La diversidad beta por nivel (Figura 4.12) tampoco separa los grupos. Sí se observa que, con Bray-Curtis, la nube de puntos se vuelve más dispersa a medida que se desciende de filo a especie, porque en los niveles finos hay más taxones que pueden diferir entre muestras. Esa mayor dispersión, sin embargo, no se organiza según el estado de la planta.

En conjunto, la desagregación por reino y por nivel taxonómico no reveló ninguna diferencia entre grupos que no se viera ya sobre la comunidad completa. Ni la riqueza, que a los niveles gruesos es idéntica en todas las muestras, ni las medianas de Shannon y Simpson, ni las ordenaciones separan a las plantas saludables de las no saludables en ningún reino ni nivel. Lo único que se repite en todos los niveles es la mayor dispersión del grupo no saludable, que las pruebas de la Sección 4.2 confirman formalmente sobre la comunidad completa. Las diferencias de composición que las gráficas

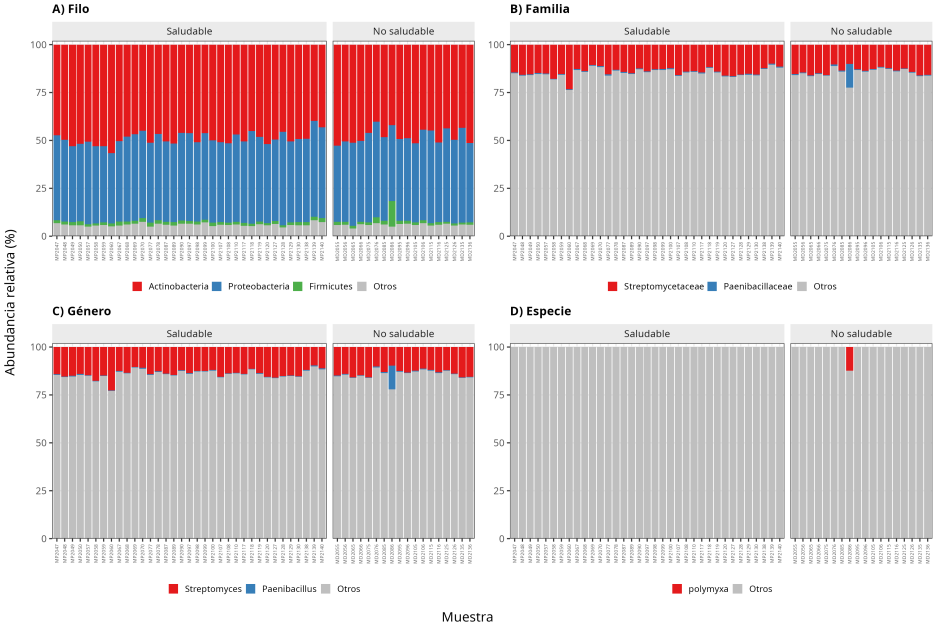


Figura 4.10: Abundancia relativa de bacterias por nivel taxonómico, con las muestras separadas por grupo y aglomeración al 10 %. A) Filo: predominio de Actinobacteria y Proteobacteria. B) Familia: Streptomycetaceae y Paenibacillaceae. C) Género: *Streptomyces* y *Paenibacillus*. D) Especie: *Paenibacillus polymyxa* en muestras aisladas. (Script: `20260919_RegenerarBarrasBacteria410.R`)

de barras sugerían a simple vista, Oomycota y *Phytophthora* algo menores y *Fusarium* algo mayor en las no saludables, *Pseudomonas* y *Bacillus* en las saludables y *Ralstonia* en las enfermas, quedan como candidatas a contrastar en la Sección 4.3, donde se comprueba que ninguna sobrevive a la comparación cuantitativa.

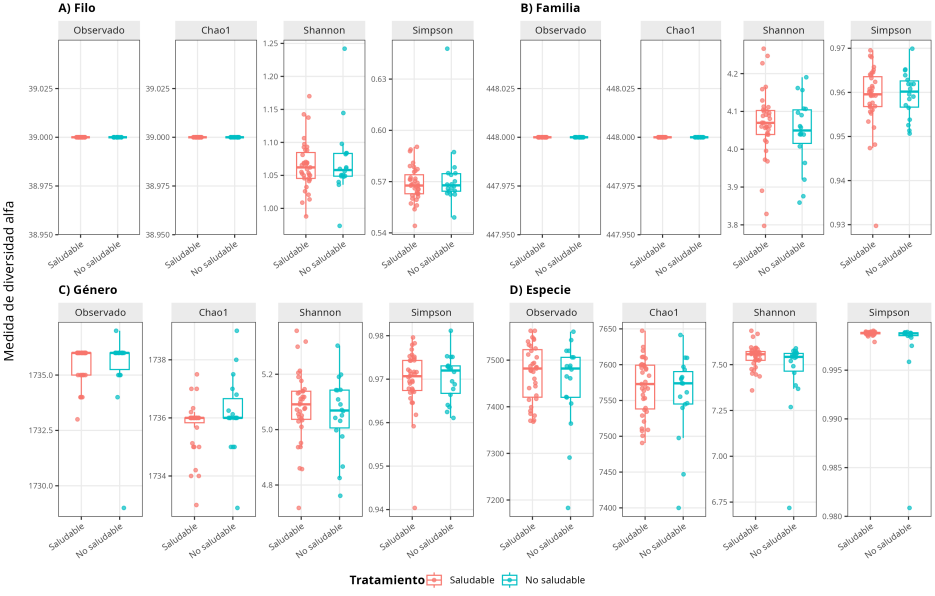


Figura 4.11: Diversidad alfa de las bacterias por nivel taxonómico: A) filo, B) familia, C) género, D) especie. La riqueza es constante a nivel de filo y familia y solo varía entre muestras a nivel de género y especie; la mayor dispersión del grupo no saludable se repite en todos los niveles. (Script: `20260919_RegenerarAlphaBacteria411.R`)

4.2. Evaluación estadística de las diferencias entre grupos

Las tendencias descritas en la sección anterior se contrastaron con las pruebas de hipótesis del Capítulo 3, usando el índice de Shannon como

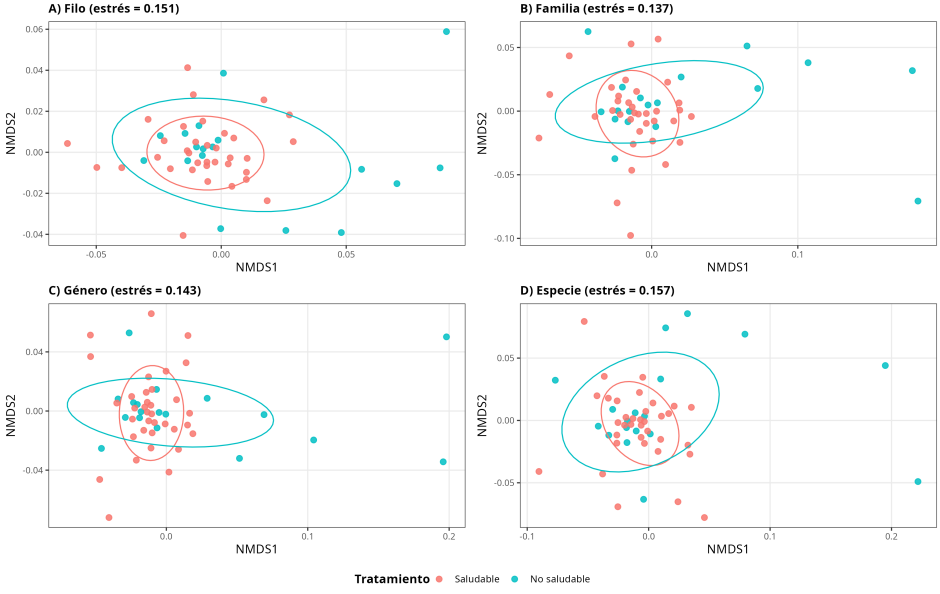


Figura 4.12: Diversidad beta (NMDS, Bray-Curtis) de las bacterias por nivel taxonómico: A) filo, B) familia, C) género, D) especie. La dispersión aumenta en los niveles finos, pero no se organiza según el estado de la planta. Las elipses cubren el 68 % de cada grupo. (Script: `20260919_RegenerarBetaBacteria412.R`)

variable de respuesta y un nivel de significancia $\alpha = 0{,}05$. Todas las pruebas son bilaterales, con hipótesis nula de igualdad entre los grupos saludable y no saludable.

4.2.1. Verificación de supuestos

Antes de aplicar la prueba t se verificaron sus dos supuestos. La prueba de Shapiro-Wilk (Shapiro and Wilk, 1965) no rechaza la normalidad del índice de Shannon en el grupo saludable ($p = 0{,}130$), pero sí la rechaza en el grupo no saludable ($p < 0{,}001$), donde una muestra con valor muy bajo (6.82) se aleja del resto. La prueba F rechaza con claridad la igualdad de varianzas ($F = 0{,}132$ con 34 y 17 grados de libertad, $p < 0{,}001$): la varianza del grupo no saludable es unas siete veces mayor que la del saludable. En consecuencia, la versión apropiada de la prueba t es la de Welch, y la prueba de Wilcoxon-Mann-Whitney se aplica como alternativa que no requiere normalidad. Conviene aclarar el orden en que ocurrieron las cosas: en la fase exploratoria del trabajo la primera prueba aplicada fue la t de Student con varianzas iguales, antes de verificar los supuestos; la verificación posterior mostró que ese supuesto no se cumple. El resultado exploratorio se conserva en las figuras y en la Tabla 4.2, identificado como tal, por dos razones: hace trazable cómo cambió la conclusión al corregir el procedimiento, y muestra cuánto depende el valor p de un supuesto que los datos no cumplen.

4.2.2. Prueba t sobre el índice de Shannon de la comunidad completa

La Figura 4.13 resume la prueba t sobre la comunidad completa. Con la prueba de Welch (Welch, 1947), que es la que corresponde dados los supuestos, el estadístico es $t = 1{,}499$ con 19.3 grados de libertad y $p = 0{,}150$, con intervalo de confianza del 95 % para la diferencia de medias de $(-0{,}024,\ 0{,}147)$. No se rechaza la hipótesis nula: la diferencia de 0.061 unidades de Shannon a favor del grupo saludable no es distinguible del ruido con el tamaño de muestra disponible. La prueba exploratoria inicial, con varianzas iguales, había dado $t = 1{,}939$ con 51 grados de libertad y $p = 0{,}058$, con intervalo $(-0{,}002,\ 0{,}125)$, que incluye al cero por un margen estrecho. La comparación es instructiva: el supuesto de varianzas iguales, que los datos no cumplen, acerca artificialmente el resultado a la

significancia, y de haberse detenido el análisis en esa primera prueba la conclusión habría quedado en el límite.

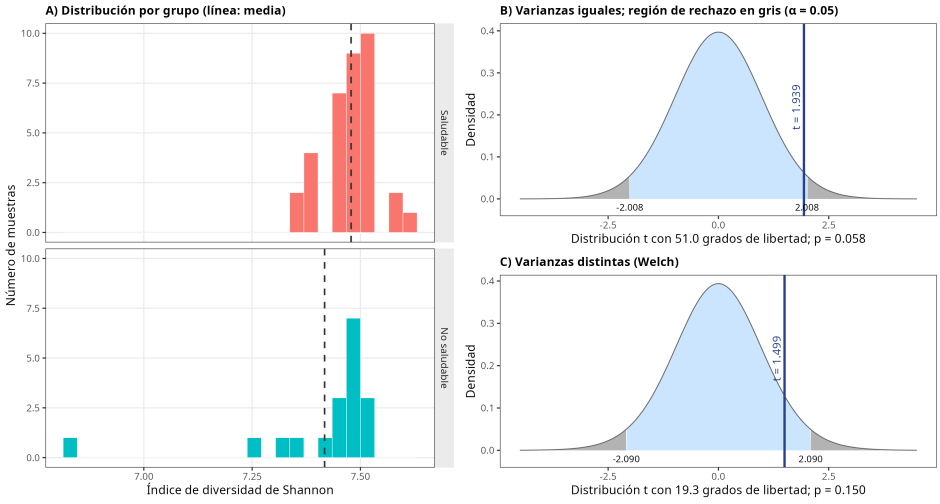


Figura 4.13: Prueba t de Student sobre el índice de Shannon de la comunidad completa. A) Distribución del índice en cada grupo, con la media señalada por la línea punteada. B) Prueba exploratoria inicial, asumiendo varianzas iguales: $t = 1{,}939$, 51 grados de libertad, $p = 0{,}058$. C) Prueba apropiada dados los supuestos, con varianzas distintas (Welch): $t = 1{,}499$, 19.3 grados de libertad, $p = 0{,}150$. En ambos casos el estadístico queda fuera de la región de rechazo y no se rechaza la hipótesis nula. (Script: `20260919_RegenerarTTestShannon413.R`)

4.2.3. Prueba t sobre el índice de Shannon de los géneros de eucariotas

La misma prueba se aplicó al índice de Shannon calculado sobre los 58 géneros de eucariotas, grupo que incluye a *Fusarium* y a *Phytophthora*, con el fin de comprobar si la señal asociada con los fitopatógenos, diluida en la comunidad completa, resultaba detectable al aislar la fracción eucariota. La Figura 4.14 muestra el resultado. Las medias son 3.077 en el grupo saludable y 3.035 en el no saludable. Con la prueba de Welch, $t = 0{,}902$ con 20.2

grados de libertad y $p = 0{,}378$; la prueba exploratoria con varianzas iguales había dado $t = 1{,}139$ con 51 grados de libertad y $p = 0{,}260$. La prueba de Wilcoxon-Mann-Whitney sobre estos mismos valores da $W = 318$ y $p = 0{,}963$. Los tres intervalos de confianza incluyen al cero. Por lo tanto, la diversidad de géneros de eucariotas tampoco difiere significativamente entre grupos.

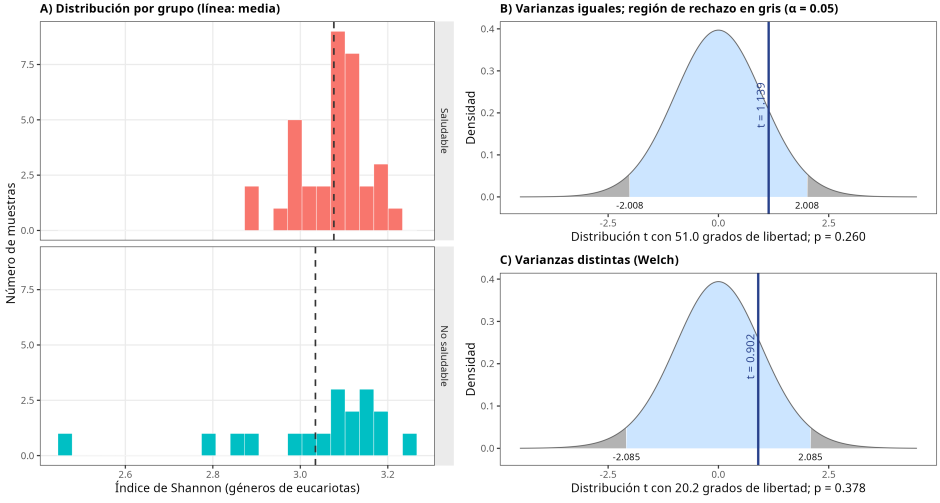


Figura 4.14: Prueba t de Student sobre el índice de Shannon calculado a nivel de género en eucariotas (58 géneros, entre ellos *Fusarium*). A) Distribución del índice en cada grupo, con la media señalada por la línea punteada: 3.077 en el grupo saludable y 3.035 en el no saludable. B) Prueba exploratoria inicial, asumiendo varianzas iguales: $t = 1{,}139$, 51 grados de libertad, $p = 0{,}260$. C) Prueba apropiada, con varianzas distintas (Welch): $t = 0{,}902$, 20.2 grados de libertad, $p = 0{,}378$. En ambos casos el estadístico queda dentro de la región de no rechazo. (Script: `20260919_RegenerarTTestFusarium414.R`)

4.2.4. Prueba de Wilcoxon-Mann-Whitney

Dado que el índice de Shannon del grupo no saludable no es normal, se aplicó la prueba de suma de rangos de Wilcoxon-Mann-Whitney sobre la

comunidad completa. La Figura 4.15 muestra los 53 valores ordenados por rango: los dos grupos aparecen mezclados a lo largo de todo el recorrido, con las plantas no saludables algo más frecuentes en los rangos bajos y las saludables en los más altos, pero sin una zona en la que un grupo predomine. El estadístico es $W = 376$ con $p = 0{,}259$. La estimación de la diferencia de ubicación entre grupos es de 0.017 unidades de Shannon a favor del grupo saludable, con intervalo de confianza del 95 % $(-0{,}012,\ 0{,}056)$, que incluye al cero. La prueba no paramétrica coincide, por lo tanto, con la prueba t: no hay evidencia de una diferencia en la distribución del índice de Shannon entre plantas saludables y no saludables.

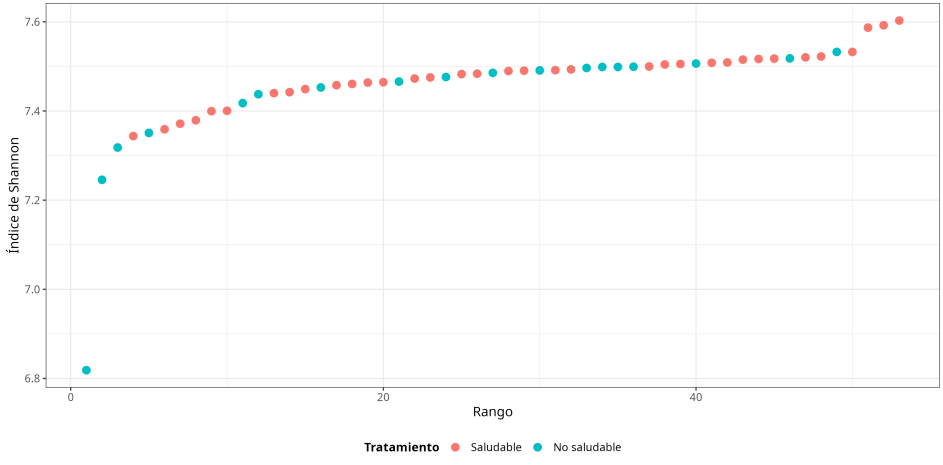


Figura 4.15: Valores del índice de Shannon de la comunidad completa ordenados por rango, coloreados por grupo. Los grupos aparecen mezclados en todo el recorrido. Prueba de Wilcoxon-Mann-Whitney: $W = 376$, $p = 0{,}259$. (Script: `20260919_RegenerarWilcoxonShannon415.R`)

4.2.5. Tamaño del efecto y potencia estadística

La ausencia de significancia debe leerse junto con la potencia del diseño. A partir de las medias y desviaciones estándar de la Tabla 4.1, el tamaño del efecto estandarizado (d de Cohen) para el índice de Shannon de la comunidad completa es $d = 0{,}56$, un efecto de magnitud moderada según

la convención usual (Cohen, 1988). Con 35 y 18 muestras, la potencia de la prueba t para detectar un efecto de ese tamaño al nivel $\alpha = 0{,}05$ es de 0.48 aproximadamente, calculada con la media armónica de los tamaños de grupo ($n \approx 24$) y la desviación estándar combinada ($s_p = 0{,}109$). Para alcanzar una potencia de 0.8 se necesitarían alrededor de 51 muestras por grupo, casi el triple de las plantas no saludables disponibles. La Tabla 4.2 resume todas las pruebas de esta sección.

Tabla 4.2: Resumen de las pruebas de hipótesis sobre el índice de Shannon. Nivel de significancia $\alpha = 0{,}05$. Solo las dos pruebas de dispersión, F de varianzas y PERMDISP, rechazan su hipótesis nula. Scripts: `20260919_RegenerarTTestShannon413.R` (comunidad completa), `20260919_RegenerarTTestFusarium414.R` (géneros de eucariotas), `20260919_RegenerarWilcoxonShannon415.R` (Mann-Whitney) y `20260930_RegenerarPermanovaPermdisp44.R` (PERMANOVA y PERMDISP).

Conjunto	Prueba	Estadístico	g.l.	Valor p
Comunidad completa	t, varianzas iguales (exploratoria)	$t = 1{,}939$	51	0.058
Comunidad completa	t de Welch	$t = 1{,}499$	19.3	0.150
Comunidad completa	Wilcoxon-Mann-Whitney	$W = 376$	–	0.259
Comunidad completa	F de varianzas	$F = 0{,}132$	34, 17	$< 0{,}001$
Géneros de eucariotas	t, varianzas iguales (exploratoria)	$t = 1{,}139$	51	0.260
Géneros de eucariotas	t de Welch	$t = 0{,}902$	20.2	0.378
Géneros de eucariotas	Wilcoxon-Mann-Whitney	$W = 318$	–	0.963
Composición (Bray-Curtis)	PERMANOVA	$F = 1{,}26$, $R^2 = 0{,}024$	1, 51	0.167
Composición (Jaccard)	PERMANOVA	$F = 1{,}24$, $R^2 = 0{,}024$	1, 51	0.170
Dispersión (Bray-Curtis)	PERMDISP	$F = 5{,}10$	1, 51	0.023

4.2.6. Sensibilidad a la normalización y la rarefacción

Las muestras saludables tienen más lecturas que las no saludables (Figura 4.2), y los índices de riqueza dependen del esfuerzo de muestreo. Para separar el efecto de la profundidad del efecto del estado de la planta se aplicaron las tres estrategias descritas en la Sección 3.2.5; la Figura 4.16 y la Tabla 4.3 resumen los resultados.

Las curvas de rarefacción (panel A) se aplanan mucho antes de la profundidad mínima del conjunto, 4.05 millones de lecturas: a esa profundidad cada muestra ya ha detectado en promedio el 96.6 % de su riqueza observada final, y la que menos, el 94.8 %. El muestreo está saturado en todas las

muestras, de modo que secuenciar más no habría cambiado sustancialmente el inventario de taxones. Las curvas de los dos grupos se superponen por completo; no hay un grupo que acumule taxones más rápido que el otro.

Al rarificar todas las muestras a 4 053 295 lecturas con la semilla 2026 se perdieron 44 de los 9 003 taxones, que quedaron sin lecturas en todas las muestras. El panel B muestra la diversidad alfa sobre los datos rarificados. Los índices de Shannon y Simpson no cambian, como corresponde a medidas que dependen solo de las proporciones: las medias de Shannon pasan de 7.478 y 7.417 a 7.478 y 7.416, y la prueba de Welch da exactamente el mismo valor ($t = 1{,}499$, $p = 0{,}150$). Los índices de riqueza sí cambian, y en la dirección esperada: la diferencia de riqueza observada entre grupos se reduce de 26 a 12 taxones y la de Chao1 de 16 a 3, y los valores p de Welch suben de 0.39 a 0.55 y de 0.41 a 0.84, respectivamente. Es decir, la parte de la tendencia hacia mayor riqueza en las plantas saludables que se observaba en los datos originales se explica en buena medida por su mayor profundidad, mientras que la tendencia en Shannon, pequeña y no significativa, es independiente de ella. La mayor varianza del grupo no saludable se mantiene tras rarificar ($F = 0{,}133$, $p < 0{,}001$).

Tabla 4.3: Efecto de la rarefacción sobre los índices de diversidad alfa y las pruebas entre grupos. Medias por grupo y valores p de la prueba de Welch y de Mann-Whitney, sobre los datos originales y sobre los datos rarificados a 4 053 295 lecturas. (Script: `20261001_RegenerarRarefaccionNormalizacion416.R`)

Índice	Datos	Media		Valor p	
		saludable	no saludable	Welch	Mann-Whitney
Riqueza observada	originales	8639.9	8613.7	0.394	0.606
Riqueza observada	rarificados	8342.9	8331.3	0.546	0.293
Chao1	originales	8767.6	8751.6	0.407	0.583
Chao1	rarificados	8590.1	8587.1	0.843	0.993
Shannon	originales	7.478	7.417	0.150	0.259
Shannon	rarificados	7.478	7.416	0.150	0.275
Simpson	originales	0.998	0.997	0.261	0.635
Simpson	rarificados	0.998	0.997	0.261	0.596

La normalización TMM produjo factores de escala entre 0.83 y 1.20, es decir, correcciones composicionales moderadas. Como se anticipó en la

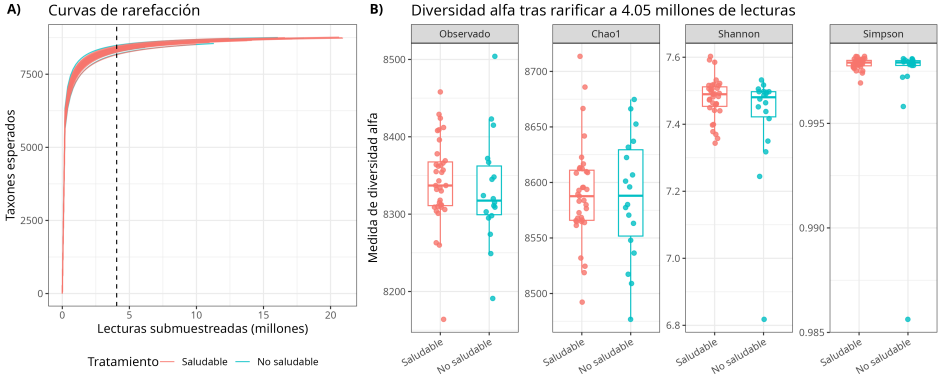


Figura 4.16: Rarefacción. A) Curvas de rarefacción de las 53 muestras filtradas: número esperado de taxones en función del número de lecturas submuestreadas. La línea punteada marca la profundidad mínima del conjunto, a la que se rarificaron todas las muestras. Las curvas se aplanan antes de esa profundidad y los dos grupos se superponen. B) Diversidad alfa calculada sobre los datos rarificados a 4.05 millones de lecturas. Shannon y Simpson son idénticos a los de los datos originales; la diferencia de riqueza entre grupos se reduce. (Script: `20261001_RegenerarRarefaccionNormalizacion416.R`)

Sección 1.10, no altera los índices de diversidad alfa, por lo que su efecto se evaluó sobre el PERMANOVA (Tabla 4.4). Con abundancias relativas y con datos rarificados el resultado es el mismo ($R^2 = 0{,}024$, $p = 0{,}167$); con TMM la fracción explicada baja a 0.020 y el valor p sube a 0.364. En ninguna de las tres versiones el estado de la planta explica una fracción distinguible del azar. La conclusión sobre la composición no depende, por lo tanto, de la estrategia de normalización elegida.

Tabla 4.4: PERMANOVA sobre la disimilitud de Bray-Curtis con tres normalizaciones de la tabla de conteos. Un factor (estado de la planta), 999 permutaciones, semilla 2026. (Script: `20261001_RegenerarRarefaccionNormalizacion416.R`)

Normalización	pseudo-F	R^2	p
Abundancias relativas (TSS)	1.26	0.024	0.167
TMM	1.04	0.020	0.364
Rarefacción a profundidad común	1.26	0.024	0.167

4.3. Patrones asociados con el estado de salud de la planta

Aunque ninguna prueba sobre los índices agregados alcanzó significancia, el análisis por niveles dejó algunos patrones que se reúnen aquí como respuesta al tercer objetivo. Primero se contrasta cuantitativamente la proporción de *Fusarium* y de los demás géneros candidatos identificados en la exploración, y después se describe el patrón de heterogeneidad del grupo no saludable, que es el resultado más sólido del trabajo. Su valor es orientar los modelos y los muestreos futuros que se discuten en los Capítulos 5 y 6.

4.3.1. Taxones candidatos

Proporción de *Fusarium*

Fusarium es el género que motivó buena parte del análisis: incluye a los agentes causales de la marchitez de la fresa, y las plantas del grupo no saludable fueron etiquetadas precisamente por estar marchitas. Si la marchitez

observada se debiera a *Fusarium*, sería esperable una mayor proporción de lecturas de ese género en la rizósfera de esas plantas. Para comprobarlo se calculó, para cada muestra, el porcentaje de lecturas clasificadas asignadas a *Fusarium* con dos denominadores: todas las lecturas clasificadas de la muestra y únicamente las lecturas asignadas a eucariotas (Figura 4.17, paneles A y B). El denominador importa porque los eucariotas representan en promedio solo el 0.64 % de las lecturas clasificadas, de modo que un mismo número de lecturas de *Fusarium* es una fracción minúscula de la comunidad completa pero una fracción grande de la comunidad eucariota.

Sobre la comunidad completa, *Fusarium* representa en promedio el 0.136 % de las lecturas en las plantas saludables y el 0.151 % en las no saludables, con medianas de 0.119 % y 0.127 %. Las distribuciones se superponen casi por completo: el rango de las plantas saludables, de 0.07 % a 0.23 %, contiene a la mayoría de las no saludables, y solo dos plantas marchitas tienen proporciones claramente mayores, de 0.31 % y 0.39 %. La prueba de Mann-Whitney no detecta diferencia ($U = 317$, $p = 0{,}978$); el valor de U es casi exactamente la mitad de los $35 \times 18 = 630$ pares posibles, que es lo esperado si los dos grupos tuvieran la misma distribución. Dentro de la fracción eucariota el cuadro es el mismo: *Fusarium* es el género eucariota dominante, con el 21.1 % de las lecturas de eucariotas en las plantas saludables y el 22.3 % en las no saludables ($p = 0{,}889$). La ligera diferencia de medias se debe por completo a las dos plantas marchitas atípicas, y desaparece en las medianas.

Géneros candidatos

El mismo procedimiento se aplicó a los seis géneros que la exploración por niveles había señalado como candidatos: los fitopatógenos *Phytophthora* y *Ralstonia*, y los géneros asociados con la promoción del crecimiento o el biocontrol *Pseudomonas*, *Bacillus*, *Streptomyces* y *Paenibacillus* (Berendsen et al., 2012; Nam et al., 2023; Spooren et al., 2024). La Figura 4.17, panel C, y la Tabla 4.5 muestran el resultado, que corrige las impresiones obtenidas de las gráficas de barras. Para *Pseudomonas*, *Bacillus*, *Streptomyces* y *Ralstonia* las medianas de los dos grupos difieren en menos del 10 % de su valor y ningún valor p se acerca a la significancia; *Pseudomonas* es incluso ligeramente más abundante en las plantas no saludables.

La media de *Paenibacillus* en el grupo no saludable, 0.95 %, está inflada por una sola muestra con 11.6 %; su mediana, 0.32 %, es igual a la del grupo saludable. El único género con una diferencia nominal es *Phytophthora*: 0.060 % frente a 0.055 %, $p = 0{,}013$, y lo mismo ocurre con el filo Oomycota ($p = 0{,}016$) y la familia Peronosporaceae ($p = 0{,}013$) que lo contienen. La dirección, sin embargo, es la contraria a la esperada para un patógeno, con mayor proporción en las plantas saludables, y la diferencia es pequeña. Al corregir los siete contrastes por comparaciones múltiples con el método de Benjamini-Hochberg (Benjamini and Hochberg, 1995), el valor p ajustado de *Phytophthora* es 0.10 y ninguna diferencia se mantiene.

En conjunto, la comparación cuantitativa no respalda la existencia de géneros biomarcadores del estado de salud en estos datos: ni los patógenos esperados están enriquecidos en las plantas marchitas, ni los géneros benéficos lo están en las saludables. Las diferencias que sugerían las gráficas de barras eran efectos de la escala, de la aglomeración al 10 % y de unas pocas muestras atípicas.

Tabla 4.5: Porcentaje de lecturas clasificadas asignadas a *Fusarium* y a los géneros candidatos, por grupo. Media y mediana por grupo, estadístico U y valor p de Mann-Whitney, y valor p ajustado por Benjamini-Hochberg sobre los siete contrastes. (Script: `20261001_RegenerarProporcionesFusarium417.R`)

Género	Saludable		No saludable		p	p ajustado
	media	mediana	media	mediana		
Fusarium	0.136	0.119	0.151	0.127	0.978	0.978
Phytophthora	0.060	0.062	0.055	0.056	0.013	0.100
Ralstonia	0.195	0.185	0.191	0.174	0.221	0.589
Pseudomonas	1.940	1.886	2.016	1.950	0.418	0.776
Bacillus	0.113	0.107	0.115	0.093	0.485	0.776
Streptomyces	12.95	12.99	12.50	12.41	0.609	0.812
Paenibacillus	0.349	0.338	0.955	0.320	0.147	0.587

4.3.2. Heterogeneidad del grupo no saludable

El patrón estadísticamente más sólido de este trabajo no está en las medias sino en las varianzas. El índice de Shannon de la comunidad completa tiene una desviación estándar de 0.061 en las plantas saludables y de

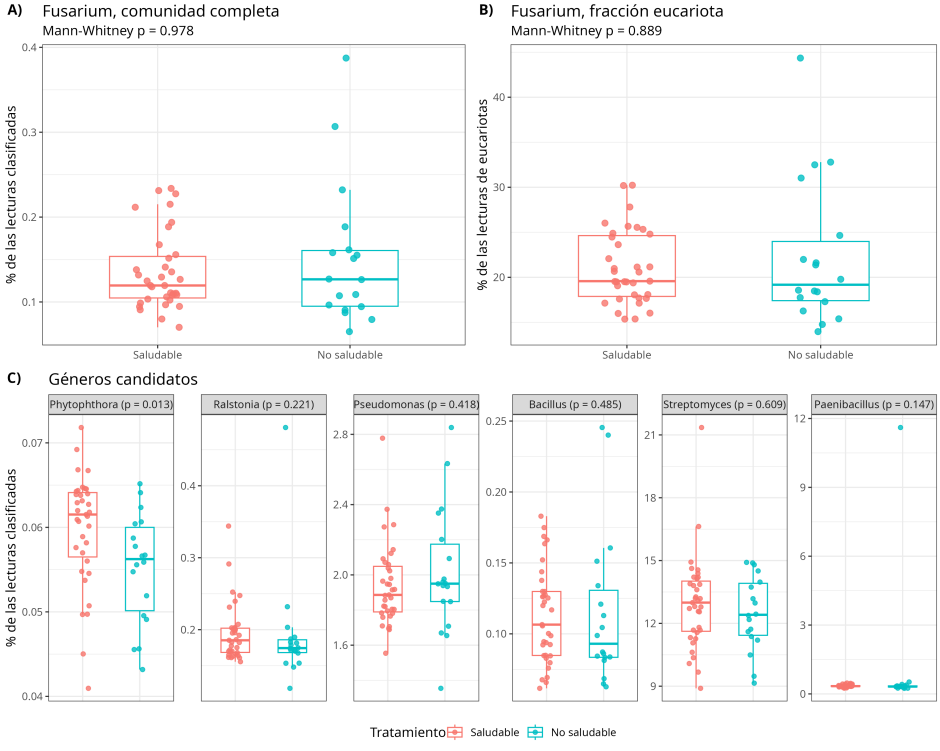


Figura 4.17: Proporción de *Fusarium* y de los géneros candidatos por grupo. A) Porcentaje de las lecturas clasificadas de cada muestra asignadas a *Fusarium*. B) El mismo porcentaje calculado sobre las lecturas asignadas a eucariotas. C) Porcentaje de las lecturas clasificadas asignadas a cada uno de los seis géneros candidatos; cada panel tiene su propia escala. En cada panel se indica el valor p de la prueba de Mann-Whitney sin corrección. (Script: `20261001_RegenerarProporcionesFusarium417.R`)

0.168 en las no saludables, y la prueba F rechaza la igualdad de varianzas con $p < 0{,}001$. El mismo patrón se repite en la diversidad alfa de bacterias por nivel (Figura 4.11), donde los valores del grupo no saludable se extienden mucho más que los del saludable en Shannon a nivel de género y especie. Y se repite en la composición completa: la prueba PERMDISP sobre Bray-Curtis (Figura 4.4) muestra que las plantas no saludables están significativamente más lejos del centroide de su grupo ($p = 0{,}023$). Es decir, las plantas saludables tienen comunidades parecidas entre sí, mientras que cada planta marchita se aleja de ese perfil a su manera: algunas conservan una diversidad indistinguible de la de las plantas sanas y otras la pierden de forma marcada. Este resultado sugiere que la variable que mejor distingue a los grupos no es el nivel de diversidad sino su estabilidad, y que el diagnóstico del estado de salud a partir del microbioma tendría que apoyarse en la distancia de cada muestra al perfil saludable, más que en un umbral de diversidad.

4.3.3. Dónde está y dónde no está la señal

Los resultados de este capítulo delimitan con claridad dónde no está la señal del estado de salud: no está en la composición global de la comunidad, que el PERMANOVA atribuye en más del 97 % a otros factores; no está en el nivel medio de los índices de diversidad, ni en la comunidad completa ni en la fracción eucariota; y no está en los filos dominantes, que tienen proporciones semejantes en todas las muestras. Lo que sí se observa es una tendencia débil pero consistente hacia mayor riqueza en las plantas saludables, que la rarefacción atribuye en buena parte a la profundidad de secuenciación, y una mayor heterogeneidad de las plantas no saludables, confirmada tanto en la diversidad como en la composición. La señal tampoco está en los géneros candidatos: ni *Fusarium* ni ningún otro género difiere entre grupos una vez que se cuantifica su proporción. Con 53 muestras y una potencia cercana a 0.5 para efectos moderados, estas tendencias no pueden confirmarse ni descartarse con las herramientas de este capítulo; el Capítulo 6 describe cómo el modelado con redes bayesianas y la simulación de metagenomas pueden llevar la pregunta más lejos.

4.4. Material didáctico: taller práctico del análisis estadístico

El cuarto objetivo específico fue convertir el análisis de este capítulo en una clase práctica que pueda impartirse y reproducirse sin más requisitos que un navegador. El resultado son dos cuadernos de Python para Google Colab (Sección 1.5.3), disponibles en la carpeta `Taller_Practico` del repositorio de la tesis, pensados para que cada docente elija según el tiempo y el curso de que disponga:

- **Taller completo**, archivo `Taller_Practico_Analisis_estadistico_de_Datos_Metagenomicos.ipynb`, de unas tres horas y media con descanso, que puede darse en dos sesiones. Está organizado en siete episodios al estilo de las lecciones de The Carpentries, cada uno con preguntas y objetivos al inicio, explicación paso a paso, un ejercicio y sus puntos clave: los datos, con un caso real y uno simulado; la lógica de una prueba de hipótesis y el valor p construido por permutaciones; las pruebas t de Student y de Welch con la verificación de supuestos; las pruebas de rangos de Mann-Whitney y de Wilcoxon, con énfasis en cuándo corresponde cada una; la proporción de un género de interés (*Fusarium*) por grupo; el PERMANOVA y el PERMDISP programados a partir de la matriz de Bray-Curtis; y un cierre sobre cómo reportar y comparar los dos casos. Incluye siete ejercicios con la solución oculta en un desplegable, preguntas de opción múltiple cuya respuesta explica por qué fallan las otras opciones, tres laboratorios con controles deslizantes para cambiar la verdad de los datos simulados y ver cómo responde cada prueba, y un glosario.

- **Taller rápido**, archivo `Taller_Rapido_Pruebas_de_hipotesis_con_Datos_Metagenomicos.ipynb`, una versión de 60 minutos en cuatro episodios con los mismos datos y los mismos resultados: los dos casos y la pregunta; diferencia real o azar; elegir la prueba (supuestos, Welch y Mann-Whitney); y comparar comunidades completas con PERMANOVA y PERMDISP. Tiene tres ejercicios y un laboratorio, y el script que lo genera se detiene si el contenido pasa de una hora.

Cada prueba se aplica a dos casos. El primero son los datos reales de este trabajo, reducidos a tablas de texto que se descargan desde el repositorio con una sola instrucción: los metadatos de las 58 muestras, los cuatro índices de diversidad alfa por muestra calculados con phyloseq y los conteos por género y por filo. El segundo es un conjunto simulado dentro del cuaderno, de 60 muestras que cumplen los supuestos de las pruebas y en el que la verdad se conoce porque la elige quien simula; el contraste entre ambos es lo que permite ver qué hace cada prueba cuando los supuestos se cumplen y cuando no. Los resultados que obtiene el estudiante con los datos reales coinciden con los de la Tabla 4.2; la única excepción es el PERMANOVA, que en el taller se calcula sobre la tabla de géneros para que el cómputo sea rápido en Colab, y por eso da $R^2 = 0{,}022$ y $p = 0{,}28$ en lugar de los valores de la tabla completa, con la misma conclusión. Los procedimientos aleatorios usan la misma semilla que la tesis. El taller recoge además las dos lecciones que más pesaron en este trabajo: la comprobación de que los identificadores de muestra coinciden antes de unir dos tablas, y el hecho de que los mismos datos producen valores p de 0.04, 0.058, 0.15 y 0.26 según la prueba que se aplique, de modo que la respuesta válida es la de la prueba cuyos supuestos se cumplen y no la que da el valor p más pequeño. Un laboratorio lo muestra con simulaciones sin diferencia verdadera y el diseño de los datos reales: la t de Student declara una diferencia en el 14 % de los estudios simulados, Mann-Whitney en el 11 % y Welch en el 5 %. Acompañan a los cuadernos un explorador interactivo con figuras de Plotly y una encuesta para los estudiantes, antes y después del taller.

Nota sobre el uso de inteligencia artificial. Para construir este taller me apoyé en Claude Code, el asistente de programación de Anthropic. Partí de una primera versión del cuaderno que escribí yo misma y usé la herramienta para organizar y redactar las celdas de texto y de código, preparar los ejercicios con su solución oculta y comprobar que todo se ejecuta sin errores en Google Colab. El diseño de la clase, la elección de las pruebas que se enseñan, los datos y los resultados que el cuaderno reproduce son los de mi análisis, y revisé y validé cada celda antes de incluirla. Esta nota se refiere únicamente al taller.

Capítulo 5

Discusión y conclusiones

En este capítulo se interpretan los resultados presentados en el Capítulo 4 a la luz de los objetivos planteados en el Capítulo 2. Primero se discuten los hallazgos sobre la calidad de los datos, la diversidad alfa y beta, la composición taxonómica y las pruebas estadísticas; después se señalan las limitaciones del estudio y se presentan las conclusiones. Las perspectivas y el trabajo a futuro que se derivan de estas conclusiones se presentan en el Capítulo 6.

5.1. Discusión

5.1.1. La calidad de los datos condiciona la interpretación

El primer resultado del análisis fue metodológico: la diversidad alfa calculada sobre los datos crudos no permitía distinguir entre plantas saludables y no saludables, mientras que, tras eliminar las cinco muestras con menos de 25 millones de lecturas (MP2079, MP2080, MP2088, MP2109 y MP2137), las tendencias entre grupos se hicieron visibles. Casos como el de la muestra MP2088, con solo dos lecturas, muestran que una única muestra defectuosa puede dominar la escala de los índices y ocultar la estructura del resto de los datos. El filtrado de calidad no es, por lo tanto, un paso accesorio, sino una condición necesaria para que las comparaciones posteriores tengan sentido.

Sin embargo, aun después del filtrado persistió una diferencia sistemática en la profundidad de secuenciación: las muestras de plantas saludables

tuvieron, en promedio, más lecturas que las de plantas no saludables. Los índices que dependen del número de taxones observados o de los *singletons* y *doubletons*, como Chao1, son sensibles a esta diferencia, porque una muestra con más lecturas tiene mayor probabilidad de detectar taxones raros. Por ello, parte de la mayor diversidad observada en las plantas saludables podría explicarse por el esfuerzo de muestreo y no únicamente por el estado de salud de la planta (McMurdie and Holmes, 2014). La rarefacción a profundidad común permitió separar los dos efectos (Sección 4.2.6): las curvas de rarefacción muestran que todas las muestras están saturadas, y al igualar el esfuerzo de muestreo la diferencia de riqueza entre grupos se redujo a menos de la mitad, mientras que la de Shannon, que no depende de la profundidad, se mantuvo idéntica. Es decir, la mayor riqueza aparente de las plantas saludables era en buena parte un efecto de la profundidad; la tendencia en equidad, aunque débil, es genuina. El PERMANOVA tampoco cambió de conclusión con ninguna de las tres normalizaciones probadas, lo que indica que la ausencia de separación entre grupos no es un artefacto de la estrategia de normalización (Weiss et al., 2017).

5.1.2. Diversidad alfa: una tendencia consistente pero débil

Sobre la comunidad completa, en todos los índices de diversidad alfa (riqueza observada, Chao1, Shannon y Simpson) las plantas saludables mostraron valores ligeramente mayores que las no saludables. Al separar los datos por reino y descender a los niveles de filo, familia, género y especie, la tendencia no se mantuvo: la riqueza resultó idéntica en todas las muestras a los niveles gruesos y las medianas de Shannon y Simpson fueron semejantes entre grupos en todos los niveles, de modo que la diferencia es una propiedad del conjunto completo y no de un reino o nivel en particular. La dirección de la tendencia global coincide con lo reportado en otros estudios sobre la rizósfera de fresa y de otros cultivos, en los que la enfermedad se asocia con una pérdida de diversidad microbiana (Xiong et al., 2020; Gao et al., 2021; Yang et al., 2020).

No obstante, la magnitud de la diferencia fue pequeña. Para el índice de Shannon calculado sobre la comunidad completa, las medias fueron 7.478 en el grupo saludable y 7.417 en el no saludable, una diferencia de apenas 0.061 unidades. Ni la prueba t con varianzas distintas ($p = 0{,}1501$) ni la

prueba de Wilcoxon-Mann-Whitney ($p = 0{,}2586$) permitieron rechazar la hipótesis nula de igualdad entre grupos. La tendencia visual, por consistente que sea, no alcanzó a separarse del ruido propio de los datos.

Un resultado que merece atención es la diferencia en la dispersión de los grupos. La desviación estándar del índice de Shannon fue de 0.061 en las plantas saludables y de 0.168 en las no saludables, y la prueba F rechazó con claridad la igualdad de varianzas ($F = 0{,}132$, $p < 0{,}001$). Es decir, las plantas no saludables no difieren tanto en su diversidad promedio como en su variabilidad: sus comunidades microbianas son más heterogéneas entre sí. Este patrón es consistente con el llamado *principio de Anna Karenina* aplicado a microbiomas, según el cual los microbiomas de hospederos sanos tienden a parecerse entre sí, mientras que cada hospedero enfermo o estresado se desestabiliza a su manera (Zaneveld et al., 2017). El mismo principio se ha confirmado recientemente en microbiomas vegetales bajo estrés por patógenos, a partir de más de mil muestras de maíz en las que las plantas enfermas mostraron una dispersión beta sistemáticamente mayor (Li et al., 2026), y la mayor heterogeneidad de las plantas no saludables de este trabajo se verificó también en la composición completa mediante PERMDISP ($p = 0{,}023$, Capítulo 4). Desde el punto de vista estadístico, esta observación sugiere que comparar solo medias puede ser insuficiente y que la dispersión es, en sí misma, una característica diferenciadora entre los grupos.

5.1.3. Diversidad beta: gran superposición entre grupos

Ninguna de las métricas de distancia utilizadas (Bray-Curtis, Jaccard, Euclidiana, Manhattan y Jensen-Shannon) produjo una separación visible entre muestras saludables y no saludables en las ordenaciones. Para cuantificar esta observación se aplicó un análisis PERMANOVA sobre la matriz de disimilitud de Bray-Curtis de las abundancias relativas: el estado de la planta explicó solo el 2.4 % de la variación total en la composición ($R^2 = 0{,}024$, $F = 1{,}26$, $p = 0{,}167$, 999 permutaciones) (Anderson, 2001; Anderson et al., 2011). Es decir, más del 97 % de la variación entre muestras se debe a factores distintos del estado sano o enfermo de la planta. La prueba PERMDISP (Anderson, 2006), en cambio, sí fue significativa ($p = 0{,}023$): las plantas no saludables están más dispersas alrededor de su centroide. Esta combi-

nación, centroides iguales y dispersiones distintas, es precisamente la que recomiendan examinar las revisiones metodológicas antes de interpretar un PERMANOVA con grupos desbalanceados (Kleine Bardenhorst et al., 2021; Aldirawi and Morales, 2023).

Esta superposición indica que la composición global del microbioma rizosférico está dominada por otros factores, probablemente el tipo de suelo, el manejo agronómico, el sitio y el momento de muestreo, que no fueron registrados en los metadatos disponibles. Al restringir el análisis a niveles taxonómicos más finos, en particular género y especie, las diferencias en Bray-Curtis resultaron más evidentes, lo que sugiere que la señal asociada a la salud de la planta, si existe, no está en la estructura global de la comunidad sino en un subconjunto reducido de taxones.

5.1.4. Composición taxonómica: taxones candidatos, no biomarcadores

A nivel de filo, Actinobacteria y Proteobacteria fueron los grupos más abundantes en ambos tipos de muestras, lo que concuerda con la composición típica de la rizósfera de fresa (Yang et al., 2020; Xiong et al., 2020). La exploración por niveles sugería un cuadro familiar en la literatura: géneros benéficos como *Bacillus* y *Pseudomonas* más presentes en las plantas saludables, y fitopatógenos como *Fusarium* y *Ralstonia* en las no saludables, tal como se ha reportado para fresa invadida por *Fusarium* (Yang et al., 2023), en el metaanálisis de rizósferas con marchitez (Su et al., 2025) y en los microbiomas supresores de enfermedad (Spooren et al., 2024). La cuantificación de las proporciones (Sección 4.3.1) no confirmó ese cuadro. *Fusarium* representa alrededor del 0.14 % de las lecturas en ambos grupos, con distribuciones casi idénticas ($p = 0{,}978$); *Pseudomonas*, *Bacillus*, *Streptomyces* y *Ralstonia* tienen medianas prácticamente iguales entre grupos; y la única diferencia nominal, la de *Phytophthora* y su filo Oomycota, va en la dirección contraria a la esperada para un patógeno, es pequeña y no sobrevive a la corrección por comparaciones múltiples.

Este resultado merece dos comentarios. El primero es metodológico: las impresiones que dejan las gráficas de barras con aglomeración al 10 % son engañosas, porque reescalan fracciones minúsculas y porque unas pocas muestras atípicas, como las dos plantas marchitas con el triple de *Fusarium*,

dominan la percepción visual. Solo la comparación cuantitativa, con sus pruebas y su corrección por comparaciones múltiples, permite decidir. El segundo es biológico: que *Fusarium* no esté enriquecido en la rizósfera de las plantas marchitas no descarta su papel en la enfermedad. La clasificación con Kraken asigna lecturas al género y no distingue cepas patógenas de saprófitas; la marchitez puede deberse a otros agentes, como *Verticillium* o *Macrophomina*, no necesariamente bien representados en la base de datos; y la rizósfera no es el tejido donde el patógeno se concentra. Además, los datos son composicionales: las abundancias relativas suman uno, de modo que el aumento de un taxón obliga a la disminución aparente de otros, aun cuando su abundancia absoluta no haya cambiado (Gloor et al., 2017; Calle, 2019). En estos datos, por lo tanto, no se identifican géneros biomarcadores del estado de salud; lo que sí se identifica es que la señal, si existe, no está en la abundancia de un taxón particular.

5.1.5. Diversidad de eucariotas a nivel de género: una señal que no se confirmó

Se esperaba que la señal asociada con los fitopatógenos, diluida en la comunidad completa, resultara detectable al aislar la fracción eucariota, y en particular al índice de Shannon calculado sobre los 58 géneros de eucariotas, grupo que incluye a *Fusarium* y a *Phytophthora*. No fue así: las medias fueron 3.077 en las plantas saludables y 3.035 en las no saludables, y ni la prueba t ($p = 0{,}378$ con Welch; $p = 0{,}260$ en la versión exploratoria con varianzas iguales) ni la de Wilcoxon-Mann-Whitney ($p = 0{,}963$) rechazaron la igualdad entre grupos.

Este resultado tiene una historia que conviene dejar registrada. Una versión anterior del análisis reportaba para este mismo contraste una diferencia significativa ($p = 0{,}0017$), que llegó a presentarse como el hallazgo principal del trabajo. Al recalcularla se encontró que el script construía la tabla de abundancias con funciones que reordenan las muestras por abundancia y luego la unía a los metadatos sin emparejar por nombre de muestra, de modo que cada valor de diversidad quedaba asignado al estado de salud de otra planta. La "diferencia" era un artefacto de ese desemparejamiento. El error es instructivo desde el punto de vista del análisis de datos: una verificación tan simple como comprobar que los identificadores de muestra coinciden

antes de unir dos tablas habría evitado un resultado espurio con un valor p muy convincente. Por eso todas las cifras del Capítulo 4 se recalcularon con scripts que verifican explícitamente ese emparejamiento.

Descartada esa señal, la conclusión es coherente con el resto del capítulo: la comunidad eucariota tampoco distingue a los grupos en su nivel medio de diversidad. Cabe recordar, además, que este contraste fue uno de varios realizados sobre distintos subconjuntos y niveles taxonómicos, de modo que cualquier resultado significativo que aparezca en análisis futuros deberá evaluarse con una corrección por comparaciones múltiples, por ejemplo la de Benjamini-Hochberg (Benjamini and Hochberg, 1995).

5.1.6. Tamaño de muestra y potencia estadística

La ausencia de significancia en la comunidad completa no debe leerse como evidencia de que no exista diferencia entre los grupos. Con las medias y desviaciones estándar observadas del índice de Shannon, el tamaño del efecto estandarizado (d de Cohen) fue de aproximadamente 0.56, un efecto de magnitud moderada. Con los 35 y 18 metagenomas disponibles, la potencia de una prueba t para detectar un efecto de ese tamaño con $\alpha = 0{,}05$ es de apenas 0.48 aproximadamente: aun si la diferencia fuera real, el diseño la detectaría menos de la mitad de las veces. Para alcanzar una potencia de 0.8 se necesitarían alrededor de 51 muestras por grupo, casi el triple del número actual de plantas no saludables (Xia et al., 2018).

Este cálculo reencuadra los resultados del Capítulo 4: la falta de significancia es compatible con un efecto real que el diseño no tiene potencia suficiente para detectar. El desbalance entre grupos, con casi el doble de muestras saludables que no saludables, y la mayor varianza precisamente en el grupo más pequeño agravan el problema. Esta limitación motiva directamente el trabajo a futuro descrito en el Capítulo 6.

5.1.7. Limitaciones del estudio

Además del tamaño de muestra, el estudio presenta las siguientes limitaciones:

- **Diseño observacional y metadatos limitados.** Solo se contó con la etiqueta saludable o no saludable de cada planta. No se dispuso

de variables como tipo de suelo, sitio, fecha de muestreo, variedad o manejo agronómico, que podrían explicar buena parte de la variación observada en la diversidad beta.

- **Etiquetado binario de la enfermedad.** La categoría "no saludable" agrupa plantas marchitas sin identificar el agente causal ni la severidad de la enfermedad, lo que puede contribuir a la alta variabilidad observada en ese grupo.
- **Clasificación taxonómica.** La asignación con Kraken depende de la base de datos de referencia; los eucariotas, en particular los hongos, están menos representados que las bacterias, lo que puede sesgar su detección y abundancia.
- **Profundidad de secuenciación desigual.** Las muestras saludables tuvieron más lecturas, lo que puede inflar los índices de riqueza en ese grupo.
- **Asociación y no causalidad.** Las diferencias observadas son asociaciones; con el diseño actual no es posible determinar si los cambios en el microbioma son causa o consecuencia de la enfermedad.

5.2. Conclusiones

En relación con los objetivos planteados, se concluye lo siguiente:

1. **Caracterización de la composición y la diversidad.** Se caracterizó el microbioma rizosférico de 53 plantas de fresa, 35 saludables y 18 no saludables, a los niveles de reino, filo, familia, género y especie. La comunidad está dominada por bacterias, principalmente Actinobacteria y Proteobacteria, en ambos grupos. Sobre la comunidad completa, las plantas saludables mostraron una diversidad alfa ligeramente mayor en los cuatro índices, diferencia que no se mantuvo al desagregar por reino y nivel taxonómico, donde las medianas de los grupos coinciden y lo único que se repite es la mayor dispersión del grupo no saludable. Además, el filtrado de calidad resultó indispensable para obtener comparaciones interpretables, y la rarefacción mostró que la

diferencia de riqueza se debe en buena parte a la mayor profundidad de secuenciación de las plantas saludables, mientras que la diferencia en Shannon es independiente de la profundidad.

2. **Evaluación estadística de las diferencias.** Ni en la comunidad completa ni en la fracción eucariota las diferencias en diversidad alfa fueron estadísticamente significativas, y el estado de la planta explicó una fracción muy pequeña de la variación en la composición. Las únicas pruebas que rechazaron su hipótesis nula fueron las de igualdad de dispersión, la F sobre las varianzas de Shannon y PERMDISP sobre la composición: las plantas no saludables son significativamente más heterogéneas entre sí. El análisis de potencia muestra que el tamaño de muestra actual es insuficiente para detectar efectos moderados, por lo que los resultados no significativos deben interpretarse como no concluyentes y no como ausencia de efecto.

3. **Patrones asociados con el estado de salud.** Las plantas no saludables presentaron comunidades más heterogéneas entre sí, con una varianza de la diversidad significativamente mayor. En cambio, la comparación cuantitativa de las proporciones de *Fusarium* y de los géneros candidatos que la exploración había sugerido, *Pseudomonas*, *Bacillus*, *Streptomyces*, *Paenibacillus*, *Ralstonia* y *Phytophthora*, no mostró diferencias entre grupos: ningún género está enriquecido en una condición una vez que se corrige por comparaciones múltiples. El estado de salud no se refleja en la abundancia de un taxón particular sino en la estabilidad del conjunto, lo que orienta hacia modelos que capturen las relaciones entre microorganismos.

4. **Clase práctica.** El análisis se convirtió en un taller en forma de cuadernos de Google Colab de acceso abierto, en dos versiones según la necesidad del curso o del docente: una completa de siete episodios y unas tres horas y media, y una rápida de cuatro episodios y una hora, que reproducen con los mismos datos cada prueba de este trabajo y la explican con ejercicios resueltos y laboratorios interactivos. El taller enseña a elegir la prueba según el diseño y los supuestos, a construir un valor p por permutaciones y a reportar tamaño del efecto, estadístico y valor p, y recoge como lecciones los dos problemas que más pesaron

en este trabajo: el emparejamiento de tablas por identificador y la dependencia del valor p respecto de los supuestos de cada prueba.

En conjunto, este trabajo muestra que el análisis de datos metagenómicos requiere algo más que la aplicación directa de índices ecológicos: exige controlar la calidad y la profundidad de los datos, tener en cuenta su naturaleza composicional, evaluar la potencia estadística del diseño y considerar la dispersión, y no solo las medias, como una característica informativa. Las tendencias observadas son consistentes con la hipótesis de que la salud de la planta de fresa se asocia con un microbioma rizosférico más diverso y estable, pero confirmarla requiere más datos y modelos capaces de capturar la estructura de dependencia entre los microorganismos.

Capítulo 6

Perspectivas y trabajo a futuro

Las limitaciones identificadas en el Capítulo 5, en particular la baja potencia estadística y la dificultad de separar los grupos con métricas globales, orientan el trabajo a futuro en dos líneas complementarias: una que se encuentra actualmente en desarrollo, la modelación con redes bayesianas, y otra de más largo plazo, la puesta en funcionamiento de un simulador de datos metagenómicos.

6.1. Redes bayesianas (en desarrollo)

Todo el análisis de este trabajo responde a una misma clase de pregunta: ¿difieren los grupos? Los índices de diversidad resumen cada comunidad en un número, las pruebas de hipótesis comparan esos números y el PERMANOVA compara composiciones completas, pero ninguno dice *cómo* se relacionan las piezas entre sí. Los resultados del Capítulo 4 dejan precisamente esa pregunta abierta: la proporción de *Fusarium* no distingue a las plantas enfermas, y sin embargo las plantas enfermas son más heterogéneas, de modo que si *Fusarium* interviene en la marchitez no lo hace solo, sino a través de su relación con el resto de la comunidad. Para formular esa hipótesis como un modelo se está desarrollando una red bayesiana.

Una red bayesiana es un modelo gráfico probabilístico (Pearl, 1988; Koller and Friedman, 2009): un grafo acíclico dirigido $G = (V, E)$ cuyos nodos son variables aleatorias y cuyos arcos representan dependencias condiciona-

les directas. Su propiedad central es que la distribución conjunta de todas las variables se factoriza en términos locales,

$$P(X_1, \ldots, X_n) = \prod_{i=1}^{n} P\left(X_i \mid \mathrm{Pa}(X_i)\right), \tag{6.1}$$

donde $\mathrm{Pa}(X_i)$ es el conjunto de padres del nodo X_i en el grafo. Cada variable depende solo de sus padres, y eso convierte el grafo en una afirmación legible sobre qué influye en qué: si el estado de la planta tiene como padre al índice de Shannon y este a su vez a *Fusarium*, el modelo dice que *Fusarium* afecta a la salud de la planta a través de la diversidad y no directamente. A diferencia de una red de coocurrencia como las de la Sección 3.3, que solo registra qué taxones varían juntos, una red bayesiana permite calcular probabilidades condicionales, hacer predicciones y comparar hipótesis sobre la estructura de dependencia.

En el modelo que se está construyendo, los nodos son la abundancia relativa de *Fusarium*, el índice de Shannon como resumen de la diversidad alfa, las abundancias de los taxones dominantes de la comunidad y el estado de salud de la planta. La estructura, es decir, qué arcos existen, no se fija de antemano sino que se aprende de los datos con el paquete `bnlearn` de R (Scutari, 2010), mediante algoritmos de búsqueda que puntúan cada grafo candidato por qué tan bien explica las 53 muestras. Con tan pocas muestras, el grafo aprendido es inestable: un cambio pequeño en los datos puede añadir o quitar arcos. Para no leer como hallazgo lo que es ruido, la estructura se valida de dos maneras. Con *bootstrapping* se reaprende la red sobre cientos de remuestreos de los datos y se conservan solo los arcos que aparecen en una fracción alta de ellas; con validación cruzada de k particiones se mide si el modelo predice el estado de salud de plantas que no vio durante el aprendizaje. Un arco que sobrevive al bootstrapping y mejora la predicción fuera de muestra es una relación en la que se puede confiar.

Lo que este enfoque aporta sobre lo ya hecho es un cambio de pregunta. En lugar de preguntar *si* los grupos difieren, pregunta *qué* variables se relacionan con el estado de la planta y por medio de cuáles otras; permite examinar el papel indirecto de *Fusarium*, cuya proporción no difiere entre grupos pero cuya relación con la diversidad y con los taxones dominantes sí podría hacerlo; y lleva las redes de coocurrencia exploratorias, construidas

con correlaciones y herramientas como MicNet (Favila et al., 2022), hacia un modelo probabilístico con el que se puede hacer inferencia. Su limitación es la misma que atraviesa todo el trabajo: con 53 muestras el número de nodos debe mantenerse pequeño, y de ahí que esta línea dependa de la siguiente.

6.2. Simulador de datos metagenómicos

A más largo plazo, se propone contar con un simulador de datos metagenómicos plenamente funcional, que permita generar conjuntos de datos adicionales para fortalecer el análisis y llegar a resultados más significativos. Como parte de este proyecto se desarrolló una primera versión de PyMetaSeem, un simulador escrito en Python que genera lecturas a partir de genomas de referencia en formato FASTA. PyMetaSeem recibe un perfil taxonómico con la cantidad de lecturas por genoma, corta lecturas aleatorias de longitud determinada, calcula su reverso complementario y produce archivos FASTQ con la calidad asociada. Se concibió como una alternativa más sencilla de instalar y usar que simuladores como CAMISIM (Fritz et al., 2019). El desempeño de este y otros simuladores de lecturas cortas ha sido evaluado de manera sistemática (Milhaven and Pfeifer, 2023), y los retos CAMI han mostrado el valor de los metagenomas simulados para comparar clasificadores y ensambladores (Meyer et al., 2022).

El flujo de trabajo propuesto consiste en:

1. Estimar, a partir de los datos reales, los perfiles taxonómicos característicos de las plantas saludables y no saludables: las abundancias medias de cada taxón, su variabilidad y las relaciones entre taxones, incluidas las aprendidas por la red bayesiana.

2. Generar nuevos perfiles taxonómicos muestreando de esos modelos y convertirlos, con PyMetaSeem, en metagenomas sintéticos, es decir, archivos de lecturas FASTQ.

3. Procesar los metagenomas sintéticos con el mismo flujo del Capítulo 3: clasificación con Kraken, filtrado, índices de diversidad y pruebas de hipótesis.

Este esquema cumple varios propósitos. En primer lugar, permite realizar análisis de potencia por simulación: generar conjuntos de datos con distintos tamaños de muestra y tamaños de efecto conocidos, y estimar cuántas muestras reales serían necesarias para detectar con confianza las diferencias observadas, lo que puede orientar el diseño de futuros muestreos. En segundo lugar, como en los datos simulados la composición verdadera es conocida, permite evaluar la exactitud del propio flujo de análisis: qué tanto sesgan la clasificación taxonómica, la profundidad de secuenciación desigual y la rarefacción los índices de diversidad. En tercer lugar, permite validar las redes bayesianas: si se simulan datos a partir de una red con estructura conocida, es posible medir qué tan bien los algoritmos de aprendizaje recuperan esa estructura con el tamaño de muestra disponible.

Es importante precisar el alcance de esta línea de trabajo. Los datos simulados heredan los supuestos del modelo con el que se generan, por lo que no sustituyen a nuevas muestras biológicas como evidencia de una diferencia real entre plantas sanas y enfermas. Su valor está en cuantificar la incertidumbre, validar los métodos y diseñar mejores experimentos. La combinación de un simulador funcional, un modelo de redes bayesianas y nuevos muestreos dirigidos permitiría, en conjunto, llegar a conclusiones estadísticamente más sólidas sobre la relación entre el microbioma rizosférico y la salud de la fresa.

6.3. Otras líneas

Por último, se identifican otras extensiones naturales de este trabajo:

- Aplicar pruebas de abundancia diferencial que consideren la naturaleza composicional de los datos, con corrección por comparaciones múltiples, para confirmar los taxones candidatos.
- Construir un clasificador de muestras saludables y no saludables con aprendizaje automático, por ejemplo un bosque aleatorio (*random forest*; Breiman, 2001), que además permita ordenar los taxones por su importancia para la clasificación.
- Integrar los conjuntos de datos adicionales obtenidos, con cinco categorías según el tipo de cultivo y el estado de la planta, para evaluar si

los patrones observados se mantienen en otros contextos agronómicos.

Apéndice A

Procedencia de las figuras, tablas y resultados

Todas las figuras y tablas con resultados de este trabajo se generan con scripts de R que están en la carpeta `Analisis_Comparativo/Fresa_Solena/` del repositorio público de la tesis:

`https://github.com/CamilaSilva1995/Tesis_Maestria`

Cada leyenda indica, entre paréntesis y con enlace al repositorio, el nombre del script que la produjo. Los scripts de 2026 siguen la convención `AAAAMMDD_Regenerar<Contenido><Figura>.R`, donde el sufijo numérico es el número de la figura en la tesis sin el punto (por ejemplo, `...BarrasFilo45.R` genera la Figura 4.5 y `...RedesMuestras32.R` la Figura 3.2). Todos fijan la semilla 2026 antes de cualquier procedimiento aleatorio, guardan la imagen a 300 dpi en `latex/Img/` y una copia en `Results_img/`, y toman la paleta de colores, el tema gráfico y el cargador de datos del archivo común `_paleta_tesis.R` (o `_cargar_complementarios.R` para los conjuntos complementarios). Los scripts de 2023 (prefijo `2023MMDD_`) y los reportes `01_` a `13_*.Rmd` son el análisis exploratorio original; las versiones de 2026 reproducen sus cálculos sobre los mismos datos y corrigen los errores descritos en el Capítulo 4. Las Tablas A.1 y A.2 indican de dónde sale cada figura y cada tabla.

Tabla A.1: Script y archivo de imagen de cada figura (archivos en `latex/Img/cap1/`, `cap2/` o `cap3/` según el capítulo; scripts en `Analisis_Comparativo/Fresa_Solena/`). Los diagramas de los capítulos 1 y 3 son de elaboración propia y no tienen script. "Data1" es el conjunto principal (53 muestras filtradas); "Data_all" y "Data3" son los conjuntos complementarios de la Sección 3.4.

Fig.	Archivo	Script	Datos
1.1	`taxonomic.png`	diagrama propio	–
1.2	`Phyloseq.png`	diagrama propio	–
1.3	`pruebat_explicacion.png`	`20260919_Regenerar PruebatExplicacion13.R`	–
3.1	`preprosecamiento.png`	diagrama propio (`01_Exploracion.Rmd`)	Data1
3.2	`Redes_muestras.png`	`20261002_Regenerar RedesMuestras32.R`	Data1
3.3	`Redes_coocurrencia.png`	`20261002_Regenerar RedesCoocurrencia33.R`	Data1, Redes/
3.4	`Complementarios_alfa.png`	`20261002_Regenerar Complementarios34.R`	Data_all
3.5	`Complementarios_beta.png`	`20261002_Regenerar Complementarios35.R`	Data_all
3.6	`Complementarios_nativo.png`	`20261002_Regenerar Complementarios36.R`	Data3
4.1	`AlphaDiversity_ CrudosFiltrados.png`	`20260924_Regenerar AlphaCrudosFiltrados41.R`	Data1
4.2	`Barras.png`	`20260924_Regenerar BarrasLecturas42.R`	Data1
4.3	`BetaDiversity.png`	`20260924_Regenerar BetaDiversity43.R`	Data1
4.4	`PERMANOVA_PERMDISP.png`	`20260930_Regenerar PermanovaPermdisp44.R`	Data1
4.5	`BarrasFilo.png`	`20260919_Regenerar BarrasFilo45.R`	Data1
4.6	`BarrasFilo_ blackandwhite.png`	`20260906_Regenerar BarrasFiloBN46.R`	Data1
4.7	`Barras_Eukarya10.png`	`20260924_Regenerar BarrasEukarya47.R`	Data1
4.8	`Alpha_Eukarya.png`	`20260919_Regenerar AlphaEukarya48.R`	Data1
4.9	`Beta_Eukarya.png`	`20260919_Regenerar BetaEukarya49.R`	Data1
4.10	`Barras_Bacteria10.png`	`20260919_Regenerar BarrasBacteria410.R`	Data1
4.11	`Alpha_Bacteria.png`	`20260919_Regenerar AlphaBacteria411.R`	Data1
4.12	`Beta_Bacteria.png`	`20260919_Regenerar BetaBacteria412.R`	Data1
4.13	`tTest_Shannon.png`	`20260919_Regenerar TTestShannon413.R`	Data1
4.14	`tTest_Shannon_Fusarium.png`	`20260919_Regenerar TTestFusarium414.R`	Data1
4.15	`Wilcoxon_Shannon.png`	`20260919_Regenerar WilcoxonShannon415.R`	Data1
4.16	`Rarefaccion_ Normalizacion.png`	`20261001_Regenerar RarefaccionNormalizacion416.R`	Data1
4.17	`Proporciones_Fusarium.png`	`20261001_Regenerar`	Data1

Tabla A.2: Script que calcula los valores de cada tabla y archivo `.csv` con los resultados, guardado en `Analisis_Comparativo/Fresa_Solena/Results_img/`. Los valores de la Tabla 4.2 se imprimen en la consola de los scripts indicados.

Tabla	Contenido	Script	Resultados (`.csv`)
3.1	Lecturas por muestra	`01_Exploracion.Rmd` (`sample_sums`)	–
3.2	Métricas de la red SparCC	`20261002_Regenerar RedesCoocurrencia33.R`	`Redes_metricas.csv`
3.3	PERMANOVA por pares, cinco categorías	`20261002_Regenerar Complementarios35.R`	`Complementarios_ permanova_pares.csv`, `Complementarios_ permanova.csv`
4.1	Medias de diversidad alfa por grupo	`20260924_Regenerar AlphaCrudosFiltrados41.R`	–
4.2	Resumen de pruebas de hipótesis	`...TTestShannon413.R`, `...TTestFusarium414.R`, `...WilcoxonShannon415.R`, `...PermanovaPermdisp44.R`	`PERMANOVA_PERMDISP_ resultados.csv`
4.3	Efecto de la rarefacción	`20261001_Regenerar RarefaccionNormalizacion416.R`	`Rarefaccion_ pruebas.csv`
4.4	PERMANOVA con tres normalizaciones	`20261001_Regenerar RarefaccionNormalizacion416.R`	`Normalizacion_ PERMANOVA.csv`
4.5	Proporciones de *Fusarium* y géneros candidatos	`20261001_Regenerar ProporcionesFusarium417.R`	`Proporciones_generos_ candidatos.csv`

Los resultados numéricos citados en el texto que no están en una tabla (potencia estadística, tamaño del efecto, prueba de Shapiro-Wilk, fracción de aristas dentro de cada grupo en las redes de muestras, Kruskal-Wallis y Mann-Whitney de los conjuntos complementarios) se imprimen en la consola de los scripts correspondientes:

- `Articulo_Popayan/calculos/Potencia_estadistica.R`: potencia y tamaño del efecto;
- `20260919_RegenerarTTestShannon413.R`: Shapiro-Wilk, prueba F y Mann-Whitney sobre Shannon;
- `20261002_RegenerarRedesMuestras32.R`: fracción de aristas dentro de cada grupo;
- `20261002_RegenerarComplementarios34.R` y `...36.R`: Kruskal-Wallis y Mann-Whitney de los conjuntos complementarios.

Las fórmulas del Capítulo 1 se verificaron numéricamente contra phyloseq y vegan en `Articulo_Popayan/calculos/Verificacion_formulas.R`.

Apéndice B

Datos, entorno de cómputo y reproducción

Datos

Los metagenomas de rizósfera de fresa fueron proporcionados por la empresa Solena, con Obed Ramírez Sánchez como contacto, ya clasificados taxonómicamente con Kraken. En el repositorio, la carpeta `Data/fresa_solena/` contiene los reportes de Kraken por muestra, las estadísticas de calidad de fastp y las tablas BIOM construidas con `kraken-biom` (Tabla B.1). El conjunto `Data1` es el que se analiza en los Capítulos 3 y 4; `Data_all` y `Data3` se usan solo en la Sección 3.4.

Tabla B.1: Conjuntos de datos del repositorio. En `Data1` el filtro de calidad elimina las muestras con menos de 25 millones de lecturas tras fastp (columna `Reads_A` de `fastp_kraken_summary.csv`): MP2079, MP2080, MP2088, MP2109 y MP2137.

Carpeta	Muestras	Archivo BIOM	Categorías
`Data1/`	58 (53 filtradas)	`fresa_kraken.biom`	saludable (35), no saludable (18)
`Data2/`	27	`fresa_kraken.biom`	cerca del cultivo (10), suelo no cultivado (10), bosque degradado (7)
`Data3/`	8	`crop_vs_native_kraken.biom`	cultivo (4), suelo nativo (4)
`Data_all/`	85 (80 filtradas)	`fresa_kraken_all.biom`	las de Data1 y Data2, cinco categorías

Los metadatos de cada conjunto están en su `metadata.csv`, con el identificador de la muestra y su categoría. Las salidas de MicNet y Alnitak para las redes de coocurrencia están en `Data1/Redes/`.

Entorno de cómputo

Los análisis se ejecutaron en R 4.3.3 con phyloseq 1.46.0, vegan 2.6.8, ggplot2 3.5.1, igraph 2.1.3, edgeR 4.0.16, cowplot 1.1.3, reshape2 1.4.4 y RColorBrewer 1.1.3. Las redes de coocurrencia SparCC se calcularon con MicNet y Alnitak (Sección 3.3). El taller de la Sección 4.4 usa Python 3 con numpy, pandas, scipy y matplotlib en Google Colab. La semilla de todos los procedimientos aleatorios (NMDS, permutaciones del PERMANOVA y del PERMDISP, rarefacción, trazado de redes) es 2026.

Cómo reproducir una figura

Desde la raíz del repositorio, cada figura se regenera ejecutando su script; por ejemplo, para la Figura 4.4:

```
cd Analisis_Comparativo/Fresa_Solena
Rscript 20260930_RegenerarPermanovaPermdisp44.R
```

El script imprime los resultados numéricos en la consola, guarda la imagen en `latex/Img/cap3/PERMANOVA_PERMDISP.png` y en `Results_img/`, y escribe los valores en `Results_img/PERMANOVA_PERMDISP_resultados.csv`. Las ordenaciones NMDS, que tardan varios minutos, se guardan en archivos `.rds` dentro de `Results_img/`; borrarlos fuerza el recálculo. La tesis se compila con `pdflatex` y `bibtex` desde `latex/main.tex`.

Bibliografía

Aldirawi, H. and Morales, F. G. (2023). Univariate and multivariate statistical analysis of microbiome data: an overview. *Applied Microbiology*, 3(2):322–338.

Anderson, M. J. (2001). A new method for non-parametric multivariate analysis of variance. *Austral Ecology*, 26(1):32–46.

Anderson, M. J. (2006). Distance-based tests for homogeneity of multivariate dispersions. *Biometrics*, 62(1):245–253.

Anderson, M. J., Crist, T. O., Chase, J. M., Vellend, M., Inouye, B. D., Freestone, A. L., Sanders, N. J., Cornell, H. V., Comita, L. S., Davies, K. F., et al. (2011). Navigating the multiple meanings of β diversity: a roadmap for the practicing ecologist. *Ecology letters*, 14(1):19–28.

Benjamini, Y. and Hochberg, Y. (1995). Controlling the false discovery rate: a practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological)*, 57(1):289–300.

Berendsen, R. L., Pieterse, C. M. J., and Bakker, P. A. H. M. (2012). The rhizosphere microbiome and plant health. *Trends in Plant Science*, 17(8):478–486.

Berry, D. and Widder, S. (2014). Deciphering microbial interactions and detecting keystone species with co-occurrence networks. *Frontiers in microbiology*, 5:219.

Bisong, E. (2019). Google Colaboratory. In *Building Machine Learning and*

Deep Learning Models on Google Cloud Platform, pages 59–64. Apress, Berkeley, CA.

Blondel, V. D., Guillaume, J.-L., Lambiotte, R., and Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10):P10008.

Bokulich, N. A., Kaehler, B. D., Rideout, J. R., Dillon, M., Bolyen, E., Knight, R., Huttley, G. A., and Caporaso, J. G. (2018). Optimizing taxonomic classification of marker-gene amplicon sequences with QIIME 2's q2-feature-classifier plugin. *Microbiome*, 6(1):90.

Bolyen, E., Rideout, J. R., Dillon, M. R., Bokulich, N. A., Abnet, C. C., Al-Ghalith, G. A., Alexander, H., Alm, E. J., Arumugam, M., Asnicar, F., et al. (2019). Reproducible, interactive, scalable and extensible microbiome data science using qiime 2. *Nature biotechnology*, 37(8):852–857.

Bray, J. R. and Curtis, J. T. (1957). An ordination of the upland forest communities of southern wisconsin. *Ecological monographs*, 27(4):326–349.

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.

Breitwieser, F. P., Lu, J., and Salzberg, S. L. (2019). A review of methods and databases for metagenomic classification and assembly. *Briefings in bioinformatics*, 20(4):1125–1136.

Calle, M. L. (2019). Statistical analysis of metagenomics data. *Genomics & informatics*, 17(1).

Chao, A. (1984). Nonparametric estimation of the number of classes in a population. *Scandinavian Journal of statistics*, pages 265–270.

Chao, A. (1987). Estimating the population size for capture-recapture data with unequal catchability. *Biometrics*, pages 783–791.

Chen, S., Zhou, Y., Chen, Y., and Gu, J. (2018). fastp: an ultra-fast all-in-one FASTQ preprocessor. *Bioinformatics*, 34(17):i884–i890.

Cock, P. J. A., Fields, C. J., Goto, N., Heuer, M. L., and Rice, P. M. (2010). The Sanger FASTQ file format for sequences with quality scores, and the Solexa/Illumina FASTQ variants. *Nucleic Acids Research*, 38(6):1767–1771.

Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences*. Lawrence Erlbaum Associates, Hillsdale, NJ, 2 edition.

Compant, S., Samad, A., Faist, H., and Sessitsch, A. (2019). A review on the plant microbiome: Ecology, functions, and emerging trends in microbial application. *Journal of Advanced Research*, 19:29–37.

Csardi, G. and Nepusz, T. (2006). The igraph software package for complex network research. *InterJournal, Complex Systems*, 1695.

Dabdoub, S. M. (2016). kraken-biom: Enabling interoperative format conversion for Kraken results. `https://github.com/smdabdoub/kraken-biom`.

Douglas, G. M., Maffei, V. J., Zaneveld, J. R., Yurgel, S. N., Brown, J. R., Taylor, C. M., Huttenhower, C., and Langille, M. G. I. (2020). PICRUSt2 for prediction of metagenome functions. *Nature Biotechnology*, 38(6):685–688.

Drobek, M., Cybulska, J., Gałązka, A., Feledyn-Szewczyk, B., Marzec-Grządziel, A., Sas-Paszt, L., Gryta, A., Trzciński, P., Zdunek, A., and Frąc, M. (2021). The use of interactions between microorganisms in strawberry cultivation (Fragaria x ananassa Duch.). *Frontiers in Plant Science*, 12:780099.

Du, Y., Han, X., and Tsuda, K. (2024). Microbiome-mediated plant disease resistance: recent advances and future directions. *Journal of General Plant Pathology*, 91(1):1–17.

Endres, D. M. and Schindelin, J. E. (2003). A new metric for probability distributions. *IEEE Transactions on Information Theory*, 49(7):1858–1860.

Favila, N., Madrigal-Trejo, D., Legorreta, D., Sánchez-Pérez, J., Espinosa-Asuar, L., Eguiarte, L. E., and Souza, V. (2022). Micnet toolbox: Visualizing and unraveling a microbial network. *Plos one*, 17(6):e0259756.

Friedman, J. and Alm, E. J. (2012). Inferring correlation networks from genomic survey data. *PLoS Computational Biology*, 8(9):e1002687.

Fritz, A., Hofmann, P., Majda, S., Dahms, E., Dr¨oge, J., Fiedler, J., Lesker, T. R., Belmann, P., DeMaere, M. Z., Darling, A. E., et al. (2019). Camisim: simulating metagenomes and microbial communities. *Microbiome*, 7(1):1–12.

Fruchterman, T. M. and Reingold, E. M. (1991). Graph drawing by force-directed placement. *Software: Practice and Experience*, 21(11):1129–1164.

Gao, M., Xiong, C., Gao, C., Tsui, C. K., Wang, M.-M., Zhou, X., Zhang, A.-M., and Cai, L. (2021). Disease-induced changes in plant microbiome assembly and functional adaptation. *Microbiome*, 9:1–18.

Gloor, G. B., Macklaim, J. M., Pawlowsky-Glahn, V., and Egozcue, J. J. (2017). Microbiome datasets are compositional: and this is not optional. *Frontiers in Microbiology*, 8:2224.

Gower, J. C. (1966). Some distance properties of latent root and vector methods used in multivariate analysis. *Biometrika*, 53(3-4):325–338.

Hall, M. and Beiko, R. G. (2018). 16s rrna gene analysis with qiime2. *Microbiome analysis: methods and protocols*, pages 113–129.

Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. *Nature*, 585:357–362.

Hunter, J. D. (2007). Matplotlib: a 2D graphics environment. *Computing in Science & Engineering*, 9(3):90–95.

Hurlbert, S. H. (1971). The nonconcept of species diversity: a critique and alternative parameters. *Ecology*, 52(4):577–586.

Jaccard, P. (1912). The distribution of the flora in the alpine zone. *New Phytologist*, 11(2):37–50.

Kleine Bardenhorst, S., Berger, T., Klawonn, F., Vital, M., Karch, A., and Rübsamen, N. (2021). Data analysis strategies for microbiome studies in human populations: a systematic review of current practice. *mSystems*, 6(1):e01154–20.

Koller, D. and Friedman, N. (2009). *Probabilistic Graphical Models: Principles and Techniques*. MIT Press, Cambridge, MA.

Kruskal, J. B. (1964). Multidimensional scaling by optimizing goodness of fit to a nonmetric hypothesis. *Psychometrika*, 29(1):1–27.

Kullback, S. and Leibler, R. A. (1951). On information and sufficiency. *The Annals of Mathematical Statistics*, 22(1):79–86.

Kumar, V., Prasad, R., Kumar, M., and Choudhary, D. K. (2019). *Microbiome in Plant Health and Disease: Challenges and Opportunities*. Springer.

Laboratorio de la Dra. Nelly Sélem Mojica (2023). Alnitak: herramienta para el cálculo de vecinos de un taxón de interés en tablas de abundancia. Software de uso interno, Centro de Ciencias Matemáticas, UNAM. Sin publicar.

Lal, S. and Tabacchioni, S. (2009). Ecology and biotechnological potential of *Paenibacillus polymyxa*: a minireview. *Indian Journal of Microbiology*, 49(1):2–10.

Larsen, R. J. and Marx, M. L. (2005). *An introduction to mathematical statistics*. Prentice Hall Hoboken, NJ.

Legendre, P. and Legendre, L. (2012). *Numerical Ecology*. Elsevier, Amsterdam, 3 edition.

Li, D., Qu, Z., Wang, C., Peng, Z., Zhou, X., and Cai, L. (2026). The Anna Karenina principle in the assembly of plant microbiome under pathogen stress. *npj Biofilms and Microbiomes*, 12:91.

Li, H., Handsaker, B., Wysoker, A., Fennell, T., Ruan, J., Homer, N., Marth, G., Abecasis, G., Durbin, R., and 1000 Genome Project Data Processing Subgroup (2009). The Sequence Alignment/Map format and SAMtools. *Bioinformatics*, 25(16):2078–2079.

Lin, J. (1991). Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, 37(1):145–151.

Lozupone, C. A. and Knight, R. (2008). Species divergence and the measurement of microbial diversity. *FEMS microbiology reviews*, 32(4):557–578.

Lu, J., Breitwieser, F. P., Thielen, P., and Salzberg, S. L. (2017). Bracken: estimating species abundance in metagenomics data. *PeerJ Computer Science*, 3:e104.

Lu, J., Rincon, N., Wood, D. E., Breitwieser, F. P., Pockrandt, C., Langmead, B., Salzberg, S. L., and Steinegger, M. (2022). Metagenome analysis using the kraken software suite. *Nature protocols*, 17(12):2815–2839.

Magurran, A. E. (2021). Measuring biological diversity. *Current Biology*, 31(19):R1174–R1177.

Mann, H. B. and Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1):50–60.

Marchesi, J. R. and Ravel, J. (2015). The vocabulary of microbiome research: a proposal. *Microbiome*, 3:31.

McDonald, D., Clemente, J. C., Kuczynski, J., Rideout, J. R., Stombaugh, J., Wendel, D., Wilke, A., Huse, S., Hufnagle, J., Meyer, F., Knight, R., and Caporaso, J. G. (2012). The Biological Observation Matrix (BIOM) format or: how I learned to stop worrying and love the ome-ome. *GigaScience*, 1:7.

McInnes, L., Healy, J., and Melville, J. (2018). UMAP: Uniform manifold approximation and projection for dimension reduction. arXiv:1802.03426.

McKinney, W. (2010). Data structures for statistical computing in Python. In *Proceedings of the 9th Python in Science Conference*, pages 56–61.

McMurdie, P. J. and Holmes, S. (2013). phyloseq: an r package for reproducible interactive analysis and graphics of microbiome census data. *PloS one*, 8(4):e61217.

McMurdie, P. J. and Holmes, S. (2014). Waste not, want not: why rarefying microbiome data is inadmissible. *PLoS computational biology*, 10(4):e1003531.

Menzel, P., Ng, K. L., and Krogh, A. (2016). Fast and sensitive taxonomic classification for metagenomics with kaiju. *Nature communications*, 7(1):11257.

Meyer, F., Fritz, A., Deng, Z.-L., Koslicki, D., Lesker, T. R., Gurevich, A., Robertson, G., Alser, M., Antipov, D., Beghini, F., et al. (2022). Critical assessment of metagenome interpretation: the second round of challenges. *Nature methods*, 19(4):429–440.

Milhaven, M. and Pfeifer, S. P. (2023). Performance evaluation of six popular short-read simulators. *Heredity*, 130(2):55–63.

Nam, J. H., Thibodeau, A., Qian, Y. L., Qian, M. C., and Park, S. H. (2023). Multidisciplinary evaluation of plant growth promoting rhizobacteria on soil microbiome and strawberry quality. *Amb Express*, 13(1):18.

Newman, M. E. (2003). Mixing patterns in networks. *Physical Review E*, 67(2):026126.

Oksanen, J., Simpson, G. L., Blanchet, F. G., Kindt, R., Legendre, P., Minchin, P. R., O'Hara, R. B., Solymos, P., Stevens, M. H. H., Szoecs, E., Wagner, H., et al. (2022). vegan: Community ecology package. R package version 2.6-4. `https://CRAN.R-project.org/package=vegan`.

Oulas, A., Pavloudi, C., Polymenakou, P., Pavlopoulos, G. A., Papanikolaou, N., Kotoulas, G., Arvanitidis, C., and Iliopoulos, l. (2015). Metagenomics: tools and insights for analyzing next-generation sequencing data derived from biodiversity studies. *Bioinformatics and biology insights*, 9:BBI–S12462.

Pearl, J. (1988). *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*. Morgan Kaufmann, San Mateo, CA.

R Core Team (2023). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria. `https://www.R-project.org/`.

Ranjan, R., Rani, A., Metwally, A., McGee, H. S., and Perkins, D. L. (2016). Analysis of the microbiome: Advantages of whole genome shotgun versus 16S amplicon sequencing. *Biochemical and Biophysical Research Communications*, 469(4):967–977.

Robinson, M. D., McCarthy, D. J., and Smyth, G. K. (2010). edgeR: a Bioconductor package for differential expression analysis of digital gene expression data. *Bioinformatics*, 26(1):139–140.

Robinson, M. D. and Oshlack, A. (2010). A scaling normalization method for differential expression analysis of RNA-seq data. *Genome Biology*, 11(3):R25.

Rosenberg, E. (2021). *Microbiomes: Current Knowledge and Unanswered Questions*. Springer Nature.

Scutari, M. (2010). Learning Bayesian networks with the bnlearn R package. *Journal of Statistical Software*, 35(3):1–22.

Shannon, C. E. (1948). A mathematical theory of communication. *The Bell system technical journal*, 27(3):379–423.

Shapiro, S. S. and Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, 52(3-4):591–611.

Siegieda, D., Panek, J., and Frąc, M. (2024). Ecological processes of bacterial microbiome assembly in healthy and dysbiotic strawberry farms. *BMC Plant Biology*, 24(1):692.

Simpson, E. H. (1949). Measurement of diversity. *nature*, 163(4148):688–688.

Spooren, J., van Bentum, S., Thomashow, L. S., Pieterse, C. M. J., Weller, D. M., and Berendsen, R. L. (2024). Plant-driven assembly of disease-suppressive soil microbiomes. *Annual Review of Phytopathology*, 62:1–30.

Su, L., Feng, H., Li, H., Yang, F., Yan, X., Wang, X., Li, P., Wang, K., Shu, X., Liu, Y., Shen, Q., Yan, Y., and Zhang, R. (2025). General variation in the Fusarium wilt rhizosphere microbiome. *Nature Communications*, 17:1017.

Suhaimi, N. S. M., Goh, S.-Y., Ajam, N., Othman, R. Y., Chan, K.-G., and Thong, K. L. (2017). Diversity of microbiota associated with symptomatic and non-symptomatic bacterial wilt-diseased banana plants determined using 16s rrna metagenome sequencing. *World Journal of Microbiology and Biotechnology*, 33:1–10.

Trivedi, P., Leach, J. E., Tringe, S. G., Sa, T., and Singh, B. K. (2020). Plant–microbiome interactions: from community assembly to plant health. *Nature Reviews Microbiology*, 18(11):607–621.

Tuomisto, H. (2010a). A consistent terminology for quantifying species diversity? yes, it does exist. *Oecologia*, 164(4):853–860.

Tuomisto, H. (2010b). A diversity of beta diversities: straightening up a concept gone awry. part 1. defining beta diversity as a function of alpha and gamma diversity. *Ecography*, 33(1):2–22.

Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: fundamental algorithms for scientific computing in Python. *Nature Methods*, 17:261–272.

Wackerly, D. D., Mendenhall III, W., Scheaffer, R. L., Yescas Milanés, J., et al. (2002). *Estadística matemática con aplicaciones*. Thomson, México, 6 edition.

Weiss, S., Xu, Z. Z., Peddada, S., Amir, A., Bittinger, K., Gonzalez, A., Lozupone, C., Zaneveld, J. R., Vázquez-Baeza, Y., Birmingham, A., Hyde, E. R., and Knight, R. (2017). Normalization and microbial differential abundance strategies depend upon data characteristics. *Microbiome*, 5:27.

Welch, B. L. (1947). The generalization of "Student's" problem when several different population variances are involved. *Biometrika*, 34(1-2):28–35.

Whittaker, R. H. (1960). Vegetation of the siskiyou mountains, oregon and california. *Ecological monographs*, 30(3):279–338.

Whittaker, R. H. (1972). Evolution and measurement of species diversity. *Taxon*, 21(2-3):213–251.

Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag, New York.

Wilcox, R. R. (2010). *Fundamentals of Modern Statistical Methods*. Springer New York, NY.

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83.

Woese, C. R., Kandler, O., and Wheelis, M. L. (1990). Towards a natural system of organisms: proposal for the domains Archaea, Bacteria, and Eucarya. *Proceedings of the National Academy of Sciences*, 87(12):4576–4579.

Wood, D. E. and Salzberg, S. L. (2014). Kraken: ultrafast metagenomic sequence classification using exact alignments. *Genome biology*, 15(3):1–12.

Xia, Y., Sun, J., Chen, D.-G., et al. (2018). *Statistical analysis of microbiome data with R*, volume 847. Springer.

Xiong, W., Song, Y., Yang, K., Gu, Y., Wei, Z., Kowalchuk, G. A., Xu, Y., Jousset, A., Shen, Q., and Geisen, S. (2020). Rhizosphere protists are key determinants of plant health. *Microbiome*, 8:1–9.

Yang, H., Zhang, X., Qiu, X., Chen, J., Wang, Y., Zhang, G., Jia, S., Shen, X., Ye, W., and Yan, Z. (2023). Fusarium wilt invasion results in a strong impact on strawberry microbiomes. *Plants*, 12(24):4153.

Yang, J., Wei, S., Su, D., Zhang, Z., Chen, S., Luo, Z., Shen, X., Lai, Y., Jamil, A., Tong, J., et al. (2020). Comparison of the rhizosphere soil microbial community structure and diversity between powdery mildew-infected and noninfected strawberry plants in a greenhouse by high-throughput sequencing technology. *Current Microbiology*, 77:1724–1736.

Zaneveld, J. R., McMinds, R., and Vega Thurber, R. (2017). Stress and stability: applying the Anna Karenina principle to animal microbiomes. *Nature Microbiology*, 2(9):17121.

Zhang, L., Chen, F., Zeng, Z., Xu, M., Sun, F., Yang, L., Bi, X., Lin, Y., Gao, Y., Hao, H., Yi, W., Li, M., and Xie, Y. (2021). Advances in metagenomics and its application in environmental microorganisms. *Frontiers in Microbiology*, 12:766364.

Zhang, M., Kong, Z., Fu, H., Shu, X., Xue, Q., Lai, H., and Guo, Q. (2023). Rhizosphere microbial ecological characteristics of strawberry root rot. *Frontiers in Microbiology*, 14:1286740.